二次规划
(Quadratic Programming)

2026-2027学年 秋季学期
办公室：人工智能新大楼S107

程　骋　　c_cheng@hust.edu.cn

人工智能与自动化学院

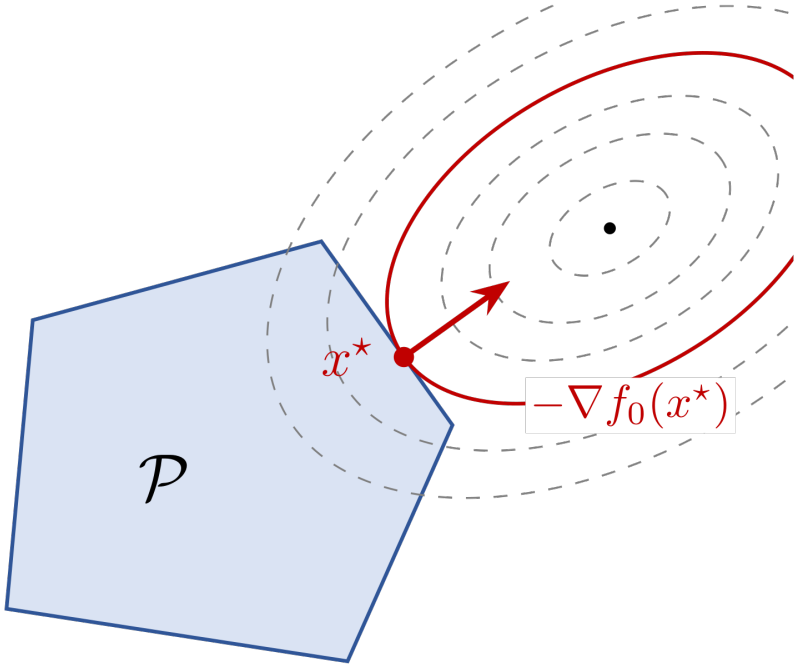
二次规划的定义

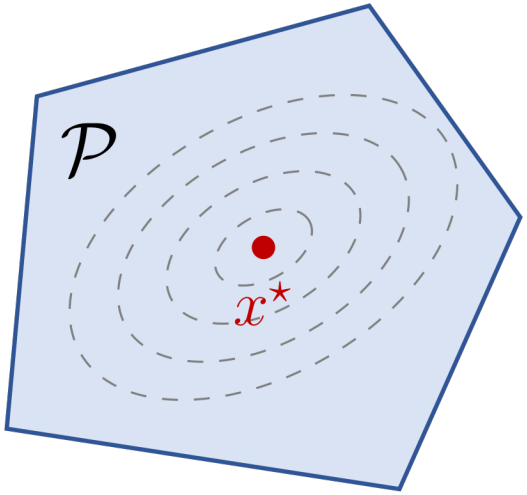
当凸优化问题的目标函数是（凸）二次型且约束函数为仿射时，该问题称为二次规划（QP）。二次规划可以表述为

$$\begin{array}{ll} \text{minimize} & \frac{1}{2}x^T Px + q^T x + r \\ \text{subject to} & Gx \preceq h \\ & Ax = b \end{array}$$

的形式，其中$P \in \boldsymbol{S}_+^n$ ，$G \in \boldsymbol{R}^{p\times n}$。在二次规划问题中，是在多面体上极小化一个凸二次函数。

二次规划的几何解释





无约束极小点在 P 内：最优解在**内部**

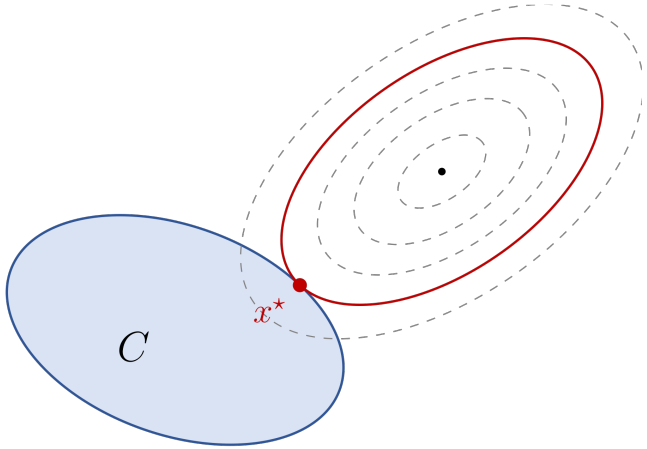
- 可行集仍是**多面体** P；$P \succ 0$ 时目标的等值线是一族**椭圆**（虚线）
- 最优点满足 $\nabla f_0(x^*)^T(y - x^*) \geq 0,\ \forall y \in P$，即 $-\nabla f_0(x^*)$ 在 x^* 处支撑 P
- 与线性规划不同：QP 的最优解**不一定在边界或顶点上**，也可以在可行集**内部**

二次约束二次规划（QCQP）

如果不仅目标函数，不等式约束也是（凸）二次型，则得到

$$\begin{array}{ll} \text{minimize} & (1/2)x^T P_0 x + q_0^T x + r_0 \\ \text{subject to} & (1/2)x^T P_i x + q_i^T x + r_i \leq 0, \quad i = 1, \ldots, m \\ & Ax = b \end{array}$$

- $P_i \in \mathbf{S}^n_+$, $i = 0,\ldots,m$；等式约束仍必须是**仿射**的
- 称为**二次约束二次规划**（Quadratically Constrained Quadratic Program）
- $P_i \succ 0$ 时可行集是**椭球的交集**，没有“顶点”可找，求解比 QP 更复杂



包含关系：LP（$P = 0$）$\subset$ QP $\subset$ QCQP（令 $P_i = 0$, $i = 1,\ldots,m$）

例1：最小二乘（Least-squares）

带噪声的线性测量系统 $b = Ax + e$：已知 A 和 b，噪声 e 未知，如何恢复 x?

$$\begin{aligned}\hat{x} &= \underset{x}{\operatorname{argmin}} \ \|b - Ax\|_2 = \underset{x}{\operatorname{argmin}} \ \|b - Ax\|_2^2 \\ &= \underset{x}{\operatorname{argmin}} \ x^T A^T Ax - 2b^T Ax + b^T b\end{aligned}$$

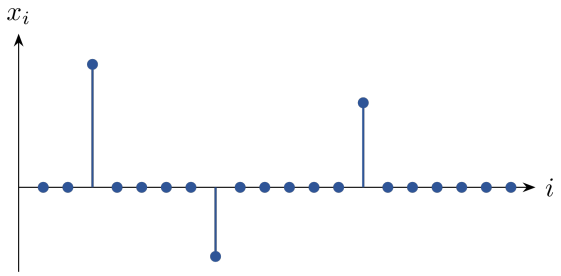
- 目标即误差平方和 $\|e\|_2{}^2$ 最小 —— **最小二乘准则**
- $A^TA \succeq 0$，所以这是一个**无约束的二次规划**
- 若 $A^TA \succ 0$（可逆），令梯度为零 $A^TAx = A^Tb$，得解析解

$$\hat{x} = (A^TA)^{-1}A^Tb$$

加上线性不等式约束（如 $l_i \leq x_i \leq u_i$）称为**约束最小二乘**，仍是 QP，但一般不再有解析解

例2：稀疏先验 —— 从 ℓ0 到 ℓ1

若已知 x 是**稀疏**的（非零元素的数目非常少），可以把这一先验加入目标：



$$\hat{x} = \underset{x}{\operatorname{argmin}} \ \|b - Ax\|_2^2 + \lambda_0 \|x\|_0$$

- $\|x\|_0$：x 中非零元素的个数；λ_0：对稀疏先验的信赖程度
- 但 $\|x\|_0$ 是**非凸**函数，很难求解 —— 用 $\|x\|_1$ 作为它的**凸近似**：

$$\hat{x} = \underset{x}{\operatorname{argmin}} \ \|b - Ax\|_2^2 + \lambda_1 \|x\|_1, \qquad \lambda_1 \geq 0$$

称为 ℓ_1-**正则化最小二乘**，是凸问题；但 $\|x\|_1$ 含**绝对值**、不可导，还不是 QP 的形式

例2（续）：化为二次规划 —— LASSO

关键技巧（线性规划中已用过）：把 x 拆成两个非负向量之差

$$x = x^+ - x^-, \qquad x^+ \succeq 0, \quad x^- \succeq 0$$

x^+ 由 x 的正元素构成，x^- 由负元素的绝对值构成，于是

$$\|x\|_1 = \sum_i |x_i^+ - x_i^-| = \sum_i \left(x_i^+ + x_i^-\right) = \mathbf{1}^T x^+ + \mathbf{1}^T x^-$$

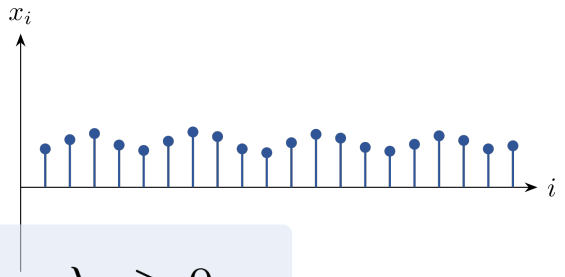
得到关于 (x^+, x^-) 的等价问题 —— 目标二次、约束线性，即 **QP**：

$$\begin{array}{ll} \text{minimize} & \|b - Ax^+ + Ax^-\|_2^2 + \lambda_1 \mathbf{1}^T x^+ + \lambda_1 \mathbf{1}^T x^- \\ \text{subject to} & x^+ \succeq 0, \quad x^- \succeq 0 \end{array}$$

LASSO（1996 年前后提出），技巧：把非光滑问题变成**规模更大、但更简单**的问题

例3：岭回归（Ridge Regression）

若已知 x 中各元素的**幅度相近**，则 $\|x\|_2$ 应比较小（某个元素过大会使 $\|x\|_2$ 很大）：



$$\hat{x} = \underset{x}{\operatorname{argmin}} \ \|b - Ax\|_2^2 + \lambda_2 \|x\|_2^2, \qquad \lambda_2 \geq 0$$

- ℓ_2-**正则化最小二乘**，又叫**岭回归**：把估计中过高的“岭”压下来，过低的抬上去
- 二次项系数 $A^TA + \lambda_2 I$ 在 $\lambda_2 > 0$ 时**正定**：一个标准的（严格凸）QP
- **等价形式**：对每个 $\lambda_2 \geq 0$，存在 $\theta \geq 0$ 使下面问题的最优解相同

$$\begin{array}{ll} \text{minimize} & \|b - Ax\|_2^2 \\ \text{subject to} & \|x\|_2^2 \leq \theta \end{array}$$

目标、约束都是二次的 —— 这是一个 **QCQP**（等价性见对偶理论）

回顾：三类问题的比较

线性规划、二次规划与二次约束二次规划的区别在于目标和约束的“次数”：

	目标函数	等式约束	不等式约束
LP	线性	线性	线性
QP	凸二次	线性	线性
QCQP	凸二次	线性	凸二次

- QP 的目标**必须是凸**的二次函数（$P \succeq 0$），否则不是凸问题，不叫二次规划
- 任何标准的凸优化问题，**等式约束都必须是仿射的**，QCQP 也不例外

例4：投资组合问题（Portfolio）

总预算为 B，有 n 种投资途径（房子、股票、银行……）

第 i 种投入 x_i，一年后变为 $p_i x_i$。最直接的模型是一个 **LP**：

$$\begin{array}{ll} \text{maximize} & p_1 x_1 + \cdots + p_n x_n \\ \text{subject to} & x_1 + \cdots + x_n \leq B \\ & x_1, \ldots, x_n \geq 0 \end{array}$$

- 预算约束可以改为等号：最优时一定把钱全部投入（留在手里相当于 $p = 1$ 的一种投资）
- 最优解一眼可见：**全部投给 p_i 最大的那一项**！

问题出在哪里？$p_1,\ldots,p_n$ 事先**并不知道**——房市、股市都有随机因素，只有存银行的回报是确定的。模型必须同时考虑**收益**和**风险**

例4（续）：收益与风险

- 把价格变化 $p \in \mathbf{R}^n$ 看作**随机向量**，均值 $\bar{p} = \mathbf{E}p$，协方差 $\Sigma = \mathbf{E}(p - \bar{p})(p - \bar{p})^T$
- 期望收益 $\bar{p}^T x$ —— **收益**；收益的方差 $x^T \Sigma x$ —— **风险**（方差越大，风险越大）

例：房子、股票、银行三种投资，各项之间互不相关（Σ 为对角阵）

$$\bar{p} = \begin{bmatrix} 1.05 \\ 1.05 \\ 1 \end{bmatrix}, \qquad \Sigma = \begin{bmatrix} 1.2 & 0 & 0 \\ 0 & 2 & 0 \\ 0 & 0 & 0 \end{bmatrix}$$

- 房子与股票的期望收益相同（均为 5%），但股市风险更大：$\Sigma_{22} = 2 > \Sigma_{11} = 1.2$
- 存银行没有收益，但也**没有风险**：$\Sigma_{33} = 0$

例4（续）：Markowitz 均值-方差模型

在保证期望收益不低于 $r_{\min}$ 的前提下，**极小化风险** —— 一个 **QP**：

$$\begin{array}{ll} \text{minimize} & x^T\Sigma x \\ \text{subject to} & \bar{p}^T x \geq r_{\min} \\ & \mathbf{1}^T x = B \\ & x \succeq 0 \end{array}$$

- 目标 $x^T\Sigma x$：风险大的项（如股票）投入要少；无风险的项（银行）不增加风险
- $\bar{p}^T x \geq r_{\min}$：收益的底线；$\mathbf{1}^T x = B$：预算；$x \succeq 0$：不允许卖空

H. Markowitz（1927 年生）**1952** 年 25 岁时提出该模型，掀起华尔街的“数学革命”；**1989** 年获 von Neumann 理论奖，**1990** 年获诺贝尔经济学奖。

启示：**好的模型**比求解本身更重要

半正定规划（SDP）

标准形式（Semidefinite Program）：优化变量是对称矩阵 $X \in \mathbf{S}^n$

$$\begin{array}{ll} \text{minimize} & \mathbf{tr}(CX) \\ \text{subject to} & \mathbf{tr}(A_i X) = b_i, \quad i = 1, \ldots, p \\ & X \succeq 0 \end{array}$$

- 其中 $C, A_1,\ldots,A_p \in \mathbf{S}^n$，$b_i \in \mathbf{R}$；$X \succeq 0$ 是**半正定约束**（所有特征值 ≥ 0），不是逐元素的不等式
- $tr(CX) = \sum_{i,j} C_{ij} X_{ij}$ 是关于 X 的**线性**函数（矩阵空间中的内积）
- 因此 SDP 可看作**矩阵空间中的线性规划**：$X \succeq 0$ 对应于 LP 中的 $x \geq 0$

与 LP / QP / QCQP 不同：变量不再是向量，而是**矩阵**

特例：对角矩阵时 SDP 退化为 LP

设 X, C, A_i 都是**对角阵**，记 $diag(X)$ 为对角元素构成的列向量，则

$$\mathbf{tr}(CX) = \mathbf{diag}(C)^T \mathbf{diag}(X), \qquad \mathbf{tr}(A_i X) = \mathbf{diag}(A_i)^T \mathbf{diag}(X)$$

对角阵的特征值就是对角元素，所以 $X \succeq 0 \Leftrightarrow diag(X) \geq 0$。问题变为

$$\begin{array}{ll} \text{minimize} & \mathbf{diag}(C)^T \mathbf{diag}(X) \\ \text{subject to} & \mathbf{diag}(A_i)^T \mathbf{diag}(X) = b_i, \quad i = 1, \ldots, p \\ & \mathbf{diag}(X) \succeq 0 \end{array}$$

这是关于向量 $diag(X)$ 的**标准形式线性规划** —— LP 是 SDP 的特例

SDP 的不等式形式

不等式形式：优化变量是向量 $x \in \mathbf{R}^n$，约束是一个**线性矩阵不等式**（LMI）

$$\begin{array}{ll} \text{minimize} & c^T x \\ \text{subject to} & x_1 A_1 + x_2 A_2 + \cdots + x_n A_n \preceq B \end{array}$$

- 其中 $B, A_1, \ldots, A_n \in \mathbf{S}^k$，$c \in \mathbf{R}^n$
- “$\preceq$”是矩阵不等式：$B - (x_1 A_1 + \cdots + x_n A_n)$ 是**半正定**矩阵
- 左端关于 x 是线性的，LMI 的解集是**凸集**（凸集一章已讨论过）
- 两种形式：标准形式优化**矩阵** $X \succeq 0$；不等式形式优化**向量** x，满足半定约束

例5：谱范数最小化

给定 $A_0, A_1, \ldots, A_n \in \mathbf{R}^{p\times q}$，仿射矩阵函数

$$A(x) = A_0 + x_1 A_1 + \cdots + x_n A_n, \qquad x \in \mathbf{R}^n$$

- **谱范数** $\|A(x)\|_2 = A(x)$ 的**最大奇异值**；直接极小化它很困难
- 关键等价关系（$s \geq 0$）：$\|A(x)\|_2 \leq s^{1/2} \Leftrightarrow A(x)^T A(x) - sI \preceq 0$

$$\text{minimize} \quad \|A(x)\|_2 \qquad \Longleftrightarrow \qquad \begin{array}{ll} \text{minimize} & \sqrt{s} \\ \text{subject to} & A(x)^T A(x) \preceq sI \end{array}$$

A 为对角阵时，$\|A\|_2 = max|a_{ii}|$，而 $A^TA - sI \preceq 0$ 即每个 $a_{ii}^2 \leq s$

变量为 (x, s)；目标 $s^{1/2}$ 非线性，约束关于 x 是二次的

例5（续）：化为半定规划

- 约束关于 (x, s) **联合凸**；极小化 $s^{1/2}$ 与极小化 s 等价 —— 已是凸问题
- 代换 $t = s^{1/2}$ 后约束含 $-t^2 I$，不是线性的；利用等价变换（Schur 补）：

$$A(x)^T A(x) - t^2 I_q \preceq 0, \quad t \geq 0 \quad \Longleftrightarrow \quad \begin{bmatrix} tI_p & A(x) \\ A(x)^T & tI_q \end{bmatrix} \succeq 0$$

标量情形的直观：$t^2 - a^2 \geq 0$ 正是 $[t, a; a, t]$ 的行列式非负。再引入矩阵 Y：

$$\begin{aligned} \text{minimize} \quad & t \\ \text{subject to} \quad & Y = \begin{bmatrix} tI_p & A(x) \\ A(x)^T & tI_q \end{bmatrix} \\ & Y \succeq 0, \quad t \geq 0 \end{aligned}$$

目标与等式约束关于 (x, t, Y) 都是**线性**的，再加 $Y \succeq 0$ —— 标准的 **SDP**

多目标优化问题

实际问题往往有**多个目标**（如“又好又快”）。形式与单目标问题相同，但目标是**向量值**的：

$$\begin{array}{ll} \text{minimize} & f_0(x) = \big(F_1(x), \ldots, F_q(x)\big) \\ \text{subject to} & f_i(x) \le 0, \quad i = 1, \ldots, m \\ & h_i(x) = 0, \quad i = 1, \ldots, p \end{array}$$

- $f_0 : \mathbf{R}^n \to \mathbf{R}^q$（同时极小化 q 个目标），$f_i : \mathbf{R}^n \to \mathbf{R}$，$h_i : \mathbf{R}^n \to \mathbf{R}$
- $F_1,\ldots,F_q$、f_i 凸，h_i 仿射时，称为**凸**多目标（多准则）优化问题

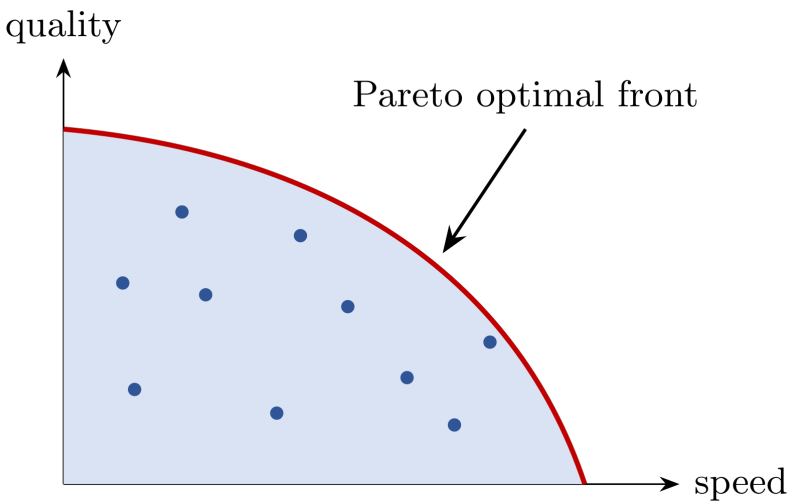
例：投资组合问题也可以写成多目标形式 —— 把“收益下限”这个约束换成目标：

$$\begin{array}{ll} \text{minimize} & \big(\text{Risk}, \ -\text{Income}\big) \\ \text{subject to} & \text{Resources} \end{array}$$

$$\begin{array}{ll} \text{minimize} & x^T \Sigma x \\ \text{subject to} & \bar{p}^T x \ge r_{\min} \\ & \mathbf{1}^T x = B \\ & x \succeq 0 \end{array}$$

P12 单目标例子

Pareto 最优

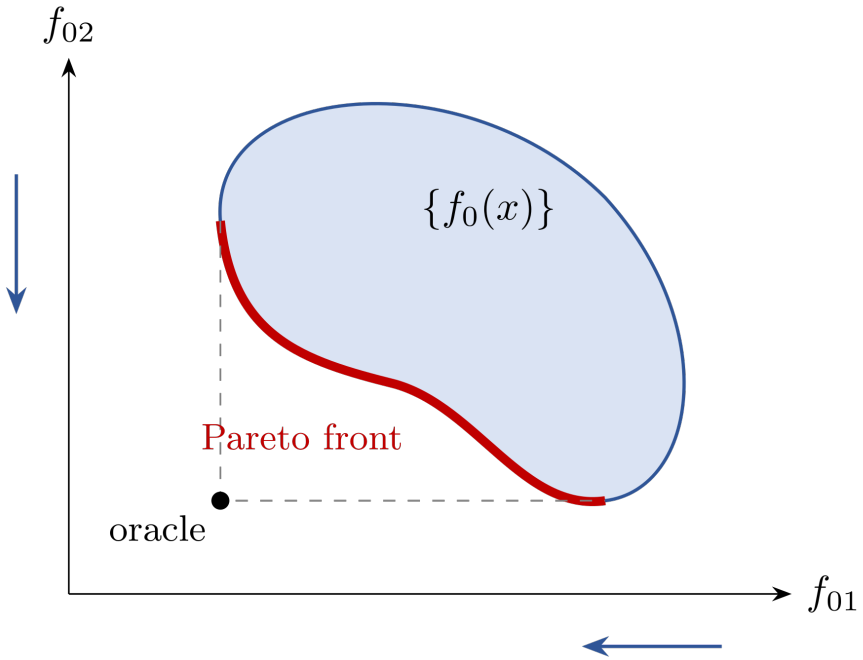


例：同时**极大化**速度（speed）与质量（quality），受资源约束

图中每个点有三层含义：**一个策略** x 和它对应的**两个目标值**

- **Pareto 最优前沿**（曲线/曲面）：前沿上任意点，若找到另一个解使它在**某个指标上更优**，则必然在**另一个指标上变得更差** —— 最优折中
- 前沿上的目标值称为 **Pareto 最优值**，对应的解称为 **Pareto 最优点**

可达集合与 Pareto 前沿



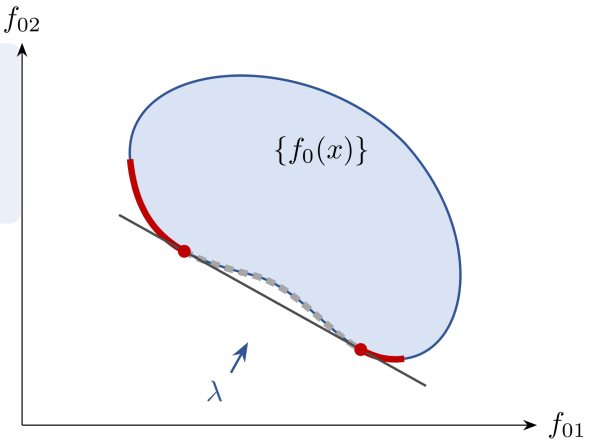
- 把所有可行解的目标值 $(f_{01}(x), f_{02}(x))$ 画在平面上，得到可达集合 $\{f_0(x)\}$
- 极小化时，Pareto 前沿是集合的**左下边界**（红线），一般**不一定连续**
- **oracle solution**：各个目标同时取到最小的点

若 oracle 点可达，则它就是所有目标的共同最优解，目标之间“非竞争”，不需要折中（Boyd §4.7.5）。一般的多目标问题很难求出整个前沿

标量化（Scalarization）

若可达集合是**凸**的，f_i 凸、h_i 仿射，则可通过下面的**单目标**问题求得 Pareto 前沿上的点：

$$\begin{aligned} \text{minimize} \quad & \sum_{i=1}^{q} \lambda_i F_i(x) \\ \text{subject to} \quad & f_i(x) \le 0, \quad h_i(x) = 0 \end{aligned} \qquad \lambda_i \ge 0$$



- **遍历** λ_i 可以找出前沿上的**所有**点
- 极端情形：只取一个 $\lambda_k = 1$，其余为 0 —— 只考虑第 k 个目标
- 变化 λ 就是在各目标之间做**线性折中**

可达集合**非凸**时（右图），与切线之间的那段前沿（灰色虚线）无论怎样选 λ 都**找不到**

实践中常把某些目标改写为**约束**，变成单目标问题（如投资组合中的收益下限）

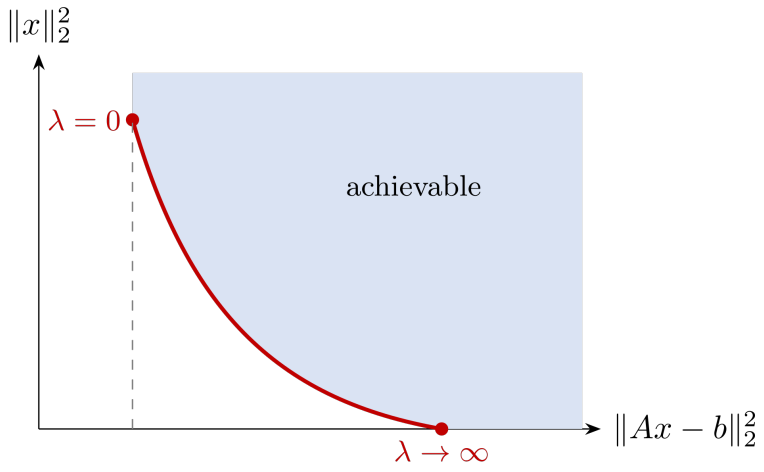
例：岭回归是一个双目标问题

测量方程 $b = Ax + e$，同时希望

- 误差平方和 $F_1 = \|Ax - b\|_2{}^2$ 小
- x 的能量 $F_2 = \|x\|_2{}^2$ 小

可达集合是凸的，曲线即**最优权衡曲线**：

- $\lambda = 0$：只管 F_1（最小二乘解）
- $\lambda \to \infty$：只管 F_2，得 $x = 0$



$$\text{minimize } \left(\|Ax-b\|_2^2,\ \|x\|_2^2\right) \iff \text{minimize } \|Ax-b\|_2^2 + \lambda\|x\|_2^2 \iff \begin{array}{ll}\text{minimize} & \|Ax-b\|_2^2 \\ \text{subject to} & \|x\|_2^2 \le \varepsilon\end{array}$$

- 左 ⇔ 中：**非负加权**标量化；左 ⇔ 右：把第二个目标改写为**约束**
- $\varepsilon = +\infty$ 对应 $\lambda = 0$；$\varepsilon = 0$ 对应 $x = 0$（$\lambda \to \infty$）

小结

问题	形式	例子
QP	凸二次目标 + 仿射约束	最小二乘、LASSO、岭回归、Markowitz
QCQP	凸二次目标 + 凸二次不等式约束	岭回归的约束形式
SDP	线性目标 + 线性矩阵不等式	LP 为其特例；谱范数最小化
多目标	向量目标 $f_0 : \mathbf{R}^n \to \mathbf{R}^q$	Pareto 前沿；标量化；岭回归

- 包含关系：LP $\subset$ QP $\subset$ QCQP；LP $\subset$ SDP