无约束最小化
(Unconstrained Minimization)

2026-2027学年 秋季学期
办公室：人工智能新大楼S107

程　骋　　c_cheng@hust.edu.cn

人工智能与自动化学院

无约束优化问题

考虑无约束优化问题（Boyd §9.1）

$$\text{minimize} \quad f(x)$$

- $f : \mathbf{R}^n \to \mathbf{R}$ 为凸函数且二阶连续可微；假设最优解 x^* 存在，最优值 $p^* = f(x^*)$
- 一般没有解析解，需要**迭代算法**：产生点列 $x^0, x^1, x^2, \ldots$，使 $f(x^k) \to p^*$

$$x^{k+1} = x^k + \alpha^k d^k$$

- d^k：**搜索方向**；$\alpha^k \geq 0$：**步长**
- **下降算法**：要求 $f(x^{k+1}) < f(x^k)$，d^k 为下降方向：$\nabla f(x^k)^T d^k < 0$

迭代算法的两个基本问题：**往哪个方向走**（d^k），**走多远**（α^k）

步长的选择：直线搜索（Line Search）

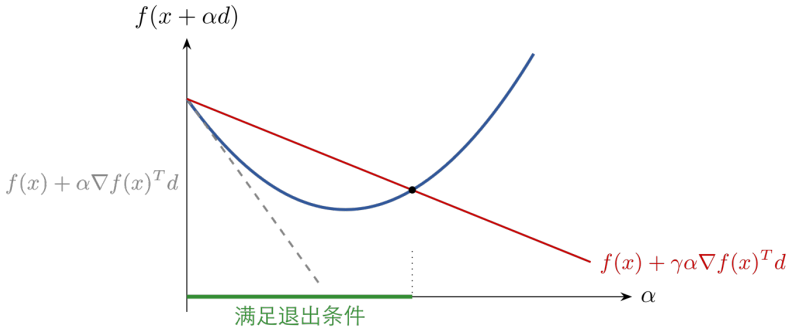
精确直线搜索（exact line search）：使目标函数在该方向上下降最多 —— 一维优化问题

$$\alpha^k = \underset{\alpha \geq 0}{\operatorname{argmin}} \; f(x^k + \alpha d^k)$$

精确求解往往代价很大，实际中常用**不精确**的直线搜索：**黄金分割法**；**回溯直线搜索**（Armijo 准则，backtracking）：

$$\begin{aligned} &\alpha := \alpha_{\max}; \\ &\text{while} \;\; f(x^k + \alpha d^k) > f(x^k) + \gamma \alpha \nabla f(x^k)^T d^k : \quad \alpha := \beta \alpha \end{aligned}$$

- “下降得还不够”时，步长缩小为 β 倍
- $\beta \in (0, 1)$，如 0.7、0.8
- $\gamma \in (0, 0.5]$，常取 0.5（便于收敛性证明）
- α 足够小时条件一定满足，回溯必停止



最优性条件与停止准则

f 可微且凸时，x^* 最优的充要条件是

$$\nabla f(x^*) = 0$$

- 迭代时用 $\|\nabla f(x^k)\|_2 \le \varepsilon$ 作为**停止准则**
- 引出两个问题：当 $\nabla f(x^k) \to 0$ 时，是否一定有

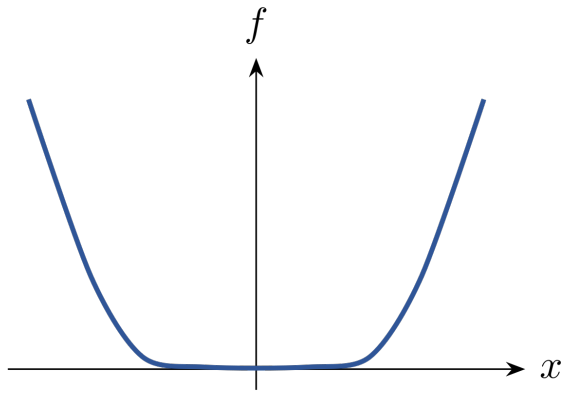
$$x^k \to x^* \quad ? \qquad\qquad f(x^k) \to f(x^*) = p^* \quad ?$$

一般的凸函数不一定！需要对 f 做更强的假设 —— **强凸性**（Boyd §9.1.2）

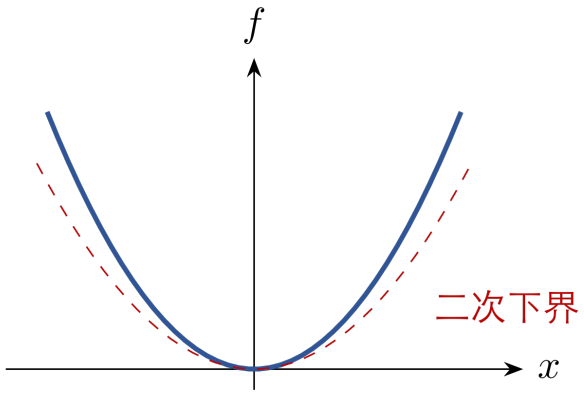
强凸性（Strong Convexity）

假设 f 二阶可微，且存在 $m > 0$，使得

$$\nabla^2 f(x) \succeq mI, \qquad \forall x \in \mathbf{dom}\, f$$



底部很平：$\nabla f \approx 0$ 但离 $x^\star$ 很远



强凸：至少像二次函数那样弯曲

等价地：对任意 $x, y \in dom\, f$（由 Taylor 展开与中值定理）

$$f(y) \geq f(x) + \nabla f(x)^T (y - x) + \frac{m}{2}\|y - x\|_2^2$$

强凸性的推论（1）：次优性的界

固定 x，右端是 y 的凸二次函数，对 y 求极小：令梯度为零

$$\nabla f(x) + m(\tilde{y} - x) = 0 \implies \tilde{y} = x - \frac{1}{m}\nabla f(x)$$

代回得：对任意 y，$f(y) \geq f(x) - (1/2m)\|\nabla f(x)\|_2{}^2$；取 $y = x^*$：

$$p^* \geq f(x) - \frac{1}{2m}\|\nabla f(x)\|_2^2 \qquad \Longleftrightarrow \qquad f(x) - p^* \leq \frac{1}{2m}\|\nabla f(x)\|_2^2$$

- 只要梯度足够小，$f(x)$ 就一定离最优值 p^* 足够近
- 因此 $\|\nabla f(x)\|_2 \leq (2m\varepsilon)^{1/2}$ 时，$f(x) - p^* \leq \varepsilon$ —— 停止准则依据

强凸性的推论（2）：到最优点的距离

在强凸不等式中取 $y = x^*$，并用 Cauchy–Schwarz 不等式 $\langle a, b\rangle \geq -\|a\|\|b\|$：

$$
\begin{aligned}
f(x) \;\geq\; p^* \;&\geq\; f(x) + \nabla f(x)^T (x^* - x) + \frac{m}{2}\|x^* - x\|_2^2 \\
&\geq\; f(x) - \|\nabla f(x)\|_2 \|x^* - x\|_2 + \frac{m}{2}\|x^* - x\|_2^2
\end{aligned}
$$

所以 $-\|\nabla f(x)\|_2 \|x^* - x\|_2 + (m/2)\|x^* - x\|_2{}^2 \leq 0$，即

$$
\|x - x^*\|_2 \;\leq\; \frac{2}{m}\|\nabla f(x)\|_2
$$

强凸时：$\nabla f(x^k) \to 0 \Longrightarrow f(x^k) \to p^*$ 且 $x^k \to x^*$。没有强凸性时，底部很平的函数梯度很小，却可能离 x^* 很远

Hessian 的上界 M

相应地，假设存在 $M > 0$，使得 $\nabla^2 f(x) \preceq MI,\ \forall x \in dom\, f$，则

$$f(y) \ \leq \ f(x) + \nabla f(x)^T (y - x) + \frac{M}{2}\|y - x\|_2^2, \qquad \forall x, y \in \mathbf{dom}\, f$$

两端同时对 y 求极小（右端在 $\tilde{y} = x - \nabla f(x)/M$ 处取到）：

$$p^* \ \leq \ f(x) - \frac{1}{2M}\|\nabla f(x)\|_2^2$$

于是对强凸函数有

$$mI \ \preceq \ \nabla^2 f(x) \ \preceq \ MI, \qquad \kappa = \frac{M}{m} \ \ \text{(condition number)}$$

m, M 一般不知道，但它们给出了算法收敛性的理论保证

梯度下降法（Gradient Descent）

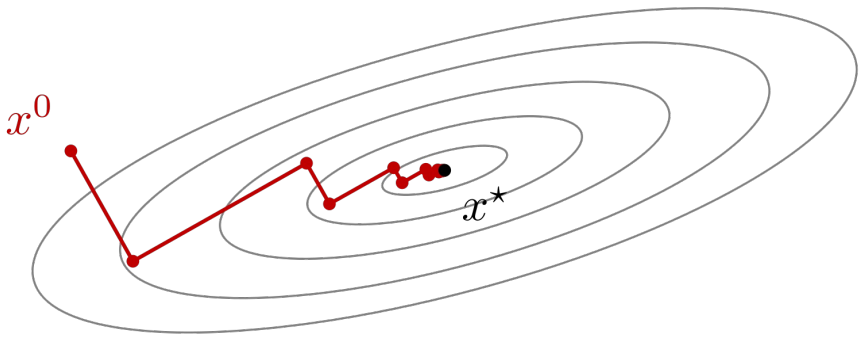
最自然的选择：沿**负梯度方向**搜索（Boyd §9.3）

given a starting point $x^0 \in \mathbf{dom}\, f$.
repeat
1. $d^k := -\nabla f(x^k)$
2. line search: $\alpha^k = \operatorname{argmin}_{\alpha \geq 0} f(x^k + \alpha d^k)$ (exact or backtracking)
3. $x^{k+1} := x^k + \alpha^k d^k$

until stopping criterion is satisfied ($\|\nabla f(x^k)\|_2 \leq \varepsilon$)

- $\nabla f^T d = -\|\nabla f\|_2{}^2 < 0$：负梯度一定是下降方向
- 一阶近似 $f(x+v) \approx f(x) + \nabla f(x)^T v$ 下降最快的方向（局部看）

梯度下降的几何：“之”字形路径



- 负梯度方向与等值线**垂直**
- 精确线搜索：在新点处，搜索方向与等值线**相切**，所以

$$\nabla f(x^{k+1})^T \nabla f(x^k) = 0$$

- 相邻两步方向**互相垂直**，路径呈“之”字形（zig-zag）

等值线越扁（条件数 M/m 越大），“之”字越密，收敛越慢；等值线是圆时一步就到最优点

收敛性分析：精确直线搜索

设 $mI \preceq \nabla^2 f \preceq MI$。由上界，记 $\tilde{f}(\alpha) = f(x^k - \alpha \nabla f(x^k))$：

$$\tilde{f}(\alpha) \ \leq \ f(x^k) - \alpha \|\nabla f(x^k)\|_2^2 + \frac{M\alpha^2}{2}\|\nabla f(x^k)\|_2^2$$

精确搜索的函数值不超过右端的最小值（在 $\alpha = 1/M$ 处取到）：

$$f(x^{k+1}) = \min_{\alpha} \tilde{f}(\alpha) \ \leq \ f(x^k) - \frac{1}{2M}\|\nabla f(x^k)\|_2^2$$

两边减去 p^*，再利用强凸的结论 $\|\nabla f(x^k)\|_2{}^2 \geq 2m(f(x^k) - p^*)$：

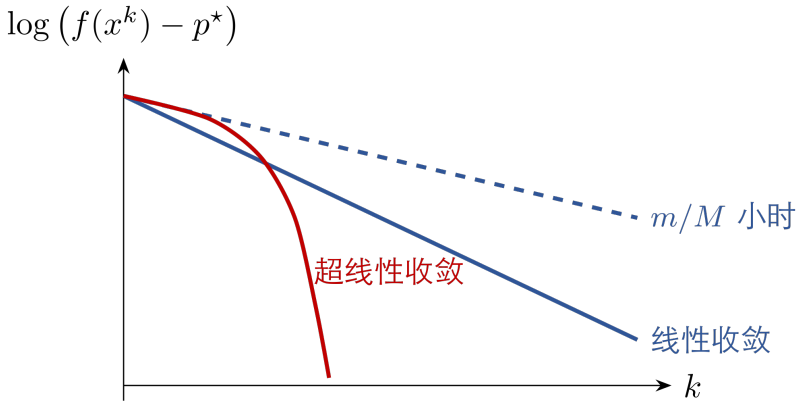
$$f(x^{k+1}) - p^* \ \leq \ \left(1 - \frac{m}{M}\right)\left(f(x^k) - p^*\right)$$

$c = 1 - m/M < 1$：每一步误差至少按固定比例缩小

线性收敛与迭代次数

由 $f(x^k)-p^* \le c^k(f(x^0)-p^*)$，$c=1-m/M$。要求相对误差 $\le \varepsilon$，需要迭代

$$c^k \le \varepsilon \impliedby k \ge \frac{\log(1/\varepsilon)}{\log(1/c)} \approx \frac{M}{m}\log\frac{1}{\varepsilon}$$



- $log(f(x^k) - p^*)$ 关于 k 是一条**直线 —— 线性收敛**
- m/M 很小（病态）时直线很平，收敛非常慢
- 比直线下降得快：**超线性收敛**；比直线慢：**次线性收敛**
- 梯度法可以证明线性收敛，但不能证明超线性收敛

收敛性分析：回溯直搜索

当 $0 \le \alpha \le 1/M$ 时，$-\alpha + M\alpha^2/2 \le -\alpha/2$，于是

$$\begin{aligned} f(x^k - \alpha\nabla f(x^k)) &\le f(x^k) - \alpha\|\nabla f(x^k)\|_2^2 + \frac{M\alpha^2}{2}\|\nabla f(x^k)\|_2^2 \\ &\le f(x^k) - \frac{\alpha}{2}\|\nabla f(x^k)\|_2^2 \ \le \ f(x^k) - \gamma\alpha\|\nabla f(x^k)\|_2^2 \end{aligned}$$

- $\alpha \le 1/M$ 时回溯一定停止，所以 $\alpha = \alpha_{\max}$ 或 $\alpha \ge \beta/M$，从而

$$f(x^{k+1}) \le f(x^k) - \min\{\gamma\alpha_{\max},\ \gamma\beta/M\}\,\|\nabla f(x^k)\|_2^2$$

$$f(x^{k+1}) - p^* \ \le \ \Big(1 - \min\{2m\gamma\alpha_{\max},\ 2m\gamma\beta/M\}\Big)\big(f(x^k) - p^*\big)$$

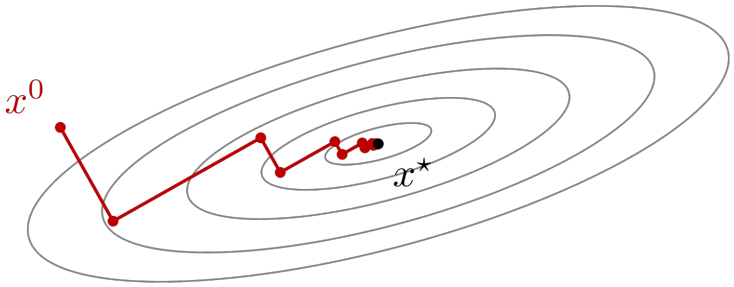
回溯直线搜索同样是**线性收敛**，收敛常数同样依赖于 m/M

例：二次函数与条件数

考虑 $f(x) = (1/2)x^T Px$，$P \in \mathbf{S}^n_{++}$，则 $\nabla^2 f(x) = P$，于是

$$mI \preceq P \preceq MI, \qquad m = \lambda_{\min}(P), \quad M = \lambda_{\max}(P), \qquad \frac{M}{m} = \mathrm{cond}(P)$$

- 例如 $P = diag(100, 1)$：$M/m = 100$，等值线非常扁
- 梯度方向几乎不指向最优点，路径来回振荡
- M/m 接近 1（等值线接近圆）时收敛很快



梯度下降法的收敛速度严重依赖于问题的**条件数** —— 这是它的主要缺点（Boyd §9.3.2）

最速下降法（Steepest Descent）

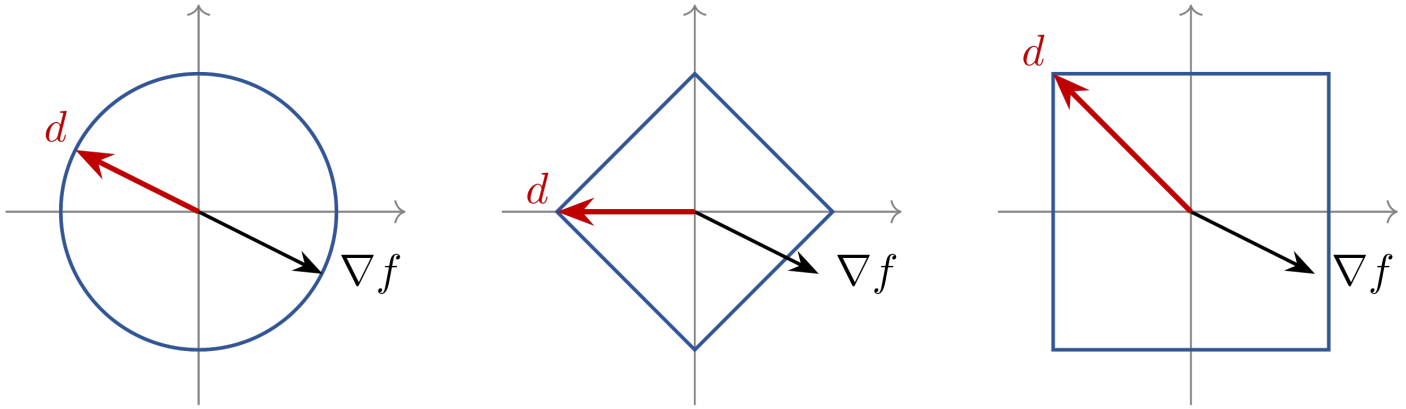
在 x^k 处，用一阶 Taylor 近似 $f(x^k + v) \approx f(x^k) + \nabla f(x^k)^T v$。在单位长度的方向中找下降最快的：

$$d^k = \operatorname*{argmin}_v \left\{ \nabla f(x^k)^T v \;\middle|\; \|v\| = 1 \right\}$$

- 称为**规范化最速下降方向**（normalized steepest descent direction，Boyd §9.4）
- $\|\cdot\|$ 可以是**任意范数**；步长 α^k 仍用精确或回溯（Armijo）直线搜索
- “最速”是相对于所选范数而言的：不同范数给出不同的方向

取 Euclid 范数时，$d^k = -\nabla f(x^k)/\|\nabla f(x^k)\|_2$，最速下降法就是**梯度下降法**

不同范数下的最速下降方向



$\|v\|_2 = 1$　　$\|v\|_1 = 1$　　$\|v\|_\infty = 1$

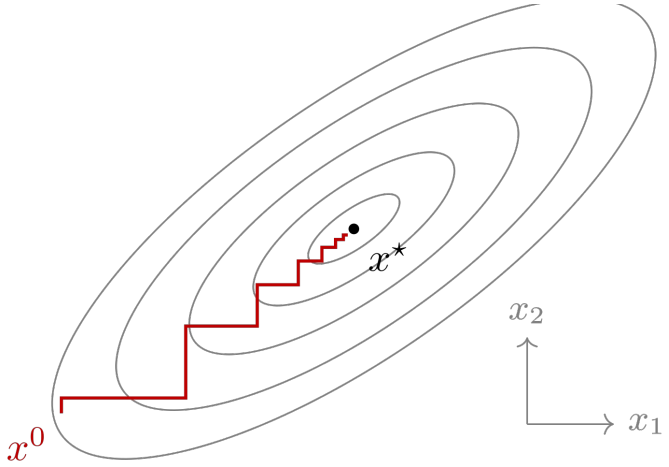
- $\|v\|_2 = 1$：$d = -\nabla f(x)/\|\nabla f(x)\|_2$，即**梯度下降法**（长度由步长吸收）
- $\|v\|_1 = 1$：取绝对值**最大**的梯度分量，沿该坐标轴反方向 $(0, \ldots, \mp 1, \ldots, 0)^T$
- $\|v\|_\infty = 1$：每个分量取梯度分量的**相反符号**，如 $(\pm 1, \pm 1, \ldots, \pm 1)^T$

以上四种选方向的方法都可以证明是**线性收敛**的

变种（1）：坐标轮换法

Gradient 与 Steepest Descent 的变种：计算梯度复杂时，坐标轴“轮流坐庄”

$$x \in \mathbf{R}^n, \qquad d^k = e_{\mathrm{mod}(k,n)}$$



- 第 k 步只沿一个坐标轴方向搜索，其余分量固定
- 选定的坐标方向可能是**上升**方向！
- 所以步长要在 $[-\alpha_{\max}, \alpha_{\max}]$ 中搜索，而不是只在 $(0, \alpha_{\max}]$ 中
- 不需要计算梯度，每步是一维问题

坐标轮换法可以看作 1-范数最速下降的“偷懒”版本：方向不由梯度决定，按固定规律轮换

块坐标下降（Block CD）

分块的坐标轮换法：设 $f(x, y)$ 凸且光滑，$x \in \mathbf{R}^n$，$y \in \mathbf{R}^m$，交替地对每一块求极小：

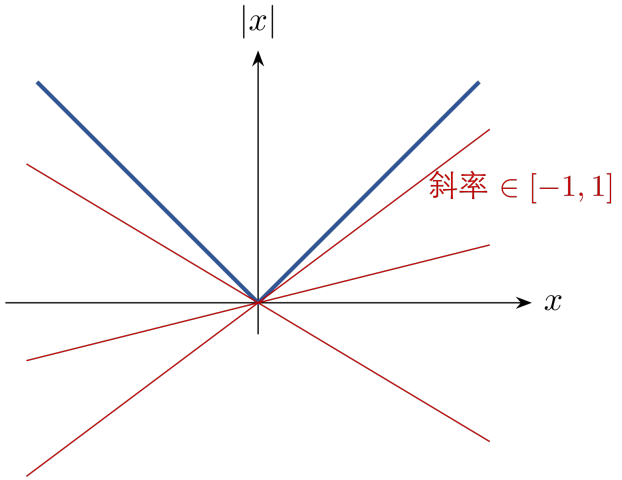
$$x^{k+1} = \underset{x}{\operatorname{argmin}} \ f(x, y^k)$$
$$y^{k+1} = \underset{y}{\operatorname{argmin}} \ f(x^{k+1}, y)$$

- **优点**：适合联合起来很复杂、但固定 x 或固定 y 后很简单的函数
- **缺点**：需要凸性；f 不光滑时可能停在非最优点（存在反例）
- 目标函数值单调不增：$f(x^{k+1}, y^{k+1}) \le f(x^{k+1}, y^k) \le f(x^k, y^k)$
- 可以看作最速下降法的特例 / 推广：方向不由梯度决定，只要按一定规律选取

变种（2）：不可微函数与次梯度

若 $f(x)$ 在某些点**不可微**（如“V”字形函数的尖点），梯度不存在；迭代点可能在尖点两侧来回跳动。

次梯度（subgradient）：



$$\frac{\partial f(x)}{\partial x} = \begin{cases} \nabla f(x), & f \text{ 在 } x \text{ 处可微} \\ \text{介于 } (\nabla f(x))^- \text{ 与 } (\nabla f(x))^+ \text{ 之间的任意值}, & \text{否则} \end{cases}$$

- 次梯度可能是一个**集合**；最优性条件：$0 \in \partial f(x^*)$
- 如 $|x|$ 在 0 处：左右导数为 −1 和 +1，次梯度为 $[-1, 1]$ 中任意值
- **次梯度下降法**（subgradient descent）：$d^k = -\partial f(x^k)/\partial x$

例：ℓ1 正则化最小二乘的次梯度

例：

$$\text{minimize} \quad f(x) = \frac{1}{2}\|Ax - b\|_2^2 + \lambda\|x\|_1$$

第一项可微，第二项在 $x_i = 0$ 处不可微：

$$\frac{\partial f(x)}{\partial x} = A^T(Ax - b) + \lambda \frac{\partial \|x\|_1}{\partial x}, \qquad \left(\frac{\partial \|x\|_1}{\partial x}\right)_i = \begin{cases} 1, & x_i > 0 \\ -1, & x_i < 0 \\ [-1, 1], & x_i = 0 \end{cases}$$

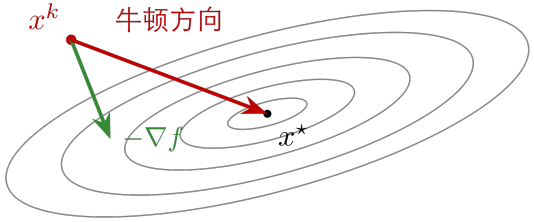
当次梯度集合 $\partial f / \partial x$ 中包含全零向量时，就达到了最优解

牛顿法（Newton's Method）

与最速下降相同的出发点，但用**二阶** Taylor 展开近似 $f(x^k+v)$（Boyd §9.5）：

$$
\begin{aligned}
d^k &= \operatorname*{argmin}_v \ \{f(x^k+v) \mid \|v\|=1\} \\
&\approx \operatorname*{argmin}_v \ \left\{f(x^k)+\nabla f(x^k)^T v+\frac{1}{2}v^T\nabla^2 f(x^k)\,v\right\}
\end{aligned}
$$

- $\nabla^2 f \succeq mI \Longrightarrow$ Hessian 正定 $\Longrightarrow$ 二次模型严格凸、有唯一极小点，Hessian 可逆，所以不再需要 $\|v\|=1$ 的约束
- 令梯度为零：



$$
\nabla f(x^k)+\nabla^2 f(x^k)\,v=0 \ \Longrightarrow\ d^k=-\left(\nabla^2 f(x^k)\right)^{-1}\nabla f(x^k)
$$

d^k 称为**牛顿方向**（Newton step）

牛顿法算法

repeat

1. $d^k := -\left(\nabla^2 f(x^k)\right)^{-1}\nabla f(x^k)$
2. $\alpha^k = \operatorname{argmin}_{\alpha_{\max}\geq\alpha\geq 0} f(x^k + \alpha d^k)$ (exact or inexact)
3. $x^{k+1} := x^k + \alpha^k d^k$

until convergence or $\left|\nabla f(x^k)^T\left(\nabla^2 f(x^k)\right)^{-1}\nabla f(x^k)\right| \leq \varepsilon$

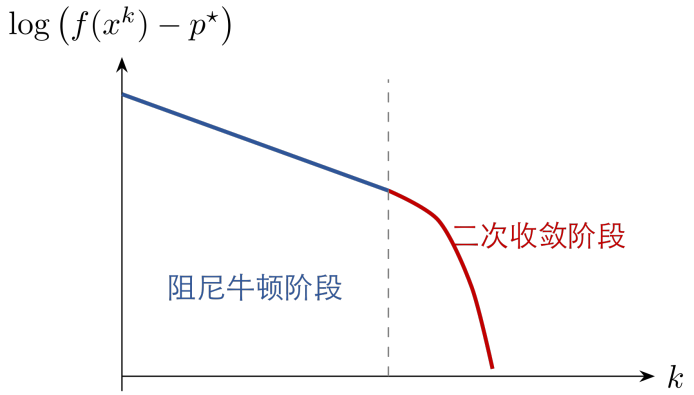
- 停止准则：$\nabla f(x^k)^T d^k = -\nabla f^T(\nabla^2 f)^{-1}\nabla f$ 是一阶 Taylor 项，接近最优点时趋于 0
- $\lambda(x) = (\nabla f^T(\nabla^2 f)^{-1}\nabla f)^{1/2}$ 称为**牛顿减量**（Newton decrement）
- 步长可以用精确或不精确（Armijo）直线搜索

牛顿法的收敛性：两个阶段

收敛性分析：存在 $\eta > 0$（证明见 Boyd §9.5.3）

- 若 $\|\nabla f(x^k)\|_2 > \eta$：**阻尼牛顿阶段**（damped Newton phase）—— 离最优点远时像有“阻力”，走得慢
- 若 $\|\nabla f(x^k)\|_2 < \eta$：**二次收敛阶段**（quadratically convergent phase）

$$\frac{f(x^{k+1}) - p^*}{\left(f(x^k) - p^*\right)^2} \sim u \qquad (\text{近似为常数})$$



- 对比线性收敛：$(f(x^{k+1}) - p^*)/(f(x^k) - p^*)$ 约为小于 1 的常数
- 画 $log(f(x^k) - p^*)$ 关于 k 的曲线即可看出区别

牛顿法的几何解释与拟牛顿法

- 每一步极小化 f 在 x^k 处的**二次近似**；x^0 离最优点远时二次近似不准，进入小邻域后近似得很好，收敛非常快
- 主要缺点：**Hessian 及其逆的计算代价很大**

拟牛顿法（Quasi-Newton method）：用一个与 Hessian 同维、容易求逆的矩阵 B 代替 Hessian：

$$\nabla^2 f(x^k)\, d^k = -\nabla f(x^k) \qquad \longrightarrow \qquad B\, d^k = -\nabla f(x^k)$$

- 比较有名的方法：**BFGS**（四个人名字的首字母）

所有方法都是“先找方向，再找步长”；根据 Hessian 是否容易计算来选择方法

无约束优化算法小结

无约束优化问题 $min\ f(x)$：所有方法都是 $x^{k+1} = x^k + \alpha^k d^k$，区别在于方向 d^k

方法	搜索方向	特点
gradient descent	$d^k = -\nabla f(x^k)$	经典方法，可保证线性收敛
steepest descent	$argmin_{\|v\|=1} \nabla f(x^k)^T v$	1/2/∞-范数；线性收敛
coordinate descent	坐标轴轮换	固定部分坐标后问题简单
subgradient descent	$d^k = -\partial f(x^k)/\partial x$	在“尖点”附近困难
Newton's method	$-(\nabla^2 f(x^k))^{-1}\nabla f(x^k)$	邻域内极快，需 Hessian 及其逆
Quasi-Newton	$-B^{-1}\nabla f(x^k)$	B 近似 Hessian、易求逆