Computer Vision 计算机视觉

Computer Vision —— Object Recognition

物体识别

桑农

2026 年 9 月 29 日

课件参考 R. Fergus、S. Savarese、S. Lazebnik、D. Lowe 与 P. Viola 的计算机视觉课程资料。

2026/9/29

桑 农

Slides from CV course with R. Fergus, and S. Savarese, S. Lazebnik, D. Lowe, P. Viola

Agenda 课程目录

概述
物体与人脸识别
词袋模型
基于部件的模型

Agenda

- Introduction
- Objects & Faces recognition
- Bag-of-words models
- Part-based models

Overview 内容概览

- Specific Object Recognition
  - Lowe ‘04
  - Rothganger et al. ‘03
- Face Dectection
  - Sub-space methods
  - Neural Network-based approaches
  - Viola & Jones
- Face Recognition

特定物体识别，包括Lowe（2004）与Rothganger 等（2003）。

人脸检测，包括子空间方法、基于神经网络的方法及 Viola 与 Jones 方法。

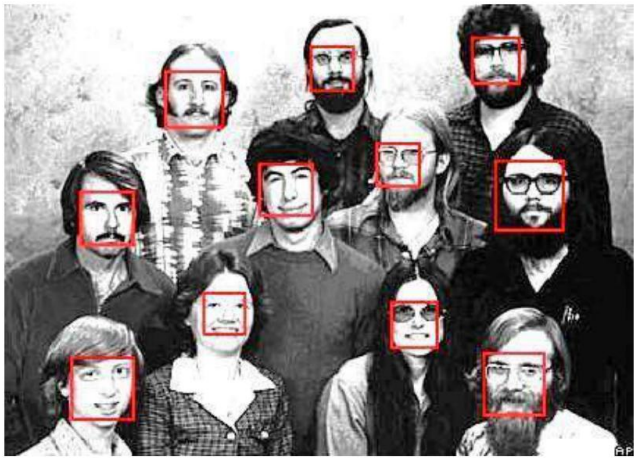
人脸识别。

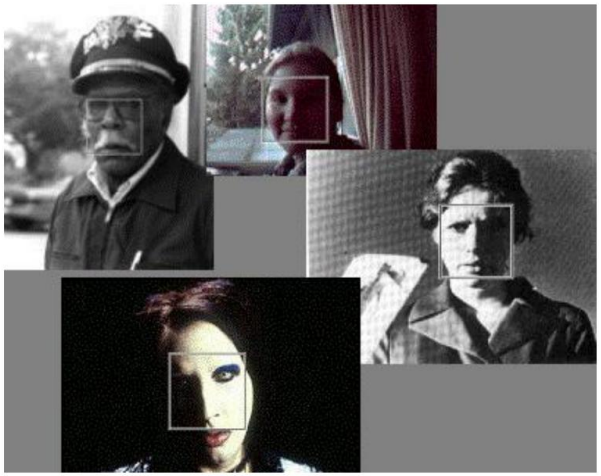
Face Detection & Recognition 人脸检测与识别

来源 P. Viola、S. Lazebnik 与 A. Torralba。

Slides from
P. Viola, S. Lazebnik, A. Torralba

Face detection　人脸检测







图中矩形框标示检测出的人脸。

Face detection and recognition　人脸检测与识别

检测阶段确定人脸的位置。

识别阶段判定人物身份，图中识别结果为 Sally。



Consumer application: iPhoto 2009　消费级应用 iPhoto 2009



图中展示照片管理软件中的人脸检测功能。

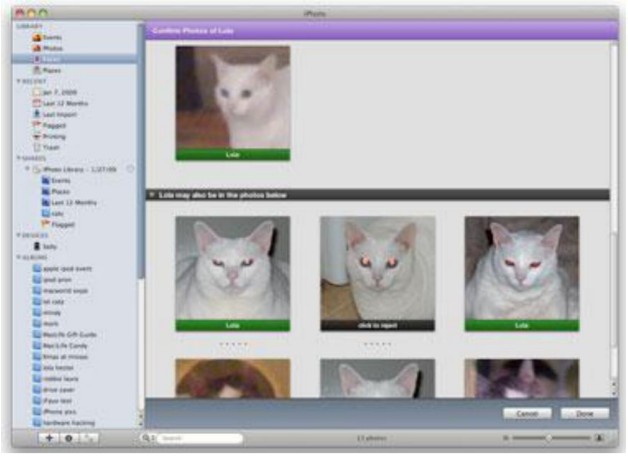
http://www.apple.com/ilife/iphoto/

Consumer application: iPhoto 2009　消费级应用 iPhoto 2009

经过训练后，还可用于宠物识别。

- Can be trained to recognize pets!





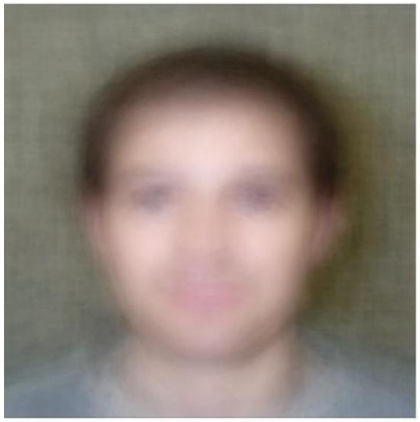
http://www.maclife.com/article/news/iphotos_faces_recognizes_cats

Challenges: 人脸检测挑战

- Variability due to:

  Intra-class variation (but fairly small)
  Illumination
  Occlusions (eyeglasses, facial hair, hair)

  Fairly limited viewpoint (frontal, profile)



外观变化来自类内差异，幅度相对较小。

其他变化包括光照与遮挡，遮挡物包括眼镜、胡须与头发。

视点范围相对有限，主要为正面与侧面。

Practical Challenges of face detection 人脸检测的实际挑战

- Sliding window detector must evaluate tens of thousands of location/scale combinations
- Faces are rare: 0–10 per image
  - For computational efficiency, we should try to spend as little time as possible on the non-face windows
  - A megapixel image has ~10^6 pixels and a comparable number of candidate face locations
  - To avoid having a false positive in every image, our false positive rate has to be less than 10^{-6}

滑动窗口检测器需要评估数万个位置与尺度组合。

人脸在图像中很少，每幅图像通常有 0 至 10 张人脸。

为提高计算效率，应尽量减少非人脸窗口的处理时间。

百万像素图像约有 10^6 个像素，候选人脸位置数量与此相当。

为避免每幅图像都出现误检，假阳性率必须小于 10^{-6}。

Overview 内容概览

- Specific Object Recognition
  - Lowe ‘04
  - Rothganger et al. ‘03
- Face Dectection
  - Sub-space methods
  - Neural Network-based approaches
  - Viola & Jones
- Face Recognition

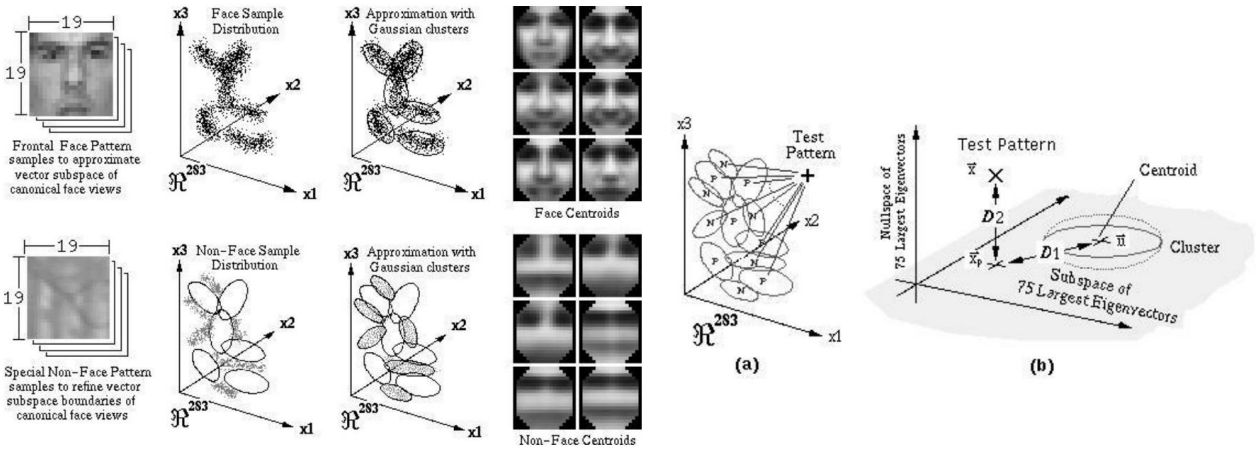
特定物体识别，包括 Lowe（2004）与 Rothganger 等（2003）。

人脸检测，包括子空间方法、基于神经网络的方法及 Viola 与 Jones 方法。

人脸识别。

Distribution-Based Face Detector　基于分布的人脸检测器

- Learn face and nonface models from examples [Sung and Poggio 95]
  - Cluster and project the examples to a lower dimensional space using Gaussian distributions and PCA
  - Detect faces using distance metric to face and nonface clusters



从样本中学习人脸与非人脸模型（Sung 与 Poggio，1995）。

利用高斯分布与主成分分析 PCA 对样本聚类，并投影到低维空间。

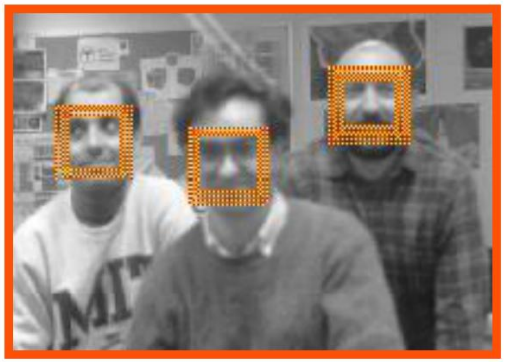
通过测试样本到人脸簇与非人脸簇的距离度量进行检测。

图中展示 19×19 的正面人脸样本、人脸与非人脸样本分布、高斯簇近似以及各簇中心。

右图将测试样本投影到前 75 个特征向量张成的子空间，分别计算投影残差 D_2 与簇内距离 D_1。

Distribution-Based Face Detector　基于分布的人脸检测器

- Learn face and nonface models from examples [Sung and Poggio 95]







Training Database

1000+ Real, 3000+ *VIRTUAL*

50,0000+ Non-Face Pattern

从样本中学习人脸与非人脸模型（Sung 与 Poggio，1995）。

训练数据库含 1000 多个真实人脸样本、3000 多个虚拟人脸样本，以及 50 万多个非人脸图样。

图中 Image 为输入图像，Output 为输出结果。

Overview 内容概览

- Specific Object Recognition
  - Lowe ‘04
  - Rothganger et al. ‘03
- Face Dectection
  - Sub-space methods
  - Neural Network-based approaches
  - Viola & Jones
- Face Recognition

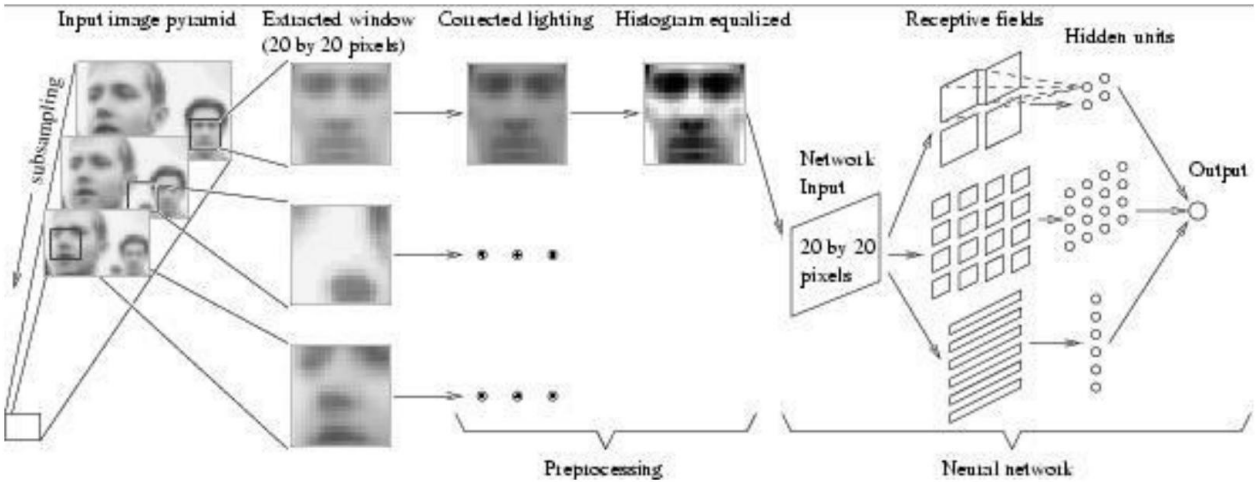
特定物体识别，包括 Lowe（2004）与 Rothganger 等（2003）。

人脸检测，包括子空间方法、基于神经网络的方法及 Viola 与 Jones 方法。

人脸识别。

Neural Network-Based Face Detector 基于神经网络的人脸检测器

- Train a set of multilayer perceptrons and arbitrate a decision among all outputs [Rowley et al. 98]

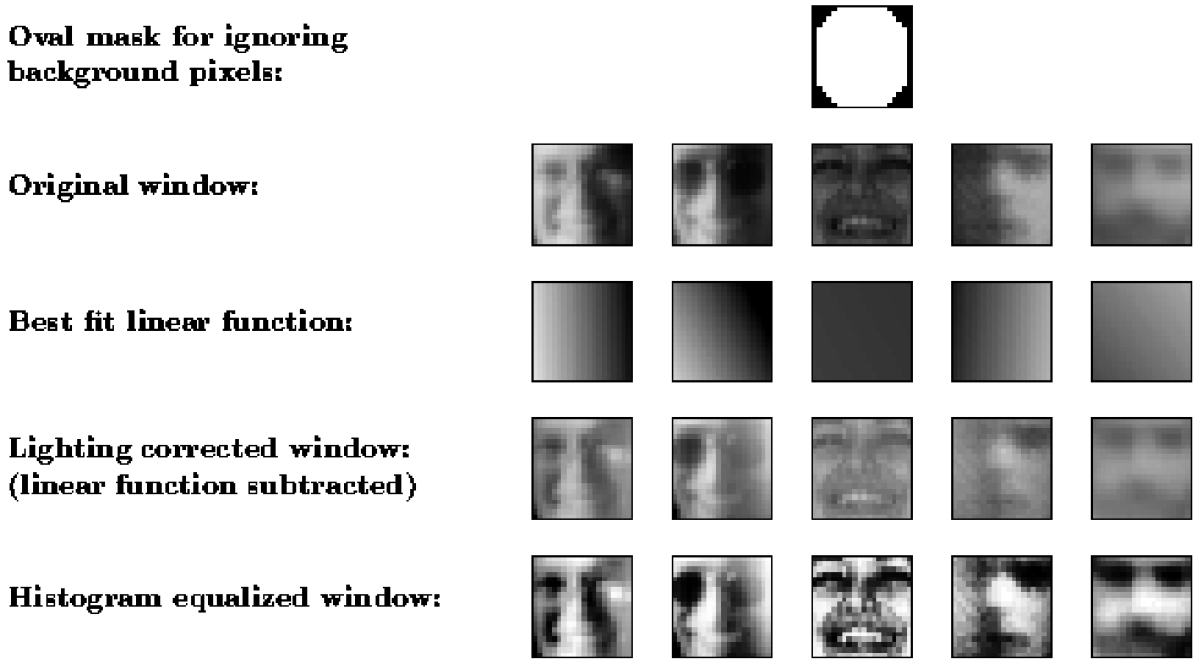


训练一组多层感知机，综合所有输出作出判决（Rowley 等，1998）。

图像金字塔通过下采样生成。提取 20×20 像素窗口，经过光照校正与直方图均衡化，作为神经网络输入。

网络图中依次标出感受野、隐藏单元与输出。

窗口预处理



The steps in preprocessing a window. First, a linear function is fit to the intensity values in the window, and then subtracted out, correcting for some extreme lighting conditions. Then, histogram equalization is applied, to correct for different camera gains and to improve contrast. For each of these steps, the mapping is computed based on pixels inside the oval mask, while the mapping is applied to the entire window.

From: http://www.ius.cs.cmu.edu/IUS/har2/har/www/CMU-CS-95-158R/

利用椭圆掩膜忽略背景像素。

图中从上至下依次为原始窗口、最佳拟合线性函数、减去线性函数后的光照校正窗口与直方图均衡化窗口。

对窗口内的强度值拟合线性函数并将其减去，可校正部分极端光照条件。随后应用直方图均衡化，以补偿相机增益差异并提高对比度。

每一步的映射均依据椭圆掩膜内的像素计算，并应用到整个窗口。

Example CMU face detector results　CMU 人脸检测结果示例

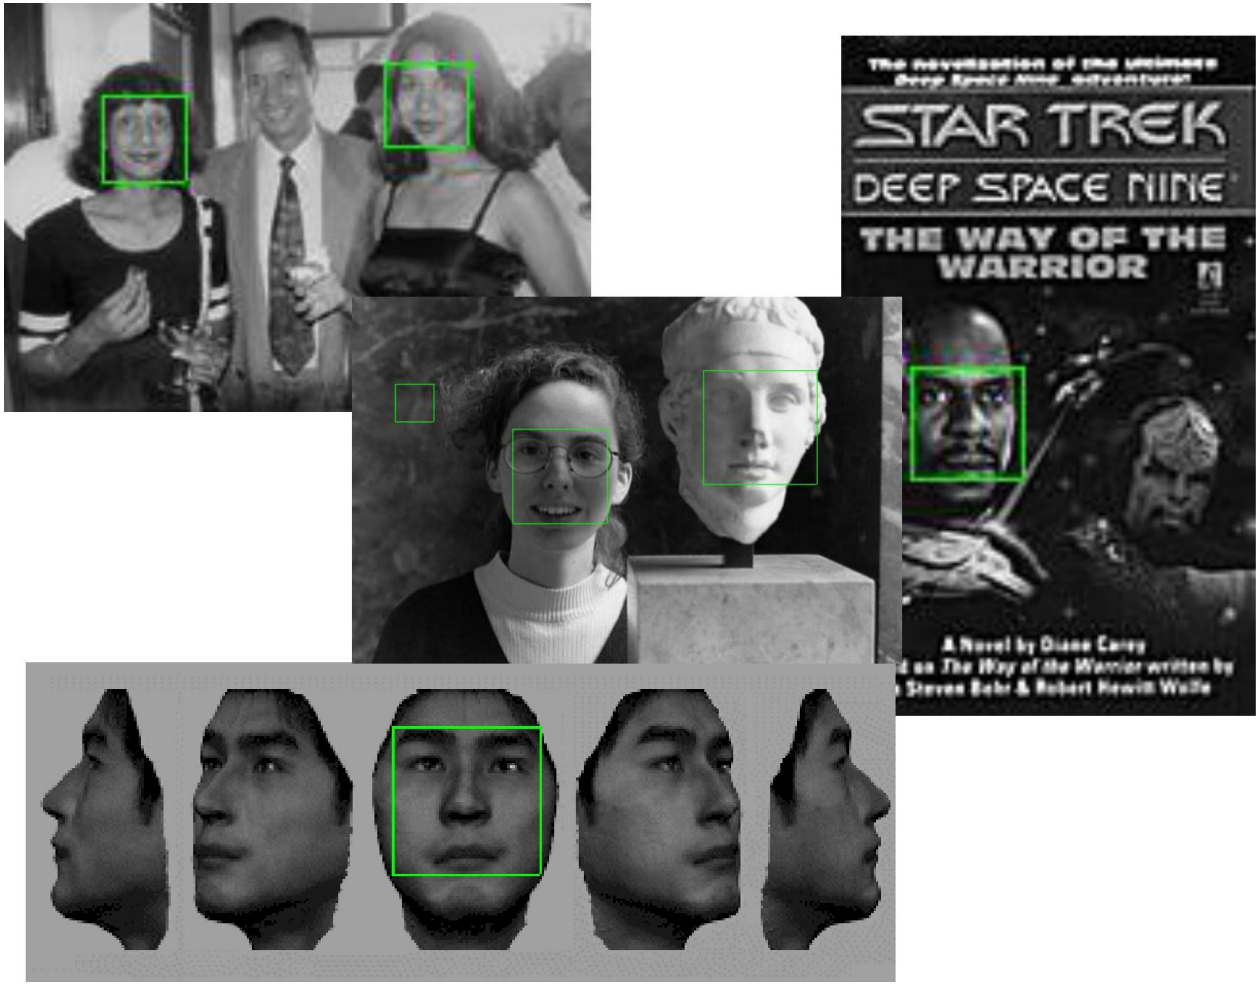
图中为输入图像。来源CMU 人脸检测演示。

input



All images from: http://www.ius.cs.cmu.edu/demos/facedemo.html

人脸检测结果示例



绿色矩形框表示检测出的人脸，示例包含多人图像及多种人脸视点。

人脸样本扩增

Example face images, randomly mirrored, rotated, translated, and scaled by small amounts (photos are of the three authors).

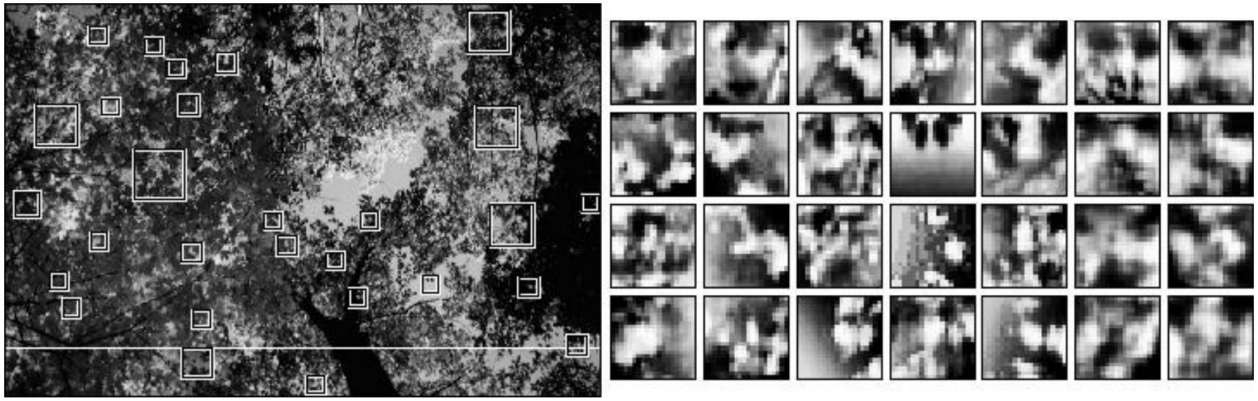
对人脸图像进行随机镜像、旋转、小幅平移与缩放。图中照片来自三位作者。



From: http://www.ius.cs.cmu.edu/IUS/har2/har/www/CMU-CS-95-158R/

困难负样本挖掘

During training, the partially-trained system is applied to images of scenery which do not contain faces (like the one on the left). Any regions in the image detected as faces (which are expanded and shown on the right) are errors, which can be added into the set of negative training examples.



From: http://www.ius.cs.cmu.edu/IUS/har2/har/www/CMU-CS-95-158R/

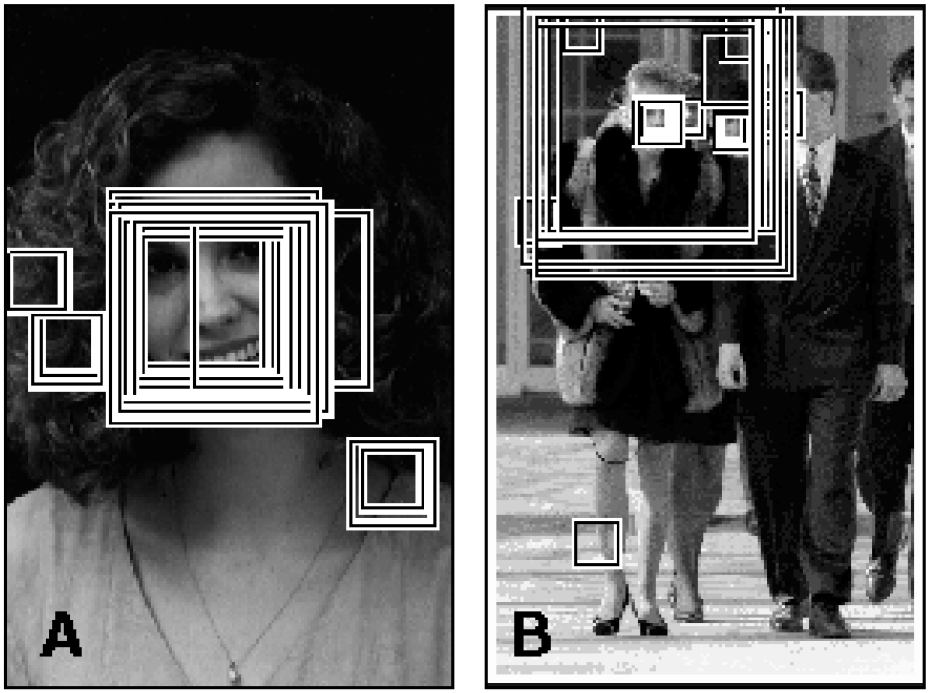
训练期间，将部分训练完成的系统应用到景物图像中，这类图像的人脸数量为零。

系统检测为人脸的区域均为误检，右侧将这些区域放大展示。它们可加入负训练样本集。

阈值筛选的检测结果

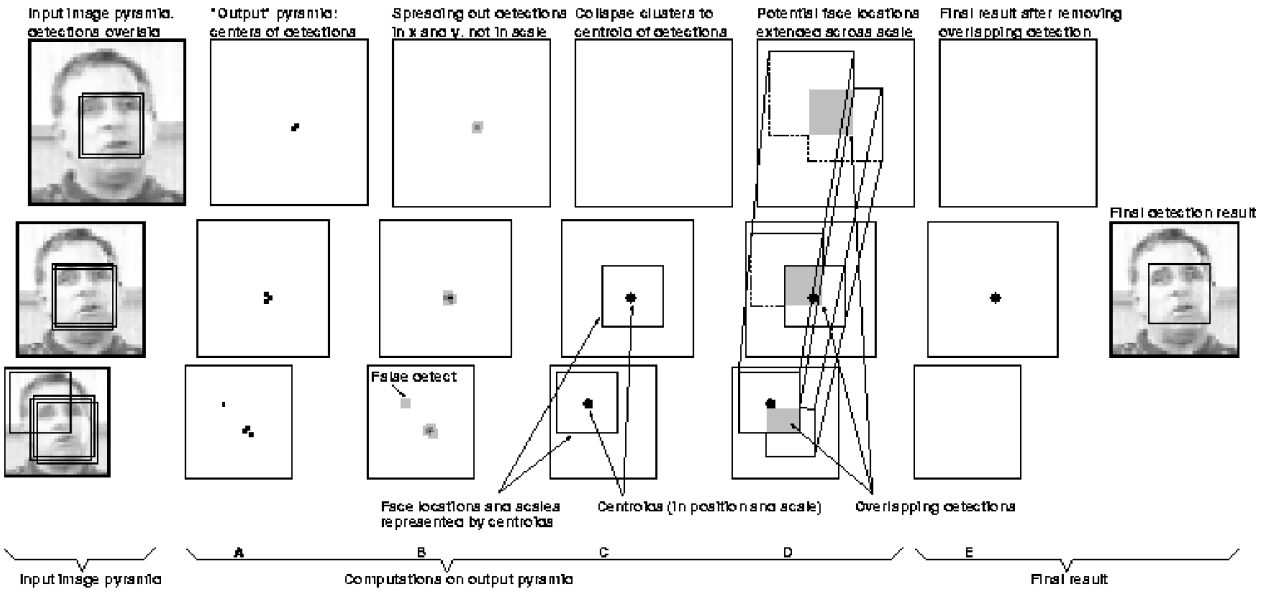
Images with all the above threshold detections indicated by boxes.

方框标示所有响应超过阈值的检测结果。



From: http://www.ius.cs.cmu.edu/IUS/har2/har/www/CMU-CS-95-158R/

多重检测结果合并



The framework used for merging multiple detections from a single network: A) The detections are recorded in an image pyramid. B) The detections are ``spread out'' and a threshold is applied. C) The centroids in scale and position are computed, and the regions contributing to each centroid are collapsed to single points. In the example shown, this leaves only two detections in the output pyramid. D) The final step is to check the proposed face locations for overlaps, and E) to remove overlapping detections if they exist. In this example, removing the overlapping detection eliminates what would otherwise be a false positive.

From: http://www.ius.cs.cmu.edu/IUS/har2/har/www/CMU-CS-95-158R/

A. 将单个网络的检测结果记录在图像金字塔中。

B. 扩散检测响应，并应用阈值。

C. 计算尺度与位置上的质心，将贡献到各质心的区域折叠为单点。示例的输出金字塔剩余两处检测。

D. 检查候选人脸区域的重叠。

E. 删除重叠检测。示例中，该步骤消除了一处假阳性。

人脸检测图像示例

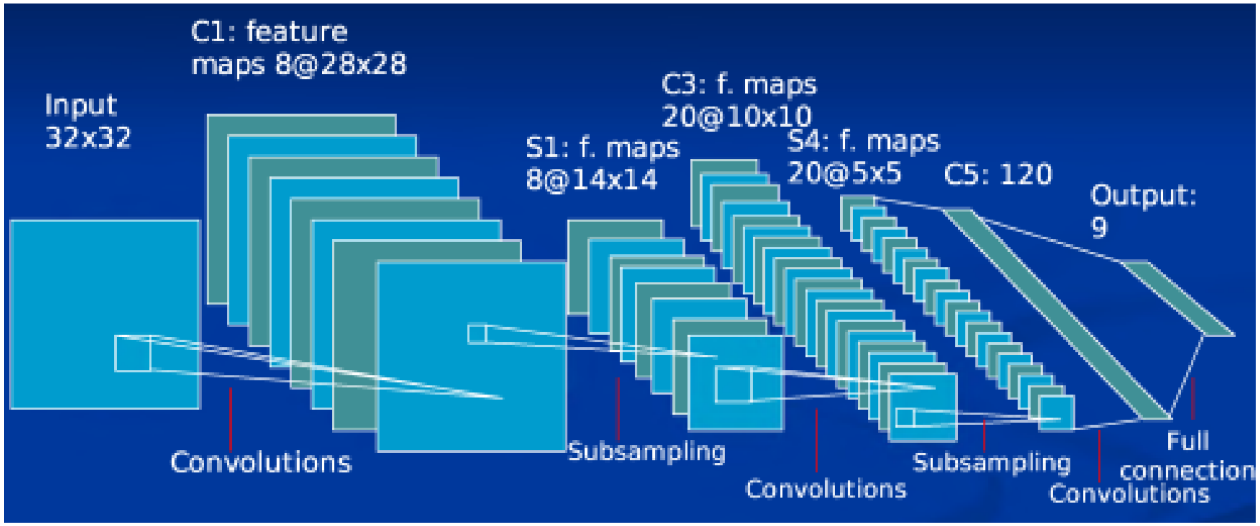


图中矩形框为检测结果。

卷积神经网络的人脸检测

Osadchy, Miller, LeCun.
Face Detection and Pose Estimation, 2004

- Application of Convolutional Neural Networks to Face Detection



Osadchy、Miller 与 LeCun，《人脸检测与姿态估计》，2004 年。

卷积神经网络在人脸检测中的应用。

输入为 32×32 像素。C1 为 8 幅 28×28 特征图，S1 为 8 幅 14×14 特征图，C3 为 20 幅 10×10 特征图，S4 为 20 幅 5×5 特征图，C5 含 120 个单元，输出含 9 个单元。

网络依次使用卷积、下采样、卷积、下采样、卷积与全连接层。

人脸检测与姿态估计

Osadchy, Miller, LeCun.
Face Detection and Pose Estimation, 2004



Osadchy、Miller 与 LeCun，《人脸检测与姿态估计》，2004 年。

图中展示多人图像的人脸检测与姿态估计结果。

Overview 内容概览

- Specific Object Recognition
  - Lowe ‘04
  - Rothganger et al. ‘03
- Face Dectection
  - Sub-space methods
  - Neural Network-based approaches
  - Viola & Jones
- Face Recognition

特定物体识别，包括Lowe（2004）与Rothganger 等（2003）。

人脸检测，包括子空间方法、基于神经网络的方法及 Viola 与 Jones 方法。

人脸识别。

简单特征提升级联的快速物体检测

Rapid Object Detection Using a Boosted Cascade of Simple Features

Paul Viola　　Michael J. Jones
Mitsubishi Electric Research Laboratories (MERL)
Cambridge, MA

Most of this work was done at Compaq CRL before the authors moved to MERL

Paul Viola 与 Michael J. Jones。

三菱电机研究实验室 MERL，美国马萨诸塞州剑桥市。

作者迁往 MERL 之前，大部分工作已在康柏剑桥研究实验室完成。

The Viola/Jones Face Detector　Viola 与 Jones 人脸检测器

- A seminal approach to real-time object detection
- Training is slow, but detection is very fast
- Key ideas
  - *Integral images* for fast feature evaluation
  - *Boosting* for feature selection
  - *Attentional cascade* for fast rejection of non-face windows

实时物体检测的奠基性方法。

训练耗时较长，检测速度很快。

核心思想包括利用积分图快速计算特征、利用提升方法选择特征、利用注意力级联快速排除非人脸窗口。

P. Viola and M. Jones. *Rapid object detection using a boosted cascade of simple features.* CVPR 2001.

P. Viola and M. Jones. *Robust real-time face detection.* IJCV 57(2), 2004.

P. Viola 与 M. Jones，《利用简单特征的提升级联进行快速物体检测》，CVPR 2001。

P. Viola 与 M. Jones，《鲁棒实时人脸检测》，IJCV 57(2)，2004 年。

Image Features 图像特征

矩形滤波器。

“Rectangle filters”

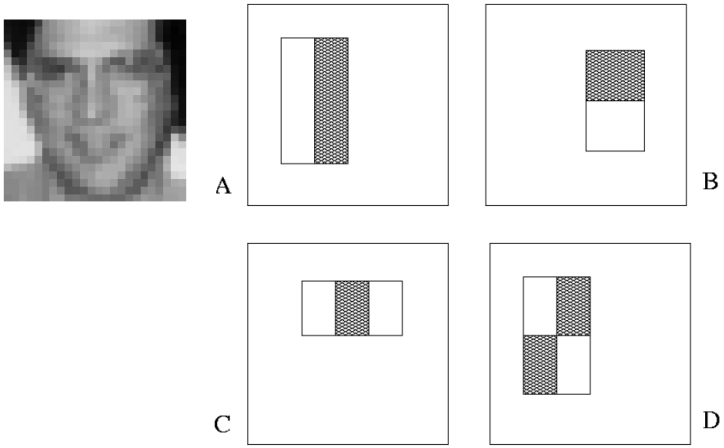
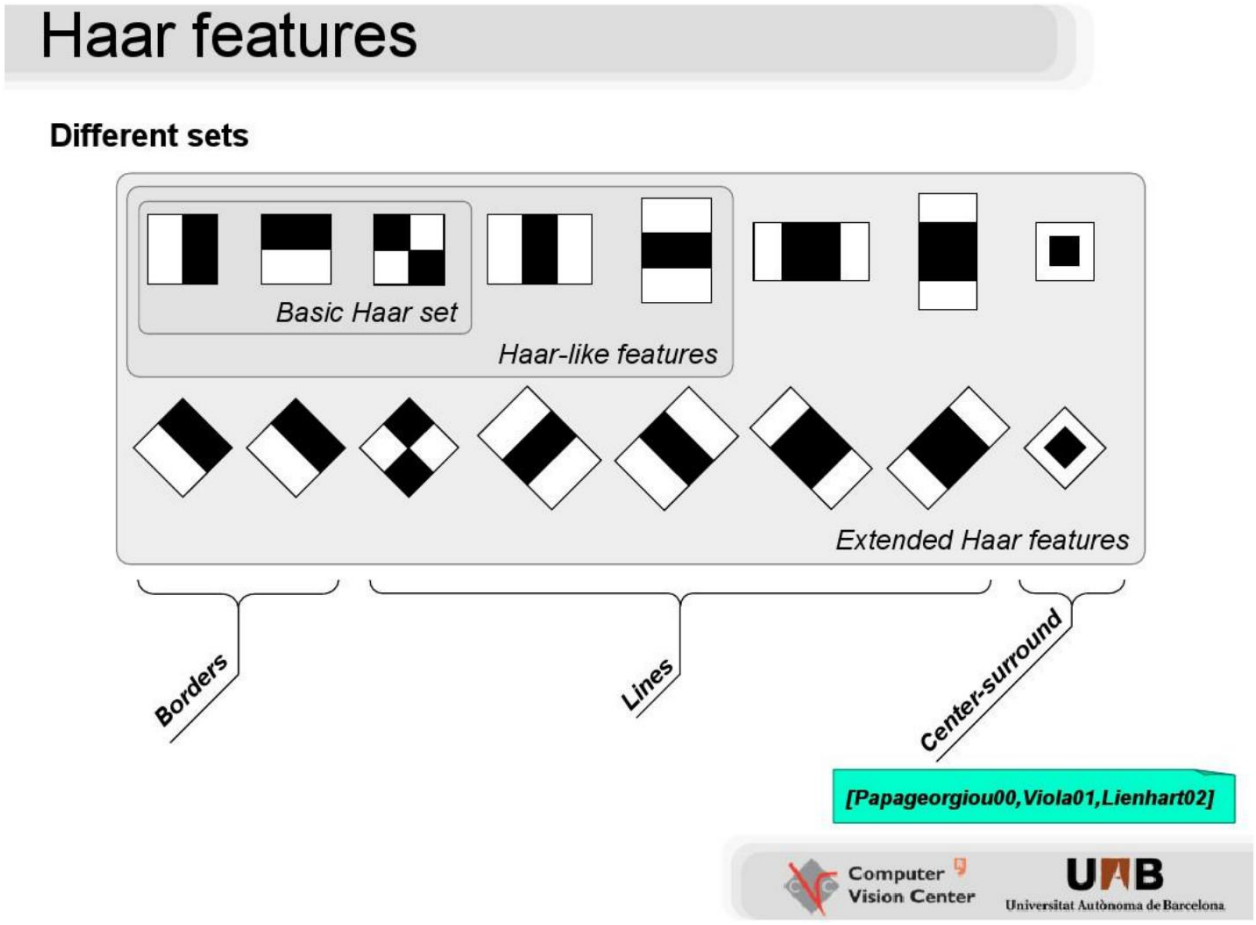


Image Features 图像特征



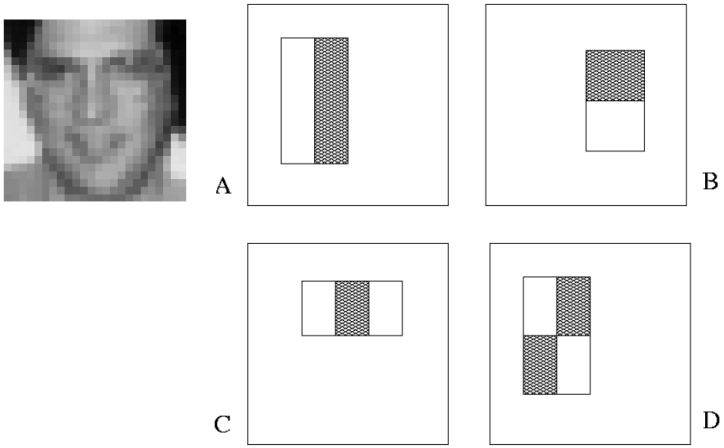
Haar 特征包括基本 Haar 特征集、类 Haar 特征及扩展 Haar 特征。

按响应模式可分为边界、线条与中心周围特征。

Image Features 图像特征

矩形滤波器的特征值 = 白色区域像素值之和 – 黑色区域像素值之和。

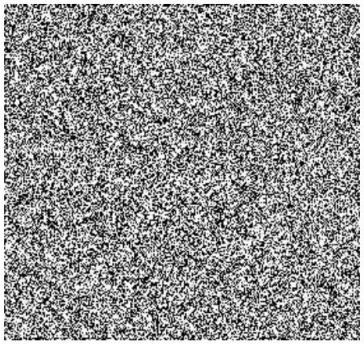
"Rectangle filters"



Value =

∑ (pixels in white area) –
∑ (pixels in black area)

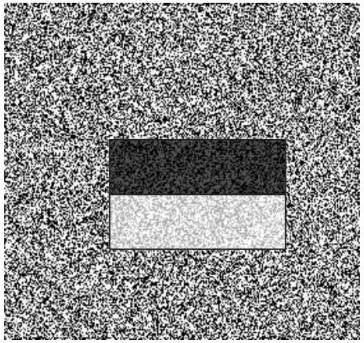
Example 矩形特征示例



Source



Result





Slide: S. Lazebnik

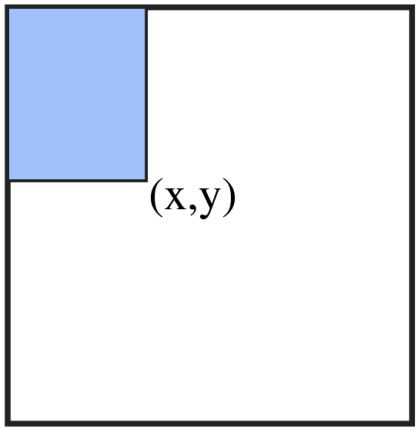
上行为源图像，下行为滤波结果。

左侧随机纹理的矩形特征响应较弱，右侧人脸眼部与面部区域呈现明显明暗结构。

来源 S. Lazebnik。

Fast computation with integral images 积分图快速计算

- The *integral image* computes a value at each pixel (*x*,*y*) that is the sum of the pixel values above and to the left of (*x*,*y*), inclusive
- This can quickly be computed in one pass through the image



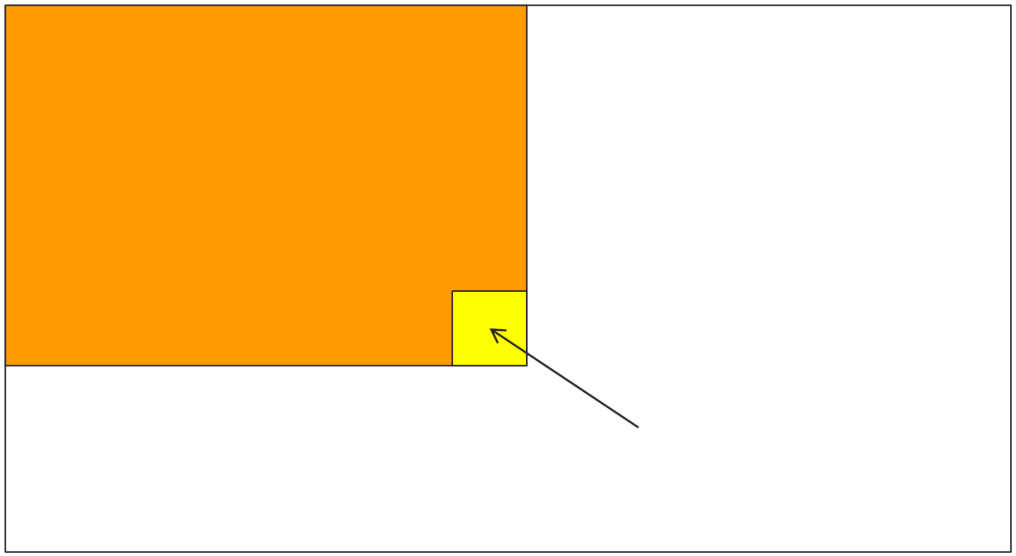
积分图在每个像素 (x, y) 处存储其左上方矩形内全部像素值之和，包含当前位置。

遍历图像一次即可快速计算积分图。

来源 S. Lazebnik。

Slide: S. Lazebnik

Computing the integral image　积分图计算

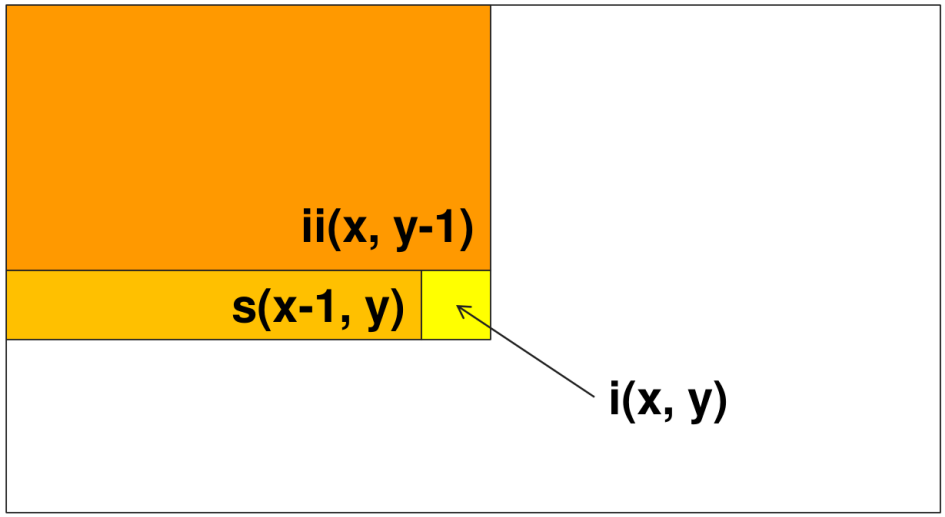


图中橙色区域为左上方累计区域，黄色区域为当前像素。

来源 S. Lazebnik。

Slide: S. Lazebnik

Computing the integral image 积分图计算



行累计和 s(x,y) = s(x−1,y) + i(x,y)。

积分图 ii(x,y) = ii(x,y−1) + s(x, y)。

MATLAB 实现采用双精度转换与两次累计求和，函数分别为 double 和 cumsum。

来源 S. Lazebnik。

- Cumulative row sum: $s(x, y) = s(x-1, y) + i(x, y)$
- Integral image: $ii(x, y) = ii(x, y-1) + s(x, y)$

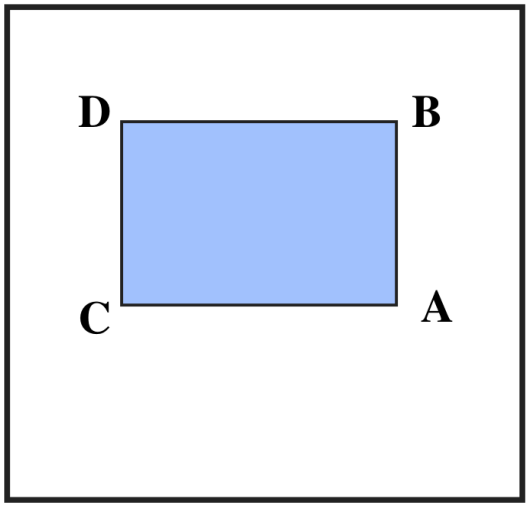
MATLAB: ii = cumsum(cumsum(double(i)), 2);

Slide: S. Lazebnik

Computing sum within a rectangle 矩形区域求和

- Let A,B,C,D be the values of the integral image at the corners of a rectangle
- Then the sum of original image values within the rectangle can be computed as:

  sum = A – B – C + D
- Only 3 additions are required for any size of rectangle!



设 A、B、C、D 为矩形四角处的积分图值。

原图矩形区域的像素值之和为 sum = A − B− C + D。

任意大小的矩形均仅需 3 次加减运算。

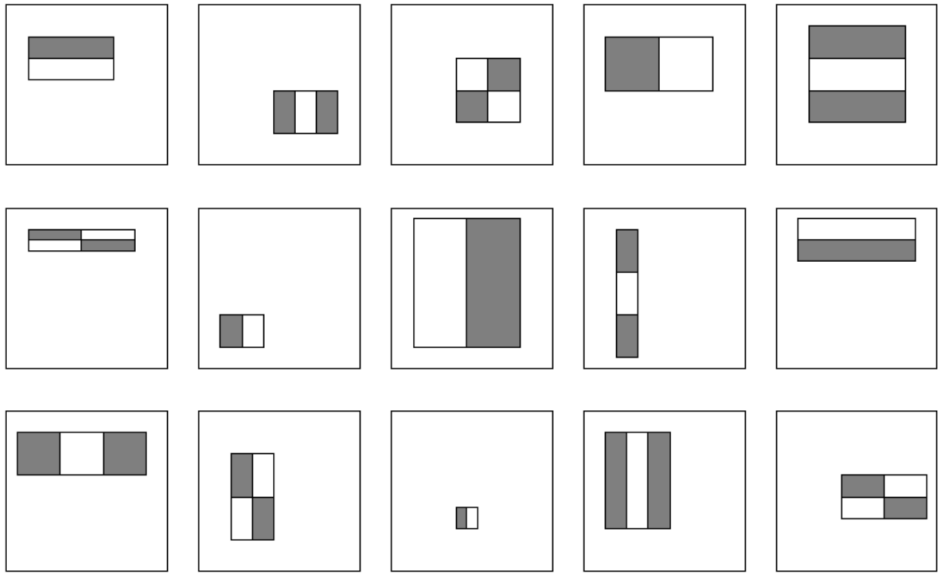
来源 S. Lazebnik。

Slide: S. Lazebnik

Feature selection 特征选择

- For a 24x24 detection region, the number of possible rectangle features is ~160,000!

对 24×24 的检测区域，矩形特征的候选数量约为 160000。



Feature selection 特征选择

- For a 24x24 detection region, the number of possible rectangle features is ~160,000!
- At test time, it is impractical to evaluate the entire feature set
- Can we create a good classifier using just a small subset of all possible features?
- How to select such a subset?

对 24×24 的检测区域，矩形特征的候选数量约为 160000。

测试时计算全部特征的代价过高。

研究问题包括以少量特征子集构建高性能分类器，以及该子集的选择方法。

Boosting 提升方法

- Boosting is a classification scheme that works by combining *weak learners* into a more accurate ensemble classifier
- Training consists of multiple *boosting rounds*
  - During each boosting round, we select a weak learner that does well on examples that were hard for the previous weak learners
  - "Hardness" is captured by weights attached to training examples

Y. Freund and R. Schapire, A short introduction to boosting, *Journal of Japanese Society for Artificial Intelligence*, 14(5):771-780, September, 1999.

提升是一种分类方案，将多个弱学习器组合成性能更高的集成分类器。

训练由多轮提升组成。每轮选择一个弱学习器，使它在此前弱学习器难以处理的样本上表现较好。

训练样本的权重表示其处理难度。

Y. Freund 与 R. Schapire，《提升方法简明介绍》，日本人工智能学会会刊 14(5)，771—780 页，1999 年 9 月。

Training procedure　提升训练流程

- Initially, weight each training example equally
- In each boosting round:
  - Find the weak learner that achieves the lowest *weighted* training error
  - Raise the weights of training examples misclassified by current weak learner
- Compute final classifier as linear combination of all weak learners (weight of each learner is directly proportional to its accuracy)
- Exact formulas for re-weighting and combining weak learners depend on the particular boosting scheme (e.g., AdaBoost)

Y. Freund and R. Schapire, A short introduction to boosting, *Journal of Japanese Society for Artificial Intelligence*, 14(5):771-780, September, 1999.

初始化时，各训练样本具有相同权重。

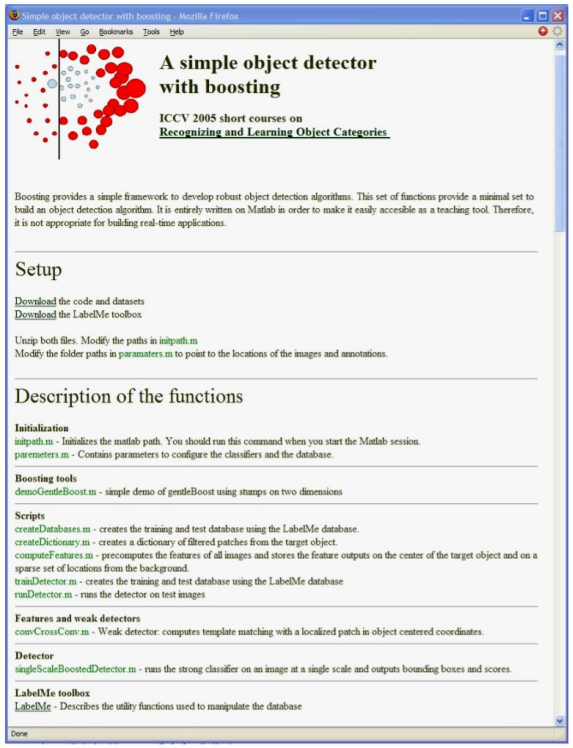
每轮选择加权训练误差最低的弱学习器，并提高被当前弱学习器误分类样本的权重。

最终分类器为所有弱学习器的线性组合，各学习器的权重与其分类表现成正比。

具体的重加权公式与组合公式取决于所选提升方案，例如 AdaBoost。

参考 Freund 与 Schapire（1999）的《提升方法简明介绍》。

A simple object detector with Boosting
基于提升的简单物体检测器



http://people.csail.mit.edu/torralba/iccv2005/

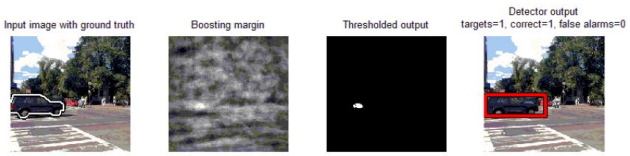
Download

- Toolbox for manipulating dataset
- Code and dataset

Matlab code

- Gentle boosting
- Object detector using a part based model

Dataset with cars and computer monitors



可下载数据集操作工具箱、代码与数据集。

MATLAB 代码包含 Gentle Boosting，以及使用基于部件模型的物体检测器。

数据集包含汽车与计算机显示器。

Why boosting? 提升方法的优势

- A simple algorithm for learning robust classifiers
  Freund & Shapire, 1995
  Friedman, Hastie, Tibshhirani, 1998
- Provides efficient algorithm for sparse visual feature selection
  Tieu & Viola, 2000
  Viola & Jones, 2003
- Easy to implement, not requires external optimization tools.

用于学习鲁棒分类器的简单算法，相关研究包括 Freund 与 Schapire（1995）、Friedman、Hastie 与 Tibshirani（1998）。

为稀疏视觉特征选择提供高效算法，相关研究包括 Tieu 与 Viola（2000）、Viola 与 Jones（2003）。

实现简便，可独立于外部优化工具运行。

Boosting 提升方法

使用加性模型定义分类器，$F(x) = \alpha_1 f_1(x) + \alpha_2 f_2(x) + \alpha_3 f_3(x) + \ldots$。

F 为强分类器，x 为特征向量，f 为弱分类器，α 为权重。

- Defines a classifier using an additive model:

$$F(x) = \alpha_1 f_1(x) + \alpha_2 f_2(x) + \alpha_3 f_3(x) + \ldots$$

Strong classifier

Features vector

Weight

Weak classifier

Boosting 提升方法

- Defines a classifier using an additive model:

$$F(x) = \alpha_1 f_1(x) + \alpha_2 f_2(x) + \alpha_3 f_3(x) + \dots$$

Strong classifier

Features vector

Weight

Weak classifier

- We need to define a family of weak classifiers

$f_k(x)$ from a family of weak classifiers

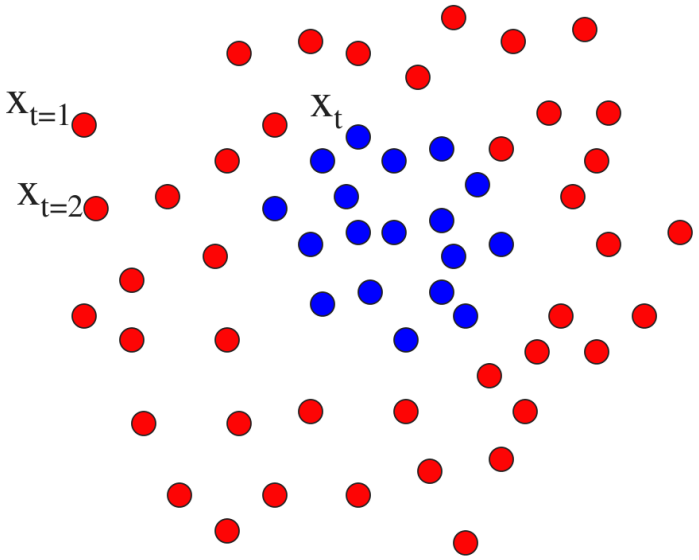
使用加性模型定义分类器，$F(x) = \alpha_1 f_1(x) + \alpha_2 f_2(x) + \alpha_3 f_3(x) + \dots$。

F 为强分类器，x 为特征向量，f 为弱分类器，α 为权重。

需要定义一个弱分类器族，并从该族中选择 $f_k(x)$。

Boosting 提升方法

- It is a sequential procedure:



Each data point has

a class label:

$$y_t = \begin{cases} +1 & (\bullet) \\ -1 & (\bullet) \end{cases}$$

and a weight:

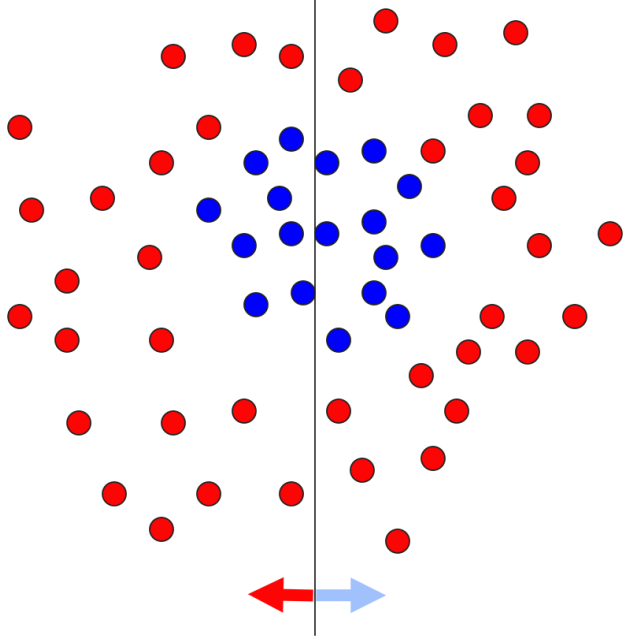
$$w_t = 1$$

提升采用序贯过程。

每个数据点 x_t 具有类别标签 y_t 与权重 w_t。红点标签为 +1，蓝点标签为 −1，初始权重 $w_t = 1$。

Toy example 简化示例

Weak learners from the family of lines



Each data point has

a class label:

$$y_t = \begin{cases} +1 & (\bullet) \\ -1 & (\bullet) \end{cases}$$

and a weight:

$$w_t = 1$$

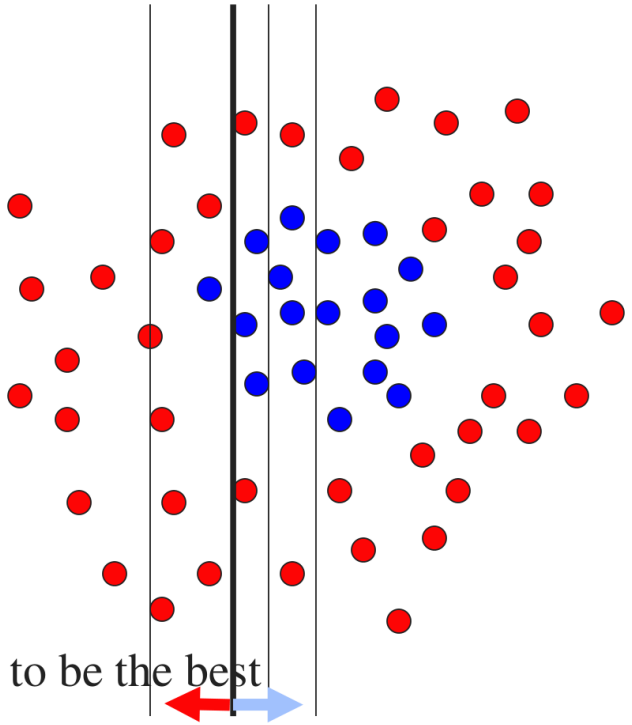
h => p(error) = 0.5 it is at chance

弱学习器来自直线分类器族。

每个数据点具有标签 y_t，红点为 +1，蓝点为 −1，初始权重 $w_t = 1$。

图中分类器 h 的错误概率为 0.5，与随机猜测相当。

Toy example 简化示例



This one seems to be the best

Each data point has

a class label:

$$y_t = \begin{cases} +1 & (\bullet) \\ -1 & (\bullet) \end{cases}$$

and a weight:

$$w_t = 1$$

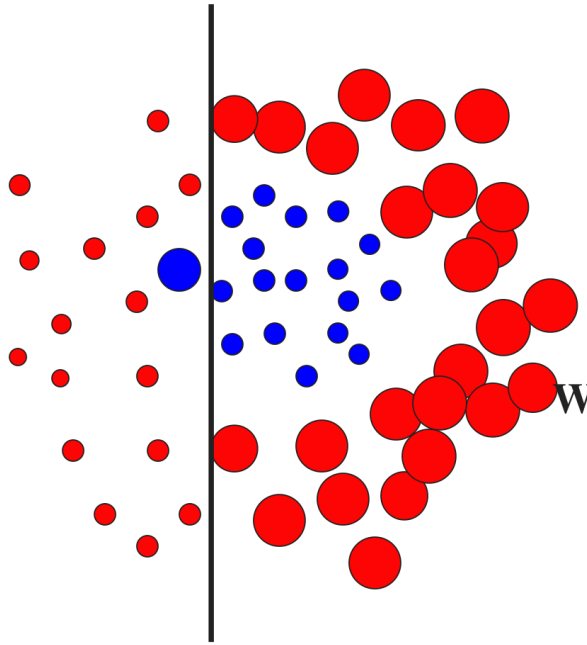
This is a '**weak classifier**': It performs slightly better than chance.

选择图中表现最好的直线分类器。

它属于弱分类器，表现略优于随机猜测。

红点标签为 +1，蓝点为 −1，初始权重 $w_t = 1$。

Toy example 简化示例



Each data point has

a class label:

$$y_t = \begin{cases} +1 & (\bullet) \\ -1 & (\bullet) \end{cases}$$

We update the weights:

$$w_t \leftarrow w_t \exp\{-y_t H_t\}$$

We set a new problem for which the previous weak classifier performs at chance again

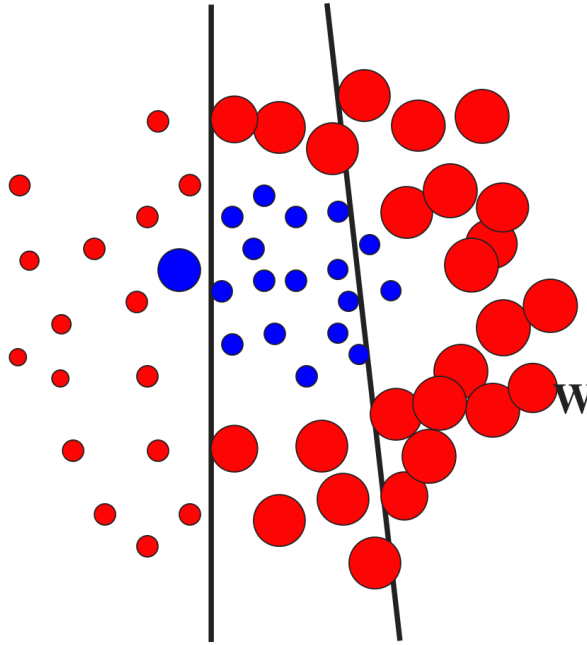
每个数据点具有类别标签，红点为 +1，蓝点为 −1。

更新样本权重，$w_t \leftarrow w_t \exp(-y_t H_t)$。

重新加权形成新的学习问题，使上一轮弱分类器在新权重下的表现与随机猜测相当。

圆点大小表示权重，图中的直线为逐轮选择的弱分类器。

Toy example 简化示例



Each data point has

a class label:

$$y_t = \begin{cases} +1 & (\bullet) \\ -1 & (\bullet) \end{cases}$$

We update the weights:

$w_t \leftarrow w_t \exp\{-y_t H_t\}$

We set a new problem for which the previous weak classifier performs at chance again

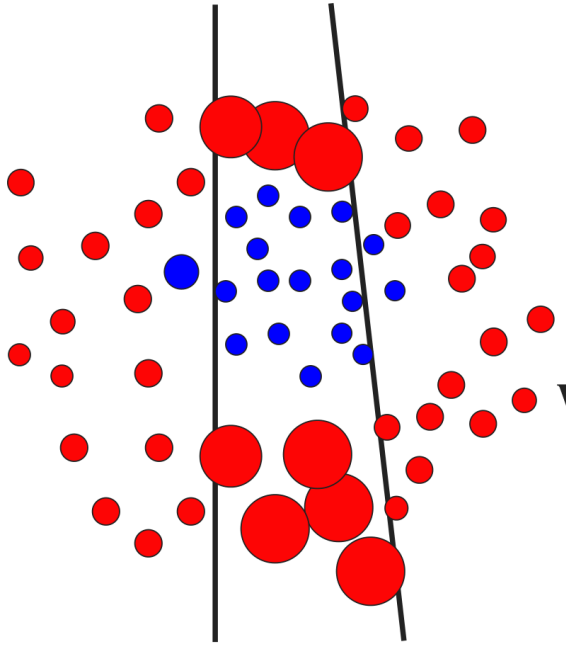
每个数据点具有类别标签，红点为 +1，蓝点为 −1。

更新样本权重，$w_t \leftarrow w_t \exp(-y_t H_t)$。

重新加权形成新的学习问题，使上一轮弱分类器在新权重下的表现与随机猜测相当。

圆点大小表示权重，图中的直线为逐轮选择的弱分类器。

Toy example 简化示例



Each data point has

a class label:

$$y_t = \begin{cases} +1 & (\bullet) \\ -1 & (\bullet) \end{cases}$$

We update the weights:

$$w_t \leftarrow w_t \exp\{-y_t H_t\}$$

We set a new problem for which the previous weak classifier performs at chance again

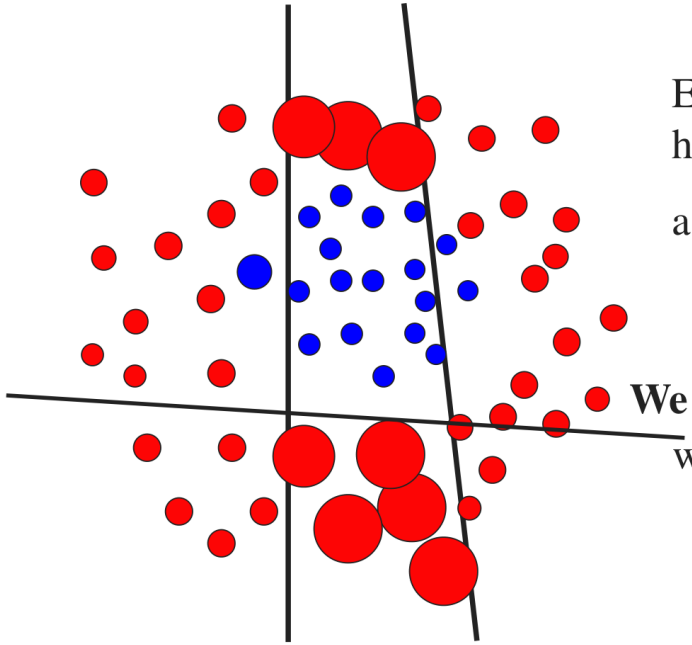
每个数据点具有类别标签，红点为 +1，蓝点为 −1。

更新样本权重，$w_t \leftarrow w_t \exp(-y_t H_t)$。

重新加权形成新的学习问题，使上一轮弱分类器在新权重下的表现与随机猜测相当。

圆点大小表示权重，图中的直线为逐轮选择的弱分类器。

Toy example 简化示例



Each data point has

a class label:

$$y_t = \begin{cases} +1 & (\bullet) \\ -1 & (\bullet) \end{cases}$$

We update the weights:

$w_t \leftarrow w_t \exp\{-y_t H_t\}$

We set a new problem for which the previous weak classifier performs at chance again

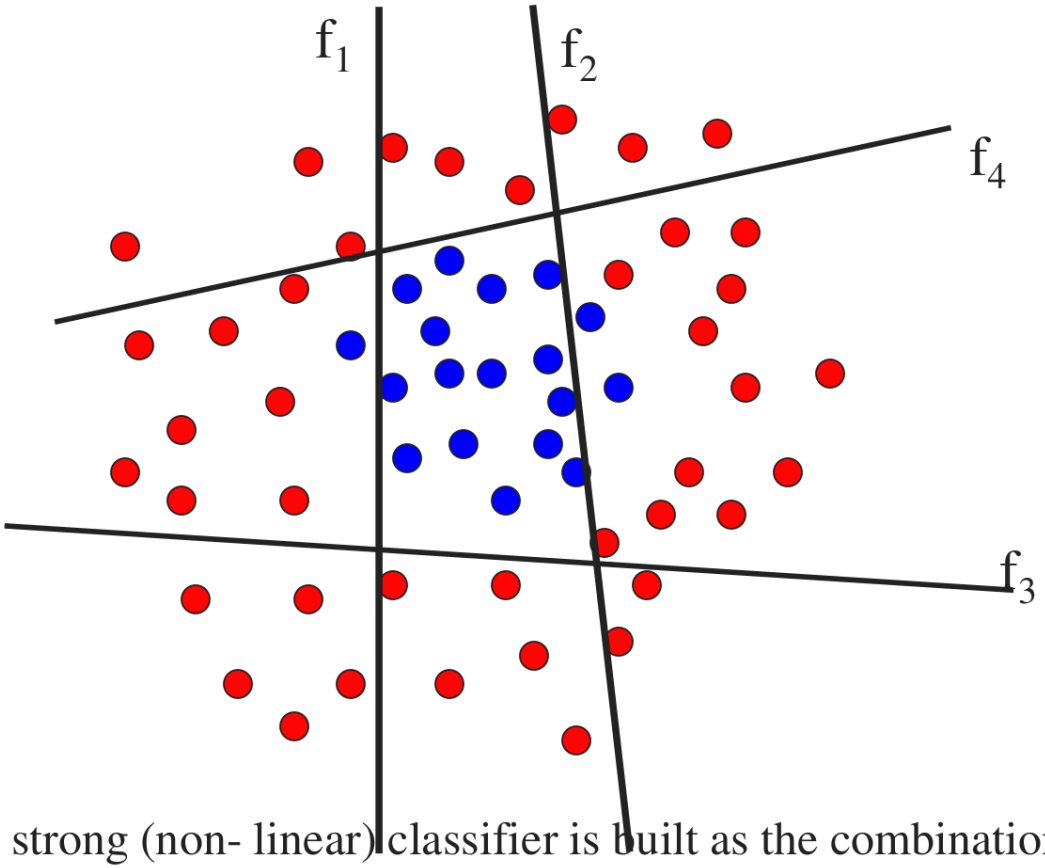
每个数据点具有类别标签，红点为 +1，蓝点为 −1。

更新样本权重，$w_t \leftarrow w_t \exp(-y_t H_t)$。

重新加权形成新的学习问题，使上一轮弱分类器在新权重下的表现与随机猜测相当。

圆点大小表示权重，图中的直线为逐轮选择的弱分类器。

Toy example 简化示例



将所有弱线性分类器 f_1、f_2、f_3、f_4 组合，得到强非线性分类器。

The strong (non- linear) classifier is built as the combination of all the weak (linear) classifiers.

Boosting vs. SVM　提升方法与支持向量机

- Advantages of boosting
  - Integrates classifier training with feature selection
  - Complexity of training is linear instead of quadratic in the number of training examples
  - Flexibility in the choice of weak learners, boosting scheme
  - Testing is fast
  - Easy to implement
- Disadvantages
  - Needs many training examples
  - Training is slow
  - Often doesn't work as well as SVM (especially for many-class problems)

提升方法的优势包括将分类器训练与特征选择结合，训练复杂度随样本数线性增长，可灵活选择弱学习器与提升方案，测试速度快且实现简便。

与之比较，课件给出的支持向量机训练复杂度随样本数呈二次增长。

提升方法的局限包括需要大量训练样本、训练较慢，表现往往逊于支持向量机，尤其在多类别问题中。

Boosting for face detection　提升方法的人脸检测

- Define weak learners based on rectangle features

value of rectangle feature

$$h_t(x) = \begin{cases} 1 & \text{if } p_t f_t(x) > p_t \theta_t \\ 0 & \text{otherwise} \end{cases}$$

window　parity　threshold

依据矩形特征定义弱学习器。

当 $p_t f_t(x) > p_t\theta_t$ 时，$h_t(x) = 1$，其余情况为 0。

x 为窗口，$f_t(x)$ 为矩形特征值，p_t 为极性，θ_t 为阈值。

Boosting for face detection　提升方法的人脸检测

- Define weak learners based on rectangle features
- For each round of boosting:
  - Evaluate each rectangle filter on each example
  - Select best filter/threshold combination based on weighted training error
  - Reweight examples

依据矩形特征定义弱学习器。

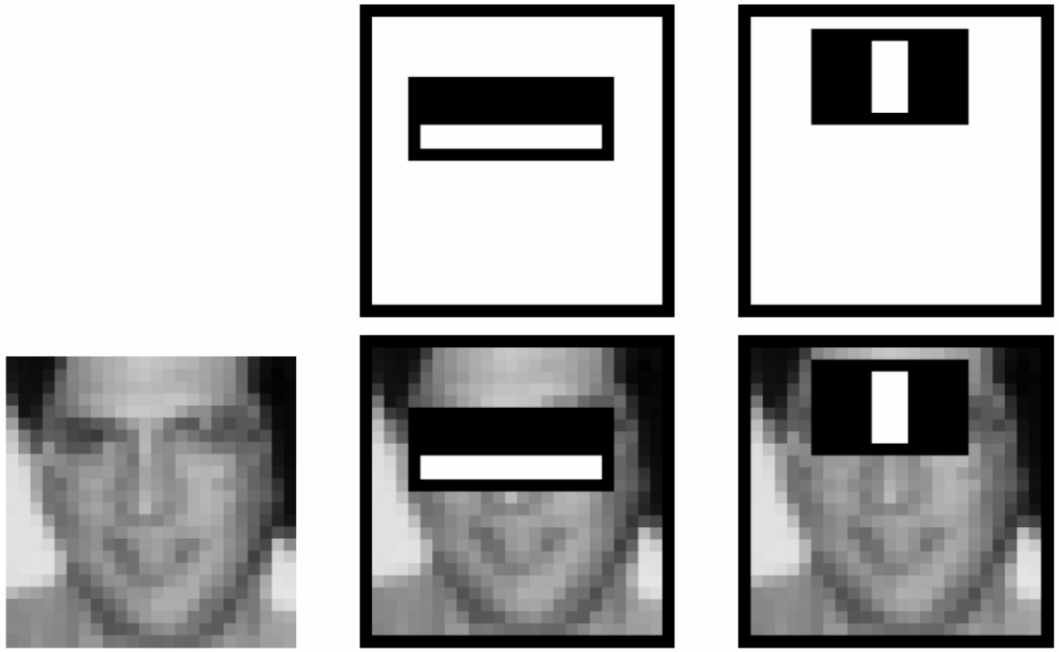
每轮对每个样本计算各矩形滤波器的响应。

依据加权训练误差，选择最佳滤波器与阈值组合。

更新样本权重。

Boosting for face detection　提升方法的人脸检测

- First two features selected by boosting:
-



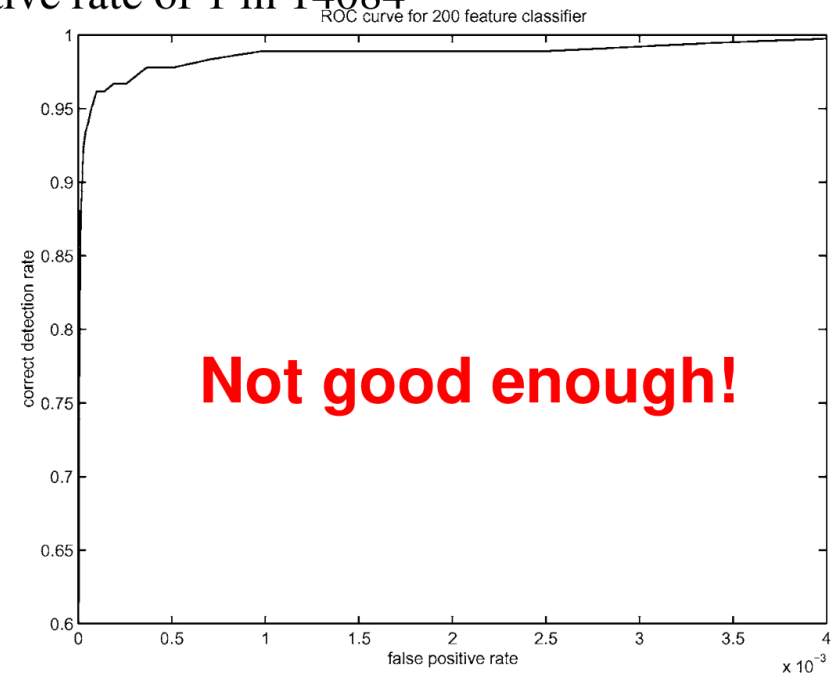
This feature combination can yield 100% detection rate and 50% false positive rate

图中为提升方法选出的前两个特征。

此特征组合可达到 100% 检测率与 50% 假阳性率。

Boosting for face detection　提升方法的人脸检测

- A 200-feature classifier can yield 95% detection rate and a false positive rate of 1 in 14084



Receiver operating characteristic (ROC) curve

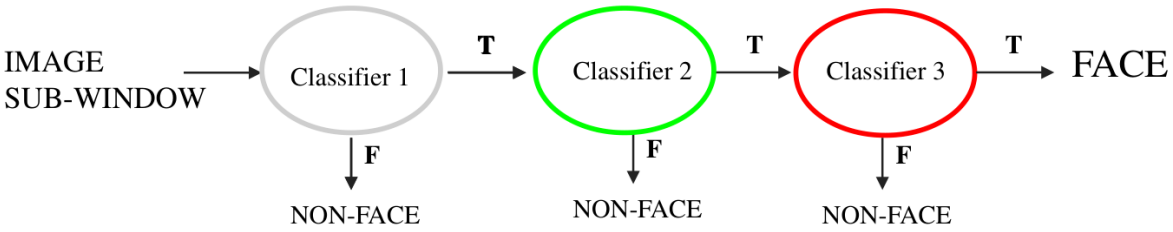
含 200 个特征的分类器可达到 95% 检测率，假阳性率为 1/14084。

该表现仍需改进。

图中为受试者工作特征 ROC 曲线，横轴是假阳性率，纵轴是检测率。

Attentional cascade 注意力级联

- We start with simple classifiers which reject many of the negative sub-windows while detecting almost all positive sub-windows
- Positive response from the first classifier triggers the evaluation of a second (more complex) classifier, and so on
- A negative outcome at any point leads to the immediate rejection of the sub-window



使用简单分类器排除大量负样本子窗口，同时检出几乎全部正样本子窗口。

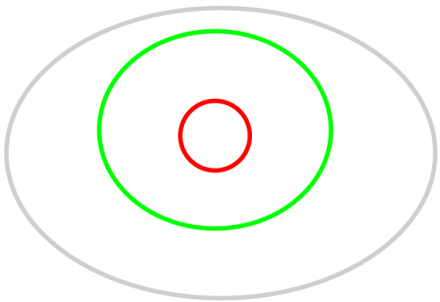
第一个分类器给出正响应后，触发第二个更复杂的分类器，后续依此类推。

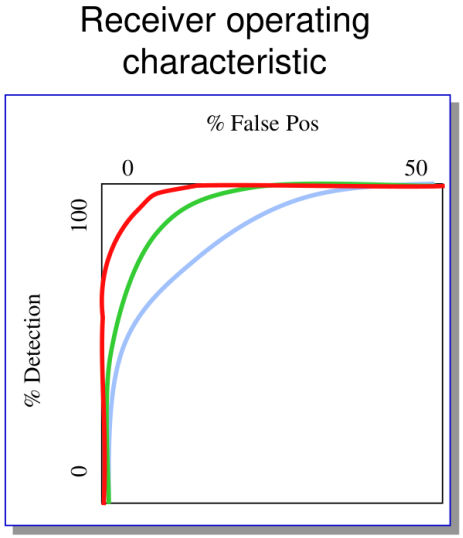
任意阶段给出负响应，即刻排除该子窗口。

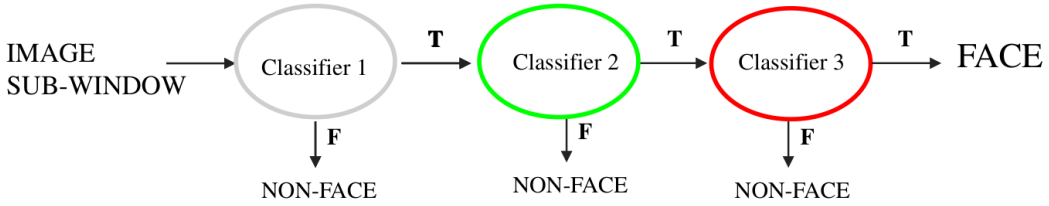
流程图中，图像子窗口依次进入分类器 1、2、3，T 为通过，F 为排除，最终输出人脸或非人脸。

Attentional cascade　注意力级联

- Chain classifiers that are progressively more complex and have lower false positive rates:







将逐渐复杂、假阳性率逐渐降低的分类器串联。

ROC 图中横轴为假阳性百分比，纵轴为检测百分比。阈值的选择控制检测率与假阳性率的权衡。

各阶段通过的窗口进入下一阶段，任一阶段失败即归为非人脸。

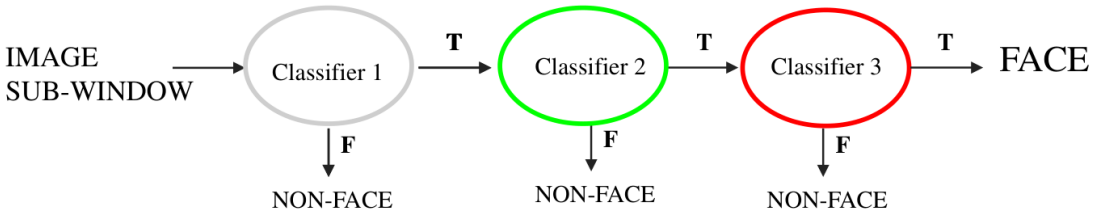
Attentional cascade　注意力级联

- The detection rate and the false positive rate of the cascade are found by multiplying the respective rates of the individual stages
- A detection rate of 0.9 and a false positive rate on the order of 10^{-6} can be achieved by a
  10-stage cascade if each stage has a detection rate of 0.99 ($0.99^{10} \approx 0.9$) and a false positive rate of about 0.30 ($0.3^{10} \approx 6 \times 10^{-6}$)

级联总体检测率等于各级检测率的乘积，总体假阳性率等于各级假阳性率的乘积。

若每级检测率为 0.99、假阳性率约为 0.30，10 级级联的检测率为 $0.99^{10} \approx 0.9$，假阳性率为 $0.3^{10} \approx 6 \times 10^{-6}$。

这可实现约 0.9 的检测率与 10^{-6} 量级的假阳性率。



Training the cascade 级联训练

- Set target detection and false positive rates for each stage
- Keep adding features to the current stage until its target rates have been met
  - Need to lower AdaBoost threshold to maximize detection (as opposed to minimizing total classification error)
  - Test on a *validation set*
- If the overall false positive rate is not low enough, then add another stage
- Use false positives from current stage as the negative training examples for the next stage

为每个阶段设定目标检测率与假阳性率。

持续向当前阶段添加特征，直至达到目标。

降低 AdaBoost 的判决阈值以提高检测率，训练目标侧重检出正样本，并在验证集上测试。

当总体假阳性率高于目标时，增加新阶段。

把当前阶段的假阳性作为下一阶段的负训练样本。

The implemented system 系统实现

- Training Data
  - 5000 faces
    - All frontal, rescaled to 24x24 pixels
  - 300 million non-faces
    - 9500 non-face images
  - Faces are normalized
    - Scale, translation
- Many variations
  - Across individuals
  - Illumination
  - Pose



训练数据包括 5000 个人脸，均为正面，缩放至 24×24 像素。

非人脸样本共 3 亿个，来自 9500 幅非人脸图像。

对人脸进行尺度与平移归一化。

数据覆盖人物个体、光照与姿态等变化。

System performance　系统性能

- Training time: “weeks” on 466 MHz Sun workstation
- 38 layers, total of 6061 features
- Average of 10 features evaluated per window on test set
- “On a 700 Mhz Pentium III processor, the face detector can process a 384 by 288 pixel image in about .067 seconds”

  15 Hz

  15 times faster than previous detector of comparable accuracy (Rowley et al., 1998)

在 466 MHz Sun 工作站上，训练耗时数周。

系统包含 38 层，共 6061 个特征。

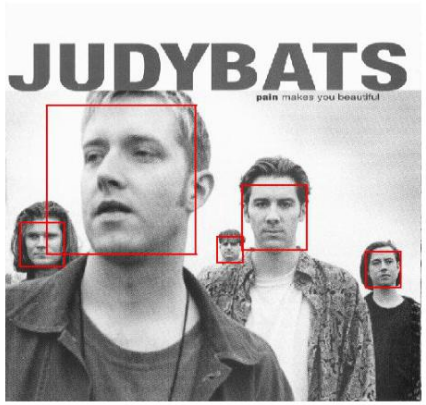
测试集上，每个窗口平均计算 10 个特征。

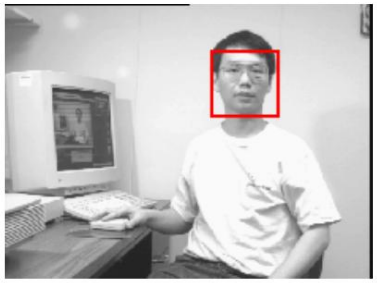
在 700 MHz Pentium III 处理器上，处理 384×288 像素图像约需 0.067 秒，即 15 Hz。

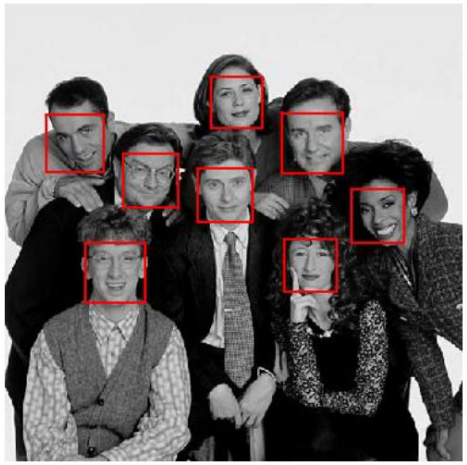
在相近分类性能下，速度为 Rowley 等（1998）检测器的 15 倍。

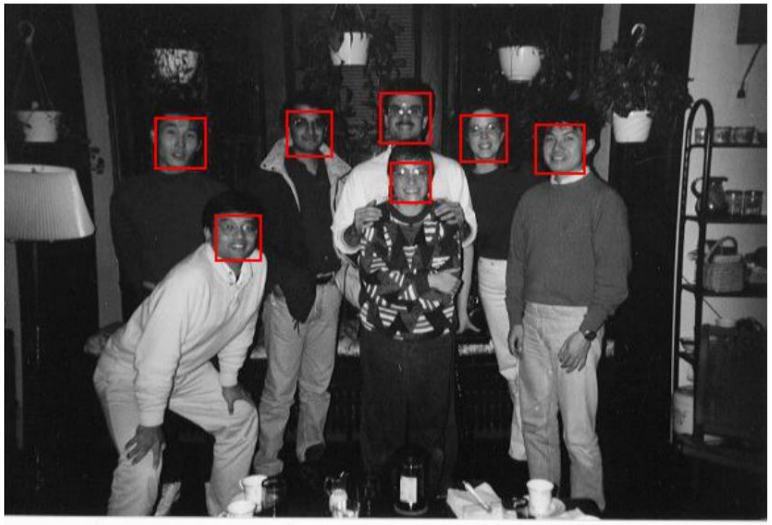
Output of Face Detector on Test Images 测试图像的人脸检测输出







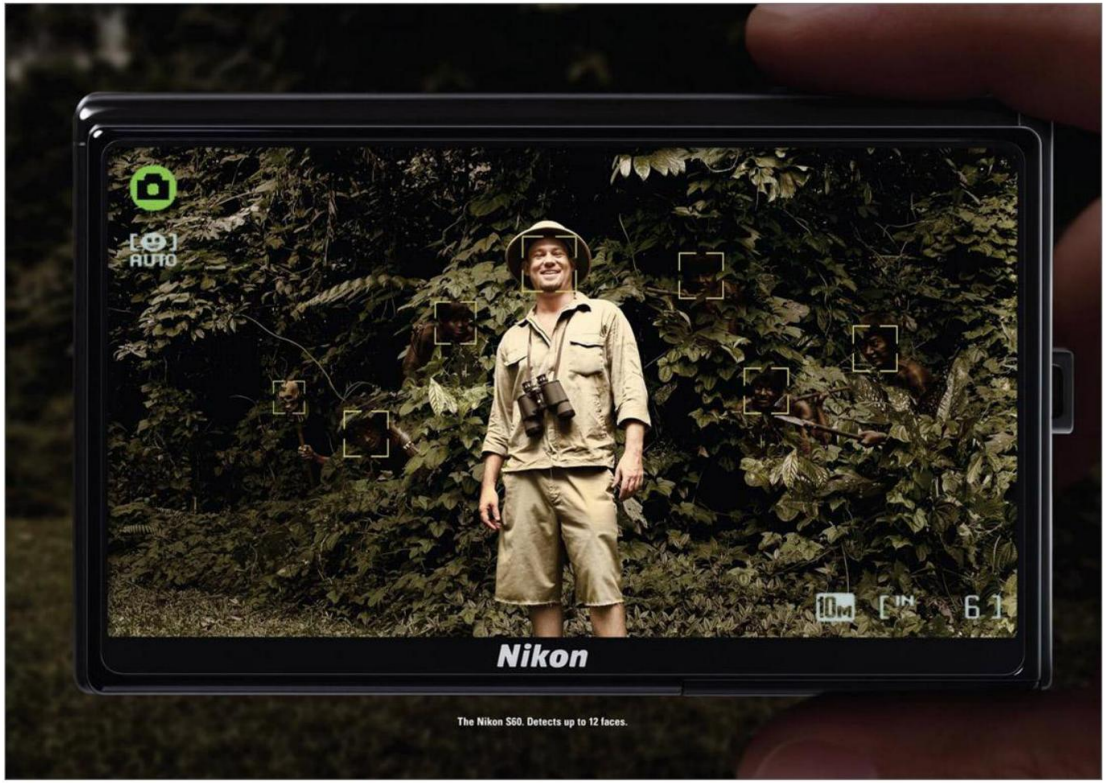




红色矩形框为人脸检测结果。

Funny Nikon ads　尼康广告示例

"The Nikon S60 detects up to 12 faces."



尼康 S60 最多可检测 12 张人脸。

来源 S. Lazebnik。

Slide: S. Lazebnik

Other detection tasks　其他检测任务

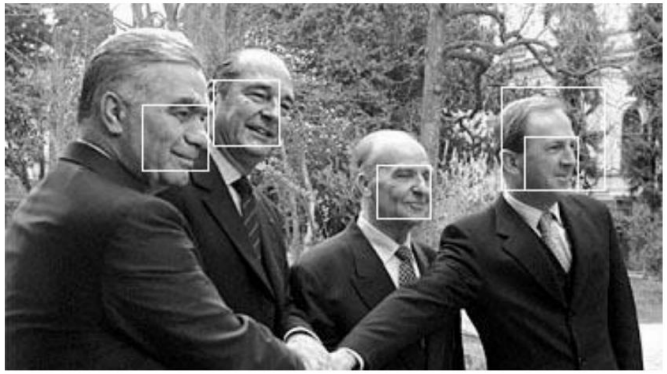
面部特征定位

男性与女性分类

侧脸检测

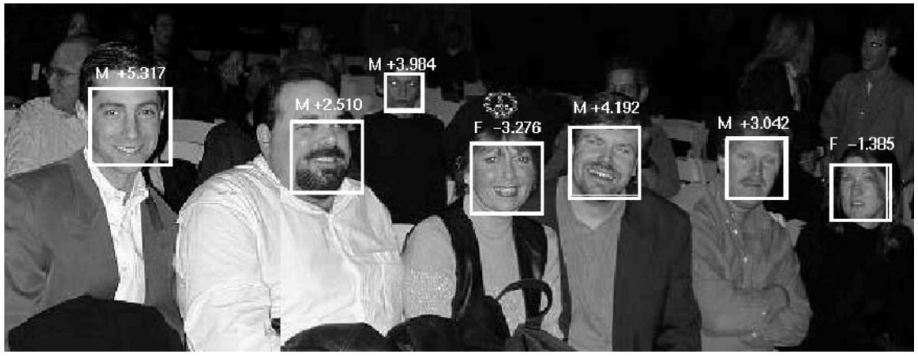


Facial Feature Localization



Profile Detection

Male vs. female

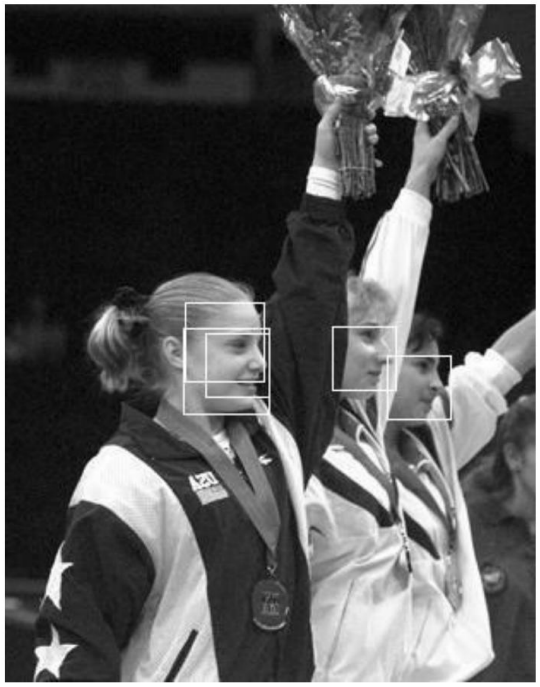


Profile Detection 侧脸检测

图中展示侧脸训练样本与检测结果。



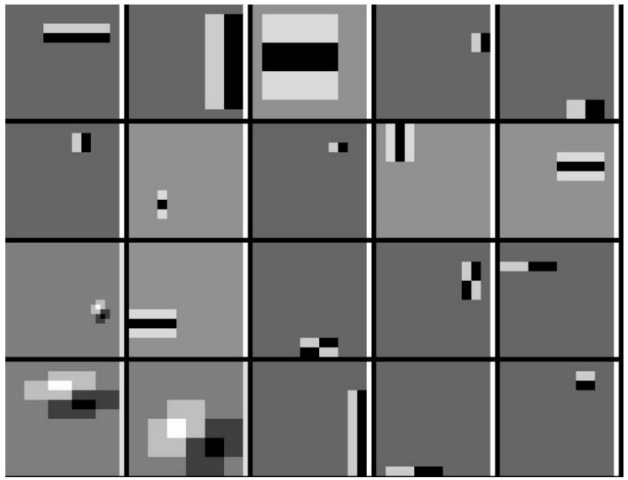




Profile Features　侧脸特征

左侧为侧脸样本，右侧为相应矩形特征示例。





Summary: Viola/Jones detector　Viola 与 Jones 检测器总结

- Rectangle features
- Integral images for fast computation
- Boosting for feature selection
- Attentional cascade for fast rejection of negative windows

矩形特征。

利用积分图快速计算。

利用提升方法选择特征。

利用注意力级联快速排除负样本窗口。

Overview 内容概览

- Specific Object Recognition
  - Lowe ‘04
  - Rothganger et al. ‘03
- Face Dectection
  - Sub-space methods
  - Neural Network-based approaches
  - Viola & Jones
- Face Recognition

特定物体识别，包括Lowe（2004）与Rothganger 等（2003）。

人脸检测，包括子空间方法、基于神经网络的方法及 Viola 与 Jones 方法。

人脸识别。

Subspace Methods　子空间方法

- PCA ("Eigenfaces", Turk and Pentland)
- PCA (Bayesian, Moghaddam and Pentland)
- LDA/FLD ("Fisherfaces", Belhumeur & Kreigman)
- ICA

主成分分析 PCA，特征脸方法，Turk 与 Pentland。

贝叶斯 PCA，Moghaddam 与 Pentland。

线性判别分析 LDA 或 Fisher 线性判别 FLD，Fisher 脸方法，Belhumeur 与 Kriegman。

独立成分分析 ICA。

Principal Component Analysis 主成分分析

- Given: N data points $x_1, \ldots, x_N$ in R^d
- We want to find a new set of features that are linear combinations of original ones:

$$u(x_i) = u^T(x_i - \mu)$$

$$\text{var}(x)=E(x-E(x))^2 = E(x^2) \text{ when } E(x)=0$$

(μ: mean of data points)

- What unit vector u in R^d captures the most variance of the data?

给定 R^d 中的 N 个数据点 $x_1,\ldots,x_n$。

寻找由原始特征线性组合形成的新特征，$u(x_i) = u^T(x_i-\mu)$，μ 为数据均值。

寻找能保留最多数据方差的单位向量 u。

方差 $\text{var}(x) = E[(x-E(x))^2]$。当 $E(x)=0$ 时，$\text{var}(x)=E(x^2)$。

Principal Component Analysis 主成分分析

- Direction that maximizes the variance of the projected data:

$$var(u) = \frac{1}{N}\sum_{i=1}^{N} \underbrace{\mathbf{u}^{\mathrm{T}}(\mathbf{x}_i-\mu)}_{\text{Projection of data point}}(\mathbf{u}^{\mathrm{T}}(\mathbf{x}_i-\mu))^{\mathrm{T}}$$

$$= \mathbf{u}^{\mathrm{T}}\underbrace{\left[\sum_{i=1}^{N}(\mathbf{x}_i-\mu)(\mathbf{x}_i-\mu)^{\mathrm{T}}\right]}_{\text{Covariance matrix of data}}\mathbf{u}$$

$$= \mathbf{u}^{\mathrm{T}}\Sigma\mathbf{u}$$

The direction that maximizes the variance is the eigenvector associated with the largest eigenvalue of Σ

求投影后数据方差最大的方向。

图中 $u^T(x_i-\mu)$ 为数据点的投影，Σ 为数据的协方差矩阵，投影方差为 $u^T\Sigma u$。

方差最大方向为 Σ 的最大特征值所对应的特征向量。

Eigenfaces: Key idea 特征脸思想

- Assume that most face images lie on a low-dimensional subspace determined by the first k ($k<d$) directions of maximum variance
- Use PCA to determine the vectors $\mathbf{u}_1,\ldots\mathbf{u}_k$ that span that subspace: $\mathbf{x} \approx \boldsymbol{\mu} + w_1\mathbf{u}_1 + w_2\mathbf{u}_2 + \ldots + w_k\mathbf{u}_k$
- Represent each face using its "face space" coordinates $(w_1,\ldots w_k)$
- Perform nearest-neighbor recognition in "face space"

M. Turk and A. Pentland, Face Recognition using Eigenfaces, CVPR 1991

假设多数人脸图像位于一个低维子空间，该子空间由前 k 个最大方差方向确定，k<d。

使用 PCA 求张成该子空间的向量 $u_1,\ldots,u_k$。

$x \approx \mu + w_1u_1 + w_2u_2 + \ldots + w_ku_k$。

以人脸空间坐标 $(w_1,\ldots,w_k)$ 表示每张人脸，并在人脸空间中进行最近邻识别。

M. Turk 与 A. Pentland，《利用特征脸进行人脸识别》，CVPR 1991。

Eigenfaces example　特征脸示例

- Training images
- $\mathbf{x}_1,\ldots,\mathbf{x}_N$



图中为训练图像
$x_1,\ldots,x_n$。

Eigenfaces example　特征脸示例

Mean: μ



Top eigenvectors:

$\mathbf{u}_1,\ldots\mathbf{u}_k$



左图为平均人脸 μ。

右图为最大的若干特征值对应的特征向量 $u_1,\ldots,u_k$。

Eigenfaces example　特征脸示例

人脸 x 在人脸空间中的坐标为
$[u_1^T(x-\mu),\ldots,u_k^T(x-\mu)] = (w_1,\ldots,w_k)$。

- Face **x** in "face space" coordinates:



$$\mathbf{x} \rightarrow [\mathbf{u}_1^{\mathrm{T}}(\mathbf{x}-\mu),\ldots,\mathbf{u}_k^{\mathrm{T}}(\mathbf{x}-\mu)]$$
$$= \quad w_1,\ldots,w_k$$

Eigenfaces example　特征脸示例

人脸 x 在人脸空间中的坐标为 $(w_1,\ldots, w_k)$，其中 $w_j = u_j^T(x-\mu)$。

重建人脸 $\hat{x} = \mu + w_1u_1 + w_2u_2 + w_3u_3 + w_4u_4 + \ldots$。

- Face **x** in "face space" coordinates:



$$\mathbf{x} \rightarrow [\mathbf{u}_1^{\mathrm{T}}(\mathbf{x}-\mu), \ldots, \mathbf{u}_k^{\mathrm{T}}(\mathbf{x}-\mu)]$$
$$= \quad w_1, \ldots, w_k$$

- Reconstruction:



$$\hat{\mathbf{x}} = \boldsymbol{\mu} + w_1\mathbf{u}_1 + w_2\mathbf{u}_2 + w_3\mathbf{u}_3 + w_4\mathbf{u}_4 + \ldots$$

Summary: Recognition with eigenfaces 特征脸识别流程

- Process labeled training images:
- Find mean $\boldsymbol{\mu}$ and covariance matrix $\boldsymbol{\Sigma}$
- Find k principal components (eigenvectors of $\boldsymbol{\Sigma}$) $\mathbf{u}_1,\ldots\mathbf{u}_k$
- Project each training image $\mathbf{x}_i$ onto subspace spanned by principal components:
  $(w_{i1},\ldots,w_{ik}) = (\mathbf{u}_1^T(\mathbf{x}_i - \boldsymbol{\mu}), \ldots, \mathbf{u}_k^T(\mathbf{x}_i - \boldsymbol{\mu}))$

- Given novel image $\mathbf{x}$:
- Project onto subspace:
  $(w_1,\ldots,w_k) = (\mathbf{u}_1^T(\mathbf{x} - \boldsymbol{\mu}), \ldots, \mathbf{u}_k^T(\mathbf{x} - \boldsymbol{\mu}))$
- **Optional: check reconstruction error $\hat{x} - x$ to determine whether image is really a face**
- Classify as closest training face in k-dimensional subspace

处理带标签的训练图像，计算均值 μ 与协方差矩阵 Σ，求前 k 个主成分 $u_1,\ldots,u_k$，即 Σ 的特征向量。

把每幅训练图像 x_i 投影到主成分张成的子空间，得到 $(w_{i1},\ldots,w_{ik}) = (u_1^T(x_i-\mu),\ldots,u_k^T(x_i-\mu))$。

对新图像 x，投影得到 $(w_1,\ldots,w_k) = (u_1^T(x-\mu),\ldots,u_k^T(x-\mu))$。

可选步骤，通过重建误差 $\hat{x}-x$ 检验图像是否为人脸。

在 k 维子空间中，按距离最近的训练人脸分类。

Limitations 方法局限

全局外观方法易受对齐偏差与背景变化影响。

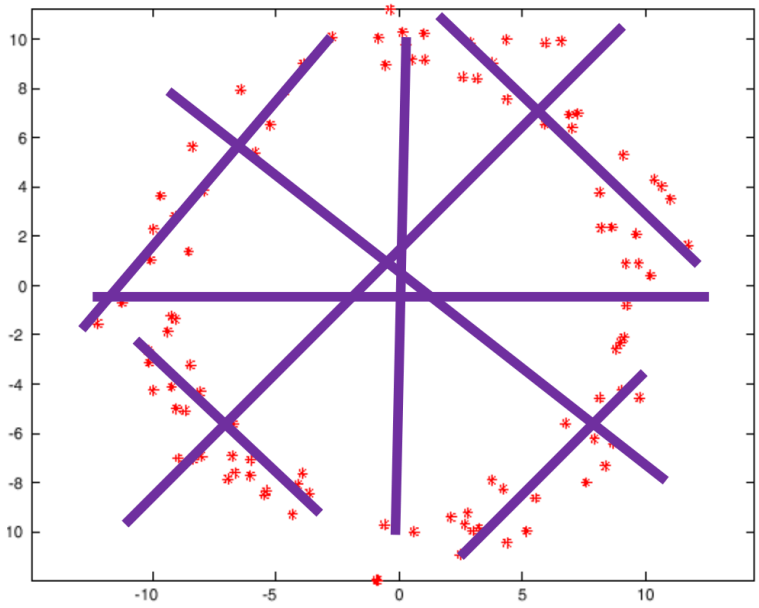
- Global appearance method: not robust to misalignment, background variation





Limitations 方法局限

- PCA assumes that the data has a Gaussian distribution (mean μ, covariance matrix Σ)



The shape of this dataset is not well described by its principal components

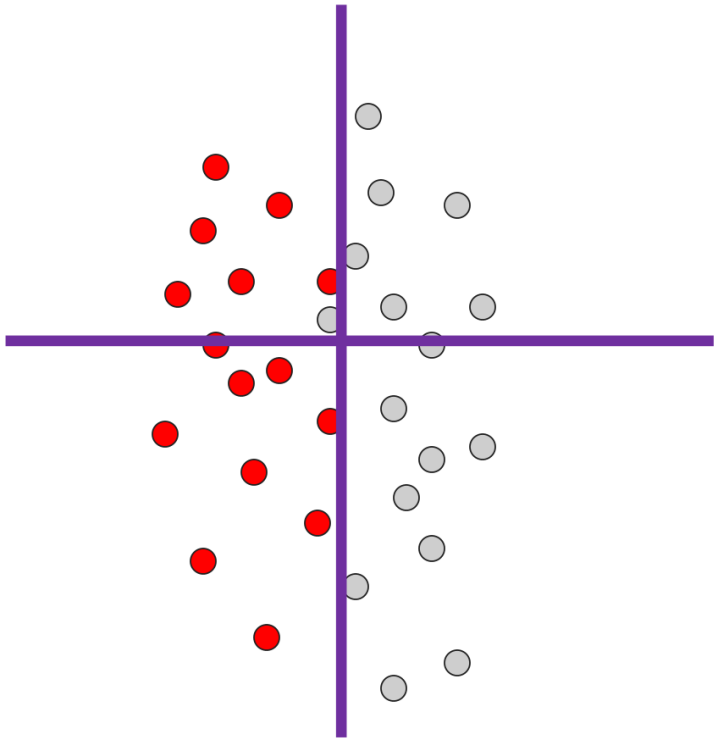
PCA 假设数据服从均值 μ、协方差矩阵 Σ 的高斯分布。

图中的数据集形状难以通过主成分充分描述。

Limitations 方法局限

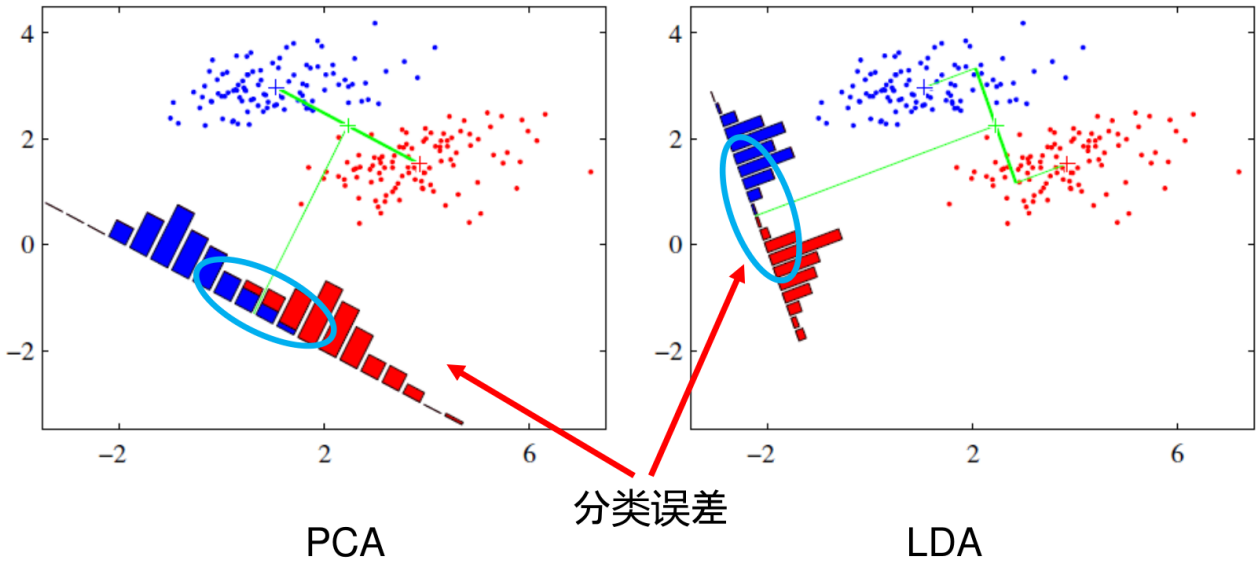
- The direction of maximum variance is not always good for classification

最大方差方向可能缺乏适合分类的判别能力。



Limitations 方法局限

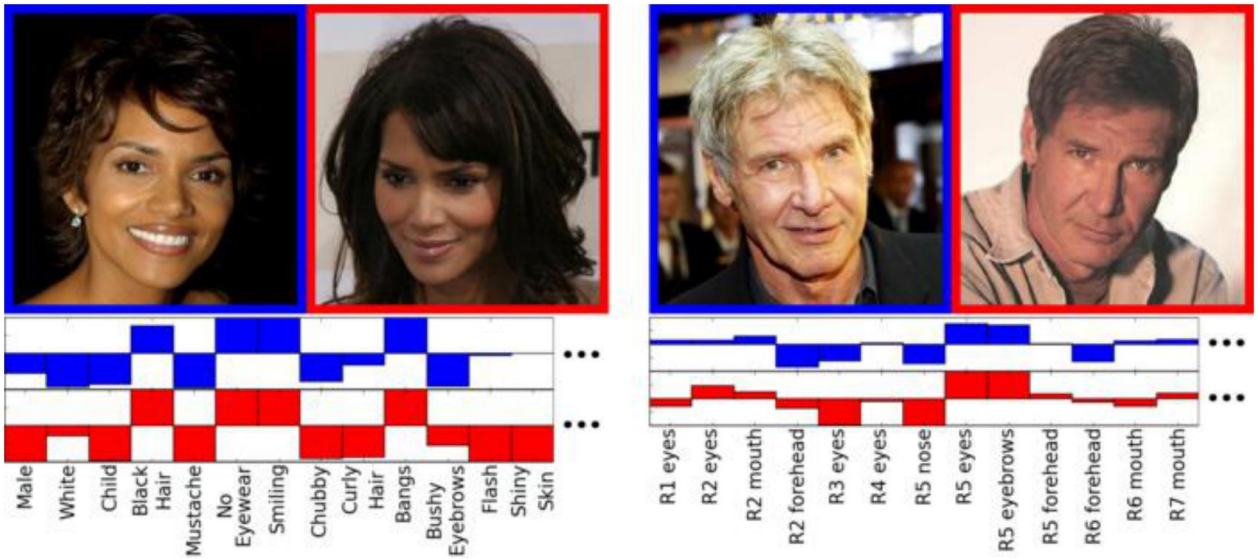
- The direction of maximum variance is not always good for classification



最大方差方向可能缺乏适合分类的判别能力。

图中比较主成分分析 PCA 与线性判别分析 LDA，并标示分类误差。

Face Recognition 人脸识别



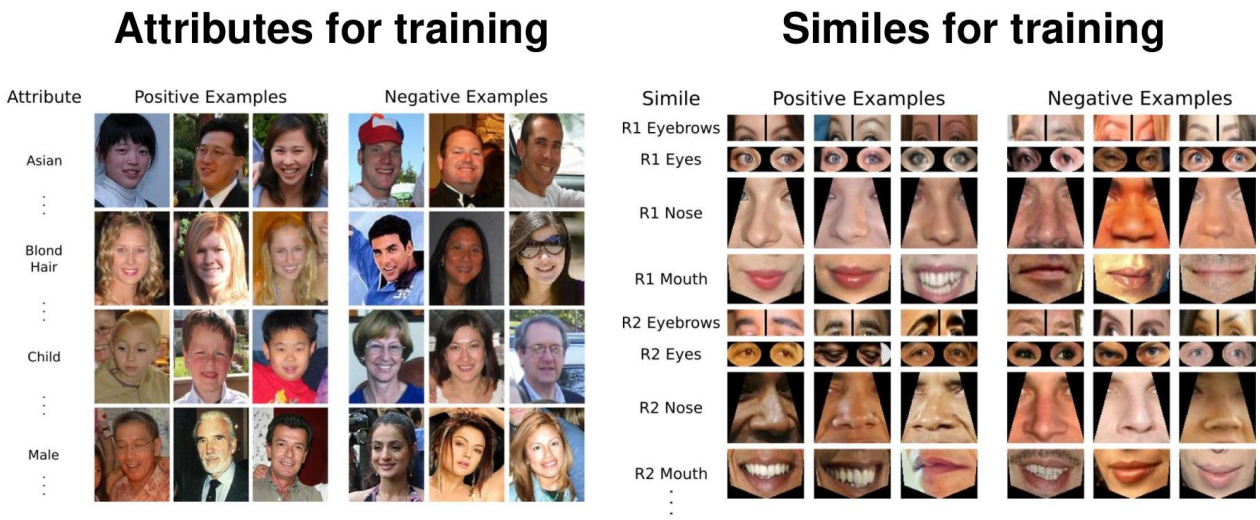
- N. Kumar, A. C. Berg, P. N. Belhumeur, and S. K. Nayar, "Attribute and Simile Classifiers for Face Verification," ICCV 2009.

N. Kumar、A. C. Berg、P. N. Belhumeur 与 S. K. Nayar，《用于人脸验证的属性分类器与相似性分类器》，ICCV 2009。

属性包括男性、白人、儿童、黑人、胡须、无眼镜、微笑、圆胖、卷发、刘海、浓眉、闪光与皮肤光泽。

相似性特征比较参考人物 R1、R2 等的眼、口、鼻、前额、眉毛等局部区域。

Face Recognition 人脸识别



- N. Kumar, A. C. Berg, P. N. Belhumeur, and S. K. Nayar, "Attribute and Simile Classifiers for Face Verification," ICCV 2009.

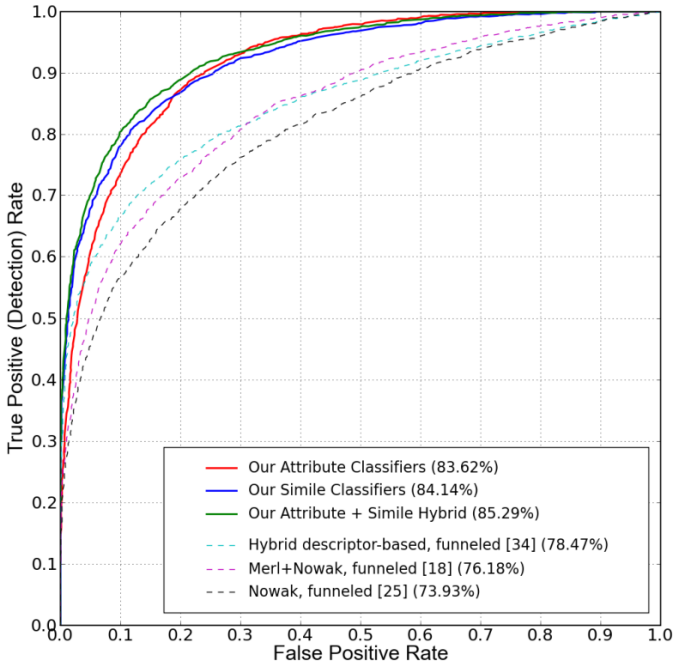
N. Kumar、A. C. Berg、P. N. Belhumeur 与 S. K. Nayar，《用于人脸验证的属性分类器与相似性分类器》，ICCV 2009。

左侧为训练用属性及其正负样本，属性示例包括亚洲人、金发、儿童与男性。

右侧为训练用相似性特征及其正负样本，比较参考人物 R1 与 R2 的眉毛、眼、鼻及嘴。

Face Recognition 人脸识别

Results on Labeled Faces in the Wild Dataset



- N. Kumar, A. C. Berg, P. N. Belhumeur, and S. K. Nayar, "Attribute and Simile Classifiers for Face Verification," ICCV 2009.

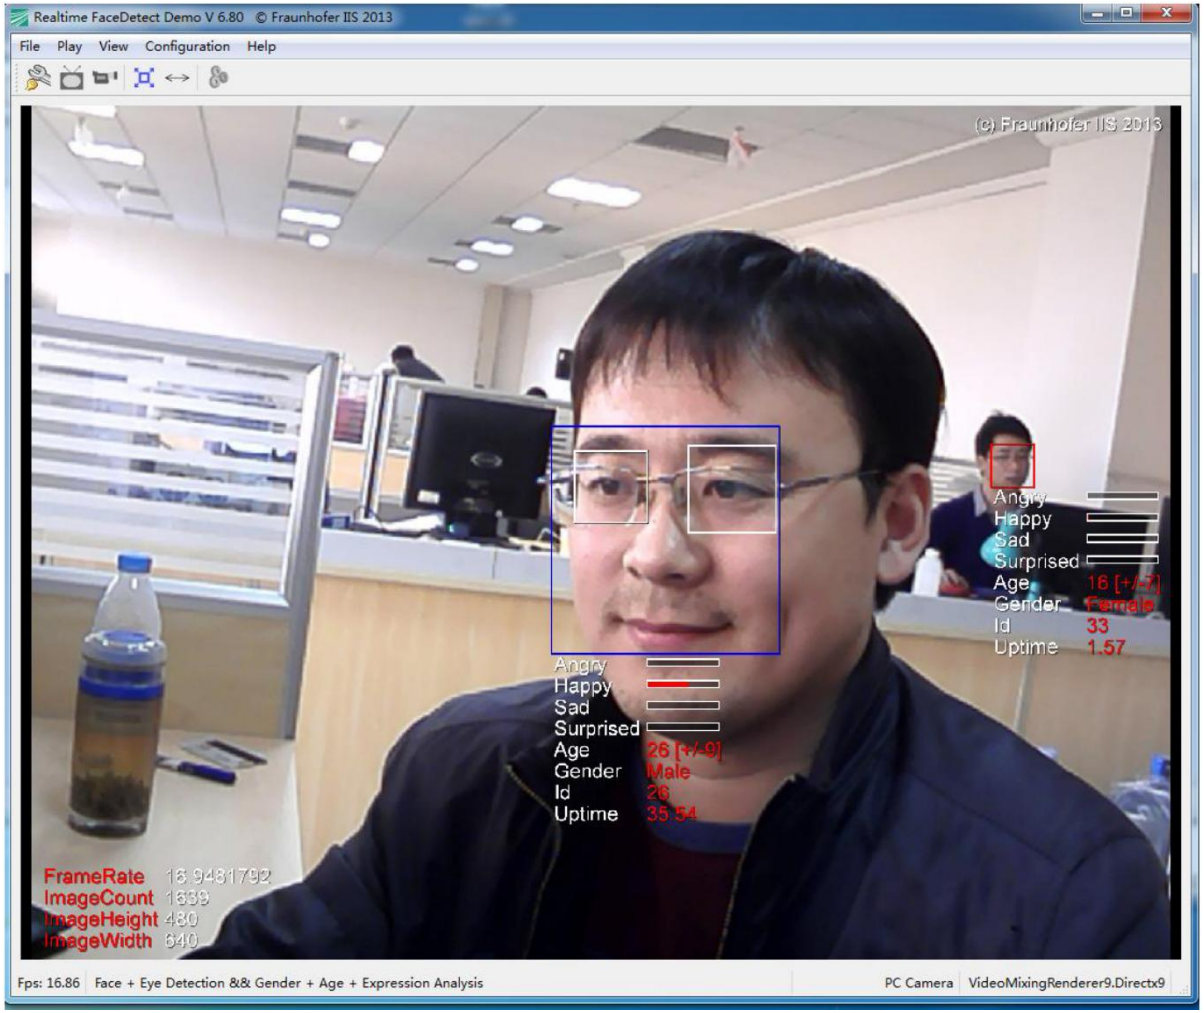
N. Kumar、A. C. Berg、P. N. Belhumeur 与 S. K. Nayar，《用于人脸验证的属性分类器与相似性分类器》，ICCV 2009。

图中为自然场景标注人脸数据集 LFW 的结果，横轴为假阳性率，纵轴为真阳性检测率。

属性分类器为 83.62%，相似性分类器为 84.14%，属性与相似性混合模型为 85.29%。

比较方法包括基于混合描述子的方法 78.47%、Merl 与 Nowak 方法 76.18%、Nowak 方法 73.93%，均采用经过对齐处理的数据。

Other tasks　其他任务



图中为实时人脸与眼部检测，以及性别、年龄和表情分析。

表情标签包含愤怒、开心、悲伤与惊讶。其他字段包括年龄、性别、身份编号与持续时间。

示例输出显示前景人物年龄 26（±9）、男性、编号 26、持续 35.54 秒，背景人物年龄 16（±7）、女性、编号 33、持续 1.57 秒。

运行信息显示帧率约 16.95，图像数 1639，图像尺寸 640×480。

The end！　课程结束

The end !