Computer Vision 计算机视觉

Computer Vision —— Object Recognition

物体识别

桑农

2026 年 9 月 29 日

课件参考 R. Fergus、S. Savarese、S. Lazebnik、D. Lowe 与 P. Viola 的计算机视觉课程资料。

2026/9/29

桑 农

Slides from CV course with R. Fergus, and S. Savarese, S. Lazebnik, D. Lowe, P. Viola

Agenda 课程目录

概述
物体与人脸识别
词袋模型
基于部件的模型

Agenda

- Introduction
- Objects & Faces recognition
- Bag-of-words models
- Part-based models

Bag-of-Words models 词袋模型

来源 S. Lazebnik、A. Torralba、L. Fei-Fei、D. Lowe 与 C. Szurka。

Slides from: S. Lazebnik, A. Torralba, L. Fei-Fei, D. Lowe, C. Szurka

Bag-of-features models　特征袋模型

图像以局部特征的集合表示。





Overview: Bag-of-features models 特征袋模型概览

- Origins and motivation
- Image representation
- Discriminative methods
  - Nearest-neighbor classification
  - Support vector machines
- Generative methods
  - Naïve Bayes
  - Probabilistic Latent Semantic Analysis
- Extensions: incorporating spatial information

起源与动机。

图像表示。

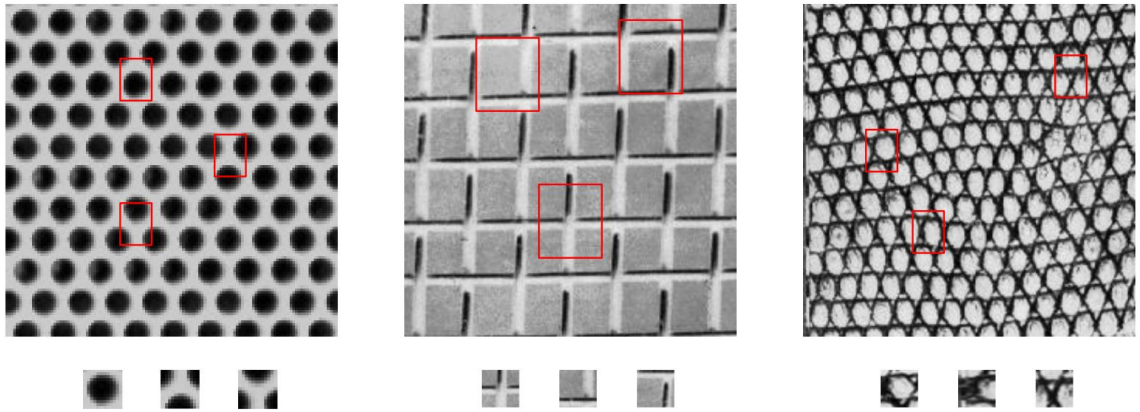
判别方法，包括最近邻分类与支持向量机。

生成方法，包括朴素贝叶斯与概率潜在语义分析。

扩展方法，引入空间信息。

Origin 1: Texture recognition　起源一 纹理识别

- Texture is characterized by the repetition of basic elements or *textons*
- For stochastic textures, it is the identity of the textons, not their spatial arrangement, that matters



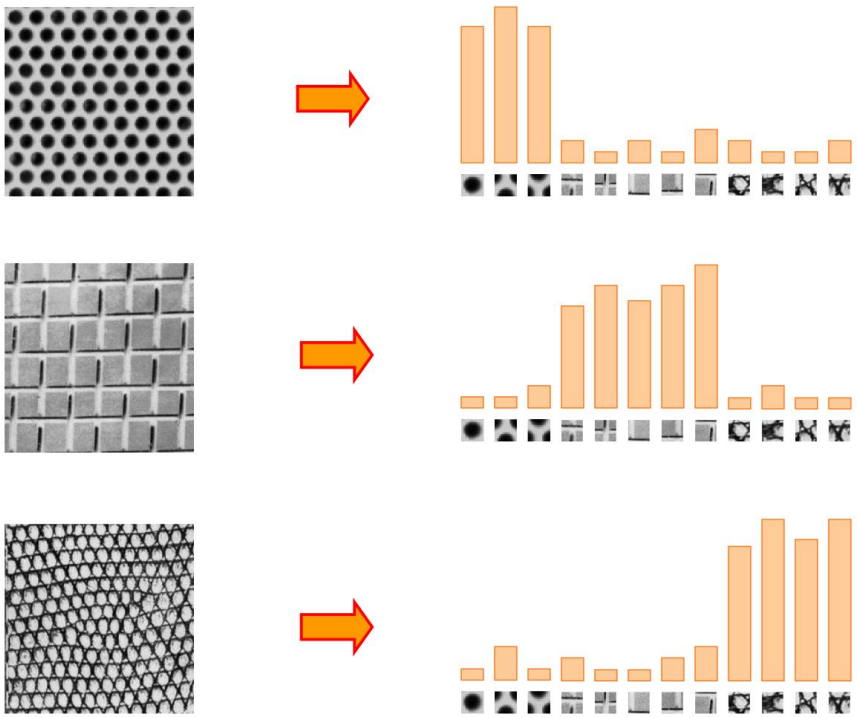
Julesz, 1981; Cula & Dana, 2001; Leung & Malik 2001; Mori, Belongie & Malik, 2001; Schmid 2001; Varma & Zisserman, 2002, 2003; Lazebnik, Schmid & Ponce, 2003

纹理以基本元素或纹理基元的重复为特征。

对于随机纹理，纹理基元的种类决定纹理特性，空间排列的作用较弱。

相关研究包括 Julesz（1981）、Cula 与 Dana（2001）、Leung 与 Malik（2001）、Mori、Belongie 与 Malik（2001）、Schmid（2001）、Varma 与 Zisserman（2002、2003）及 Lazebnik、Schmid 与 Ponce（2003）。

Origin 1: Texture recognition　起源一 纹理识别



使用通用纹理基元字典，将纹理表示为各类纹理基元的直方图。

相关研究与上一页相同。

Julesz, 1981; Cula & Dana, 2001; Leung & Malik 2001; Mori, Belongie & Malik, 2001; Schmid 2001; Varma & Zisserman, 2002, 2003; Lazebnik, Schmid & Ponce, 2003

Origin 2: Bag-of-words models　起源二 词袋模型

忽略词序的文档表示，
统计字典中各词的频率。

Salton 与 McGill
（1983）。

- Orderless document representation: frequencies of words from a dictionary Salton & McGill (1983)

Origin 2: Bag-of-words models　起源二 词袋模型

- Orderless document representation: frequencies of words from a dictionary Salton & McGill (1983)



忽略词序的文档表示，统计字典中各词的频率。Salton 与 McGill（1983）。

图中为美国总统演讲词云，字号体现词频。

2007 年 1 月 23 日，乔治 W 布什的国情咨文，显著词包括伊拉克、恐怖分子、基地组织与经济。

Origin 2: Bag-of-words models　起源二 词袋模型

- Orderless document representation: frequencies of words from a dictionary Salton & McGill (1983)



忽略词序的文档表示，统计字典中各词的频率。Salton 与 McGill（1983）。

图中为美国总统演讲词云，字号体现词频。

2007 年 1 月 23 日，乔治 W 布什的国情咨文，显著词包括伊拉克、恐怖分子、基地组织与经济。

1962 年 10 月 22 日，约翰 F 肯尼迪关于古巴的苏联导弹的演讲，显著词包括苏联、古巴、导弹、核与武器。

Origin 2: Bag-of-words models　起源二 词袋模型

- Orderless document representation: frequencies of words from a dictionary Salton & McGill (1983)



忽略词序的文档表示，统计字典中各词的频率。Salton 与 McGill（1983）。

图中为美国总统演讲词云，字号体现词频。

2007 年 1 月 23 日，乔治 W 布什的国情咨文，显著词包括伊拉克、恐怖分子、基地组织与经济。

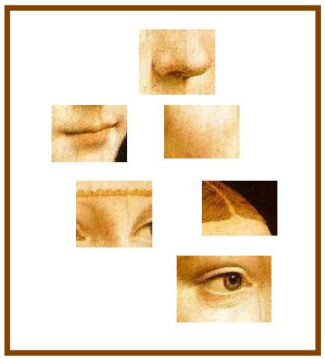
1962 年 10 月 22 日，约翰 F 肯尼迪关于古巴的苏联导弹的演讲，显著词包括苏联、古巴、导弹、核与武器。

1941 年 12 月 8 日，富兰克林 D 罗斯福的宣战请求演讲，显著词包括日本、战争与太平洋。

Bags of features for image classification 图像分类的特征袋表示

1. 提取特征。

1. Extract features







Bags of features for image classification 图像分类的特征袋表示

1. 提取特征
2. 学习视觉词汇表

1. Extract features
2. Learn “visual vocabulary”



Bags of features for image classification 图像分类的特征袋表示

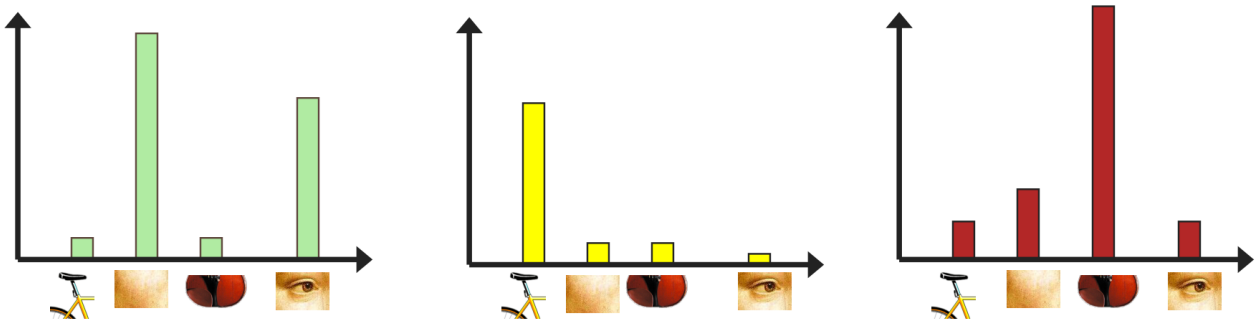
1. 提取特征
2. 学习视觉词汇表
3. 利用视觉词汇表量化特征

1. Extract features
2. Learn “visual vocabulary”
3. Quantize features using visual vocabulary

Bags of features for image classification 图像分类的特征袋表示

1. Extract features
2. Learn “visual vocabulary”
3. Quantize features using visual vocabulary
4. Represent images by frequencies of “visual words”

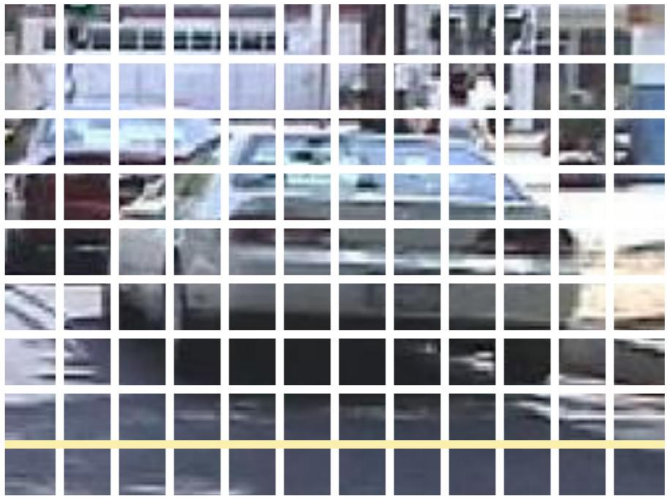
1. 提取特征
2. 学习视觉词汇表
3. 利用视觉词汇表量化特征
4. 用视觉词频表示图像



1. Feature extraction　特征提取

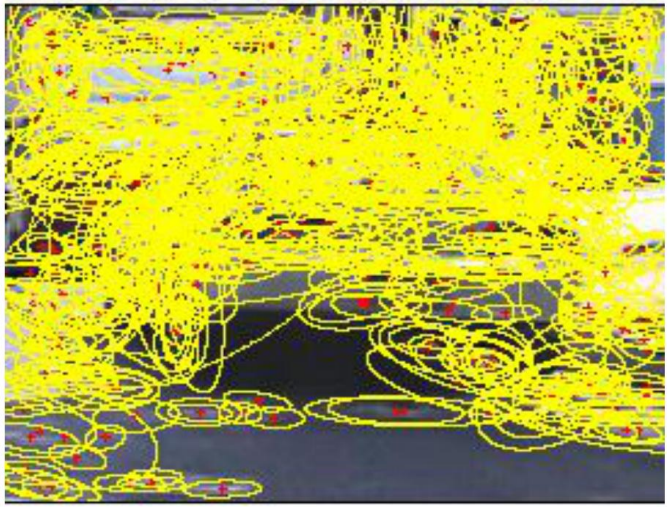
规则网格，Vogel 与 Schiele（2003）、Fei-Fei 与 Perona（2005）。

- Regular grid
  - Vogel & Schiele, 2003
  - Fei-Fei & Perona, 2005



1. Feature extraction　特征提取

- Regular grid
  - Vogel & Schiele, 2003
  - Fei-Fei & Perona, 2005
- Interest point detector
  - Csurka et al. 2004
  - Fei-Fei & Perona, 2005
  - Sivic et al. 2005



规则网格，Vogel 与 Schiele（2003）、Fei-Fei 与 Perona（2005）。

特征点检测器，Csurka 等（2004）、Fei-Fei 与 Perona（2005）、Sivic 等（2005）。

1. Feature extraction　特征提取

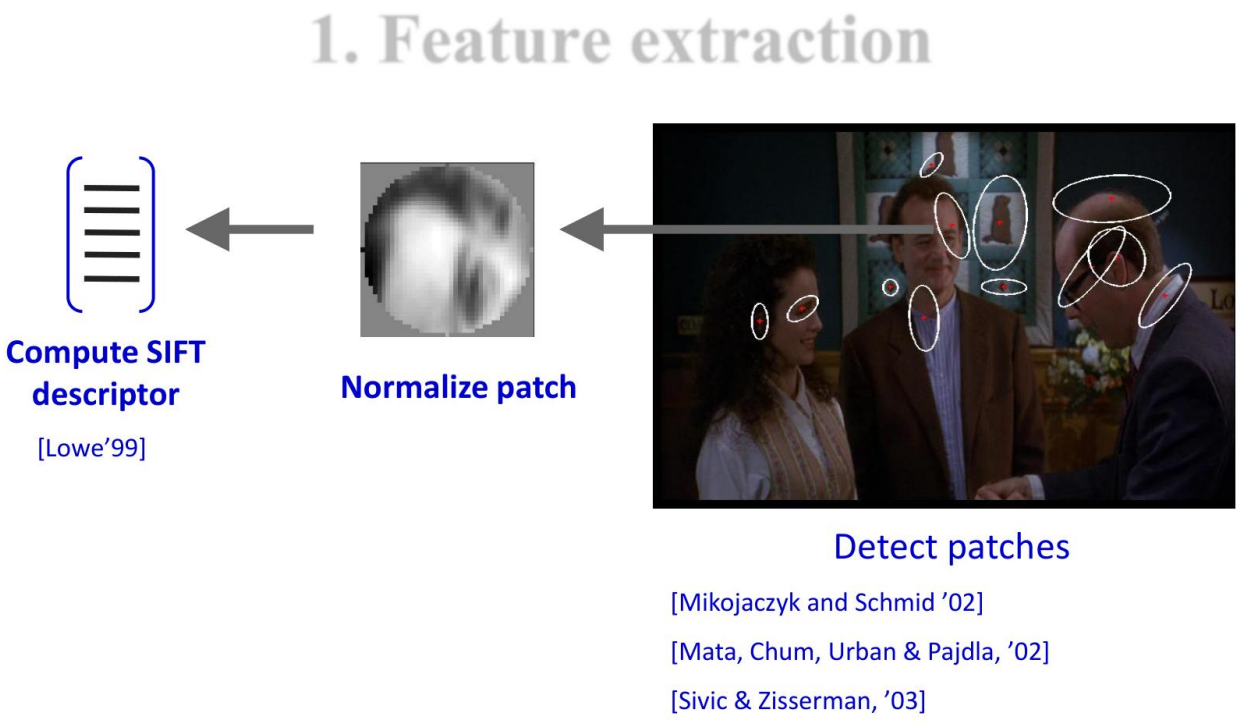
- Regular grid
  - Vogel & Schiele, 2003
  - Fei-Fei & Perona, 2005
- Interest point detector
  - Csurka et al. 2004
  - Fei-Fei & Perona, 2005
  - Sivic et al. 2005
- Other methods
  - Random sampling (Vidal-Naquet & Ullman, 2002)
  - Segmentation-based patches (Barnard et al. 2003)

规则网格，Vogel 与 Schiele（2003）、Fei-Fei 与 Perona（2005）。

特征点检测器，Csurka 等（2004）、Fei-Fei 与 Perona（2005）、Sivic 等（2005）。

其他方法包括随机采样（Vidal-Naquet 与 Ullman，2002），以及基于分割的图像块（Barnard 等，2003）。

1. Feature extraction　特征提取



检测图像块，相关方法来自 Mikolajczyk 与 Schmid（2002）、Matas、Chum、Urban 与 Pajdla（2002）、Sivic 与 Zisserman（2003）。

对图像块归一化。

计算 SIFT 描述子（Lowe，1999）。

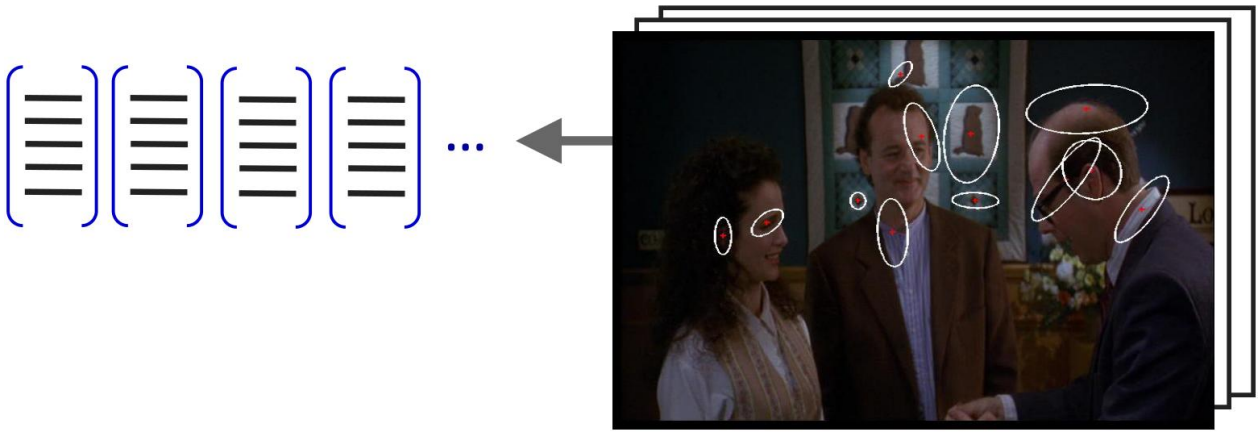
来源 Josef Sivic。

Slide credit: Josef Sivic

1. Feature extraction　特征提取

对多幅图像提取局部图像块，并计算描述子。

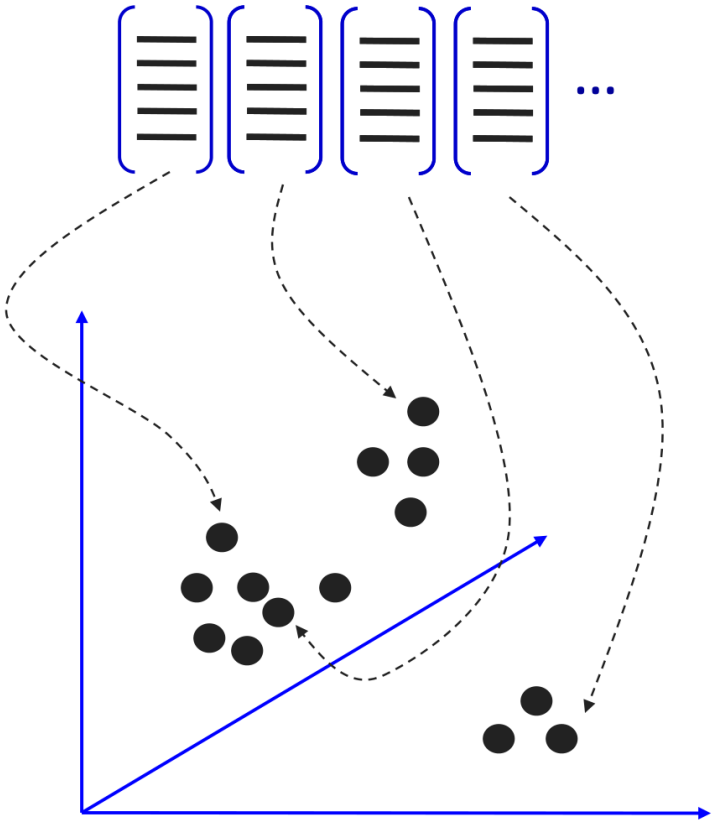
1. Feature extraction

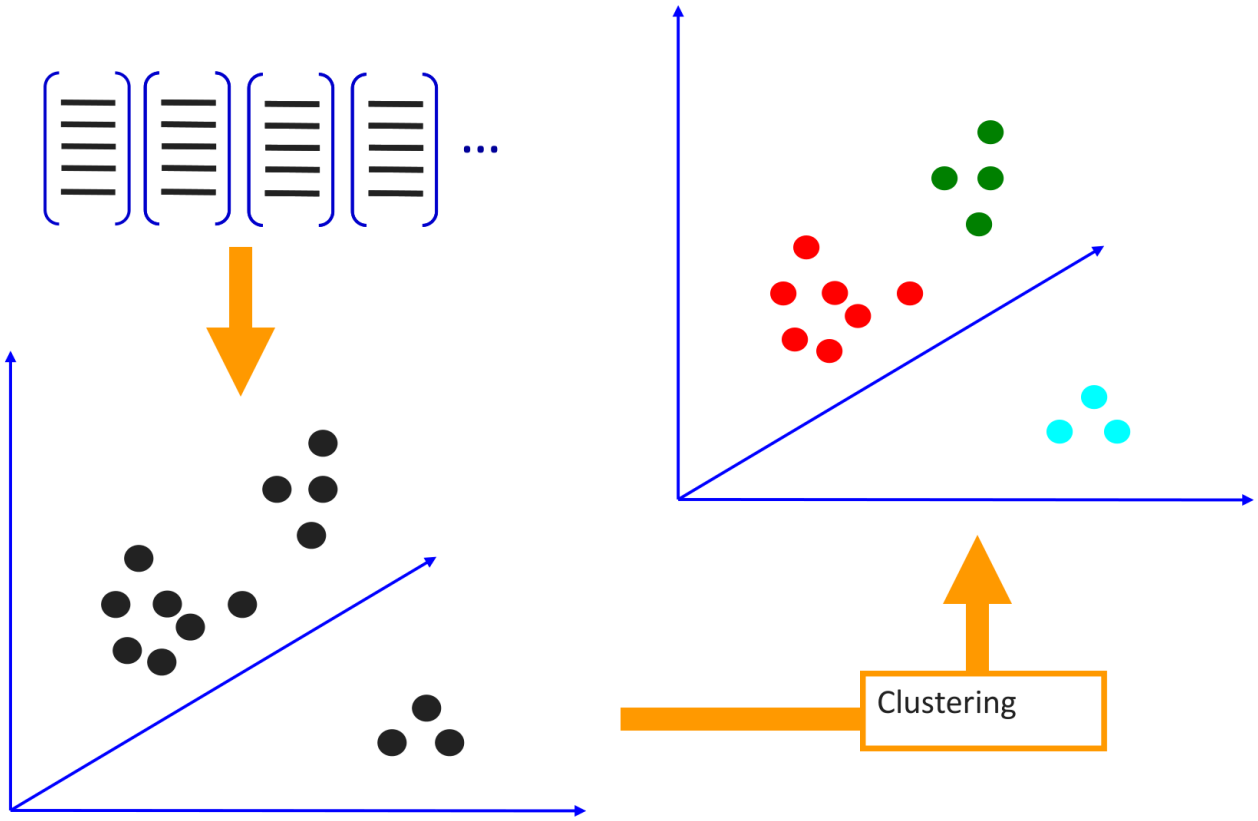


2. Learning the visual vocabulary　视觉词汇表学习

2. Learning the visual vocabulary

把训练图像的局部描述子汇集到特征空间。



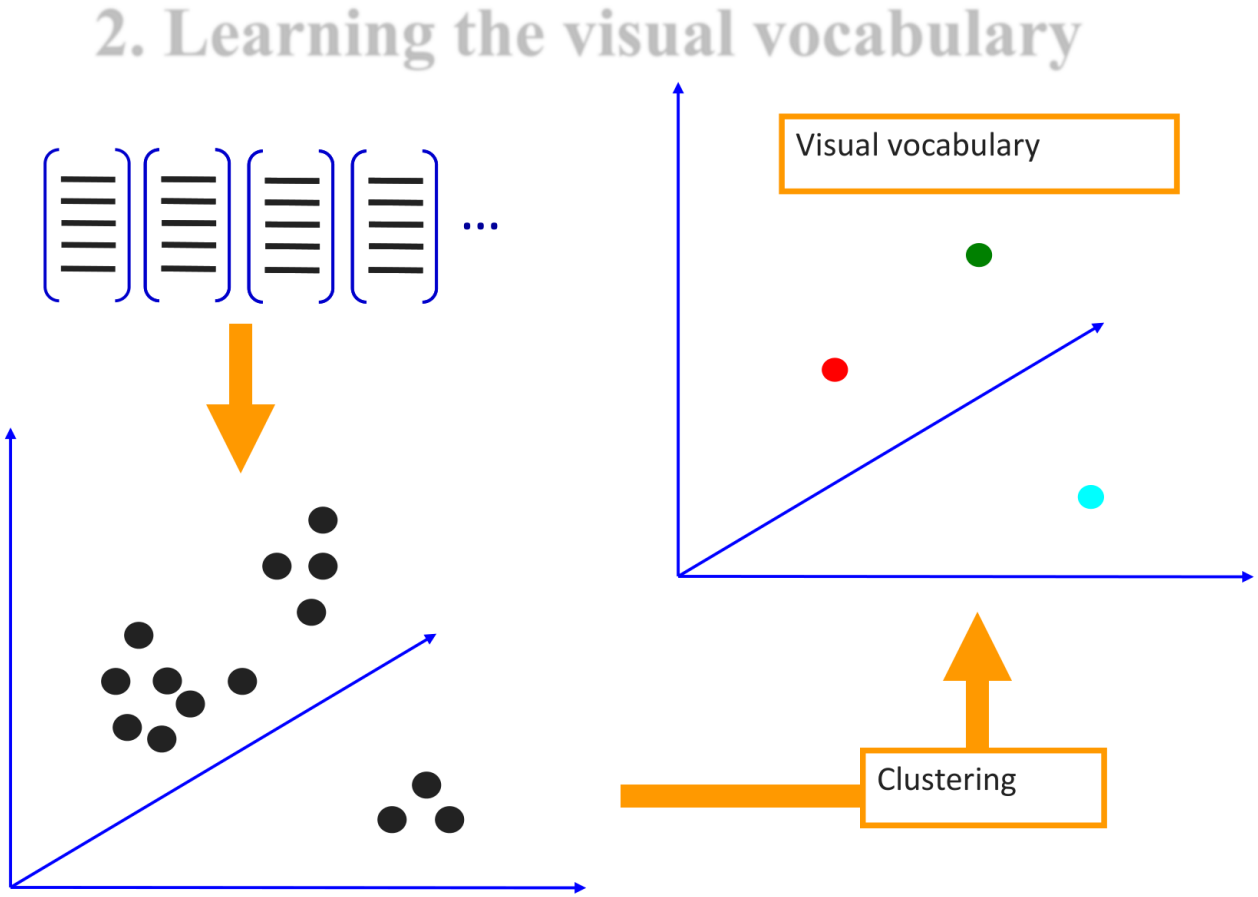


对特征空间中的描述子聚类。

来源 Josef Sivic。

Slide credit: Josef Sivic

2. Learning the visual vocabulary 视觉词汇表学习



通过聚类获得视觉词汇表，每个簇的代表点构成一个视觉词。

来源 Josef Sivic。

Slide credit: Josef Sivic

K-means clustering　K 均值聚类

- Want to minimize sum of squared Euclidean distances between points x_i and their nearest cluster centers m_k

$$D(X,M)=\sum_{\text{cluster } k}\ \sum_{\substack{\text{point } i \text{ in}\\ \text{cluster } k}}(x_i-m_k)^2$$

- Algorithm:
- 1. Randomly initialize K cluster centers
- 2. Iterate until convergence:

  Assign each data point to the nearest center

  Recompute each cluster center as the mean of all points assigned to it

目标是最小化数据点 x_i 到其最近簇中心 m_k 的欧氏距离平方和。

1. 随机初始化 K 个簇中心。

2. 迭代至收敛。把各数据点分配给最近中心，并将每个簇中心更新为该簇所有数据点的均值。

From clustering to vector quantization 聚类与向量量化

- Clustering is a common method for learning a visual vocabulary or codebook
  - Unsupervised learning process
  - Each cluster center produced by k-means becomes a codevector
  - Codebook can be learned on separate training set
  - Provided the training set is sufficiently representative, the codebook will be "universal"
- The codebook is used for quantizing features
  - A *vector quantizer* takes a feature vector and maps it to the index of the nearest codevector in a codebook
  - Codebook = visual vocabulary
  - Codevector = visual word

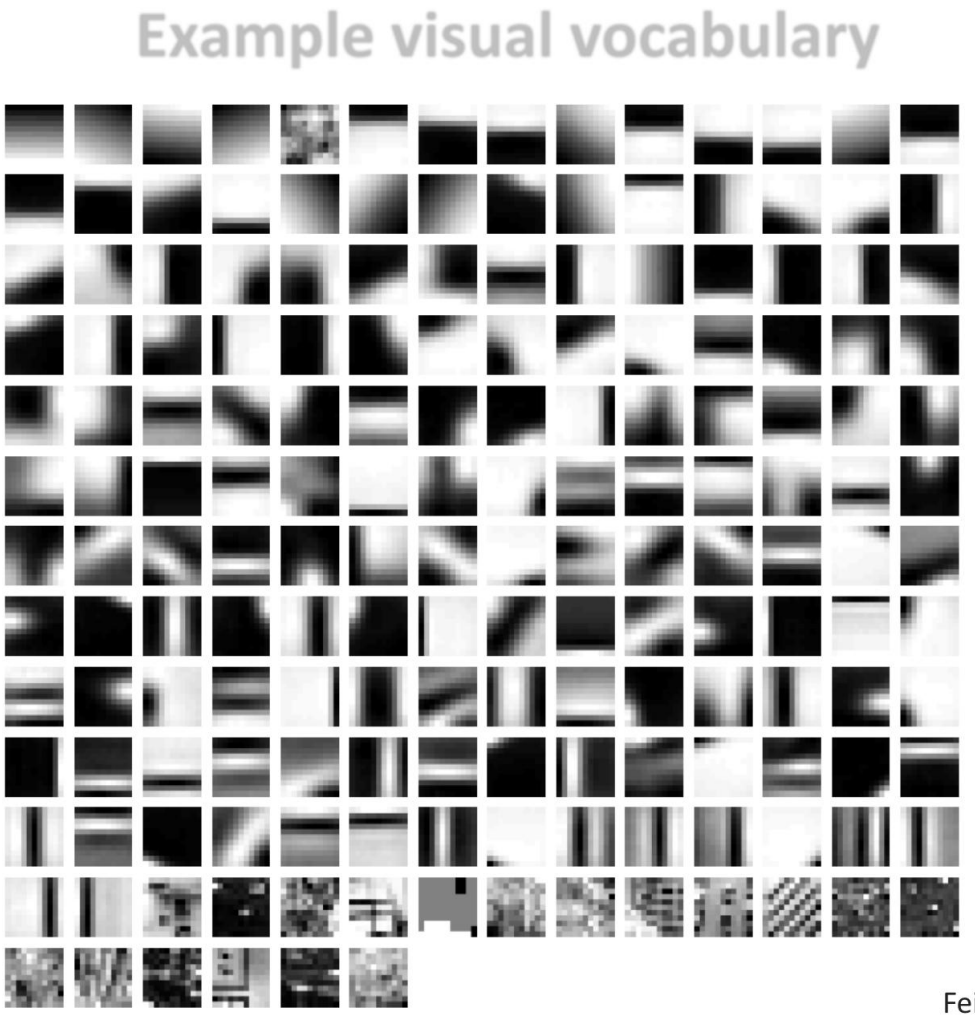
聚类是学习视觉词汇表或码本的常用方法，属于无监督学习。

K 均值产生的每个簇中心成为一个码向量。码本可用独立训练集学习。训练集具备足够代表性时，码本可具有通用性。

码本用于特征量化。向量量化器把特征向量映射为最近码向量的索引。

码本对应视觉词汇表，码向量对应视觉词。

Example visual vocabulary 视觉词汇表示例

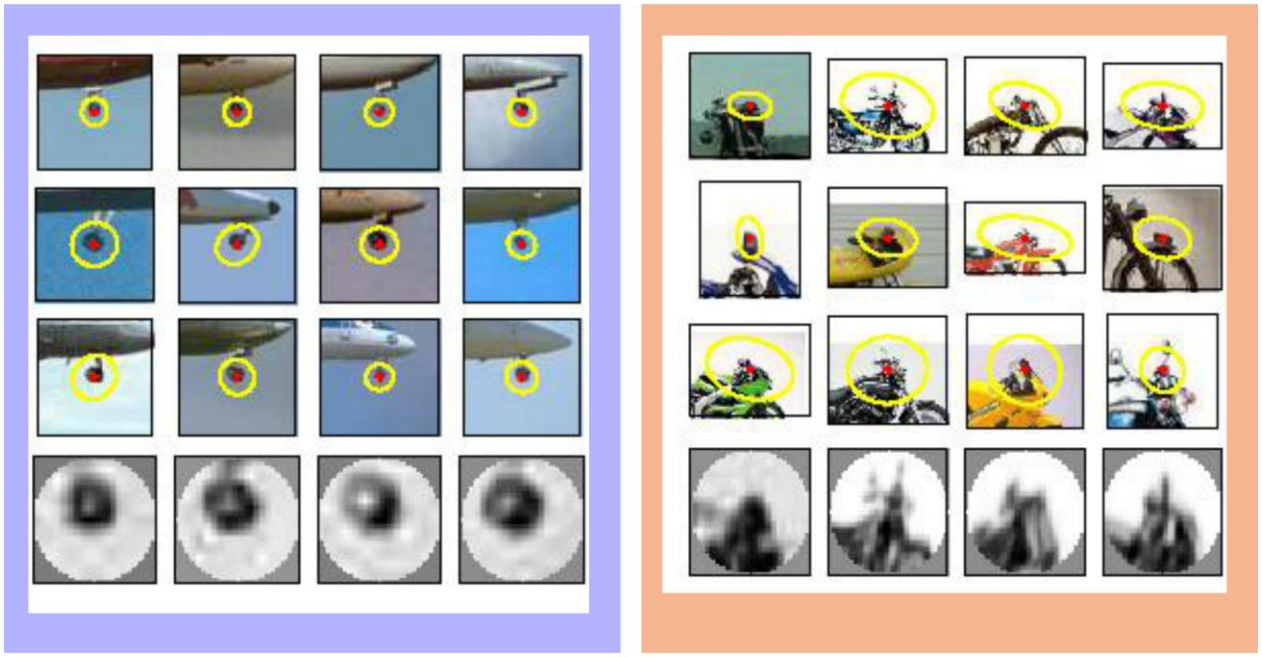


Fei-Fei et al. 2005

图中展示视觉词的代表图像块。

Fei-Fei 等（2005）。

Image patch examples of visual words　视觉词的图像块示例



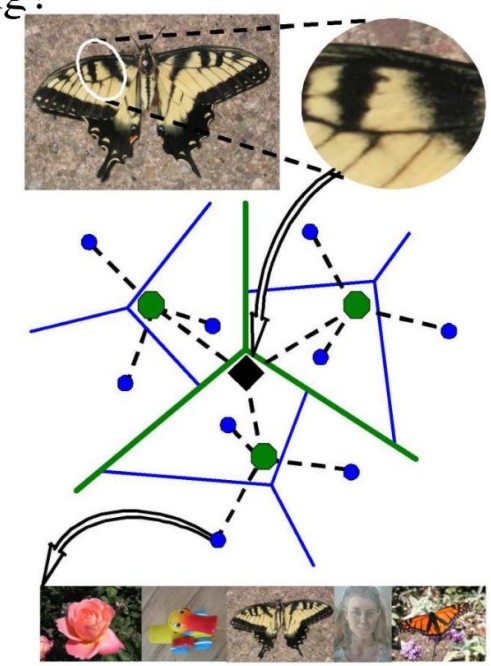
Sivic et al. 2005

每组图像块具有相似的局部外观，归入同一个视觉词。

Sivic 等（2005）。

Visual vocabularies: Issues 视觉词汇表的设计问题

- How to choose vocabulary size?
  - Too small: visual words not representative of all patches
  - Too large: quantization artifacts, overfitting
- Generative or discriminative learning?
- Computational efficiency
  - Vocabulary trees
    (Nister & Stewenius, 2006)



词汇表大小的选择。过小时，视觉词难以代表全部图像块。过大时，容易出现量化伪影与过拟合。

采用生成式学习或判别式学习。

计算效率，可采用词汇树（Nistér 与 Stewénius，2006）。

3. Image representation　图像表示

用视觉词频直方图表示图像。

横轴为码字，纵轴为频率。

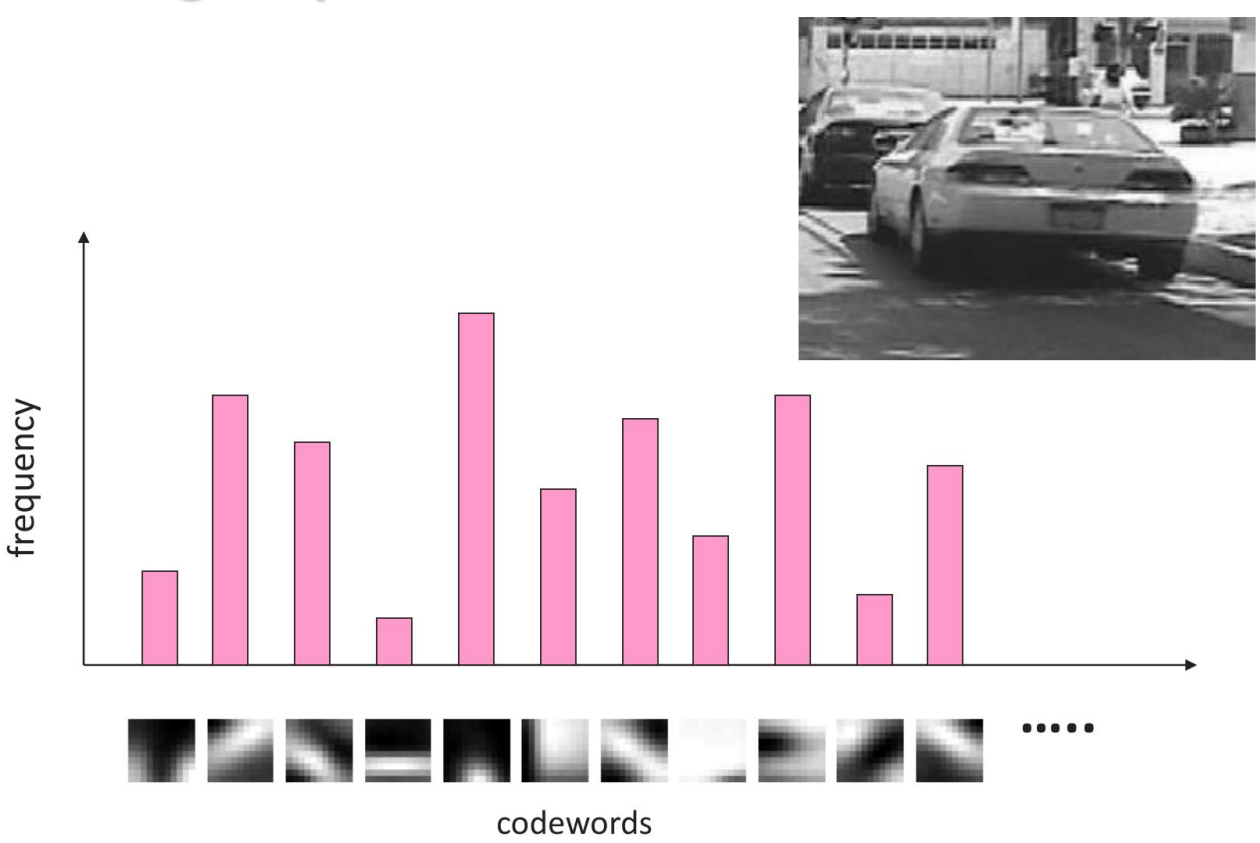
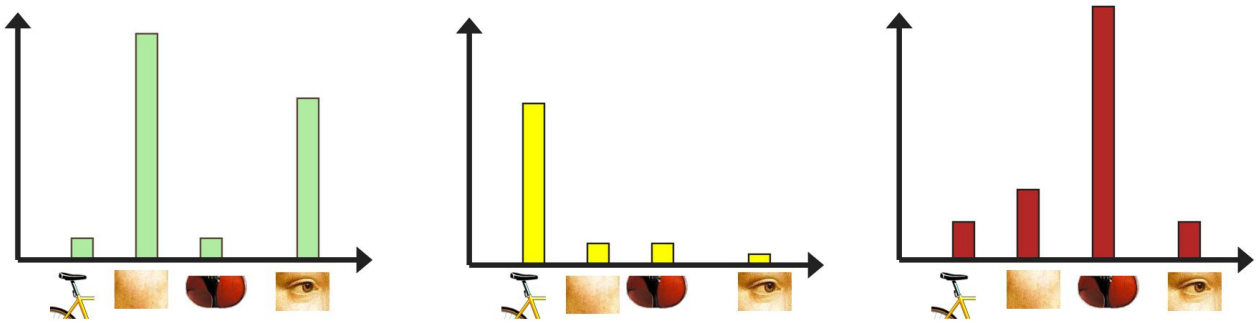


Image classification 图像分类

给定各类别图像的特征袋表示，学习能够区分类别的模型。

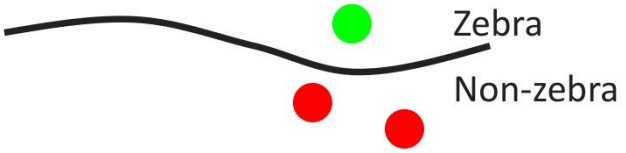
- Given the bag-of-features representations of images from different classes, how do we learn a model for distinguishing them?

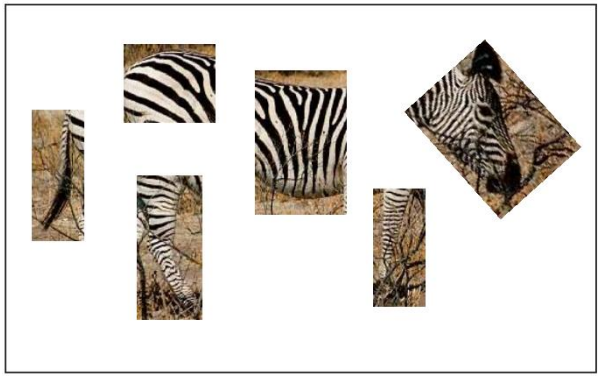


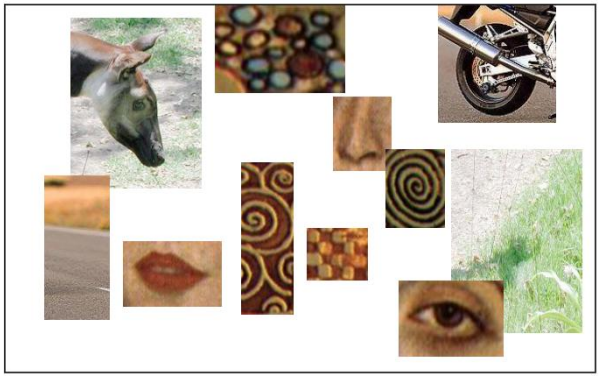
Discriminative and generative methods for bags of features
特征袋的判别与生成方法

Discriminative and generative methods for bags of features

图中以斑马和非斑马类别展示两类建模方法。





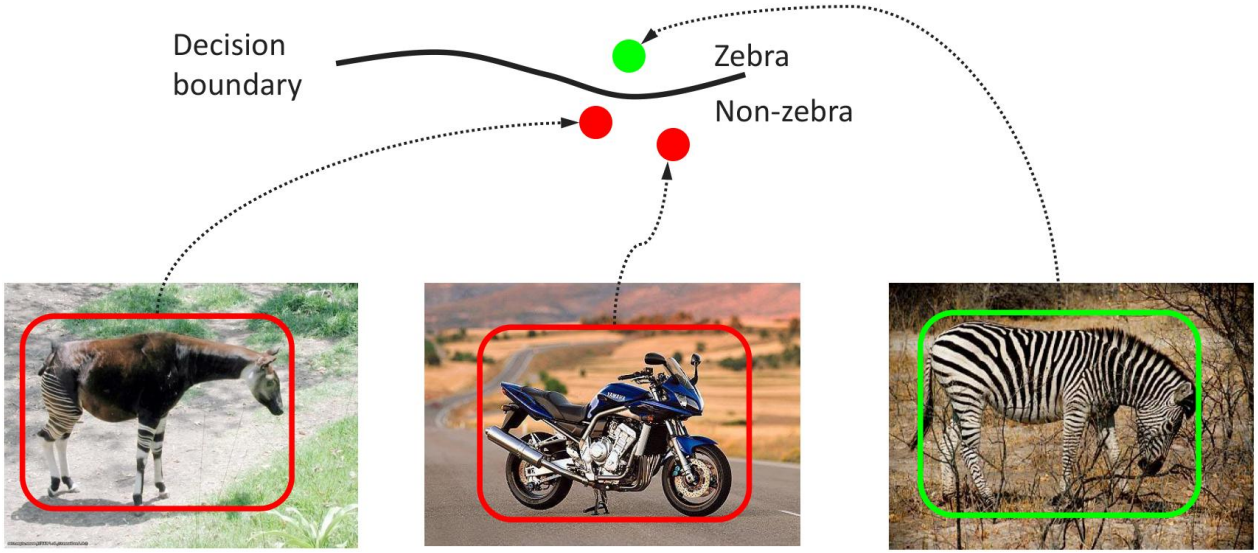


Discriminative methods 判别方法

- Learn a decision rule (classifier) assigning bag-of-features representations of images to different classes

学习决策规则，即分类器，将图像的特征袋表示分配给各类别。

图中曲线为决策边界，类别为斑马与非斑马。

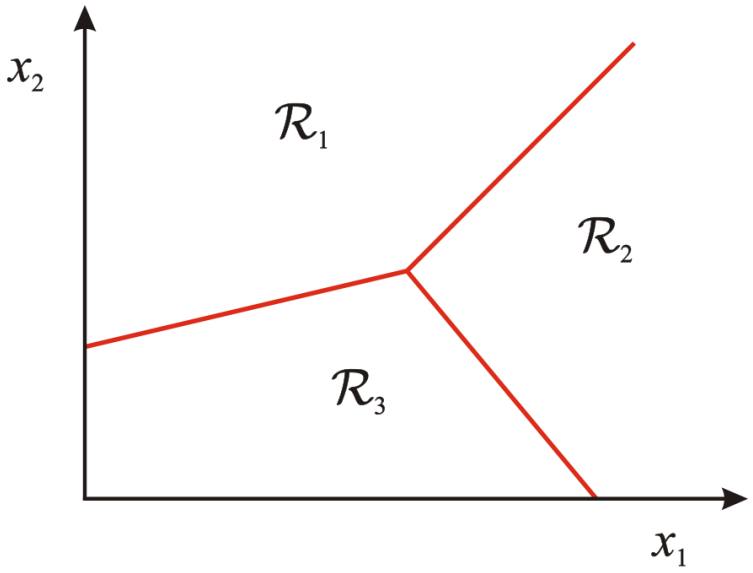


Classification 分类方法

- Assign input vector to one of two or more classes
- Any decision rule divides input space into *decision regions* separated by *decision boundaries*

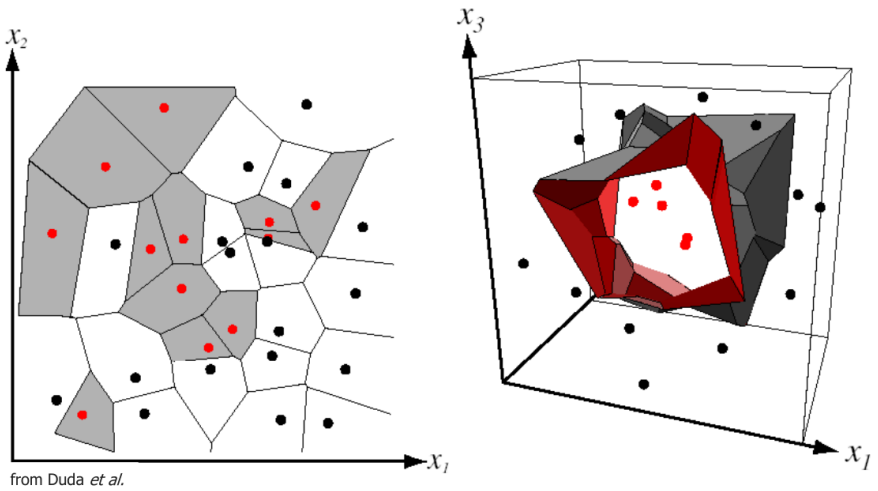
将输入向量分配给两个或多个类别中的一个。

决策规则把输入空间划分为多个决策区域，各区域由决策边界分隔。



Nearest Neighbor Classifier 最近邻分类器

- Assign label of nearest training data point to each test data point



from Duda *et al.*

Voronoi partitioning of feature space for two-category 2D and 3D data

Source: D. Lowe

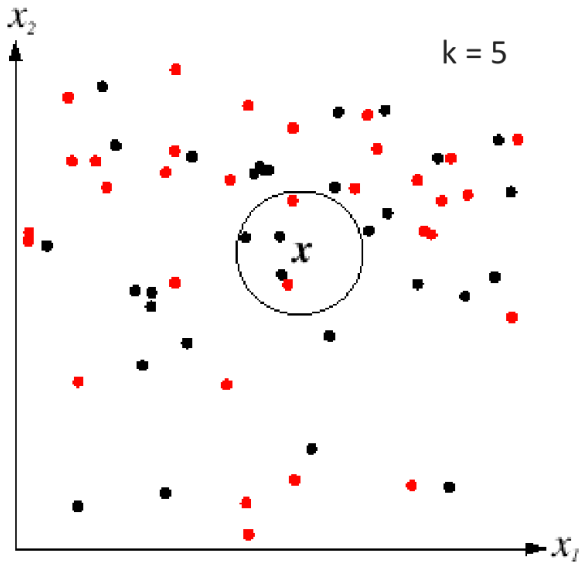
把最近训练数据点的类别标签赋给每个测试数据点。

图中展示两类二维与三维数据在特征空间中的 Voronoi 划分。

来源 Duda 等，来源 D. Lowe。

K-Nearest Neighbors　K 近邻分类

- For a new point, find the k closest points from training data
- Labels of the k points "vote" to classify
- Works well provided there is lots of data and the distance function is good



Source: D. Lowe

对新数据点，寻找训练数据中最近的 k 个点。

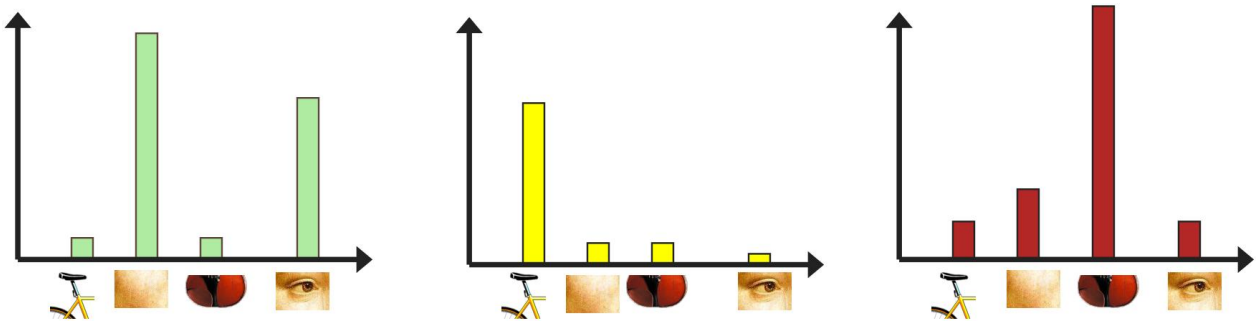
由这 k 个点的标签投票决定类别。

当数据量充足、距离函数适合时，此方法表现较好。

图中 k = 5，来源 D. Lowe。

Functions for comparing histograms　直方图比较函数

图中展示三类图像的视觉词频直方图。



Functions for comparing histograms 直方图比较函数

- L1 distance

$$D(h_1,h_2)=\sum_{i=1}^{N}|h_1(i)-h_2(i)|$$

- χ^2 distance

$$D(h_1,h_2)=\sum_{i=1}^{N}\frac{(h_1(i)-h_2(i))^2}{h_1(i)+h_2(i)}$$

- Quadratic distance (*cross-bin*)

$$D(h_1,h_2)=\sum_{i,j}A_{ij}(h_1(i)-h_2(j))^2$$

Jan Puzicha, Yossi Rubner, Carlo Tomasi, Joachim M. Buhmann: Empirical Evaluation of Dissimilarity Measures for Color and Texture. ICCV 1999

L_1 距离，累计各对应直方图分量的绝对差。

χ^2 距离，累计各分量差的平方与分量和之比。

二次距离，允许跨直方图分箱比较，由矩阵 A_{ij} 表达分箱间关系。

Jan Puzicha、Yossi Rubner、Carlo Tomasi 与 Joachim M. Buhmann，《颜色与纹理差异度量的实验评估》，ICCV 1999。

Earth Mover's Distance 推土机距离

- Each image is represented by a *signature* S consisting of a set of *centers* $\{m_i\}$ and *weights* $\{w_i\}$
- Centers can be codewords from universal vocabulary, clusters of features in the image, or individual features (in which case quantization is not required)
- Earth Mover's Distance has the form

$$EMD(S_1, S_2) = \sum_{i,j} \frac{f_{ij} d(m_i, m_j)}{f_{ij}}$$

where the *flows* f_{ij} are given by the solution of a *transportation problem*

Y. Rubner, C. Tomasi, and L. Guibas: A Metric for Distributions with Applications to Image Databases. ICCV 1998

每幅图像表示为签名 S，由中心集合 $\{m_i\}$ 与权重集合 $\{w_i\}$ 组成。

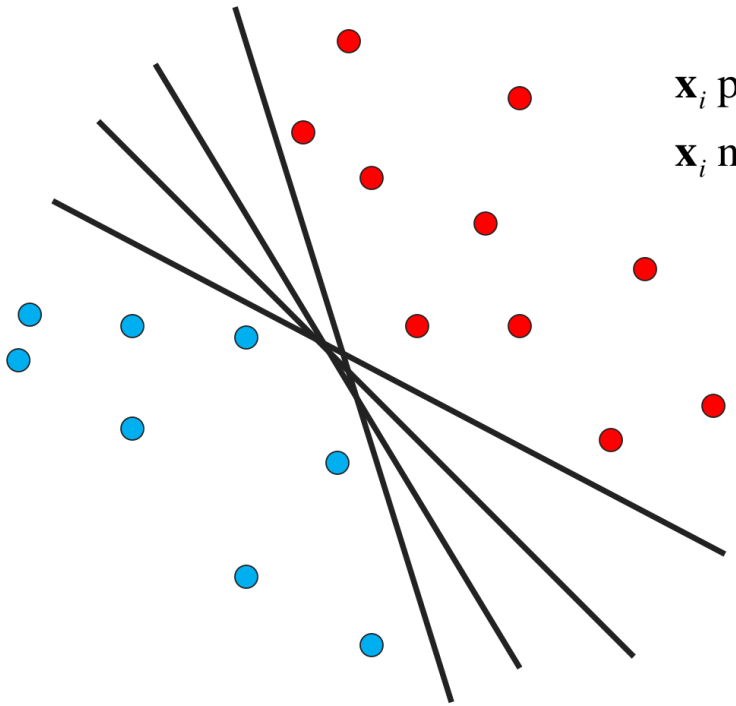
中心可选通用词汇表的码字、图像内的特征簇，或独立特征。使用独立特征时可省去量化。

推土机距离依据各中心间的距离 $d(m_i,m_j)$ 与运输流量 f_{ij} 计算，流量由运输问题的解确定。

Y. Rubner、C. Tomasi 与 L. Guibas，《面向图像数据库的分布度量》，ICCV 1998。

Linear classifiers 线性分类器

- Find linear function (*hyperplane*) to separate positive and negative examples



$$\mathbf{x}_i \text{ positive}: \quad \mathbf{x}_i \cdot \mathbf{w} + b \geq 0$$
$$\mathbf{x}_i \text{ negative}: \quad \mathbf{x}_i \cdot \mathbf{w} + b < 0$$

Which hyperplane is best?

Slide: S. Lazebni

寻找线性函数，即超平面，将正样本与负样本分隔。

正类满足 $x_i \cdot w+b \geq 0$，负类满足 $x_i \cdot w+b < 0$。

需要选择最合适的分隔超平面。

来源 S. Lazebnik。

Support vector machines　支持向量机

- Find hyperplane that maximizes the *margin* between the positive and negative examples

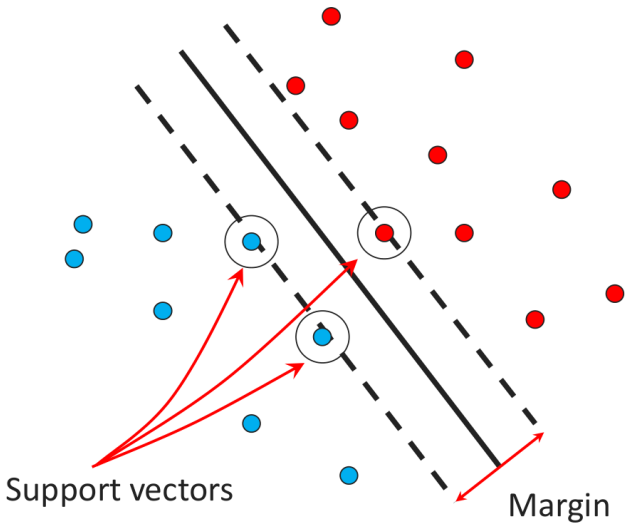
寻找使正负样本间隔最大的超平面。

C. Burges，《用于模式识别的支持向量机教程》，Data Mining and Knowledge Discovery，1998 年。

C. Burges, A Tutorial on Support Vector Machines for Pattern Recognition, Data Mining and Knowledge Discovery, 1998

Support vector machines　支持向量机

- Find hyperplane that maximizes the *margin* between the positive and negative examples



$\mathbf{x}_i$ positive $(y_i = 1)$: $\mathbf{x}_i \cdot \mathbf{w} + b \geq 1$

$\mathbf{x}_i$ negative $(y_i = -1)$: $\mathbf{x}_i \cdot \mathbf{w} + b \leq -1$

For support vectors, $\mathbf{x}_i \cdot \mathbf{w} + b = \pm 1$

Distance between point and hyperplane: $\dfrac{|\mathbf{x}_i \cdot \mathbf{w} + b|}{\|\mathbf{w}\|}$

Therefore, the margin is $2 / \|\mathbf{w}\|$

C. Burges, A Tutorial on Support Vector Machines for Pattern Recognition, Data Mining and Knowledge Discovery, 1998

寻找使正负样本间隔最大的超平面。

正样本 $y_i=1$ 满足 $x_i \cdot w+b \geq 1$，负样本 $y_i=-1$ 满足 $x_i \cdot w+b \leq -1$。

支持向量满足 $x_i \cdot w+b = \pm 1$。

数据点到超平面的距离为 $|x_i \cdot w+b| / \|w\|$，间隔为 $2/\|w\|$。

C. Burges，《用于模式识别的支持向量机教程》，Data Mining and Knowledge Discovery，1998 年。

Finding the maximum margin hyperplane 最大间隔超平面

1. Maximize margin $2/\|\mathbf{w}\|$
2. Correctly classify all training data:

$$\mathbf{x}_i \text{ positive } (y_i = 1): \quad \mathbf{x}_i \cdot \mathbf{w} + b \geq 1$$

$$\mathbf{x}_i \text{ negative } (y_i = -1): \quad \mathbf{x}_i \cdot \mathbf{w} + b \leq -1$$

- *Quadratic optimization problem*:
- $$\text{Minimize} \quad \frac{1}{2}\mathbf{w}^T\mathbf{w}$$
$$\text{Subject to} \quad y_i(\mathbf{w}\cdot\boldsymbol{x}_i + b) \geq 1$$

C. Burges, A Tutorial on Support Vector Machines for Pattern Recognition, Data Mining and Knowledge Discovery, 1998

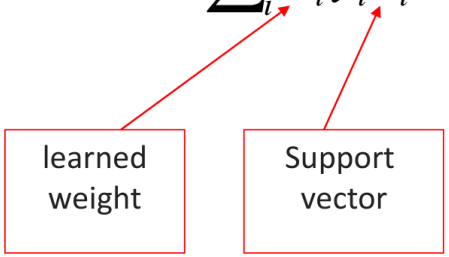
最大化间隔 $2/\|w\|$，同时正确分类全部训练数据。

等价二次优化问题为最小化 $\frac{1}{2}w^Tw$，约束为 $y_i(w\cdot x_i+b) \geq 1$。

C. Burges，《用于模式识别的支持向量机教程》，Data Mining and Knowledge Discovery，1998 年。

Finding the maximum margin hyperplane 最大间隔超平面

- Solution: $\mathbf{w} = \sum_i \alpha_i y_i \mathbf{x}_i$



解的形式为 $w = \Sigma_i \alpha_i y_i x_i$。

α_i 为学习得到的权重，x_i 为支持向量。

C. Burges，《用于模式识别的支持向量机教程》，Data Mining and Knowledge Discovery，1998 年。

C. Burges, A Tutorial on Support Vector Machines for Pattern Recognition, Data Mining and Knowledge Discovery, 1998

Finding the maximum margin hyperplane 最大间隔超平面

- Solution: $\mathbf{w} = \sum_i \alpha_i y_i \mathbf{x}_i$

  $b = y_i - \mathbf{w} \cdot \mathbf{x}_i$ for any support vector

- Classification function (decision boundary):

$$\mathbf{w} \cdot \mathbf{x} + b = \sum_i \alpha_i y_i \mathbf{x}_i \cdot \mathbf{x} + b$$

- Notice that it relies on an *inner product* between the test point $\boldsymbol{x}$ and the support vectors $\boldsymbol{x}_i$
- Solving the optimization problem also involves computing the inner products $\boldsymbol{x}_i \cdot \boldsymbol{x}_j$ between all pairs of training points

C. Burges, A Tutorial on Support Vector Machines for Pattern Recognition, Data Mining and Knowledge Discovery, 1998

解为 $w = \Sigma_i \alpha_i y_i x_i$。

对任一支持向量，$b = y_i - w \cdot x_i$。

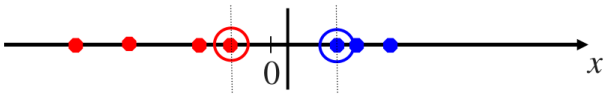
分类决策函数为 $w \cdot x + b = \Sigma_i \alpha_i y_i (x_i \cdot x) + b$。

决策依赖测试点 x 与支持向量 x_i 的内积。求解优化问题也需要计算所有训练点对之间的内积 $x_i \cdot x_j$。

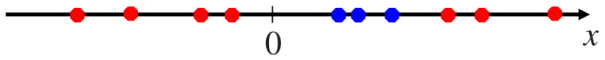
C. Burges，《用于模式识别的支持向量机教程》，Data Mining and Knowledge Discovery，1998 年。

Nonlinear SVMs 非线性支持向量机

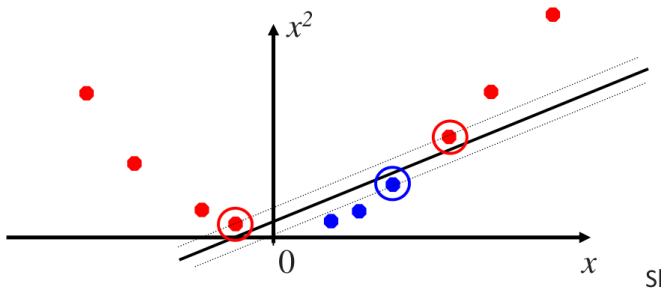
- Datasets that are linearly separable work out great:



- But what if the dataset is just too hard?



- We can map it to a higher-dimensional space:



Slide credit: Andrew Moore

线性可分数据适合采用线性分隔。

对于更复杂的数据集，可映射到高维空间。图中将一维 x 映射到二维 (x,x^2)。

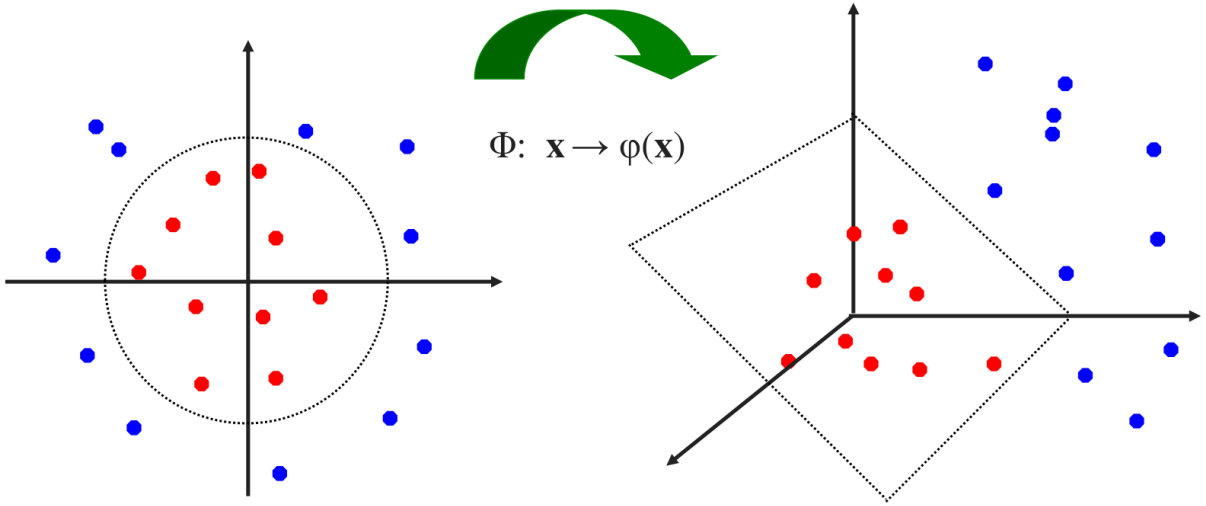
来源 Andrew Moore。

Nonlinear SVMs　非线性支持向量机

- General idea: the original input space can always be mapped to some higher-dimensional feature space where the training set is separable:

一般思想是通过映射 Φ，将原始输入 x 变为高维特征 φ(x)，使训练集在新空间中可分。

来源 Andrew Moore。



Slide credit: Andrew Moore

Nonlinear SVMs 非线性支持向量机

- *The kernel trick*: instead of explicitly computing the lifting transformation $\boldsymbol{\varphi}(\mathbf{x})$, define a kernel function K such that

$$K(\mathbf{x}_i, \mathbf{x}_j) = \boldsymbol{\varphi}(\mathbf{x}_i) \cdot \boldsymbol{\varphi}(\mathbf{x}_j)$$

- (to be valid, the kernel function must satisfy *Mercer's condition*)

矩阵K是对称矩阵，因为向量内积是对称的
矩阵K是半正定的

- This gives a nonlinear decision boundary in the original feature space:

$$\sum_i \alpha_i y_i K(\mathbf{x}_i, \mathbf{x}) + b$$

C. Burges, A Tutorial on Support Vector Machines for Pattern Recognition, Data Mining and Knowledge Discovery, 1998

核技巧通过核函数计算高维内积，$K(x_i,x_j) = \varphi(x_i)\cdot\varphi(x_j)$，从而省去显式计算映射 $\varphi(x)$。

有效核函数须满足 Mercer 条件。核矩阵 K 具有对称性与半正定性。

原始特征空间中的决策边界为非线性形式，决策函数为 $\Sigma_i\alpha_i y_i K(x_i,x)+b$。

C. Burges，《用于模式识别的支持向量机教程》，Data Mining and Knowledge Discovery，1998 年。

Kernels for bags of features　特征袋的核函数

- Histogram intersection kernel:

$$I(h_1, h_2) = \sum_{i=1}^{N} \min(h_1(i), h_2(i))$$

- Generalized Gaussian kernel:

$$K(h_1, h_2) = \exp\left(-\frac{1}{A} D(h_1, h_2)^2\right)$$

- D can be Euclidean distance, χ^2 distance, Earth Mover's Distance, etc.

J. Zhang, M. Marszalek, S. Lazebnik, and C. Schmid, Local Features and Kernels for Classifcation of Texture and Object Categories: A Comprehensive Study, IJCV 2007

直方图交集核，$I(h_1, h_2) = \Sigma_i \min(h_1(i), h_2(i))$。

广义高斯核，$K(h_1, h_2) = \exp[-D(h_1, h_2)^2/A]$。

D 可为欧氏距离、χ^2 距离或推土机距离等。

J. Zhang、M. Marszałek、S. Lazebnik 与 C. Schmid，《纹理与物体类别分类的局部特征和核函数综合研究》，IJCV 2007。

Summary: SVMs for image classification
支持向量机图像分类流程

1. Pick an image representation (in our case, bag of features)
2. Pick a kernel function for that representation
3. Compute the matrix of kernel values between every pair of training examples
4. Feed the kernel matrix into your favorite SVM solver to obtain support vectors and weights
5. At test time: compute kernel values for your test example and each support vector, and combine them with the learned weights to get the value of the decision function

1. 选择图像表示，此处为特征袋。
2. 为该表示选择核函数。
3. 计算任意两个训练样本之间的核值，形成核矩阵。
4. 把核矩阵输入 SVM 求解器，获得支持向量与权重。
5. 测试时计算测试样本与各支持向量的核值，结合学习所得权重，得到决策函数值。

What about multi-class SVMs? 多类别支持向量机

- Unfortunately, there is no "definitive" multi-class SVM formulation
- In practice, we have to obtain a multi-class SVM by combining multiple two-class SVMs
- One vs. others
  - Traning: learn an SVM for each class vs. the others
  - Testing: apply each SVM to test example and assign to it the class of the SVM that returns the highest decision value
- One vs. one
  - Training: learn an SVM for each pair of classes
  - Testing: each learned SVM "votes" for a class to assign to the test example

课件介绍的多类别 SVM 通过组合多个二分类 SVM 实现。

一对其余，训练时为每个类别与其他类别训练一个 SVM，测试时选决策值最高的类别。

一对一，训练时为每对类别训练一个 SVM，测试时由各分类器投票决定类别。

来源 S. Lazebnik。

Slide: S. Lazebni

SVMs: Pros and cons 支持向量机的优势与局限

- Pros
  - Many publicly available SVM packages: http://www.kernel-machines.org/software
  - Kernel-based framework is very powerful, flexible
  - SVMs work very well in practice, even with very small training sample sizes
- Cons
  - No "direct" multi-class SVM, must combine two-class SVMs
  - Computation, memory
    - During training time, must compute matrix of kernel values for every pair of examples
    - Learning can take a very long time for large-scale problems

优势包括公开软件包众多、基于核的框架能力强且灵活，以及小规模训练样本下仍有较好的实际表现。

多类别任务通常需要组合多个二分类 SVM。

计算与内存开销较大。训练时需计算所有样本对的核矩阵，大规模问题的学习可能耗时很长。

来源 S. Lazebnik。

Slide: S. Lazebni

Summary: Discriminative methods 判别方法总结

- Nearest-neighbor and k-nearest-neighbor classifiers
  - L1 distance, χ^2 distance, quadratic distance, Earth Mover's Distance
- Support vector machines
  - Linear classifiers
  - Margin maximization
  - The kernel trick
  - Kernel functions: histogram intersection, generalized Gaussian, pyramid match
  - Multi-class
- Of course, there are many other classifiers out there
  - Neural networks, boosting, decision trees, …

最近邻与 K 近邻分类器可采用 L_1 距离、χ^2 距离、二次距离或推土机距离。

支持向量机包括线性分类、间隔最大化、核技巧及多类别扩展。

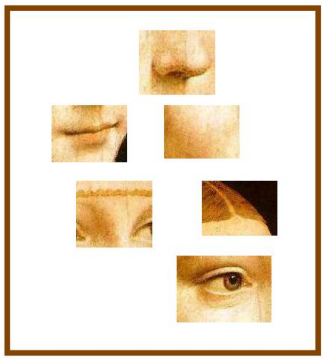
核函数包括直方图交集核、广义高斯核与金字塔匹配核。

其他分类器包括神经网络、提升方法与决策树等。

Generative learning methods for bags of features
特征袋的生成学习

建模给定类别条件下特征袋出现的概率。

- Model the probability of a bag of features given a class







Generative methods 生成方法

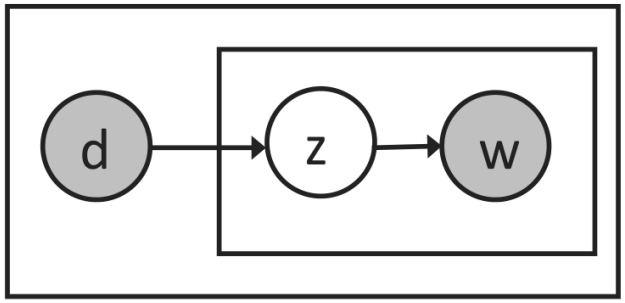
- We will cover two models, both inspired by text document analysis:
  - Naïve Bayes
  - Probabilistic Latent Semantic Analysis

介绍两种受文本分析启发的模型。

朴素贝叶斯。

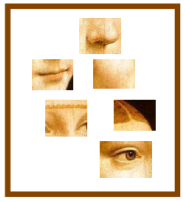
概率潜在语义分析。

图中 d 为文档，z 为潜在主题，w 为词。



The Naïve Bayes model 朴素贝叶斯模型

The Naïve Bayes model



- Assume that each feature is conditionally independent *given the class*

$$p(f_1,\ldots,f_N \mid c) = \prod_{i=1}^{N} p(f_i \mid c) = \prod_{j=1}^{M} p(w_j \mid c)^{n(w_j)}$$

f_i: ith feature in the image
N: number of features in the image

w_j: jth visual word in the vocabulary
M: size of visual vocabulary
$n(w_j)$: number of features of type w_j in the image

Csurka et al. 2004

假设在给定类别的条件下，各特征条件独立。

图像似然等于各特征条件概率的乘积，也等于各视觉词概率按其出现次数乘方后的乘积。

f_i 为图像中的第 i 个特征，N 为图像特征数。

w_j 为词汇表中的第 j 个视觉词，M 为词汇表大小，$n(w_j)$ 为图像中属于视觉词 w_j 的特征数。

Csurka 等（2004）。

The Naïve Bayes model 朴素贝叶斯模型

The Naïve Bayes model

- Assume that each feature is conditionally independent *given the class*



$$p(f_1,\ldots,f_N \mid c) = \prod_{i=1}^{N} p(f_i \mid c) = \prod_{j=1}^{M} p(w_j \mid c)^{n(w_j)}$$

$$p(w_j \mid c) = \frac{\text{No. of features of type } w_j \text{ in training images of class } c}{\text{Total no. of features in training images of class } c}$$

Csurka et al. 2004

假设在给定类别的条件下，各特征条件独立。

图像似然等于各特征条件概率的乘积，也等于各视觉词概率按其出现次数乘方后的乘积。

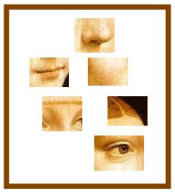
$p(w_j|c)$ = 类别 c 的训练图像中 w_j 类特征数 / 类别 c 的训练图像中特征总数。

Csurka 等（2004）。

The Naïve Bayes model 朴素贝叶斯模型

The Naïve Bayes model

- Assume that each feature is conditionally independent *given the class*



$$p(f_1,\ldots,f_N \mid c) = \prod_{i=1}^{N} p(f_i \mid c) = \prod_{j=1}^{M} p(w_j \mid c)^{n(w_j)}$$

$$p(w_j \mid c) = \frac{\text{No. of features of type } w_j \text{ in training images of class } c + 1}{\text{Total no. of features in training images of class } c + M}$$

(*Laplace smoothing* to avoid zero counts)

Csurka et al. 2004

假设在给定类别的条件下，各特征条件独立。

图像似然等于各特征条件概率的乘积，也等于各视觉词概率按其出现次数乘方后的乘积。

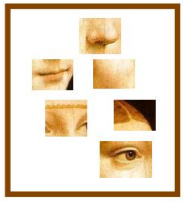
使用拉普拉斯平滑，避免零计数。

$p(w_j|c)$ = [类别 c 的训练图像中 w_j 类特征数 + 1] / [类别 c 的训练图像中特征总数 + M]。

Csurka 等（2004）。

The Naïve Bayes model 朴素贝叶斯模型

The Naïve Bayes model



- Maximum A Posteriori decision:

$$c^* = \arg\max_c p(c)\prod_{j=1}^{M} p(w_j \mid c)^{n(w_j)}$$

$$= \arg\max_c \log p(c) + \sum_{j=1}^{M} n(w_j)\log p(w_j \mid c)$$

(you should compute the log of the likelihood instead of the likelihood itself in order to avoid underflow)

Csurka et al. 2004

最大后验判决，选择使 $p(c)\prod_i p(w_j|c)^{n(wj)}$ 最大的类别 c。

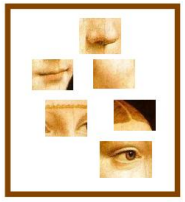
等价形式为最大化 $\log p(c) + \Sigma_j n(w_j) \log p(w_j|c)$。

计算对数似然可避免数值下溢。

Csurka 等（2004）。

The Naïve Bayes model　朴素贝叶斯模型

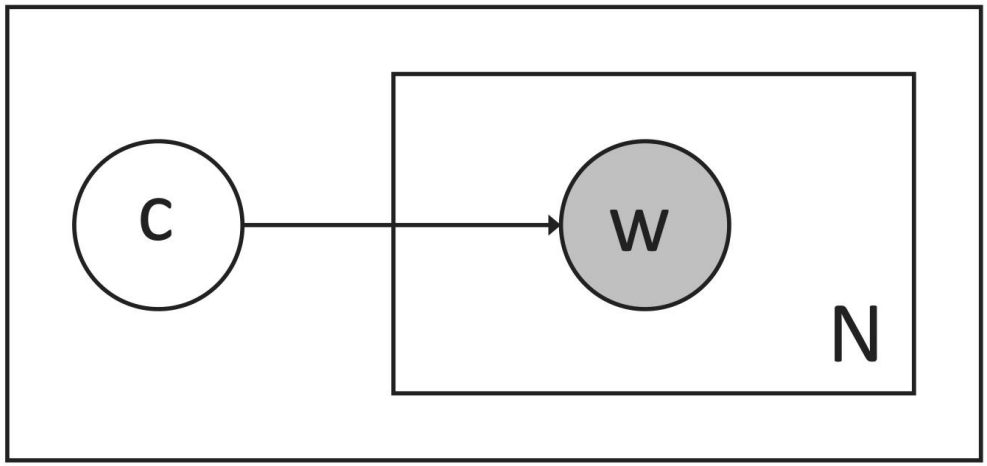
The Naïve Bayes model



图模型中，c 表示类别，w 表示视觉词，N 表示图像中重复生成的特征数。

Csurka 等（2004）。

- “Graphical model”:

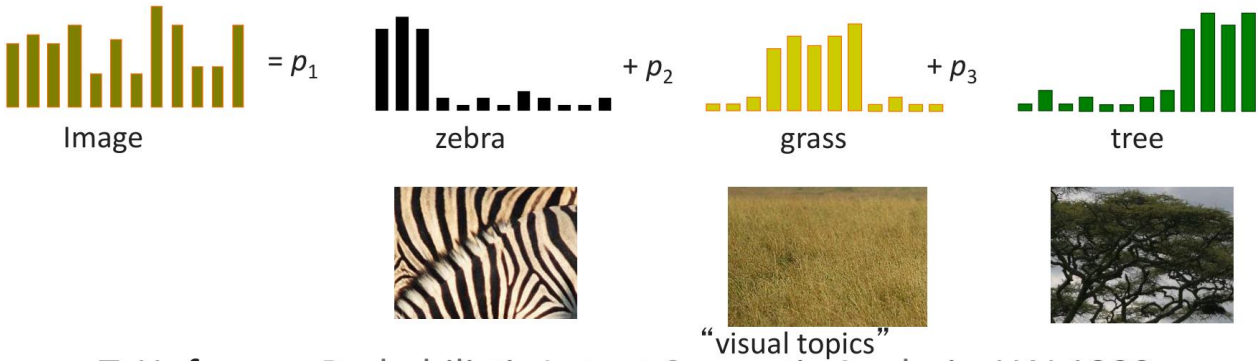


Csurka et al. 2004

Probabilistic Latent Semantic Analysis 概率潜在语义分析

Probabilistic Latent Semantic Analysis





T. Hofmann, Probabilistic Latent Semantic Analysis, UAI 1999

图像表示为多个视觉主题的混合。

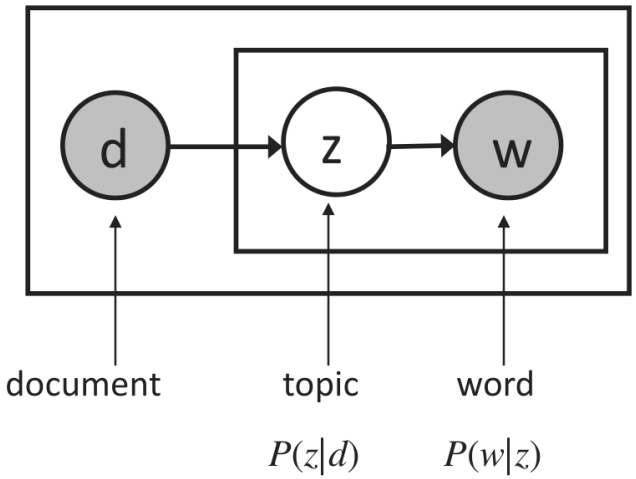
示例主题包括斑马、草地与树木，对应混合权重 p_1、p_2、p_3。

T. Hofmann，《概率潜在语义分析》，UAI 1999。

Probabilistic Latent Semantic Analysis 概率潜在语义分析

Probabilistic Latent Semantic Analysis

- Unsupervised technique
- Two-level generative model: a document is a mixture of topics, and each topic has its own characteristic word distribution



T. Hofmann, Probabilistic Latent Semantic Analysis, UAI 1999

无监督技术。

两层生成模型把文档视为主题的混合，每个主题具有其自身的特征词分布。

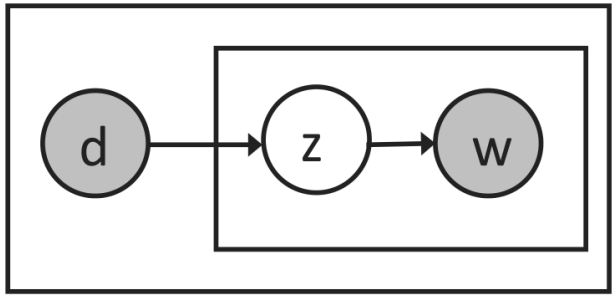
d 为文档，z 为主题，w 为词，p(z|d) 为文档中的主题分布，p(w|z) 为主题的词分布。

T. Hofmann，《概率潜在语义分析》，UAI 1999。

Probabilistic Latent Semantic Analysis 概率潜在语义分析

Probabilistic Latent Semantic Analysis

- Unsupervised technique
- Two-level generative model: a document is a mixture of topics, and each topic has its own characteristic word distribution



$$p(w_i \mid d_j) = \sum_{k=1}^{K} p(w_i \mid z_k)\, p(z_k \mid d_j)$$

T. Hofmann, Probabilistic Latent Semantic Analysis, UAI 1999

无监督技术。

两层生成模型把文档视为主题的混合，每个主题具有其自身的特征词分布。

d 为文档，z 为主题，w 为词，p(z|d) 为文档中的主题分布，p(w|z) 为主题的词分布。

$p(w_i|d_j) = \Sigma_k p(w_i|z_k)p(z_k|d_j)$。

T. Hofmann，《概率潜在语义分析》，UAI 1999。

The pLSA model　pLSA 模型

The pLSA model

$$p(w_i \mid d_j) = \sum_{k=1}^{K} p(w_i \mid z_k)\, p(z_k \mid d_j)$$

Probability of word i in document j (known)

Probability of word i given topic k (unknown)

Probability of topic k given document j (unknown)

$p(w_i|d_j) = \Sigma_k p(w_i|z_k)p(z_k|d_j)$。

$p(w_i|d_j)$ 为已知的文档 j 中词 i 的概率。

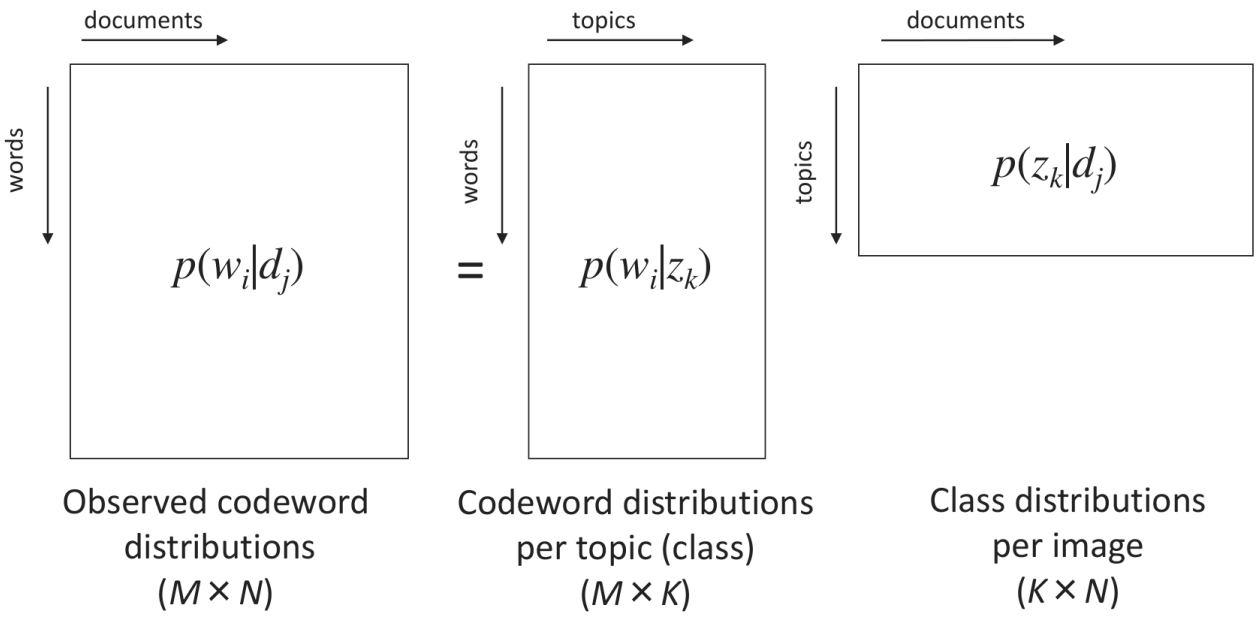
$p(w_i|z_k)$ 为未知的主题 k 条件下词 i 的概率。

$p(z_k|d_j)$ 为未知的文档 j 中主题 k 的概率。

The pLSA model　pLSA 模型

The pLSA model

$$p(w_i \mid d_j) = \sum_{k=1}^{K} p(w_i \mid z_k)\, p(z_k \mid d_j)$$



将观测的码字分布矩阵分解为主题词分布矩阵与图像主题分布矩阵。

$p(w_i|d_j)$ 的维度为 M×N，行对应词，列对应文档。

$p(w_i|z_k)$ 的维度为 M×K，行对应词，列对应主题。

$p(z_k|d_j)$ 的维度为 K×N，行对应主题，列对应文档。

M 为码字数，N 为图像数，K 为主题数。

Learning pLSA parameters　pLSA 参数学习

Learning pLSA parameters

Maximize likelihood of data:

Observed counts of word *i* in document *j*

$$L = \prod_{i=1}^{M} \prod_{j=1}^{N} P(w_i|d_j)^{n(w_i,d_j)}$$

M … number of codewords

N … number of images

$$\sum_{k=1}^{K} P(z_k|d_j)P(w_i|z_k)$$

Slide credit: Josef Sivic

最大化数据似然。

$L = \prod_i \prod_j p(w_i|d_j)^{n(wi,dj)}$，其中 $p(w_i|d_j) = \Sigma_k p(z_k|d_j)p(w_i|z_k)$。

$n(w_i,d_j)$ 为文档 j 中词 i 的观测次数。

M 为码字数，N 为图像数。

来源 Josef Sivic。

Learning pLSA parameters　pLSA 参数学习

Learning pLSA parameters

EM algorithm

E-step:

$$p(z_k \mid d_j, w_i) = \frac{p(z_k \mid d_j)\, p(w_i \mid z_k)}{\sum_k p(z_k \mid d_j)\, p(w_i \mid z_k)}$$

M-step:

$$p(w_i \mid z_k) = \frac{\sum_j p(z_k \mid d_j, w_i)}{\sum_i \sum_j p(z_k \mid d_j, w_i)}$$

$$p(z_k \mid d_j) = \frac{\sum_i p(z_k \mid d_j, w_i)}{\sum_i \sum_k p(z_k \mid d_j, w_i)}$$

Slide credit: Josef Sivic

采用期望最大化 EM 算法。

E 步计算后验主题概率 $p(z_k|d_j,w_i)$，分子为 $p(z_k|d_j)p(w_i|z_k)$，分母为该分子在全部主题上的求和。

M 步对后验分配求和并归一化，更新 $p(w_i|z_k)$ 与 $p(z_k|d_j)$。

来源 Josef Sivic。

Inference 主题推断

为图像寻找最可能的主题或类别。

z* = argmax_z p(z|d)。

Inference

- Finding the most likely topic (class) for an image:

$$z^* = \arg\max_z \; p(z \mid d)$$

Inference 主题推断

Inference

- Finding the most likely topic (class) for an image:

$$z^* = \arg\max_z \; p(z \mid d)$$

- Finding the most likely topic (class) for a visual word in a given image:

$$z^* = \arg\max_z \; p(z \mid w, d) = \arg\max_z \frac{p(w \mid z)p(z \mid d)}{\sum_{z'} p(w \mid z')p(z' \mid d)}$$

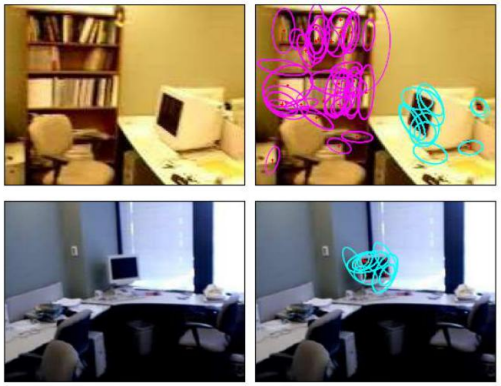
为图像寻找最可能的主题或类别，z* = argmax_z p(z|d)。

对给定图像中的一个视觉词，寻找最可能的主题，z* = argmax_z p(z|w,d)。

根据贝叶斯公式，p(z|w,d) 与 p(w|z)p(z|d) 成正比，归一化分母为对全部主题 z′ 的相应乘积求和。

Topic discovery in images　图像中的主题发现



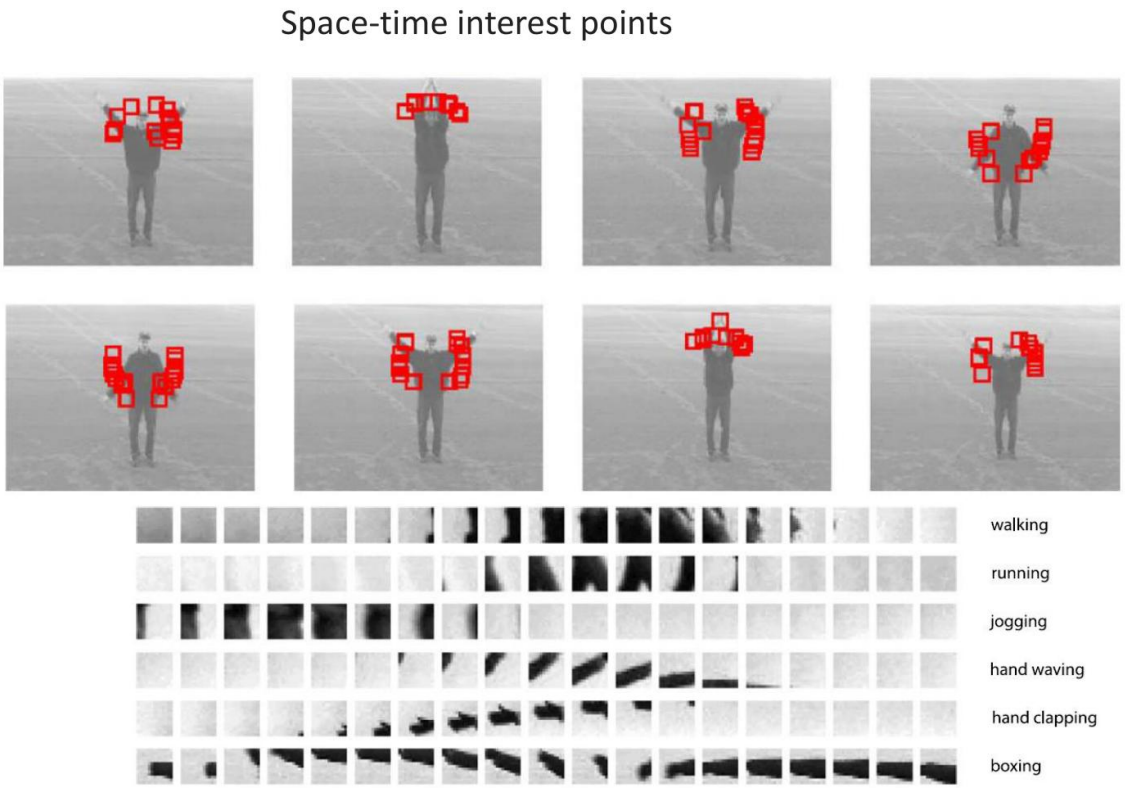


图中彩色区域表示发现的物体主题及其位置。

J. Sivic、B. Russell、A. Efros、A. Zisserman 与 B. Freeman，《在图像中发现物体及其位置》，ICCV 2005。

J. Sivic, B. Russell, A. Efros, A. Zisserman, B. Freeman, Discovering Objects and their Location in Images, *ICCV 2005*

Application of pLSA: Action recognition　pLSA 动作识别应用



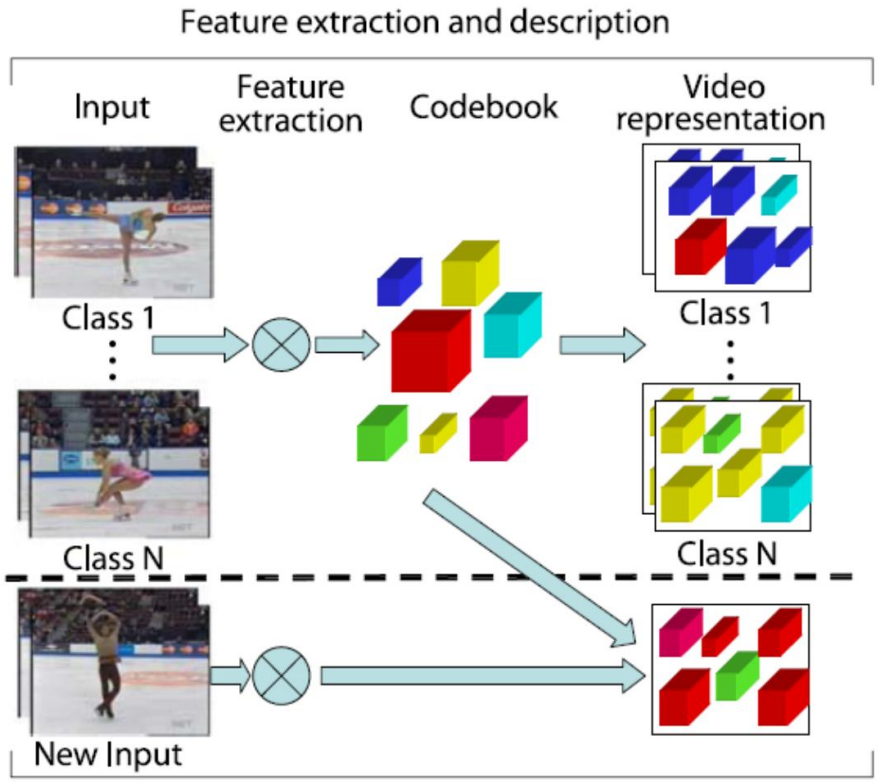
Juan Carlos Niebles, Hongcheng Wang and Li Fei-Fei, Unsupervised Learning of Human Action Categories Using Spatial-Temporal Words, IJCV 2008.

检测时空特征点，红色方框表示图中提取的位置。

下方动作类别为行走、奔跑、慢跑、挥手、拍手与拳击。

Juan Carlos Niebles、Hongcheng Wang 与 Li Fei-Fei，《使用时空词无监督学习人体动作类别》，IJCV 2008。

Application of pLSA: Action recognition　pLSA 动作识别应用



Juan Carlos Niebles, Hongcheng Wang and Li Fei-Fei, Unsupervised Learning of Human Action Categories Using Spatial-Temporal Words, IJCV 2008.

特征提取与描述流程包括视频输入、特征提取、码本量化与视频表示。

训练视频来自类别 1 至类别 N。新输入经同一码本转换，得到视频的视觉词表示。

Juan Carlos Niebles、Hongcheng Wang 与 Li Fei-Fei，《使用时空词无监督学习人体动作类别》，IJCV 2008。

pLSA model　动作识别的 pLSA 模型

$$p(w_i \mid d_j) = \sum_{k=1}^{K} p(w_i \mid z_k)\, p(z_k \mid d_j)$$

Probability of word i in video j (known)

Probability of word i given topic k (unknown)

Probability of topic k given video j (unknown)

w_i = spatial-temporal word

d_j = video

$n(w_i, d_j)$ = co-occurrence table
(# of occurrences of word w_i in video d_j)

z = topic, corresponding to an action

w_i 为时空词，d_j 为视频。

$n(w_i,d_j)$ 为共现表，记录词 w_i 在视频 d_j 中的出现次数。

z 为主题，对应一种动作。

视频中词的概率 $p(w_i|d_j)$ 为已知，主题词概率 $p(w_i|z_k)$ 与视频主题概率 $p(z_k|d_j)$ 为待学习量。

$p(w_i|d_j) = \Sigma_k p(w_i|z_k)p(z_k|d_j)$。

Action recognition example　动作识别示例

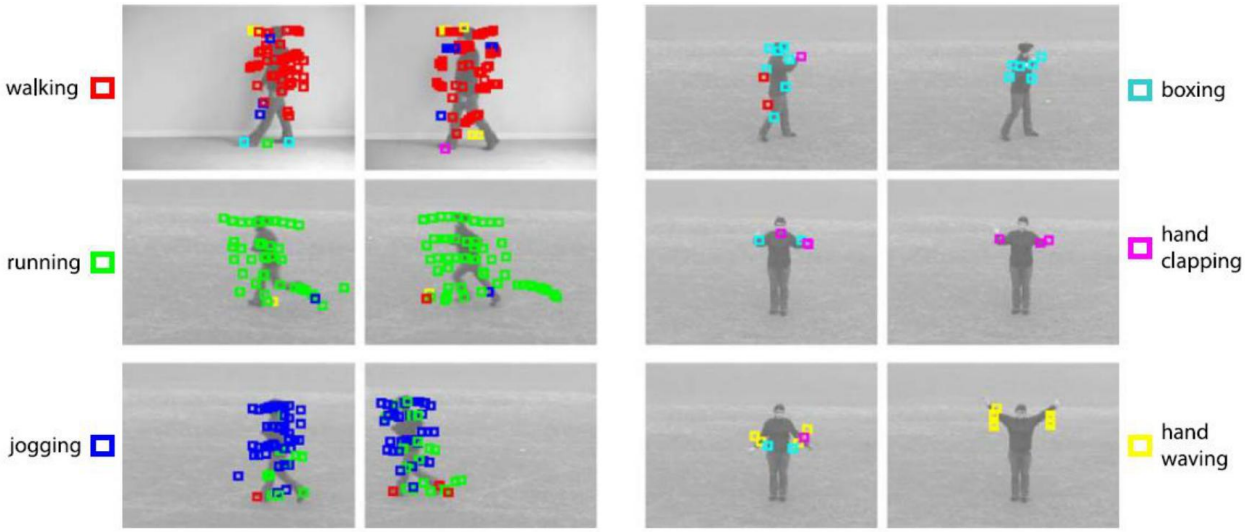


Fig. 10 Example frames from testing sequences in the KTH dataset. The spatial-temporal patches in each sequence are automatically colored according to action class that most likely generated its corresponding spatial-temporal word. Although some of the words are assigned to the wrong topic, most interest points are assigned to the correct action for each video. Consistently, the predicted action class corresponds to the actual ground truth. In addition, we usually observe that the second best ranked action class corresponds to a similar action: in the "jogging" example of the figure, the second best label is "running". The figure is best viewed in color and with PDF magnification

图中展示 KTH 数据集测试序列的帧。

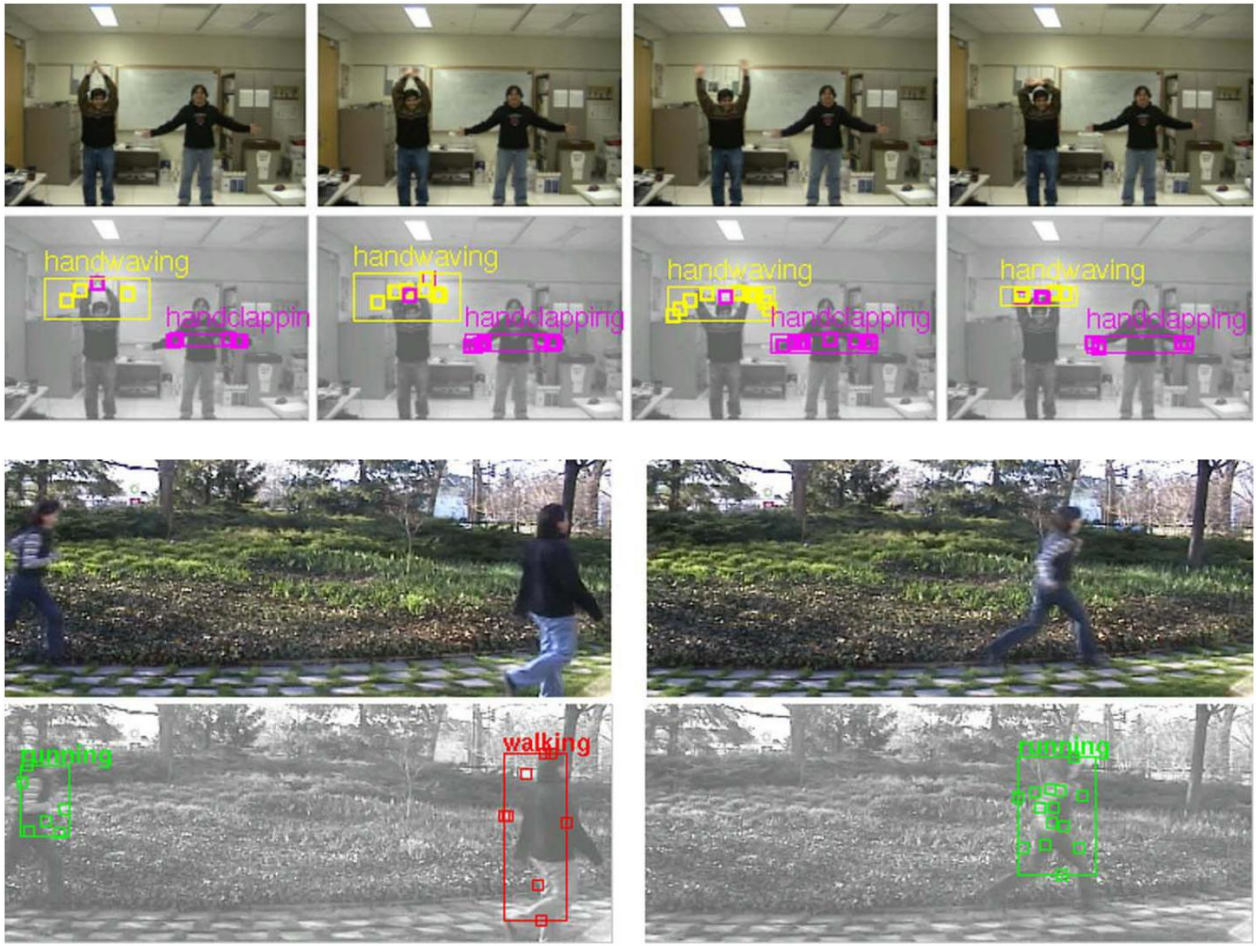
动作与颜色对应为行走红色、奔跑绿色、慢跑蓝色、拳击青色、拍手品红色、挥手黄色。

各时空图像块按最可能生成其时空词的动作类别自动着色。部分词可能被分到其他主题，多数特征点仍归入正确动作。

各视频预测类别与真实标注一致，次高排名通常对应相似动作。例如慢跑示例的第二候选标签为奔跑。

彩色放大图更便于观察。

Multiple Actions 多动作识别

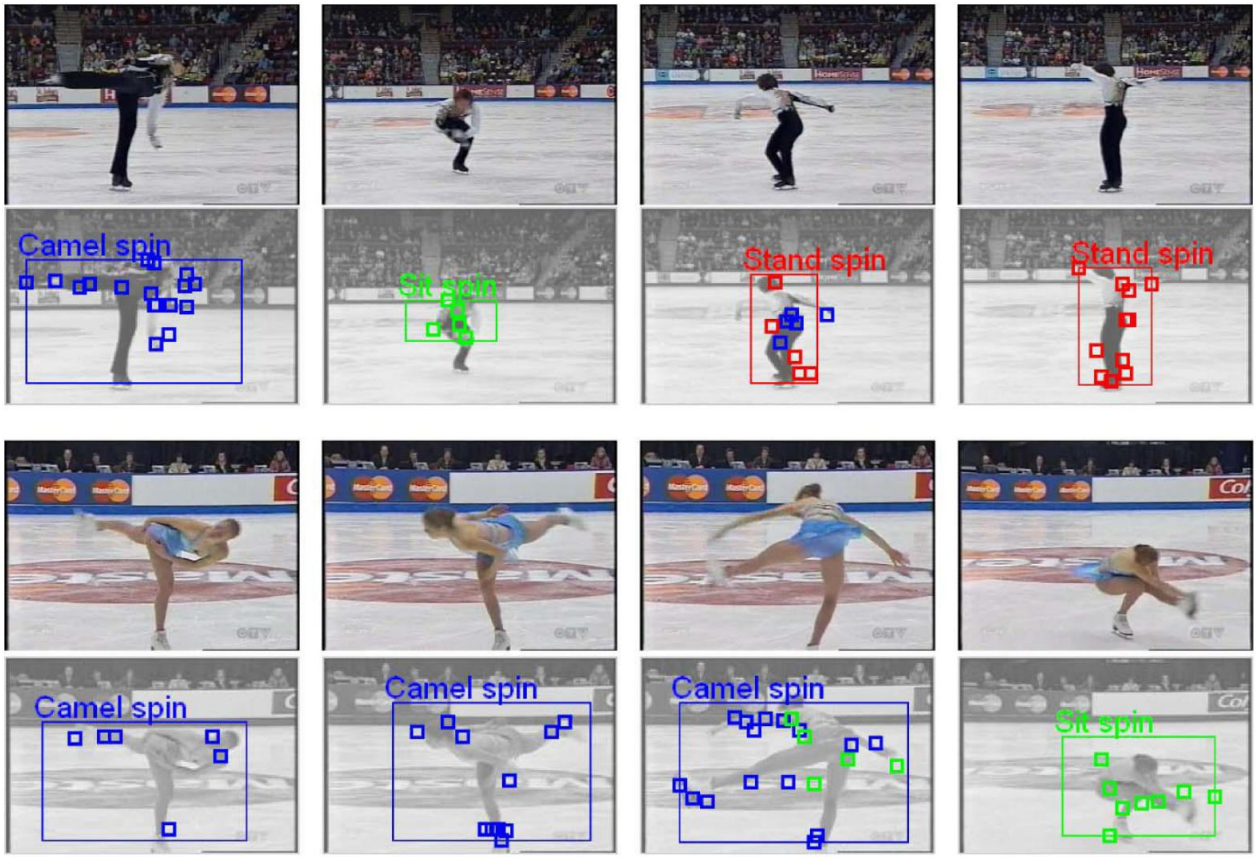


上部示例同时识别挥手与拍手。

下部示例同时识别奔跑与行走。

图中颜色标签沿用上一页。

Multiple Actions 多动作识别



花样滑冰动作类别包括燕式旋转、蹲转与直立旋转。

图中蓝色为燕式旋转，绿色为蹲转，红色为直立旋转。

Summary: Generative models 生成模型总结

- Naïve Bayes
  - *Unigram models* in document analysis
  - Assumes conditional independence of words given class
  - Parameter estimation: frequency counting
- Probabilistic Latent Semantic Analysis
  - Unsupervised technique
  - Each document is a mixture of topics (image is a mixture of classes)
  - Can be thought of as matrix decomposition
  - Parameter estimation: Expectation-Maximization

朴素贝叶斯对应文档分析中的一元词模型。给定类别后，假设各词条件独立。参数通过频率计数估计。

概率潜在语义分析是一种无监督技术，把每篇文档表示为主题混合，把图像表示为类别混合。

pLSA 可视为矩阵分解，参数采用期望最大化方法估计。

Adding spatial information 空间信息扩展

在整幅图像的各子窗口中计算特征袋。

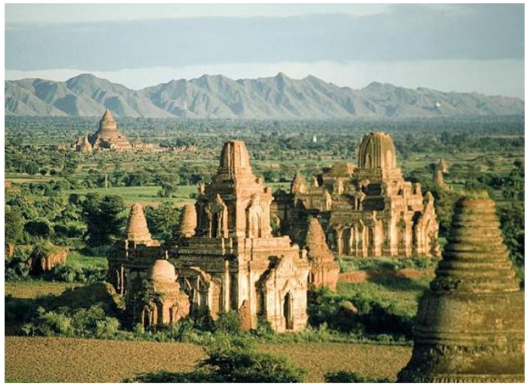
使用码本对物体位置投票。

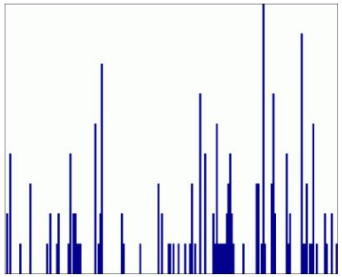
使用基于部件的生成模型。

- Computing bags of features on sub-windows of the whole image
- Using codebooks to vote for object position
- Generative part-based models

Spatial pyramid representation　空间金字塔表示

- Extension of a bag of features
- Locally orderless representation at several levels of resolution





特征袋的扩展，在多个分辨率层级建立局部无序表示。

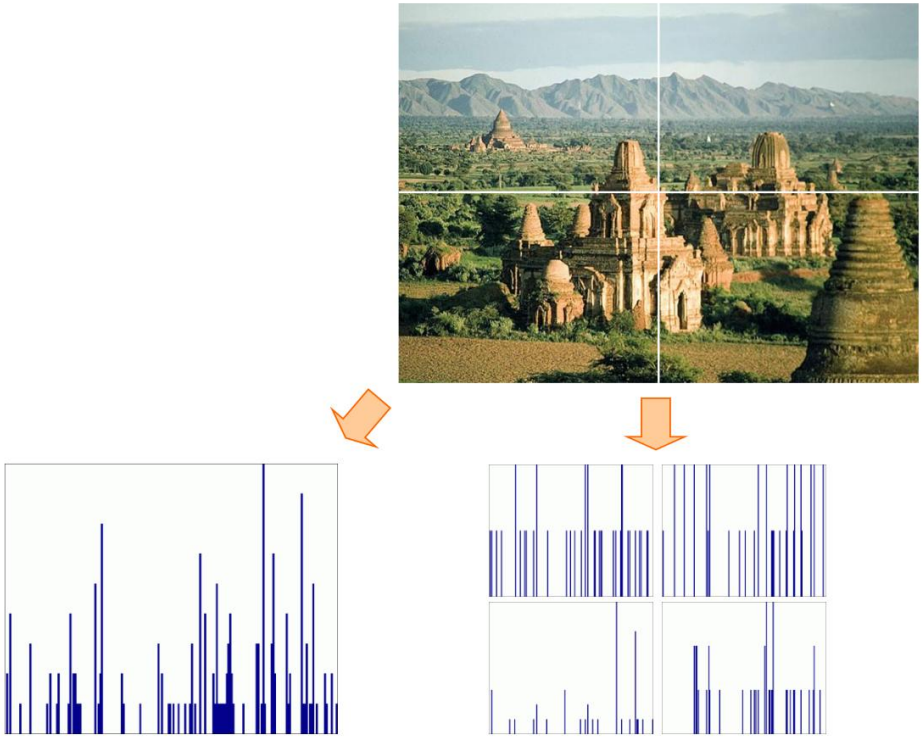
第 0 层将整幅图像作为一个区域。

Lazebnik、Schmid 与 Ponce，CVPR 2006。来源 S. Lazebnik。

Lazebnik, Schmid & Ponce (CVPR 2006)

Spatial pyramid representation　空间金字塔表示

- Extension of a bag of features
- Locally orderless representation at several levels of resolution



Lazebnik, Schmid & Ponce (CVPR 2006)

特征袋的扩展，在多个分辨率层级建立局部无序表示。

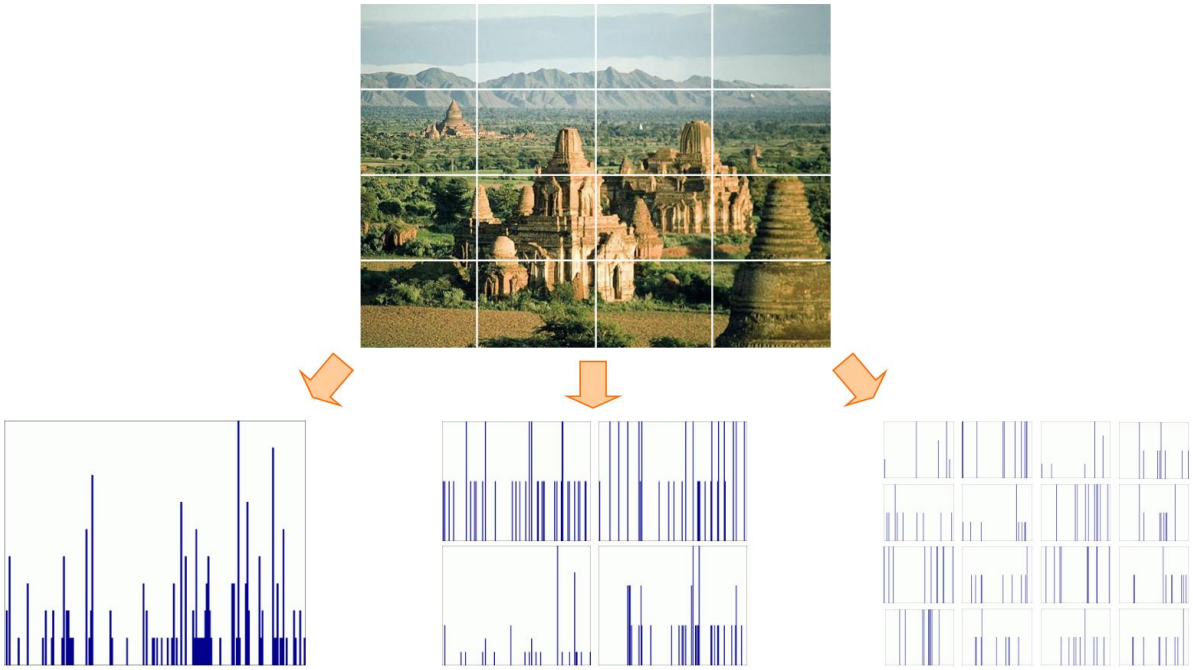
第 0 层将整幅图像作为一个区域。

第 1 层划分为 2×2 个子区域。

Lazebnik、Schmid 与 Ponce，CVPR 2006。来源 S. Lazebnik。

Spatial pyramid representation　空间金字塔表示

- Extension of a bag of features
- Locally orderless representation at several levels of resolution



Lazebnik, Schmid & Ponce (CVPR 2006)

特征袋的扩展，在多个分辨率层级建立局部无序表示。

第 0 层将整幅图像作为一个区域。

第 1 层划分为 2×2 个子区域。

第 2 层划分为 4×4 个子区域。

Lazebnik、Schmid 与 Ponce，CVPR 2006。来源 S. Lazebnik。

Scene category dataset　场景类别数据集



Multi-class classification results
(100 training images per class)

	Weak features (vocabulary size: 16)		Strong features (vocabulary size: 200)	
Level	Single-level	Pyramid	Single-level	Pyramid
0 (1 × 1)	45.3 ±0.5		72.2 ±0.6	
1 (2 × 2)	53.6 ±0.3	56.2 ±0.6	77.9 ±0.6	79.0 ±0.5
2 (4 × 4)	61.7 ±0.6	64.7 ±0.7	79.4 ±0.3	**81.1** ±0.3
3 (8 × 8)	63.3 ±0.8	**66.8** ±0.6	77.2 ±0.4	80.7 ±0.3

场景类别包括办公室、厨房、客厅、卧室、商店、工业场景、高层建筑、城市内部、街道、高速公路、海岸、开阔乡野、山地、森林与郊区。

多类别分类实验，每类 100 幅训练图像。弱特征词汇表大小为 16，强特征词汇表大小为 200。表中比较单层表示与金字塔表示。

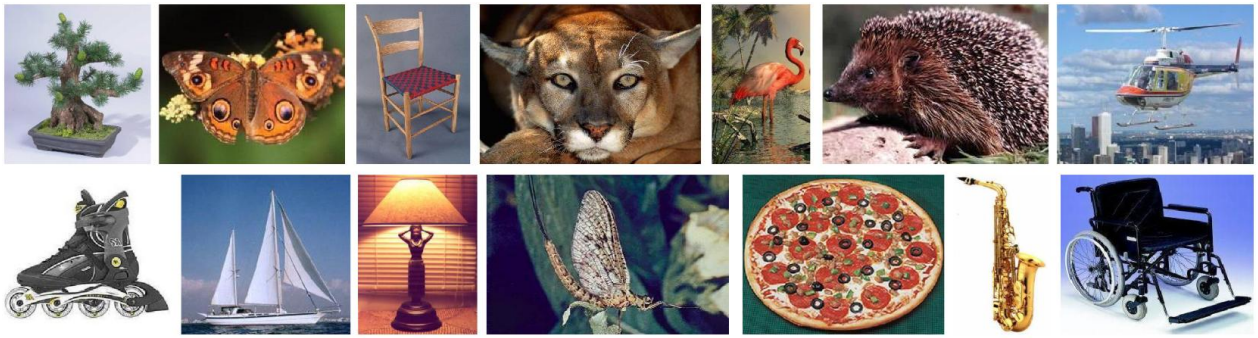
第 0 层 1×1，弱特征单层为 45.3±0.5，强特征单层为 72.2 ±0.6。

第 1 层 2×2，弱特征单层与金字塔为 53.6±0.3、56.2± 0.6，强特征为 77.9±0.6、79.0±0.5。

第 2 层 4×4，弱特征为 61.7 ±0.6、64.7±0.7，强特征为 79.4±0.3、81.1±0.3。

第 3 层 8×8，弱特征为 63.3 ±0.8、66.8±0.6，强特征为 77.2±0.4、80.7±0.3。

Caltech101 dataset　Caltech101 数据集



Multi-class classification results (30 training images per class)

	Weak features (16)		Strong features (200)	
Level	Single-level	Pyramid	Single-level	Pyramid
0	15.5 ±0.9		41.2 ±1.2	
1	31.4 ±1.2	32.8 ±1.3	55.9 ±0.9	57.0 ±0.8
2	47.2 ±1.1	49.3 ±1.4	63.6 ±0.9	**64.6** ±0.8
3	52.2 ±0.8	**54.0** ±1.1	60.3 ±0.9	64.6 ±0.7

多类别分类实验，每类 30 幅训练图像。弱特征词汇表大小为 16，强特征词汇表大小为 200。表中比较单层表示与金字塔表示。

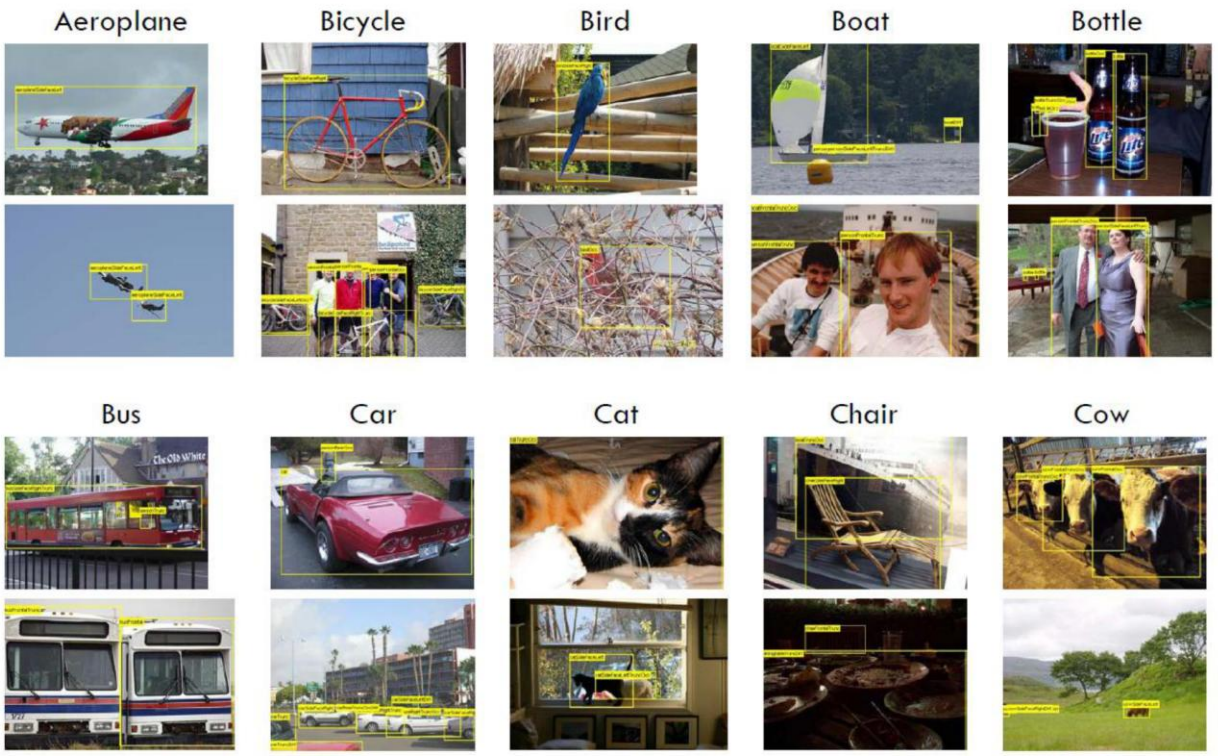
第 0 层，弱特征单层为 15.5±0.9，强特征单层为 41.2±1.2。

第 1 层，弱特征单层与金字塔为 31.4±1.2、32.8± 1.3，强特征为 55.9± 0.9、57.0±0.8。

第 2 层，弱特征为 47.2± 1.1、49.3±1.4，强特征为 63.6±0.9、64.6±0.8。

第 3 层，弱特征为 52.2± 0.8、54.0±1.1，强特征为 60.3±0.9、64.6±0.7。

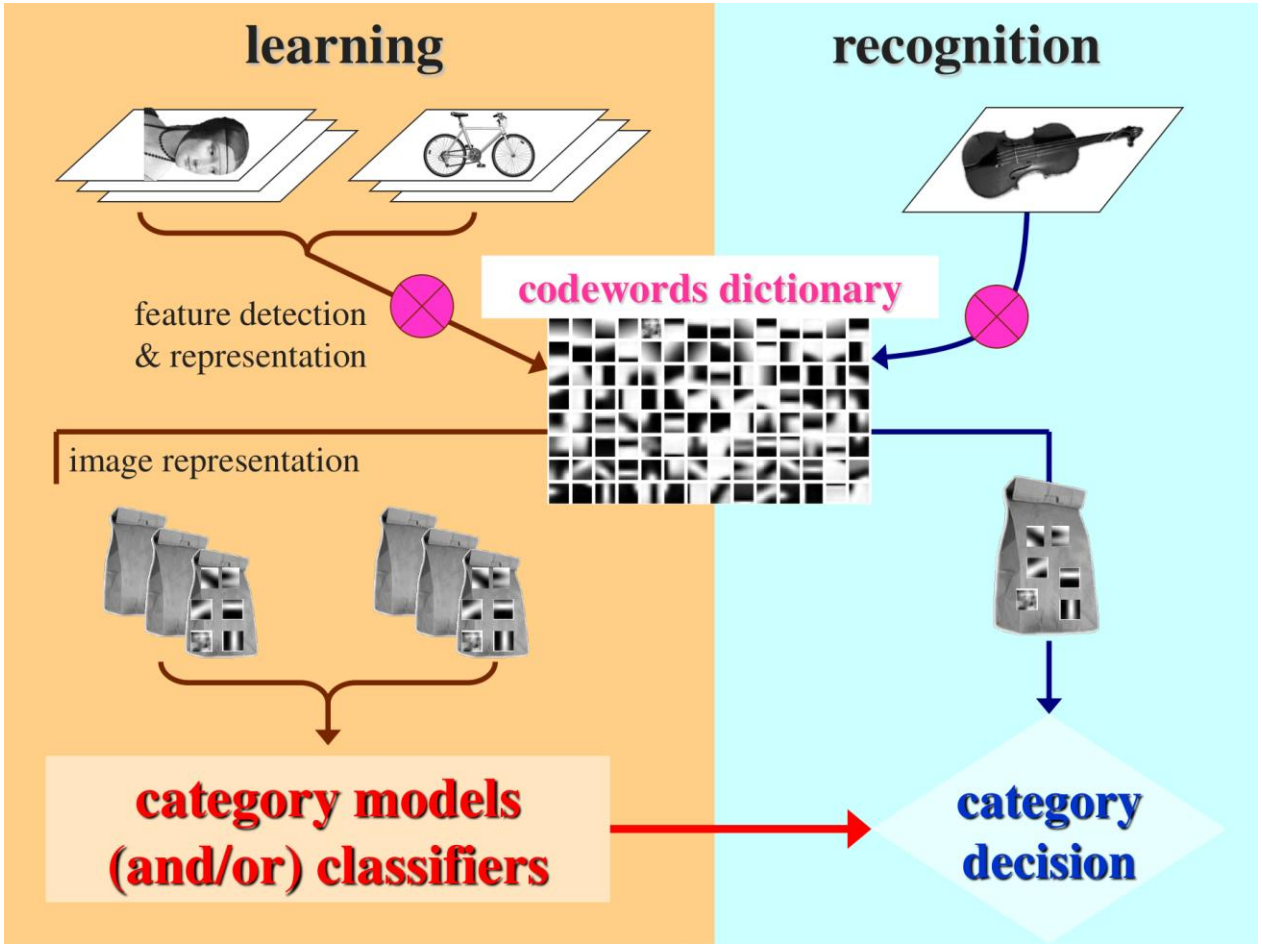
Examples from PASCAL VOC Challenge 2010
PASCAL VOC 2010 示例



图中标注的物体类别为飞机、自行车、鸟、船、瓶子、公交车、汽车、猫、椅子与牛。

黄色矩形框为物体位置标注。

视觉词分类流程

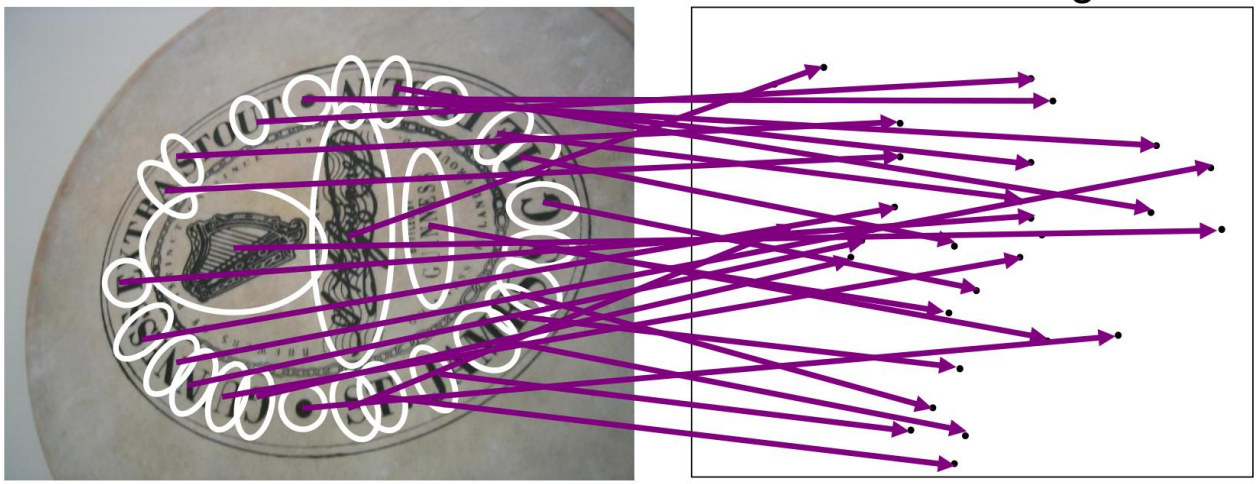


学习阶段，对训练图像进行特征检测与表示，建立码字字典，将图像转换为特征袋，学习类别模型或分类器。

识别阶段，以同一码字字典表示查询图像，并利用学习所得类别模型或分类器作出类别决策。

Example: Recognition with Vocabulary Tree 词汇树识别示例

- Extract some local features from a number of images …



e.g., SIFT descriptor space: each point is 128-dimensional

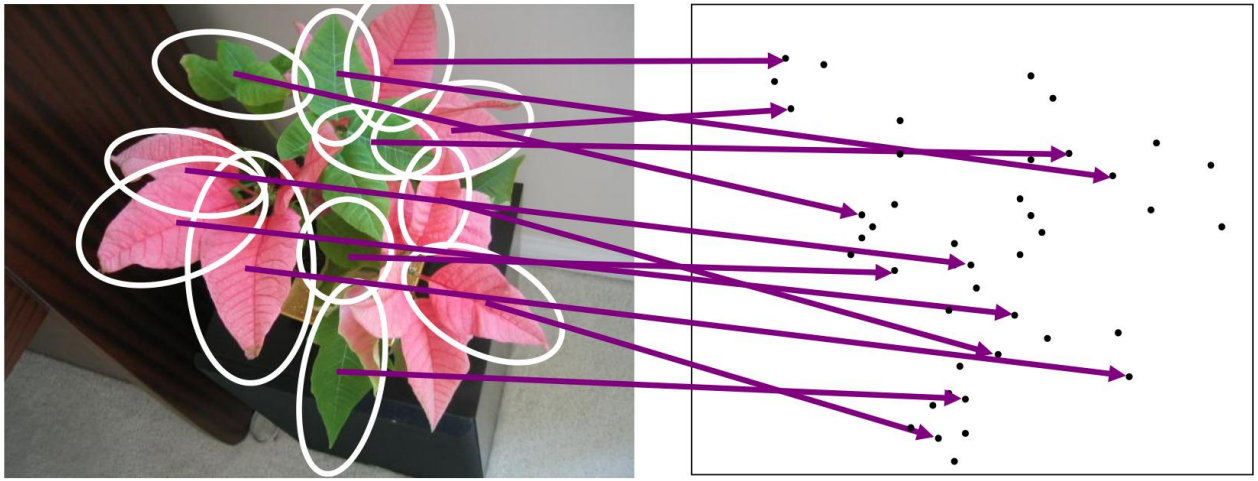
从多幅图像提取局部特征。

以 SIFT 描述子空间为例，每个点是一个 128 维描述子。

来源 D. Nistér。

Slide credit: D. Nister

Example: Recognition with Vocabulary Tree 词汇树识别示例

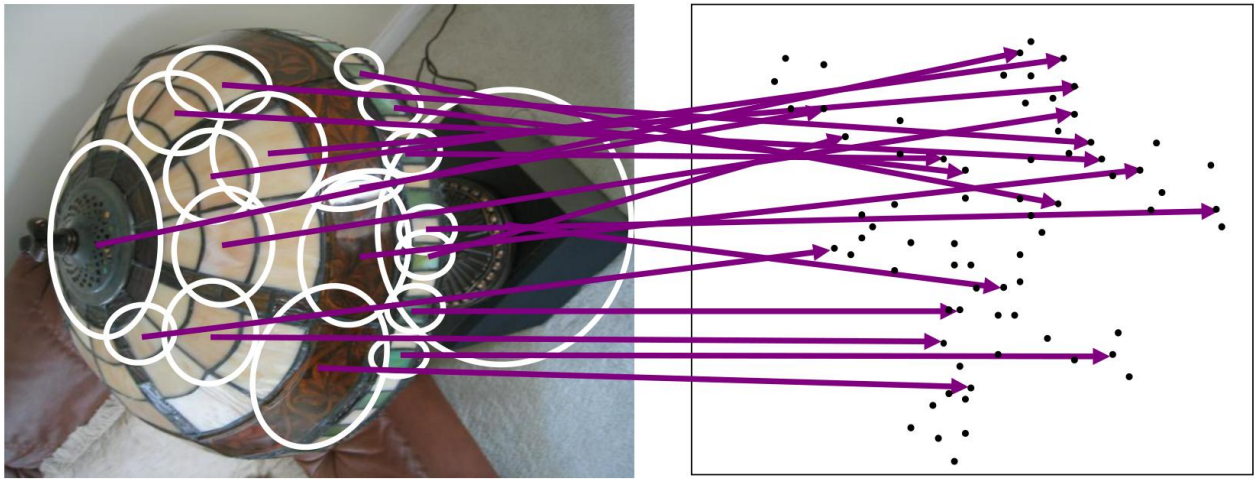


将各图像的局部特征映射到描述子空间，汇集为训练数据。

来源 D. Nistér。

Slide credit: D. Nister

Example: Recognition with Vocabulary Tree 词汇树识别示例

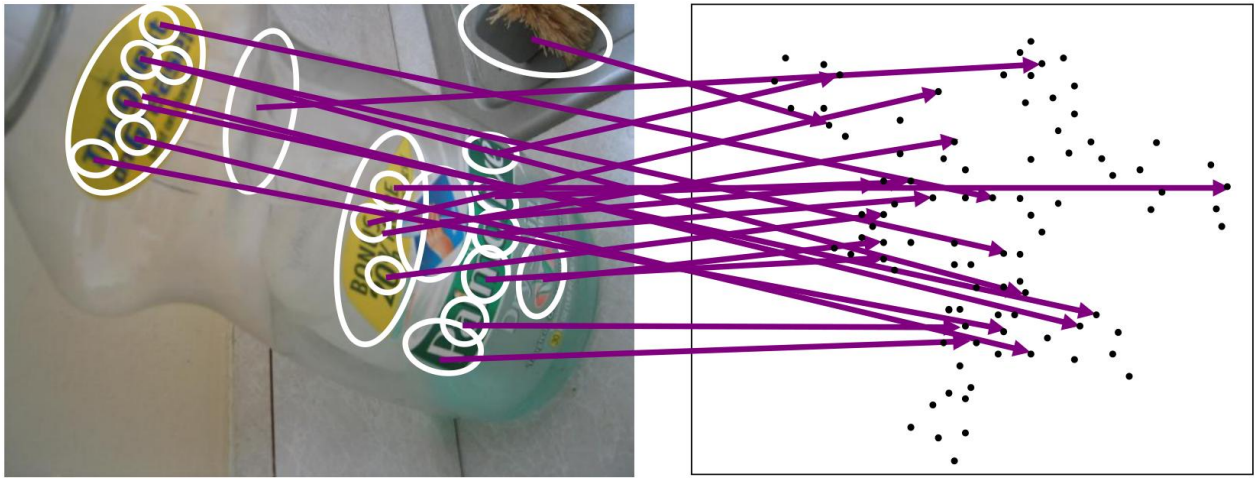


将各图像的局部特征映射到描述子空间，汇集为训练数据。

来源 D. Nistér。

Slide credit: D. Nister

Example: Recognition with Vocabulary Tree 词汇树识别示例

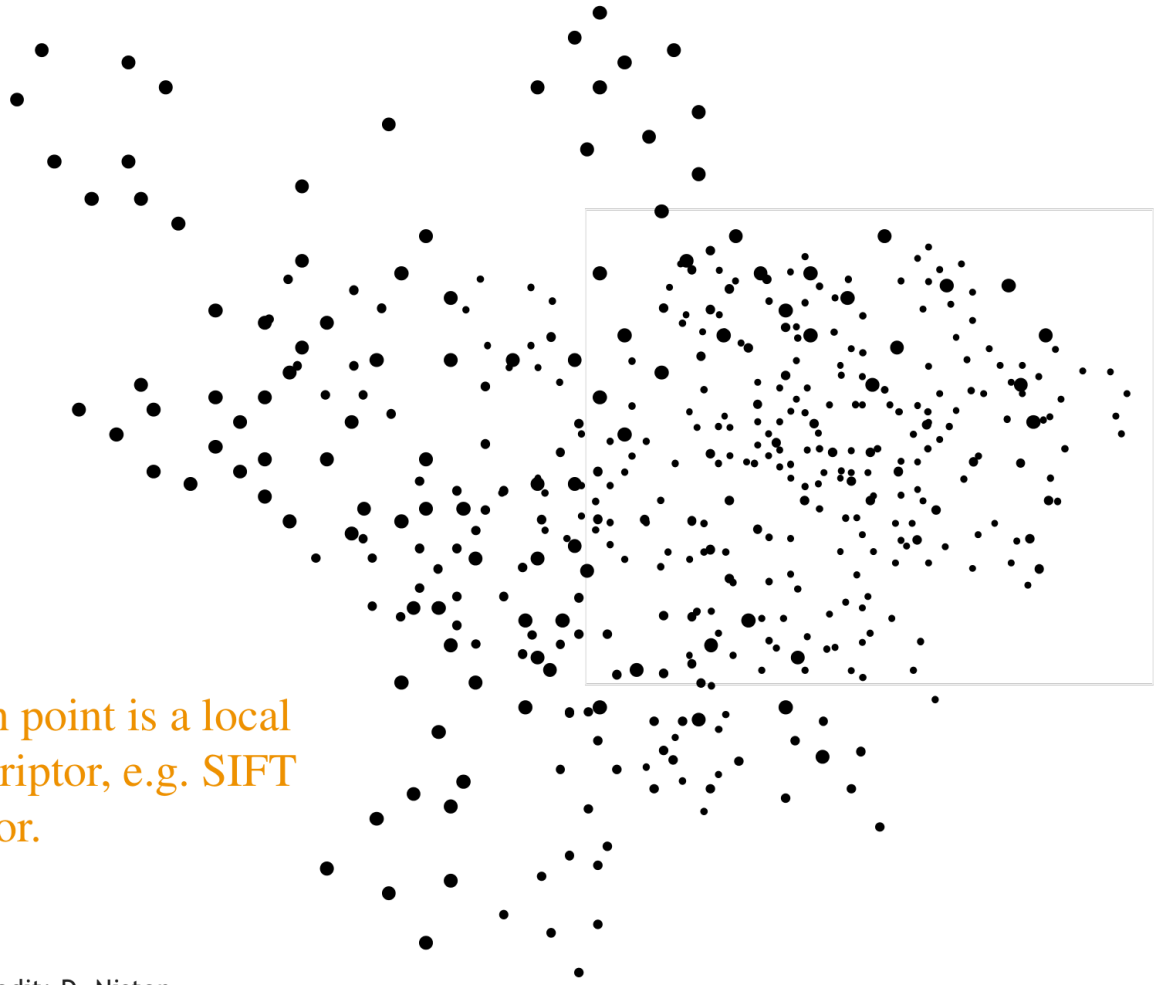


将各图像的局部特征映射到描述子空间，汇集为训练数据。

来源 D. Nistér。

Slide credit: D. Nister

局部描述子空间



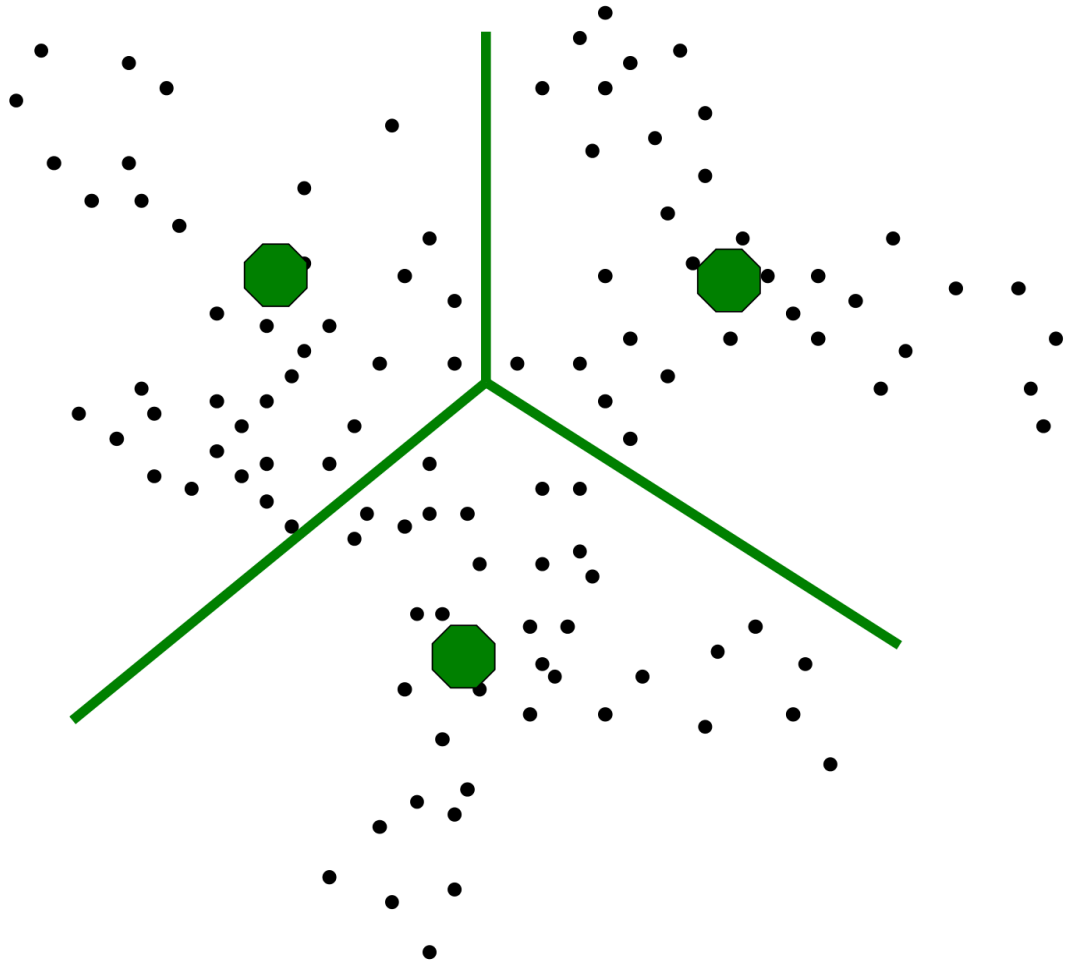
每个点对应一个局部描述子，例如 SIFT 向量。

来源 D. Nistér。

Each point is a local descriptor, e.g. SIFT vector.

Slide credit: D. Nister

描述子空间划分



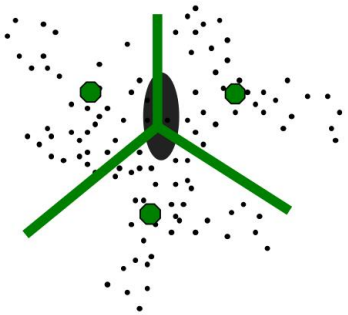
通过聚类划分描述子空间，各区域以聚类中心表示。

来源 D. Nistér。

Slide credit: D. Nister

Visual words 视觉词

- Example: each group of patches belongs to the same visual word



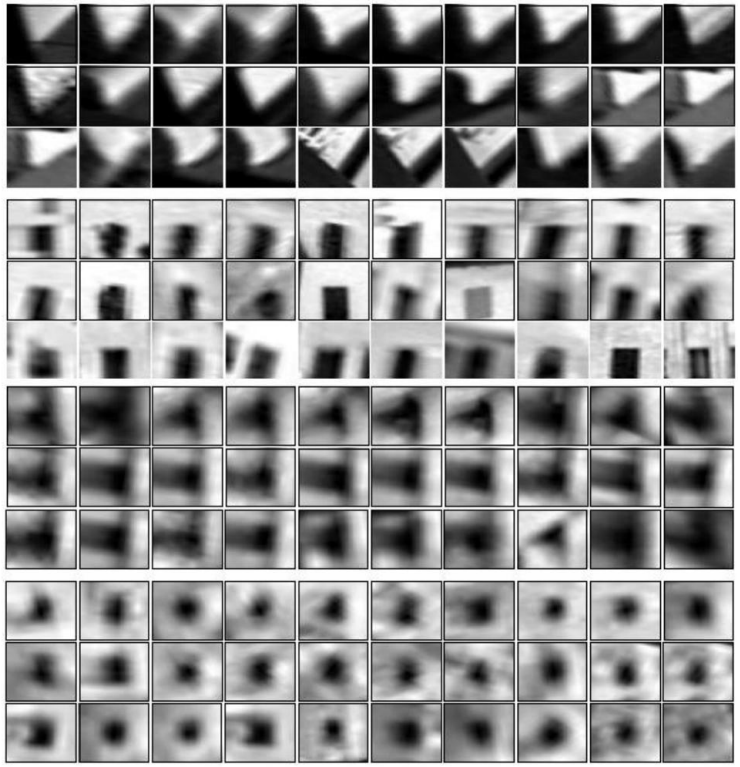


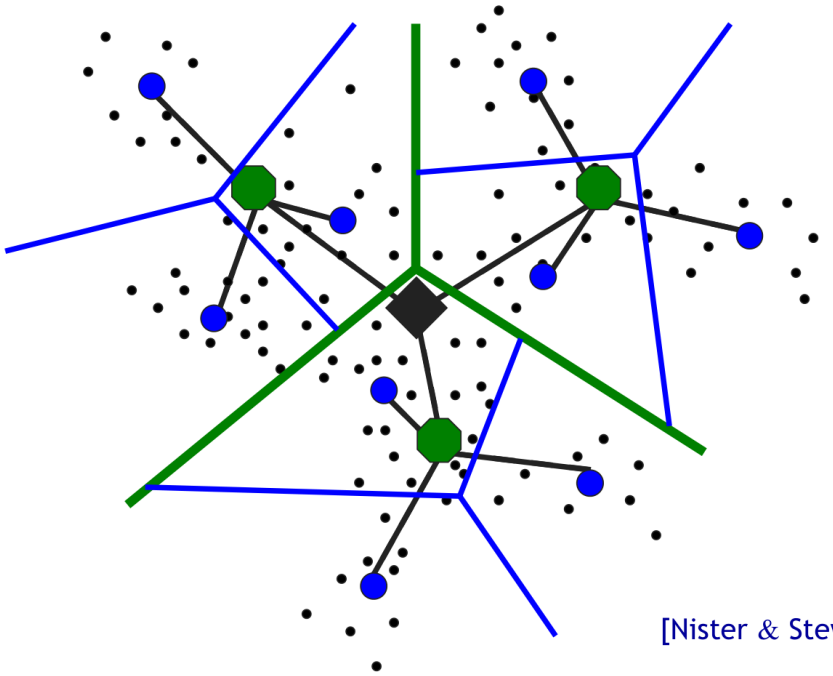
Figure from Sivic & Zisserman, ICCV 2003

每组图像块归入同一个视觉词。

来源 Sivic 与 Zisserman，ICCV 2003。

Example: Recognition with Vocabulary Tree 词汇树识别示例

- Tree construction:



[Nister & Stewenius, CVPR'06]

Slide credit: David Nister

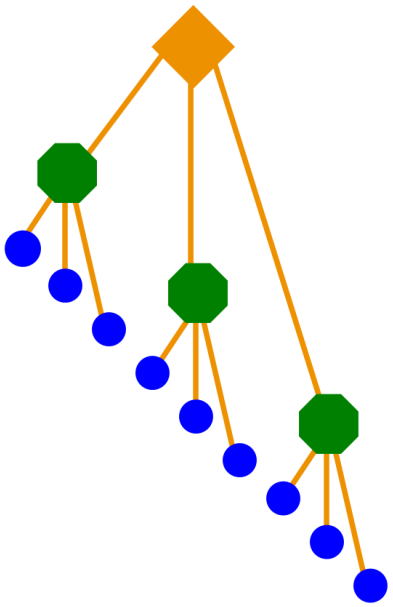
97

词汇树构建，对描述子空间进行层次聚类。

Nistér 与 Stewénius，CVPR 2006。来源 David Nistér。

Vocabulary Tree 词汇树

- Training: Filling the tree



[Nister & Stewenius, CVPR'06]

Slide credit: David Nister

98

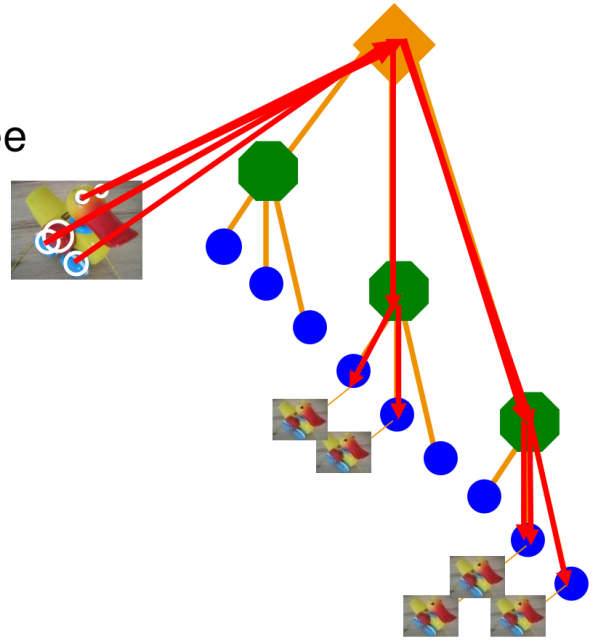
训练阶段填充词汇树。

将训练图像的局部描述子沿树逐层分配到相应节点，记录各图像与视觉词的关联。

Nistér 与 Stewénius，CVPR 2006。来源 David Nistér。

Vocabulary Tree 词汇树

- Training: Filling the tree



[Nister & Stewenius, CVPR'06]

99

Slide credit: David Nister

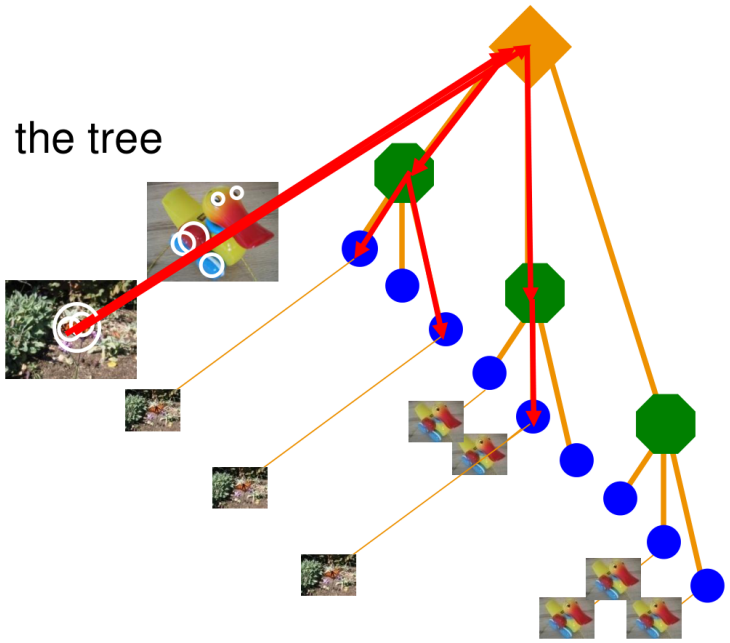
训练阶段填充词汇树。

将训练图像的局部描述子沿树逐层分配到相应节点，记录各图像与视觉词的关联。

Nistér 与 Stewénius，CVPR 2006。来源 David Nistér。

Vocabulary Tree 词汇树

- Training: Filling the tree



[Nister & Stewenius, CVPR'06]

Slide credit: David Nister

100

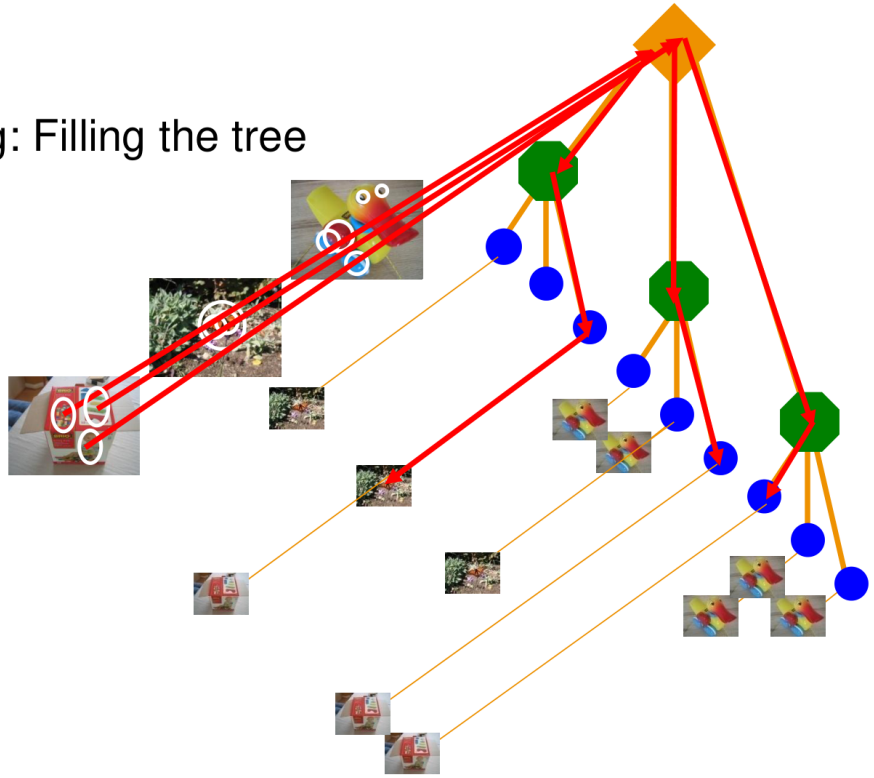
训练阶段填充词汇树。

将训练图像的局部描述子沿树逐层分配到相应节点，记录各图像与视觉词的关联。

Nistér 与 Stewénius，CVPR 2006。来源 David Nistér。

Vocabulary Tree 词汇树

- Training: Filling the tree



[Nister & Stewenius, CVPR'06]

Slide credit: David Nister

101

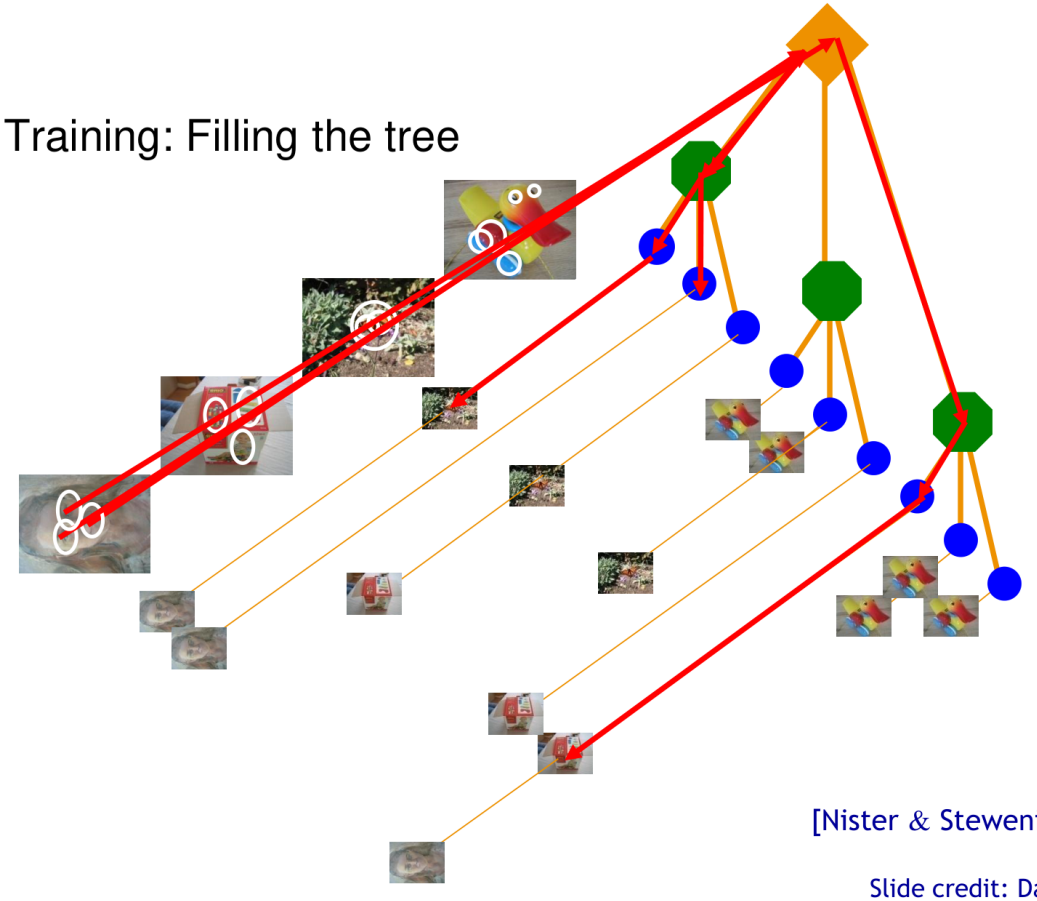
训练阶段填充词汇树。

将训练图像的局部描述子沿树逐层分配到相应节点，记录各图像与视觉词的关联。

Nistér 与 Stewénius，CVPR 2006。来源 David Nistér。

Vocabulary Tree 词汇树

- Training: Filling the tree



[Nister & Stewenius, CVPR'06]

Slide credit: David Nister

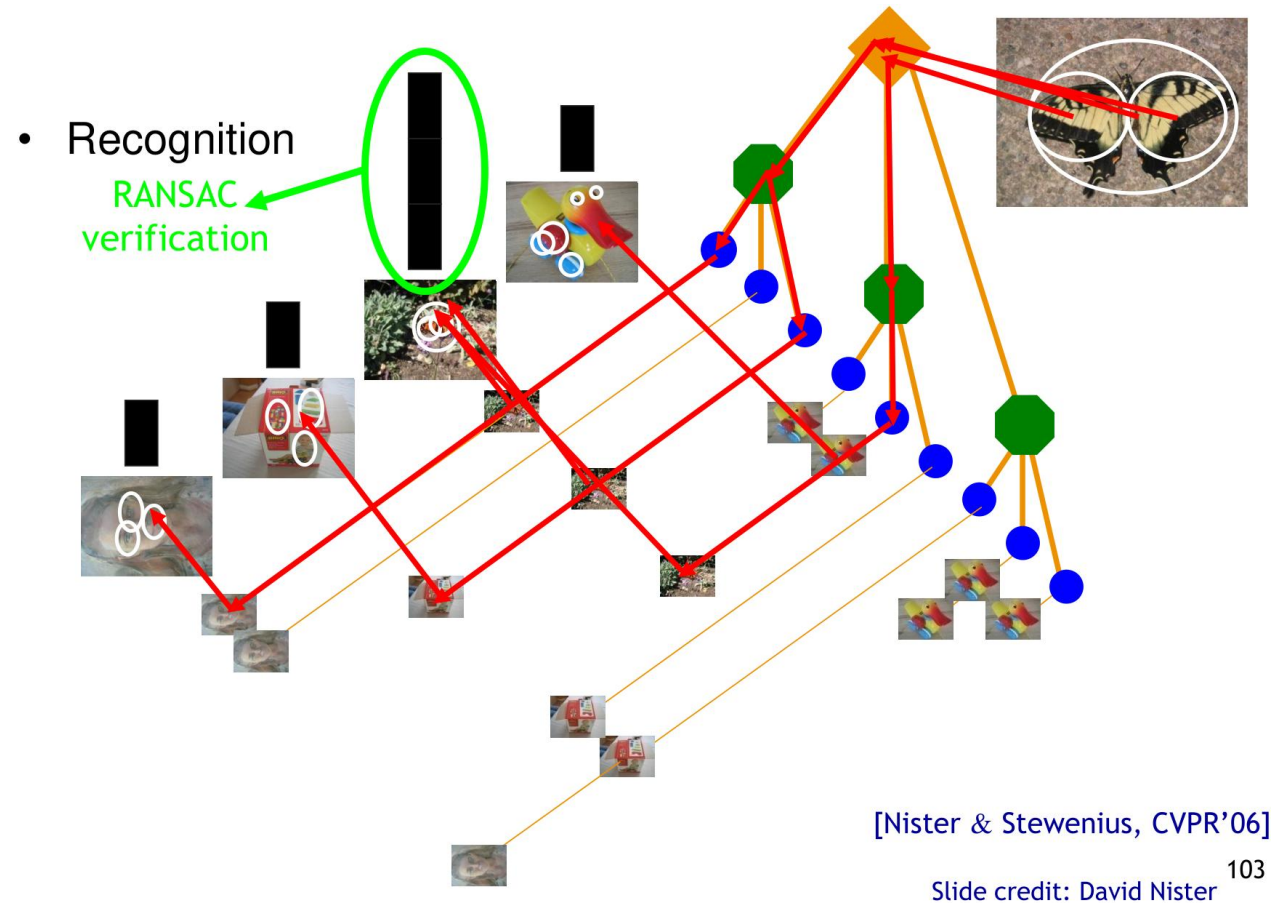
102

训练阶段填充词汇树。

将训练图像的局部描述子沿树逐层分配到相应节点，记录各图像与视觉词的关联。

Nistér 与 Stewénius，CVPR 2006。来源 David Nistér。

Vocabulary Tree 词汇树



[Nister & Stewenius, CVPR'06]

Slide credit: David Nister

103

识别阶段，把查询图像特征沿树量化，利用关联的训练图像检索候选结果。

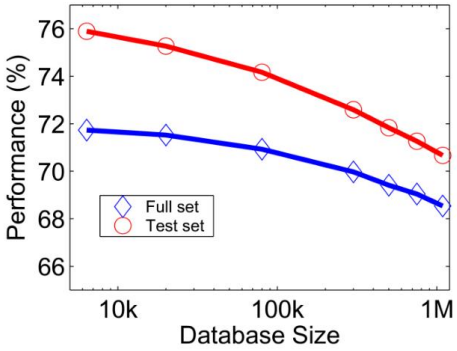
采用随机采样一致性 RANSAC 进行几何验证。

Nistér 与 Stewénius，CVPR 2006。来源 David Nistér。

Vocabulary Tree: Performance 词汇树性能

- Evaluated on large databases
  Indexing with up to 1M images
- Online recognition for database of 50,000 CD covers
  Retrieval in ~1s
- Find experimentally that large vocabularies can be beneficial for recognition

[Nister & Stewenius, CVPR'06]





104

在大规模数据库上评估，索引规模最高为 100 万幅图像。

在含 50000 张 CD 封面的数据库上进行在线识别，检索耗时约 1 秒。

实验表明，大词汇表有助于识别。

曲线横轴为数据库大小，纵轴为性能百分比，图例包含完整集与测试集。

Nistér 与 Stewénius，CVPR 2006。

The end！　课程结束

The end !