Computer Vision —— Object Recognition 计算机视觉——物体识别

2026 年 10 月 13 日
桑农
华中科技大学

2026/10/13
桑 农

Agenda 课程提纲

Agenda

- Introduction
- Objects & Faces recognition
- Bag-of-words models
- Part-based models
- Deep Networks

概述
物体与人脸识别
视觉词袋模型
基于部件的模型
深度网络

Deep Convolutional Networks 深度卷积网络

- Convolution
- Pooling
- Activation Function
- Softmax Activation Function
- Norm
- Loss Function
- Attention

卷积

池化

激活函数

Softmax 激活函数

归一化

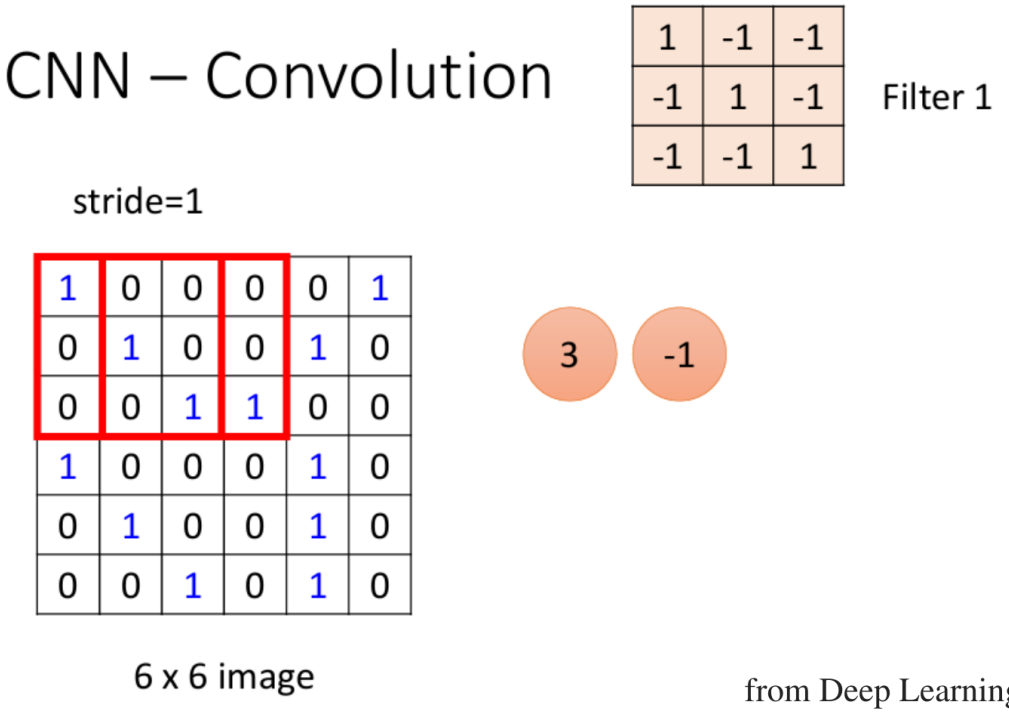
损失函数

注意力

Deep Convolutional Networks　深度卷积网络

- Convolution

General



卷积的一般过程。图中以步长 1 的滤波器扫描 6×6 图像，计算局部区域与卷积核的加权和，得到特征图。

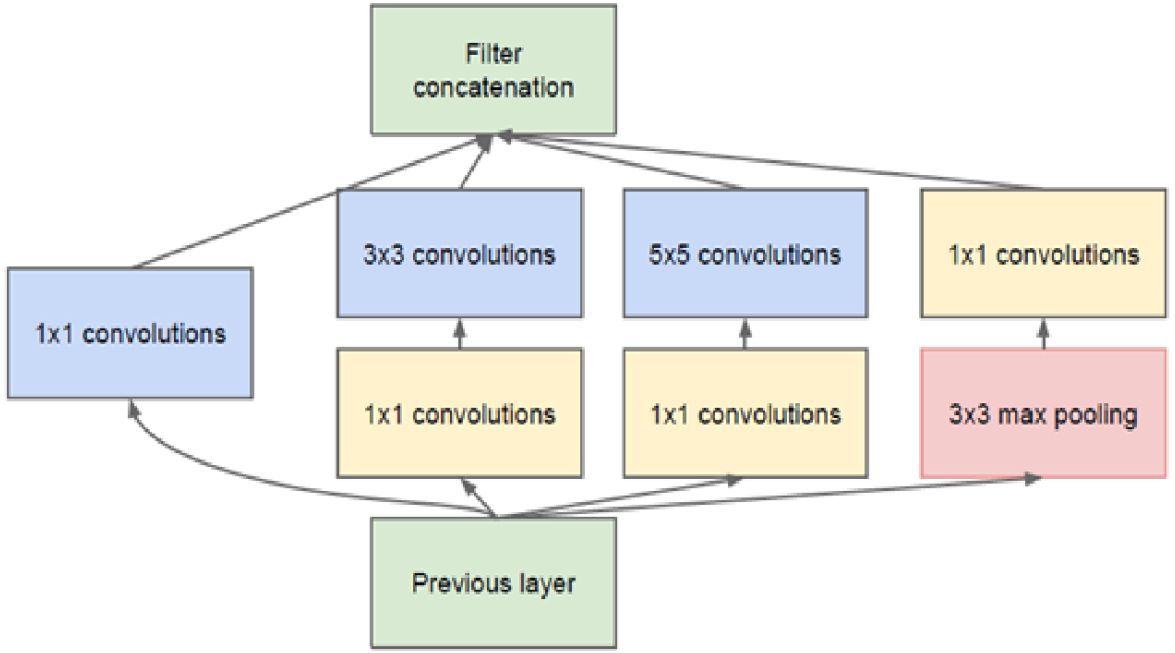
Filter 1 为滤波器 1。参考李宏毅深度学习课程。

from Deep Learning Tutorial with 李宏毅

Deep Convolutional Networks　深度卷积网络

- Convolution

  Inception（GoogleNet）：在一层中提取不同尺度的特征



Inception V1

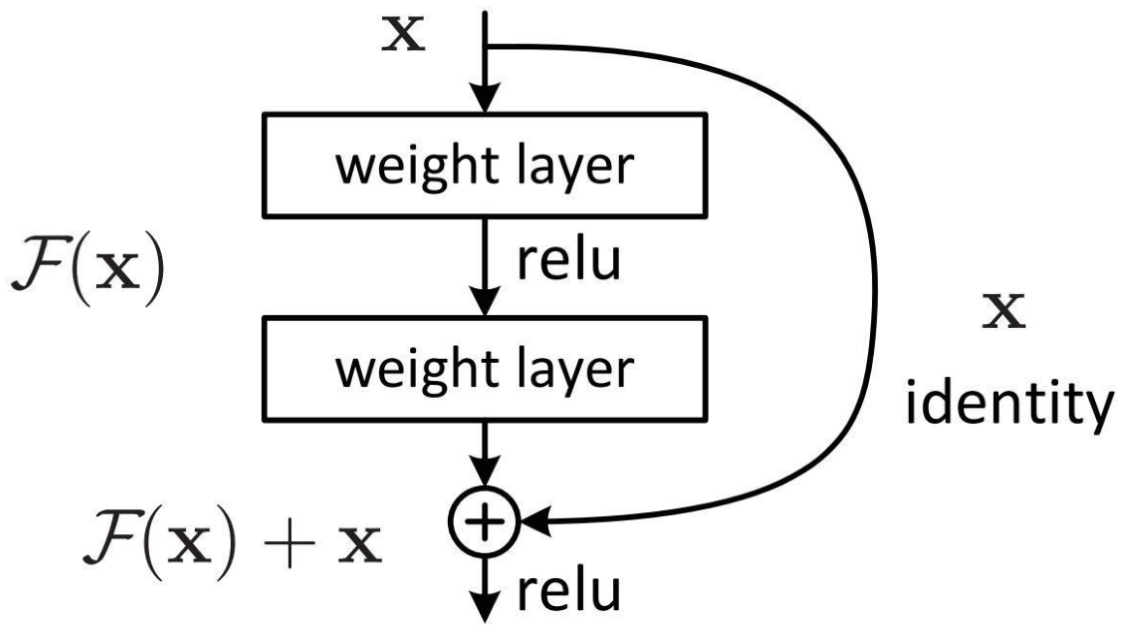
卷积模块 Inception V1。Inception（GoogleNet）在同一层提取多种尺度的特征。

各分支分别使用 1×1、3×3、5×5 卷积以及 3×3 最大池化。部分分支通过 1×1 卷积压缩通道。各分支输出沿通道维拼接。

Deep Convolutional Networks　深度卷积网络

- Convolution

  ResNet：缓解反向传播算法的梯度消失和爆炸问题



残差网络 ResNet。其作用为缓解反向传播过程中的梯度消失与梯度爆炸。

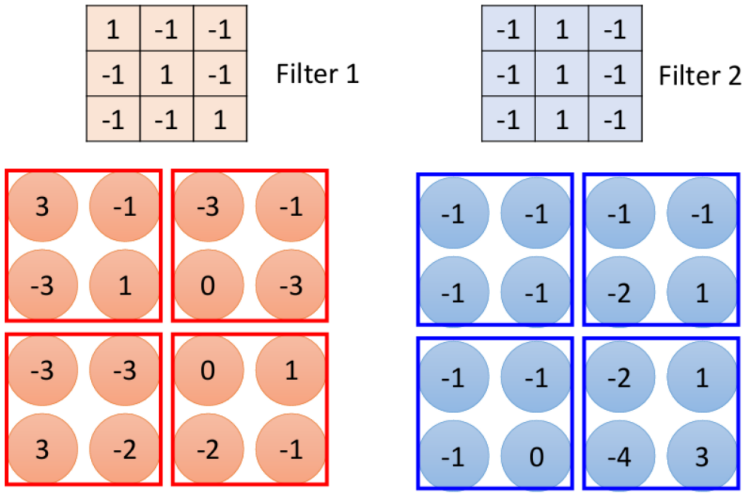
weight layer 为权重层，identity 为恒等映射。残差分支学习 F(x)，与输入 x 相加形成 F(x)+x，经过 ReLU 得到输出。

Deep Convolutional Networks　深度卷积网络

- Pooling

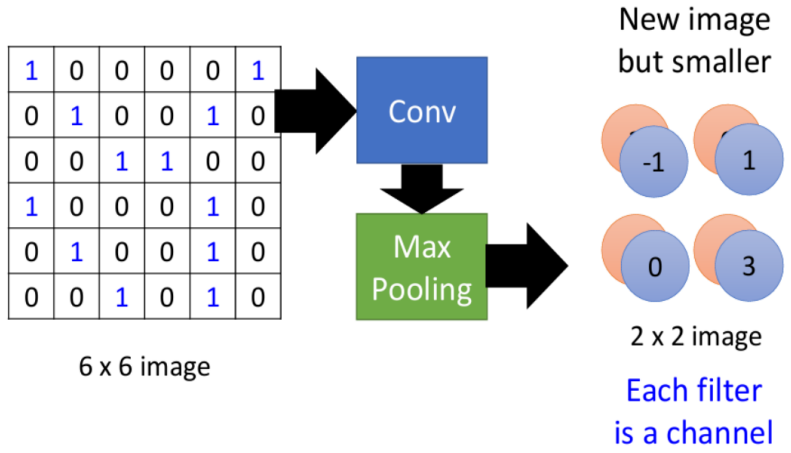
Max Pooling

CNN – Max Pooling



Average Pooling

CNN – Max Pooling



from Deep Learning Tutorial with 李宏毅

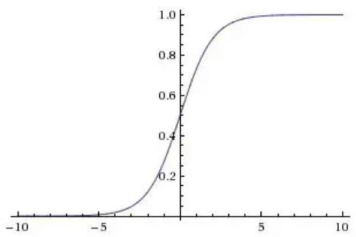
池化分为最大池化与平均池化。最大池化选取局部区域的最大值，平均池化计算局部区域的均值。

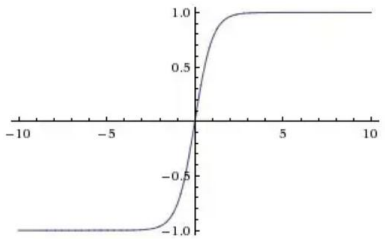
每个滤波器产生一个通道。图中卷积与池化逐步缩小特征图的空间尺寸。参考李宏毅深度学习课程。

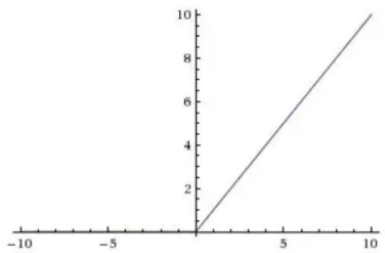
Deep Convolutional Networks　深度卷积网络

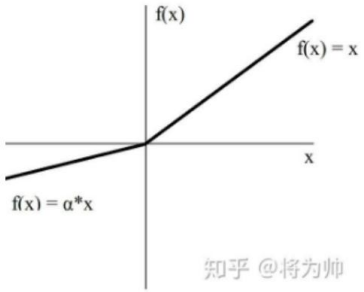
- Activation Function

Sigmoid	Tanh	ReLU	LeakyReLU
$f(x)=\frac{1}{1+e^{-x}}$	$f(x)=\frac{e^{x}-e^{-x}}{e^{x}+e^{-x}}$	$f(x)=\max(0,x)$	$f(x)=\begin{cases}x & if\ x\geq 0\\ \alpha x & if\ x<0\end{cases}$







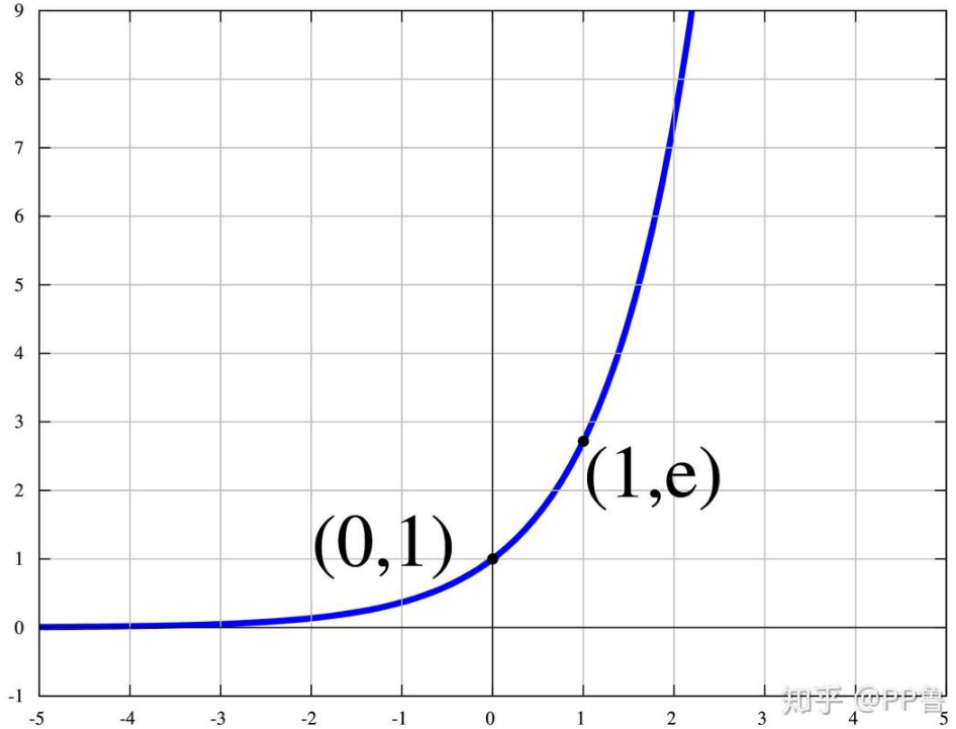


激活函数包括 Sigmoid、双曲正切 Tanh、线性整流单元 ReLU 与带泄漏的线性整流单元 LeakyReLU。

Sigmoid 将输入映射至 0 到 1，Tanh 映射至 −1 到 1。ReLU 为 max(0,x)。LeakyReLU 在 x≥0 时取 x，在 x<0 时取 αx。

- Softmax Activation Function

$$\text{Softmax}(x_i) = \frac{e^{x_i}}{\sum_j e^{x_j}}$$

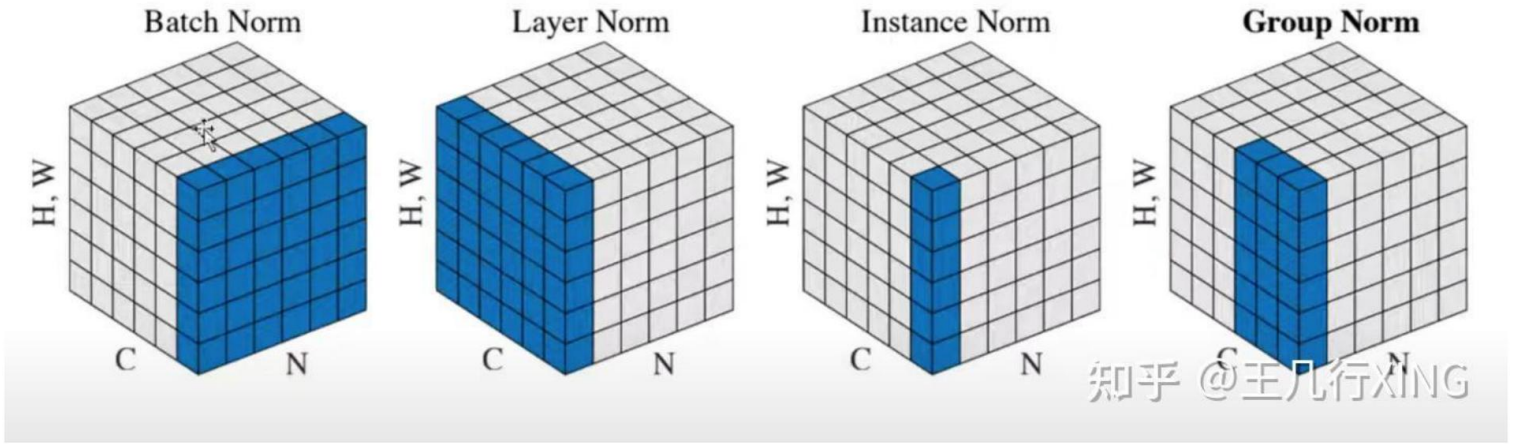


Softmax 激活函数。第 i 个输出等于 $\exp(x_i)$ 除以全部 $\exp(x_j)$ 之和，各分量总和为 1。

下图绘出指数函数的变化，标出了 (0,1) 与 (1,e)，用于说明指数运算。

Deep Convolutional Networks　深度卷积网络

- Norm



跨样本单通道　　单样本跨通道　　单样本单通道　　单样本跨若干通道

归一化方法。N 表示样本，C 表示通道，H、W 表示空间尺寸，蓝色区域表示共同计算统计量的元素。

Batch Norm 为批归一化，跨样本、单通道。Layer Norm 为层归一化，单样本、跨通道。Instance Norm 为实例归一化，单样本、单通道。Group Norm 为组归一化，单样本、跨若干通道。

Deep Convolutional Networks　深度卷积网络

- Loss Fuction

Regression Loss

$$MAE = \frac{1}{n}\sum_{i=1}^{n}|y_i - \hat{y}_i|$$

$$MSE = \frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2$$

Classification Loss

$$L = -\frac{1}{n}\sum_{i=1}^{n}\sum_{k}^{k-1} y_{ik}\log(\hat{y}_{ik})$$

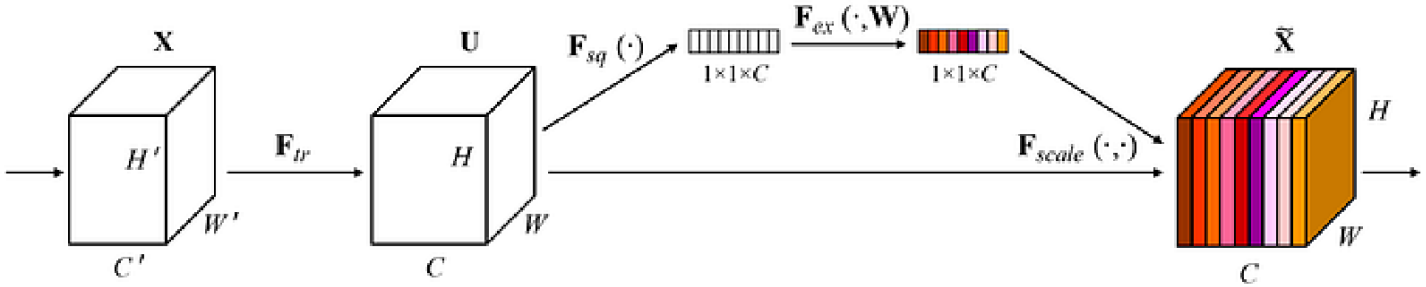
$$L = -\frac{1}{n}\sum_{i=1}^{n}[y_i\log(\hat{y}_i) + (1-y_i)\log(1-\hat{y}_i)]$$

损失函数。回归损失包含平均绝对误差 MAE 与均方误差 MSE，分别平均计算 $|y_i-\hat{y}_i|$ 与 $(y_i-\hat{y}_i)^2$。

分类损失图示为多分类交叉熵与二元交叉熵。y 表示真实标签，$\hat{y}$ 表示预测概率，n 为样本数。

- Attention

  Channel Attention: Squeeze and Excitation Network (SENet)



$$\sigma_i(y_i) = \frac{\exp(y_i)}{\sum_{j=1}^{n}\exp(y_j)}$$

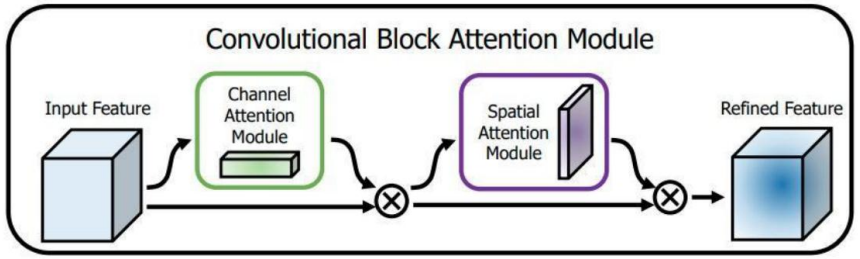
注意力机制。通道注意力示例为压缩与激励网络 SENet。

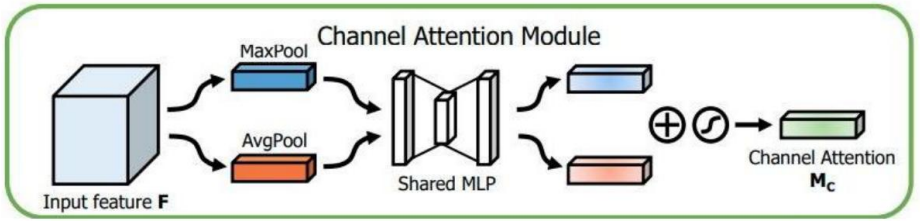
输入经过特征变换得到 U。压缩操作汇聚空间信息，激励操作生成各通道权重，缩放操作对各通道特征加权。H、W、C 分别表示高度、宽度与通道数。下方为 Softmax 形式的归一化公式。

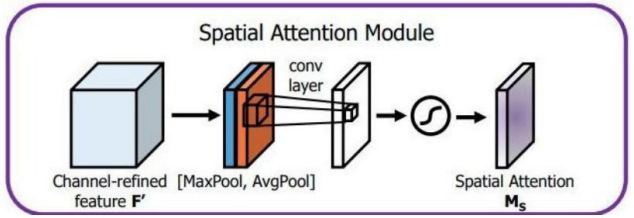
Deep Convolutional Networks　深度卷积网络

- Attention

  Spatial-Channel Attention：Convolutional Block Attention Module（CBAM）



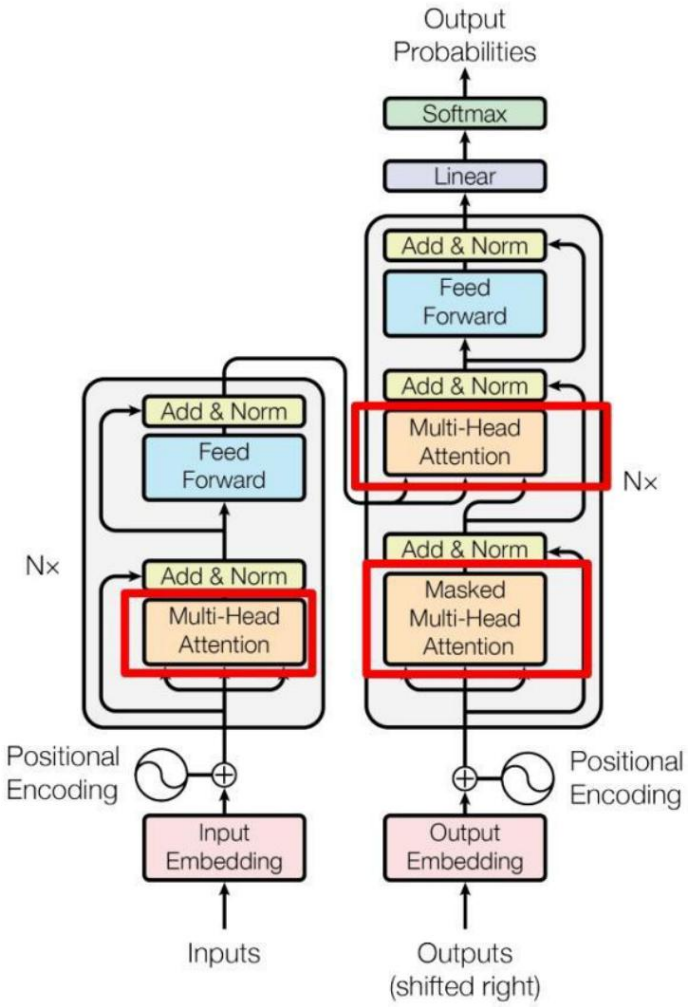




空间与通道注意力示例为卷积块注意力模块 CBAM。输入特征依次经过通道注意力和空间注意力，形成细化特征。

通道模块使用最大池化、平均池化、共享多层感知机及 Sigmoid 生成权重 M_c。空间模块对通道细化特征作池化与卷积，生成权重 M_s。乘号表示逐元素加权。

Transformer　Transformer 架构

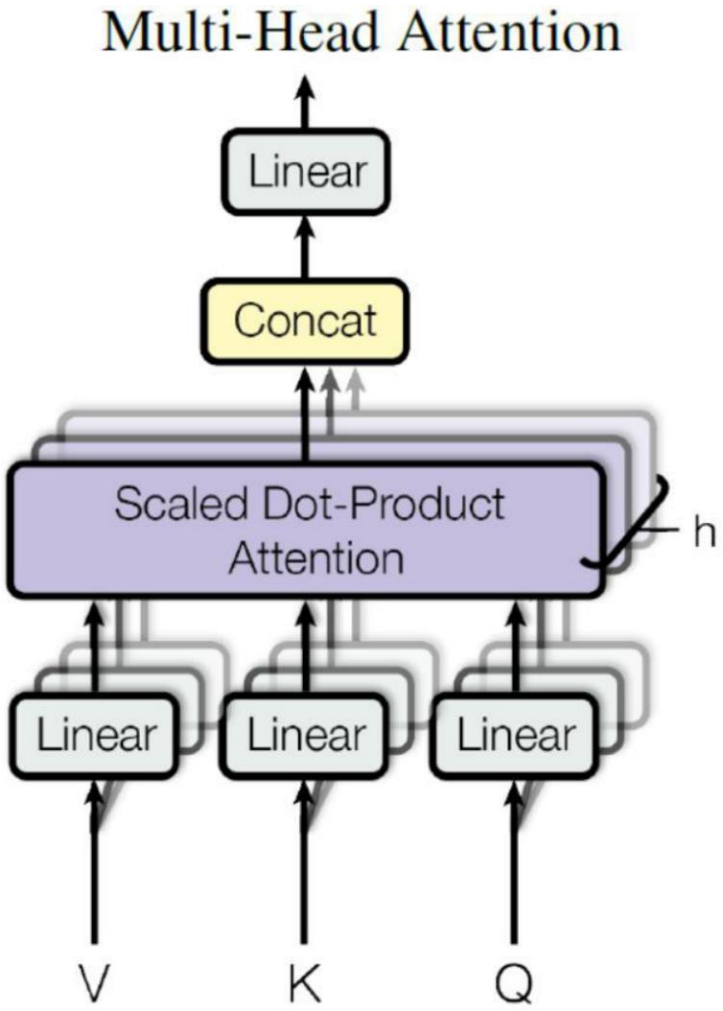


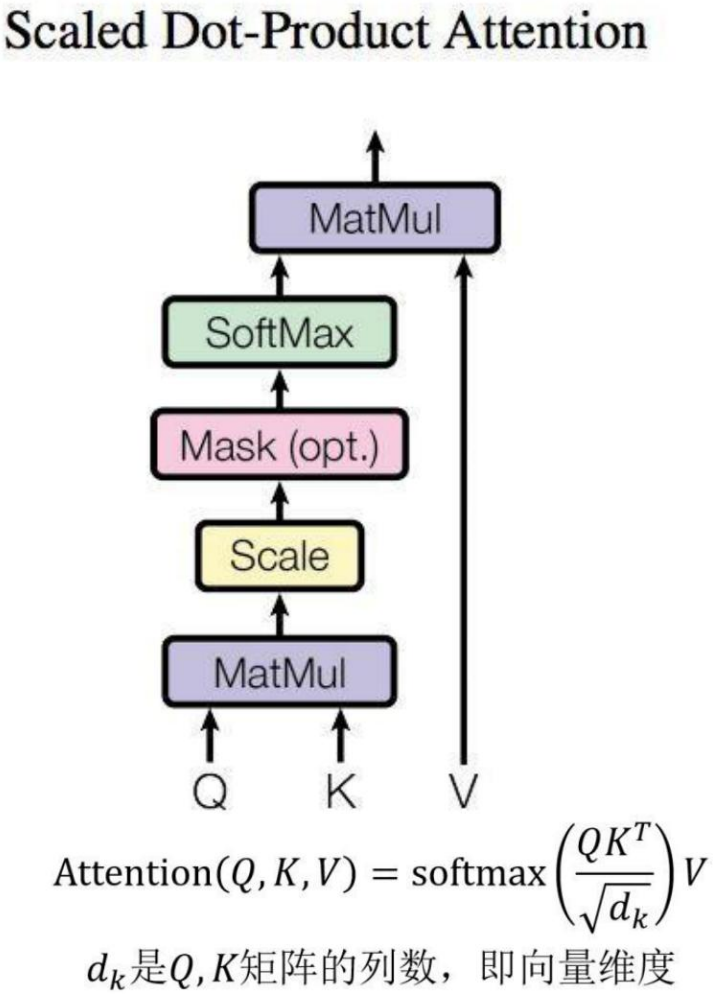
左侧为重复 N 次的编码器，右侧为重复 N 次的解码器。输入嵌入与位置编码相加。

编码器包含多头注意力、前馈网络以及残差相加与归一化。解码器包含掩码多头注意力、对编码器输出的多头注意力和前馈网络。

右移的输出序列经输出嵌入进入解码器，最终通过线性层和 Softmax 得到输出概率。

Transformer　Transformer 注意力





$$\text{Attention}(Q,K,V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

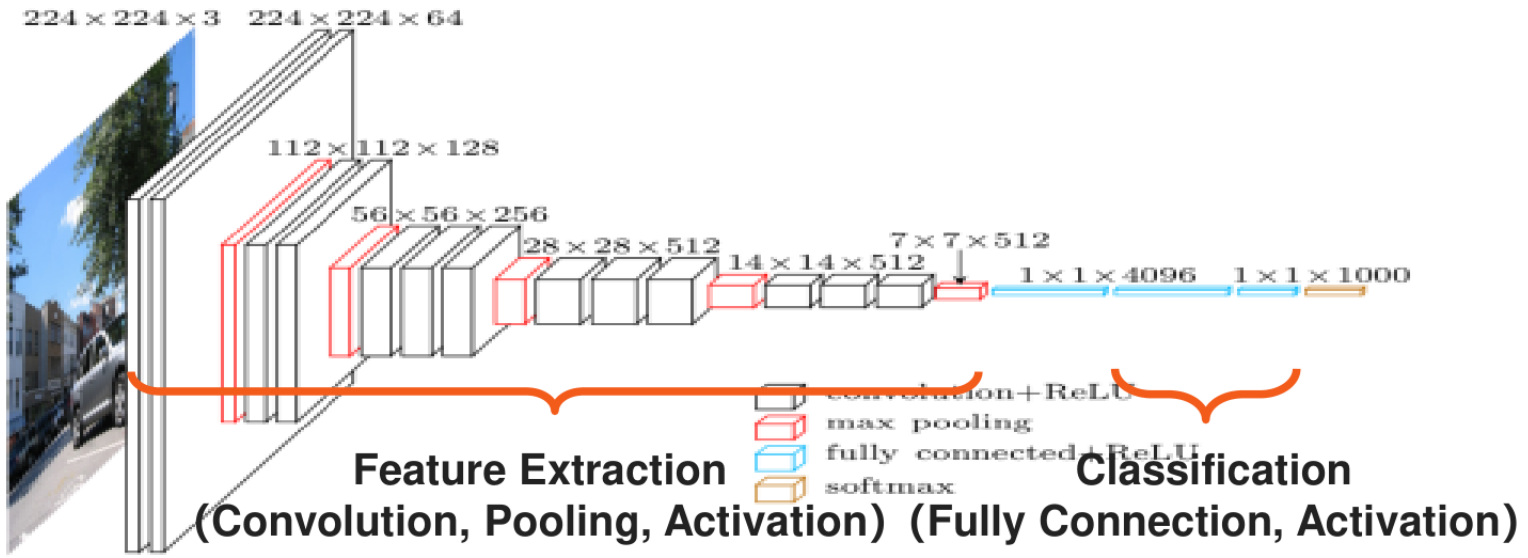
d_k是Q,K矩阵的列数，即向量维度

多头注意力将查询 Q、键 K、值 V 分别作线性投影，平行计算 h 组缩放点积注意力，拼接各组输出并作线性变换。

缩放点积注意力计算 $QK^T/\sqrt{d_k}$，可选地施加掩码，经 Softmax 后与 V 相乘。d_k 是 Q、K 的向量维度。MatMul 为矩阵乘法，Concat 为拼接。

Recognition 物体识别



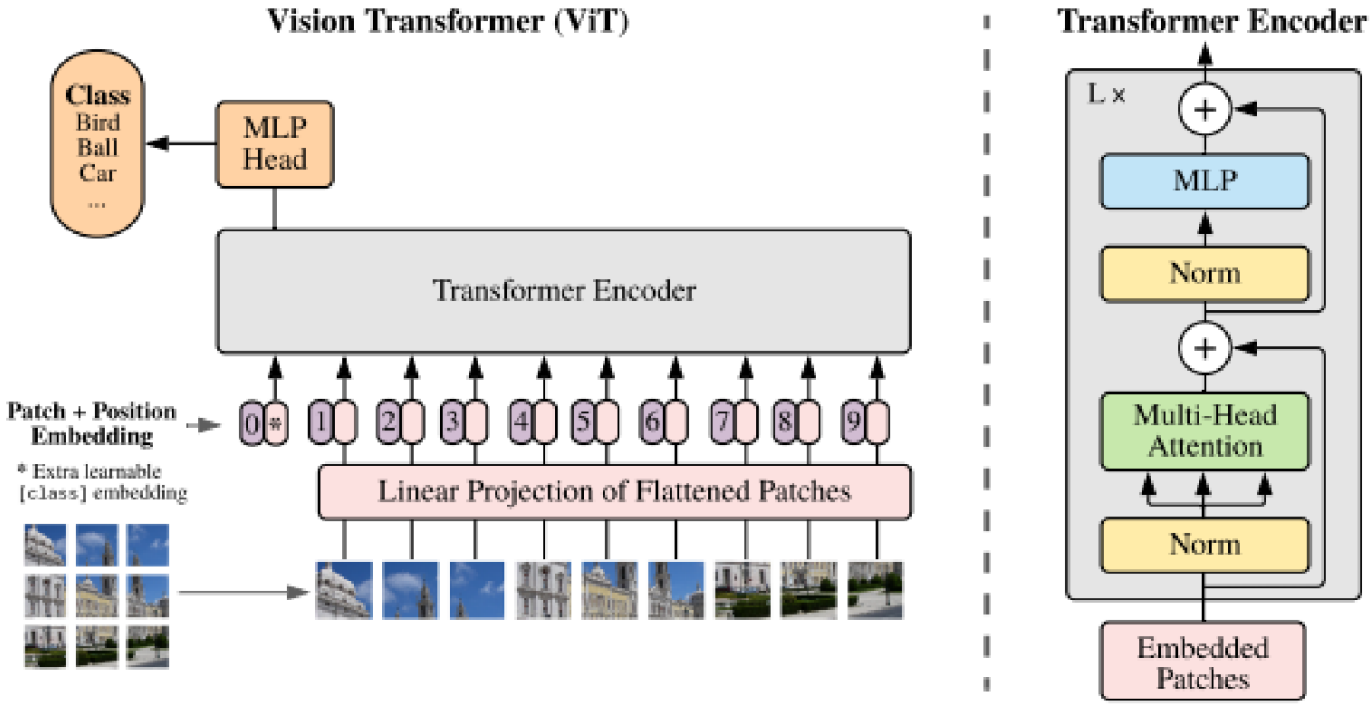


传统流程通过方向梯度直方图 HOG 提取特征，使用支持向量机 SVM、线性分类器等完成分类。

卷积网络通过卷积、池化与激活完成特征提取，通过全连接层和激活完成分类。

Recognition 物体识别

- ViT

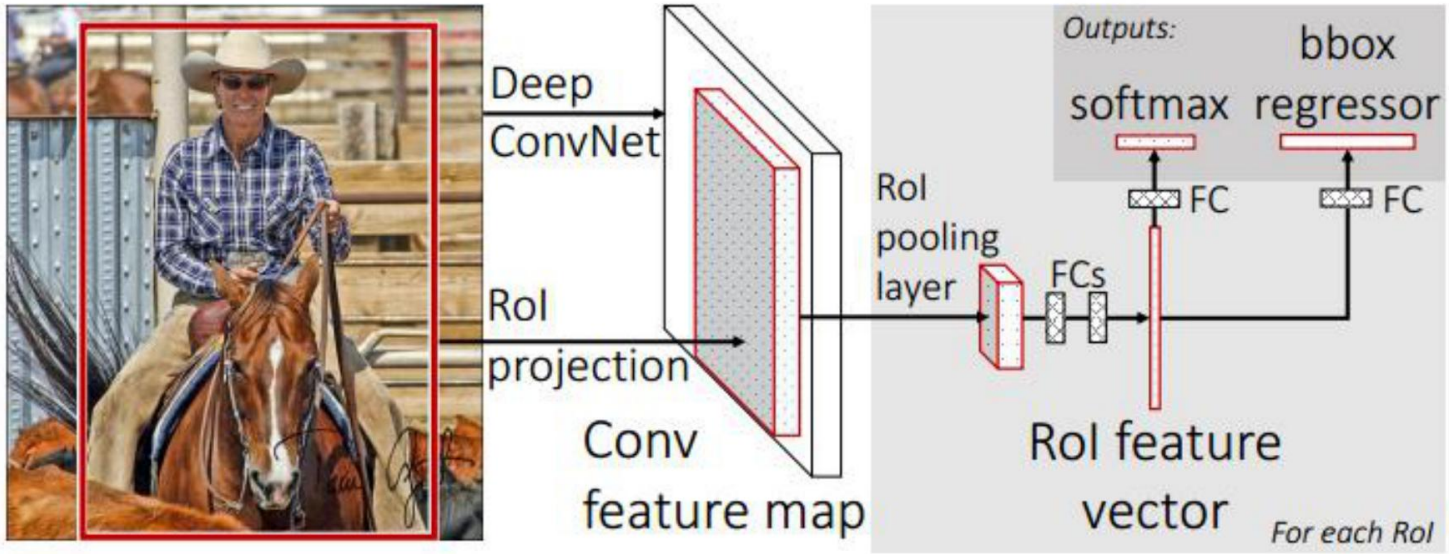


视觉 Transformer（ViT）将图像划分为图像块，展平各块并作线性投影，加入位置嵌入和可学习的分类标记。

序列经过 Transformer 编码器，分类标记的输出送入多层感知机分类头。右图编码器由归一化、多头注意力、多层感知机与残差相加组成，重复 L 次。

Detection　目标检测

- Faster R-CNN

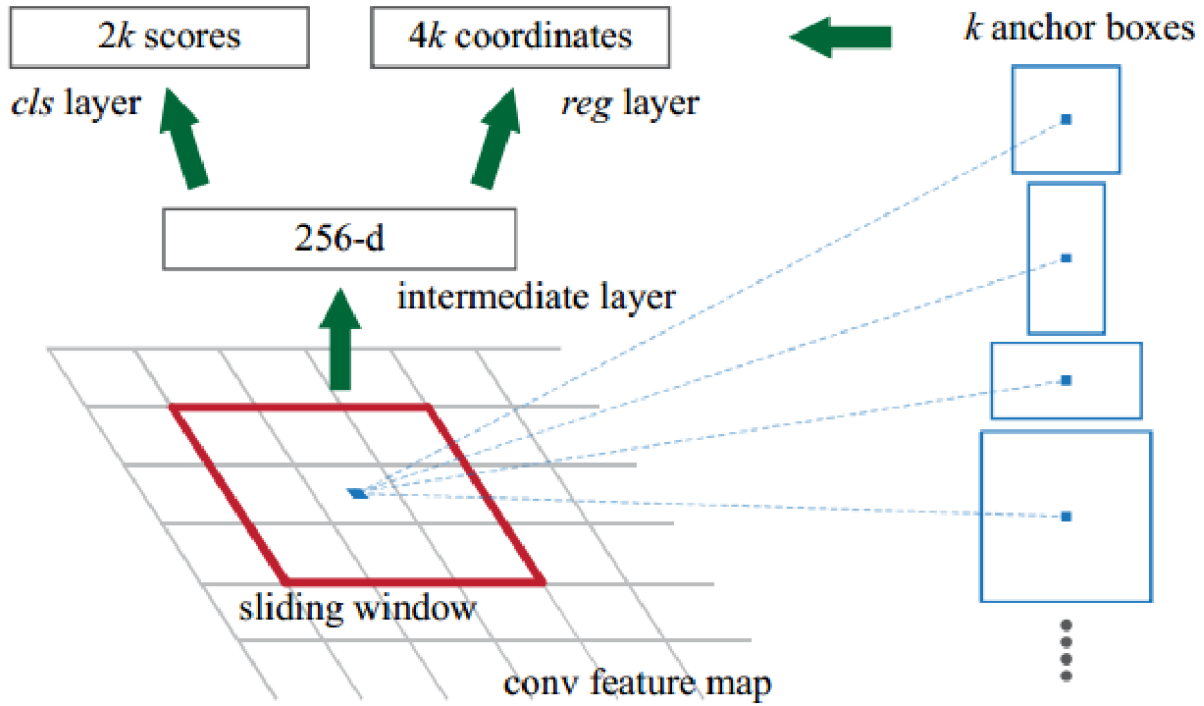


Faster R-CNN。图示展示区域分类与边界框回归流程。深度卷积网络提取卷积特征图，感兴趣区域 RoI 投影到特征图上。

RoI 池化将区域转换为固定尺寸特征，经全连接层形成特征向量，由 Softmax 输出类别，由边界框回归器输出位置。

Detection 目标检测

- Faster R-CNN

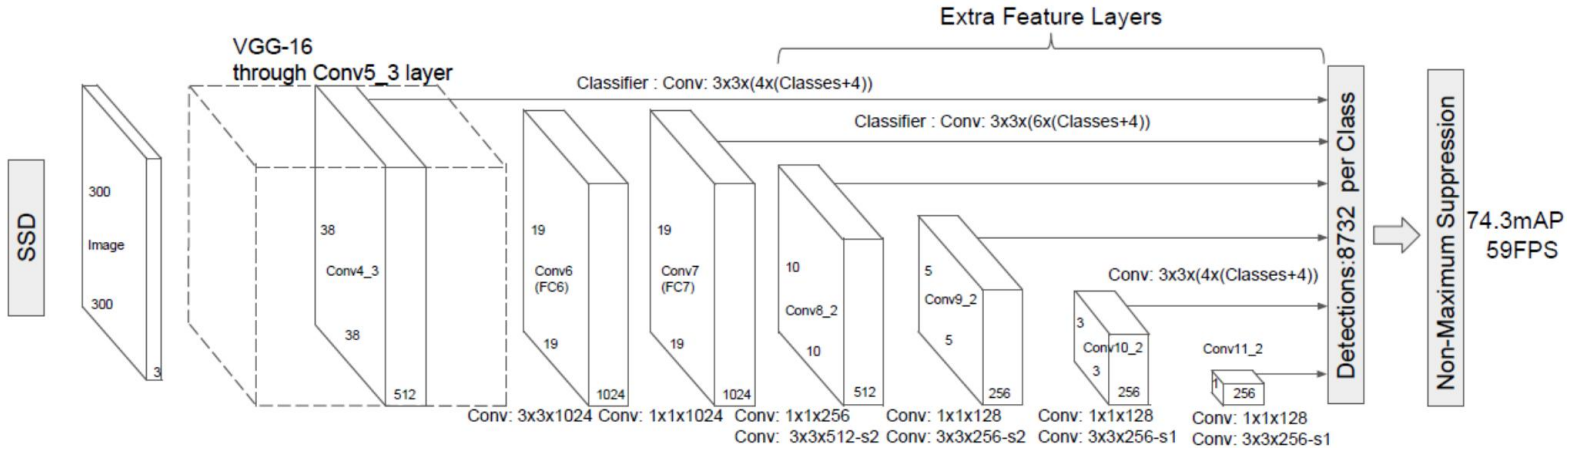


Faster R-CNN 的区域建议网络。滑动窗口遍历卷积特征图，形成 256 维中间特征。

每个位置设 k 个锚框，分类层输出 2k 个前景与背景分数，回归层输出 4k 个坐标参数。

Detection　目标检测

- SSD：Single Shot MultiBox Detector

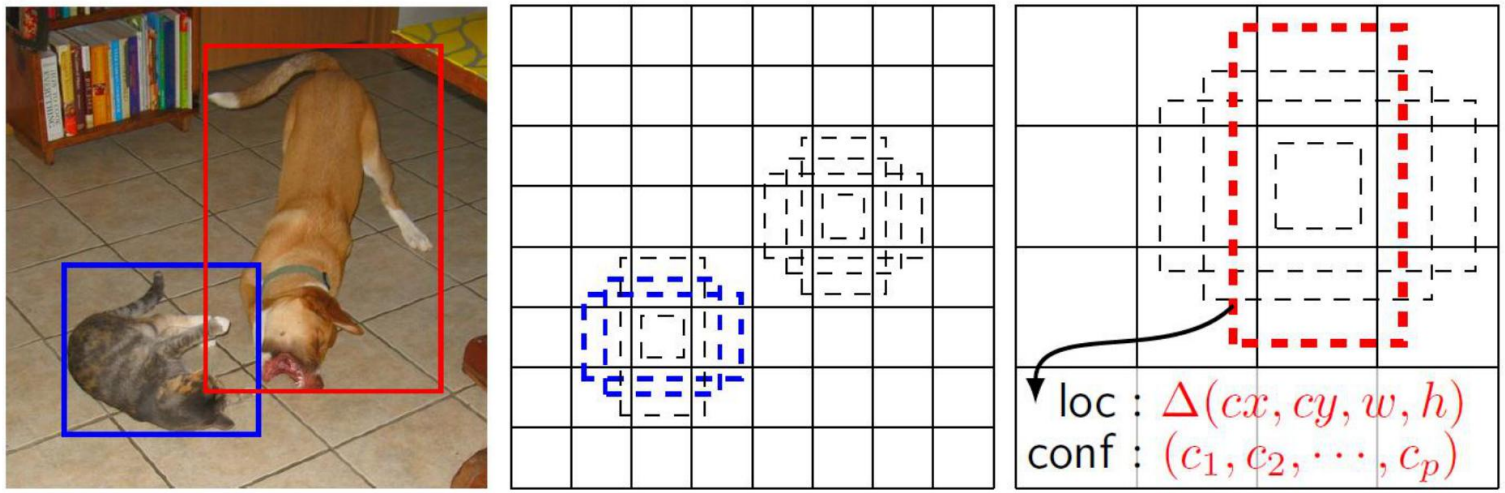


单次多框检测器 SSD 使用 VGG-16 至 Conv5_3 层及附加特征层，在多个尺度上预测类别与位置。

3×3 卷积预测每个默认框的类别分数及 4 个位置量。图示共形成 8732 个候选框，按类别执行非极大值抑制。图中报告的性能为 74.3 mAP 与每秒 59 帧。

Detection　目标检测

- SSD：Single Shot MultiBox Detector



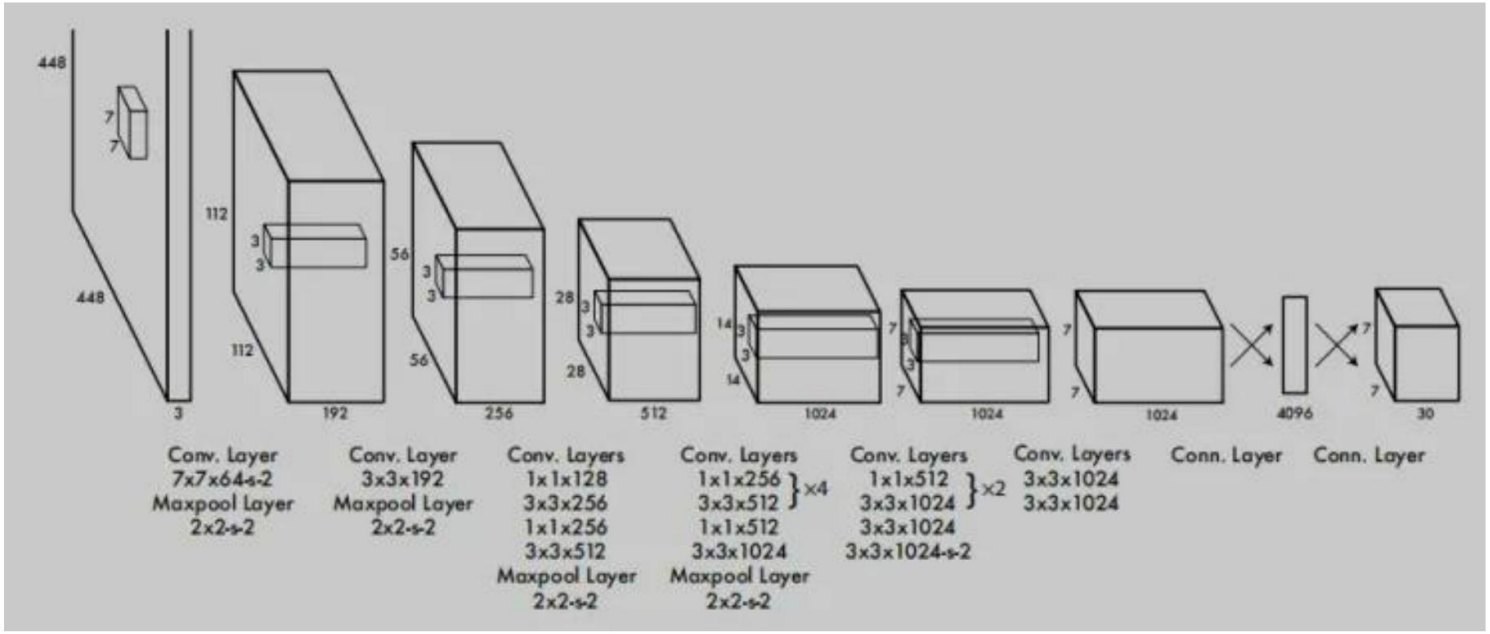
(a) Image with GT boxes　(b) 8 × 8 feature map　(c) 4 × 4 feature map

SSD 的多尺度默认框。左图为含真实标注框的图像，中图为 8×8 特征图，右图为 4×4 特征图。

细尺度特征适合较小目标，粗尺度特征适合较大目标。loc 预测中心坐标 c_x、c_y 与宽高 w、h 的偏移，conf 预测各类别置信度。

Detection　目标检测

- YOLO：You Only Look Once



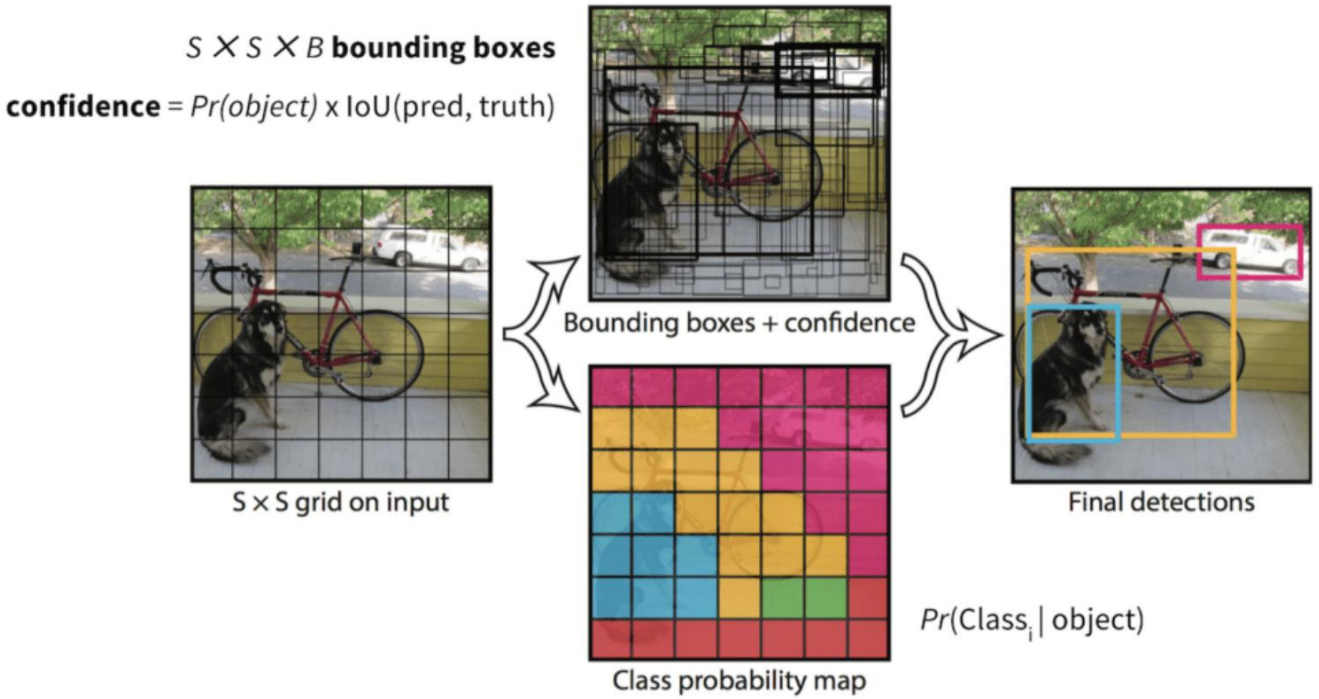
YOLO V1

YOLO 名称源于 You Only Look Once，表示单次观察完成目标检测。此页为 YOLO V1 网络。

448×448 图像经过卷积层、最大池化层和全连接层，形成 7×7×30 输出。图中 Conv 为卷积层，Maxpool 为最大池化层，Conn 为全连接层。

Detection 目标检测

- YOLO : You Only Look Once



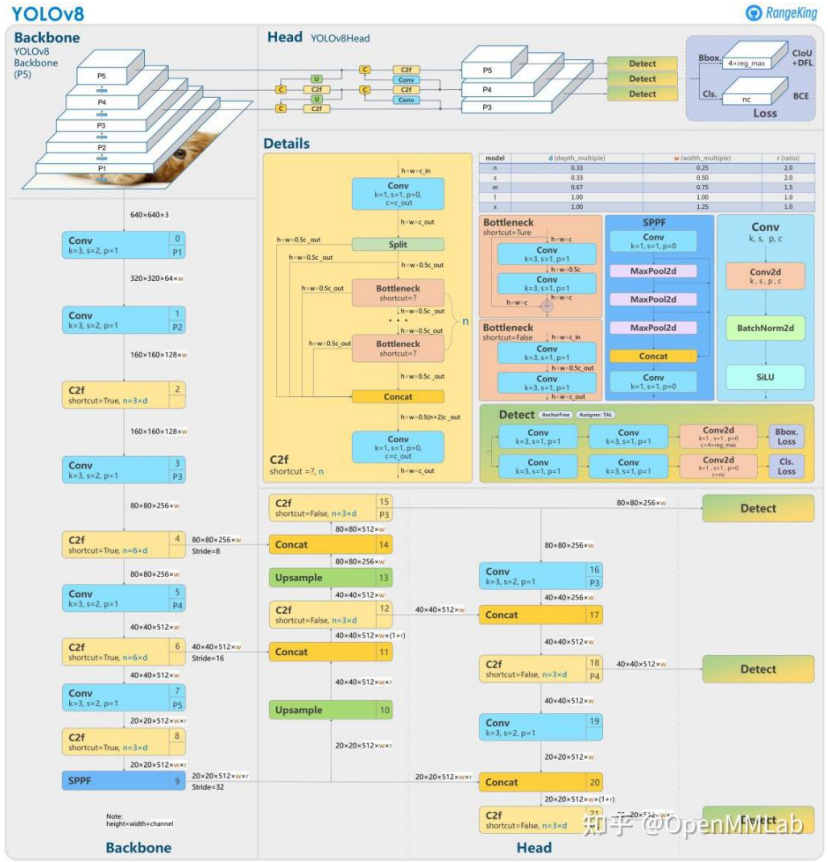
YOLO V1

YOLO V1 将输入划分为 S×S 网格，每个网格预测 B 个边界框及相应置信度，同时预测条件类别概率 $Pr(Class_i|object)$。

置信度为 Pr(object) 与预测框、真实框的交并比 IoU 的乘积。边界框和类别概率图共同生成最终检测结果。

Detection　目标检测

- YOLO：You Only Look Once



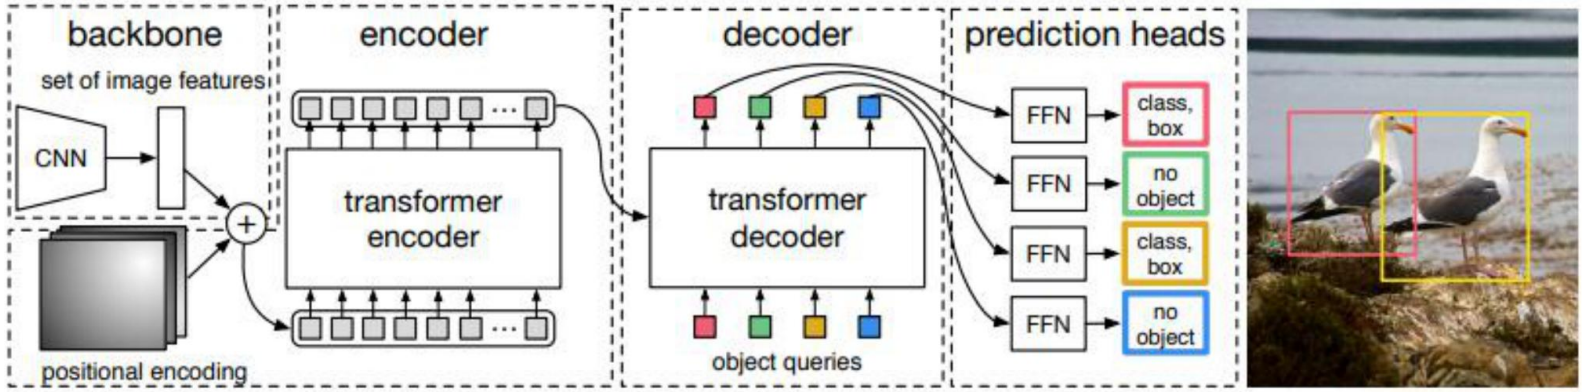
YOLO V8

YOLO V8 架构包含主干网络 Backbone 与检测头 Head。图中展示卷积模块、C2f、SPPF、上采样及特征拼接。

多尺度检测分支分别预测边界框 Bbox 与类别 Cls。Conv 为卷积，MaxPool2d 为二维最大池化，BatchNorm2d 为二维批归一化，Upsample 为上采样，Loss 为损失。

Detection 目标检测

- DETR



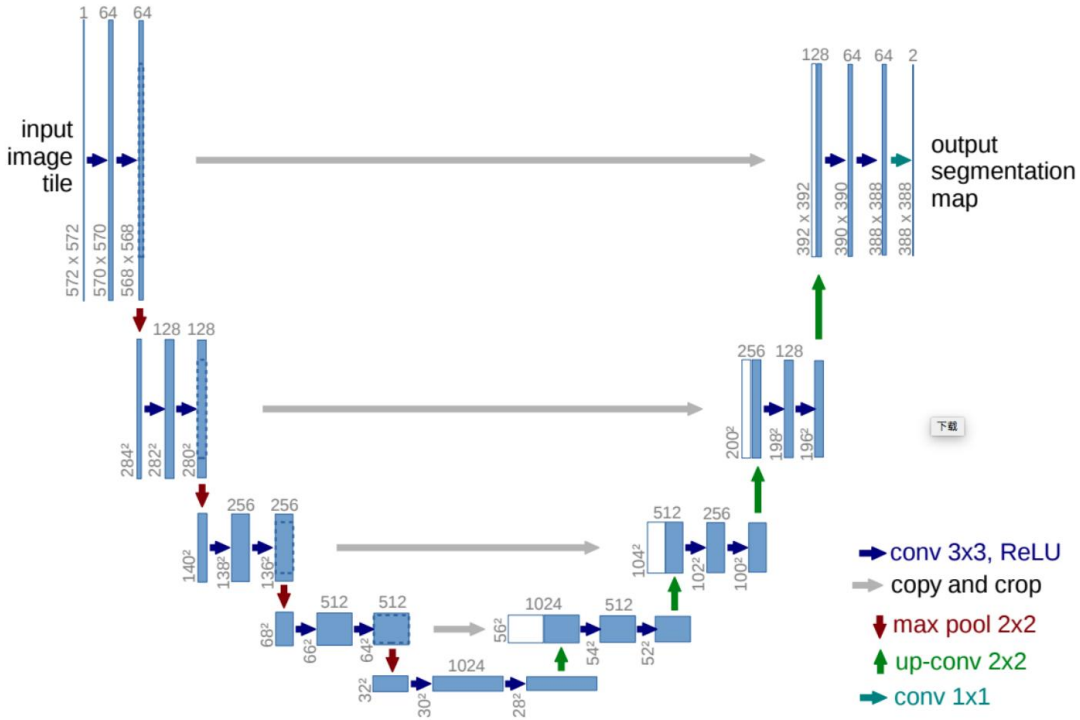
检测 Transformer（DETR）通过卷积主干提取图像特征，加入位置编码，送入 Transformer 编码器。

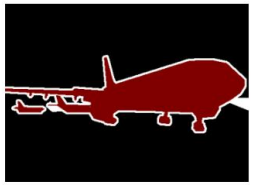
解码器利用目标查询 object queries 获取目标表示，由前馈预测头 FFN 输出类别与边界框，空查询对应无目标。右图为检测示例。

Segmentation　图像分割

- U-Net







U-Net 使用收缩路径与扩张路径生成像素级分割图。输入为图像块，输出为分割映射。

蓝色箭头表示 3×3 卷积及 ReLU，灰色箭头表示复制与裁剪，红色箭头表示 2×2 最大池化，绿色箭头表示 2×2 上采样卷积，青色箭头表示 1×1 卷积。跨层特征用于恢复空间细节。

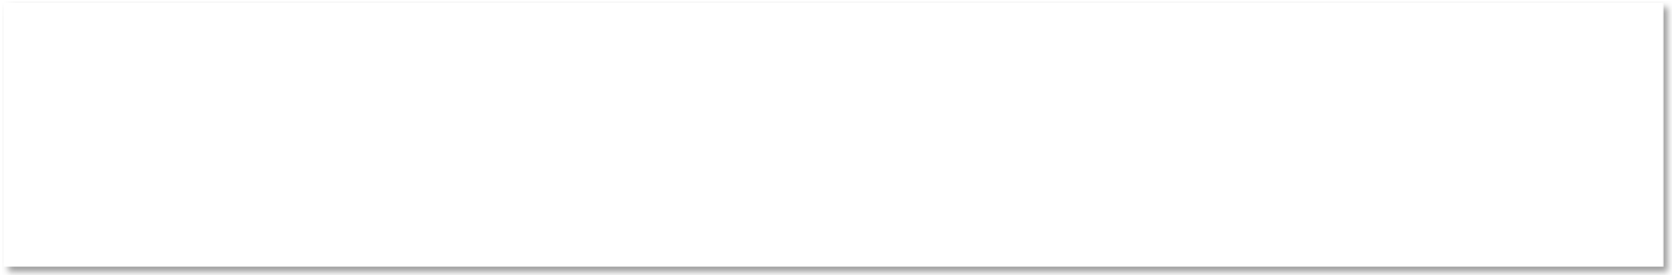
Deep Learning for Semantic Segmentation　语义分割中的深度学习

Outline 内容提纲

语义分割回顾
判别特征网络
双分支分割网络

- Semantic Segmentation Review
- Discriminative Feature Network
- Bilateral Segmentation Network

Semantic Segmentation Review　语义分割回顾



What is Semantic Segmentation ?　语义分割概念

Introduction

- Pixel-level
- Do not differentiate instances



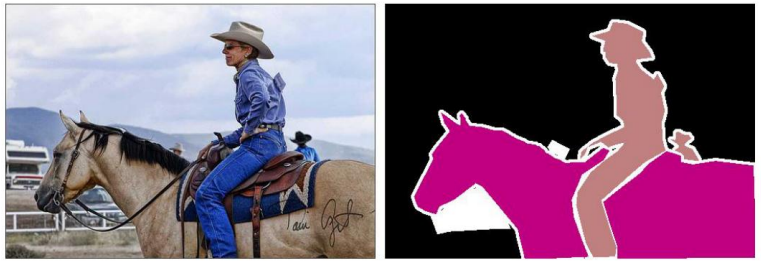


概述。语义分割在像素级分配语义类别，同一类别的各个实例共享类别标签。

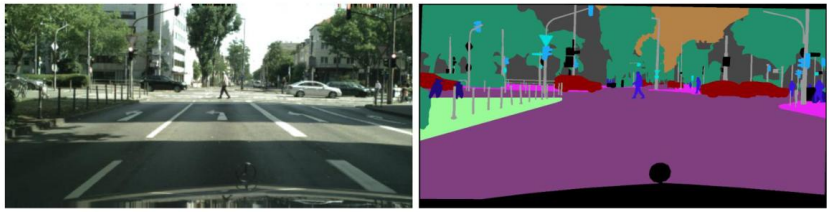
右图以相同颜色表示人物类别，人物个体的身份划分略去。

Datasets Overview　数据集概览

Datasets



PASCAL VOC



Cityscapes



ADE 20K

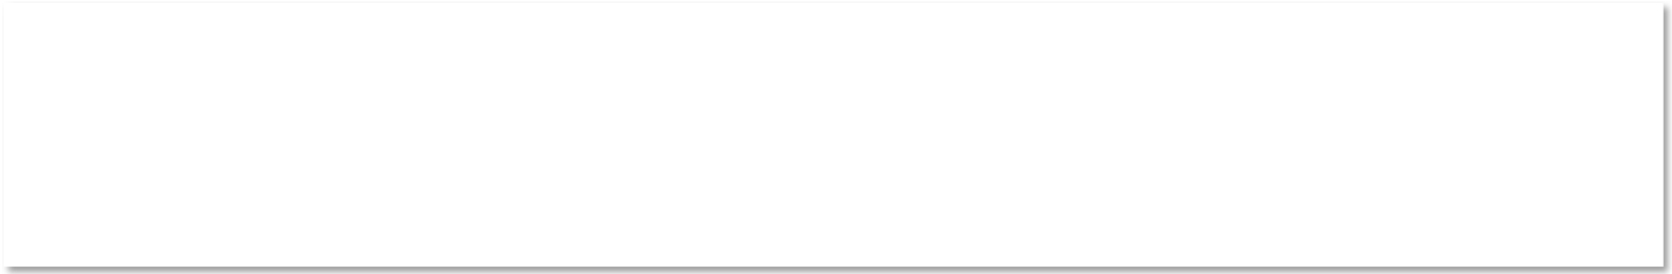


Mapillary

数据集示例包括 PASCAL VOC、Cityscapes、ADE20K 与 Mapillary。

图片展示原始场景与相应语义标签，颜色表示各个语义类别。

Discriminative Feature Network　判别特征网络



Challenges 主要挑战

Motivation

- Intra-class Inconsistency
  - same semantic label
  - different appearances
- Inter-class Indistinction
  - different sematic label
  - similar appearances



Intra-class Inconsistency



Inter-class Indistinction

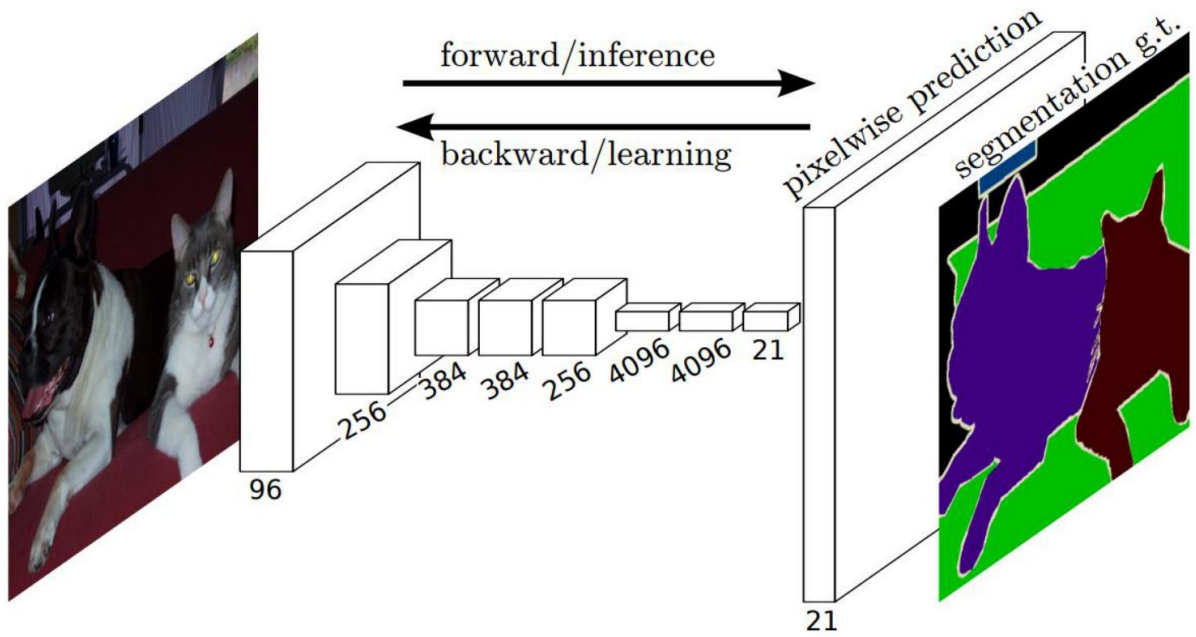
研究动机。类内差异指同一语义标签下存在多种外观。

类间混淆指语义标签各异的对象具有相似外观。上图为同类区域分割分裂，下图为相似外观引发类别混淆。

Traditional view 传统视角

Motivation

- Assign a semantic label to each single pixel



研究动机。为每一个像素分配语义标签。

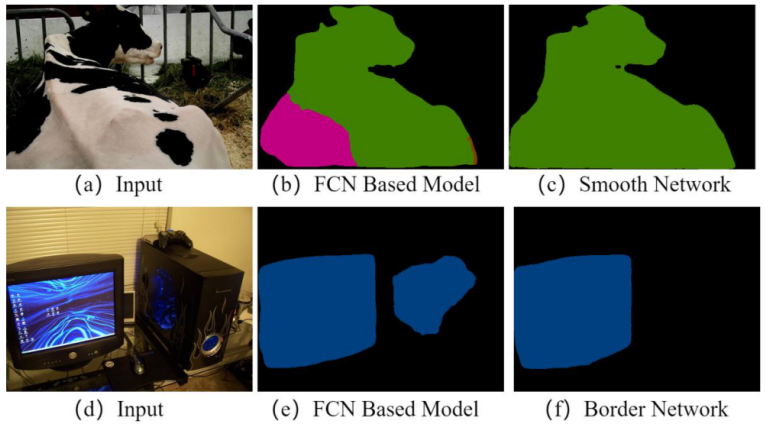
图中 forward/inference 表示前向推理，backward/learning 表示反向学习，pixelwise prediction 为逐像素预测，segmentation g.t. 为分割真实标注。

Rethink 整体视角

Motivation

- Macroscopic view: assign a consistent semantic label to a category of things
  - Regarding each category of pixels as a whole
    - Intra-class consistency
    - Inter-class variation

→ Discriminative Feature



(a) Input (b) FCN Based Model (c) Smooth Network

(d) Input (e) FCN Based Model (f) Border Network

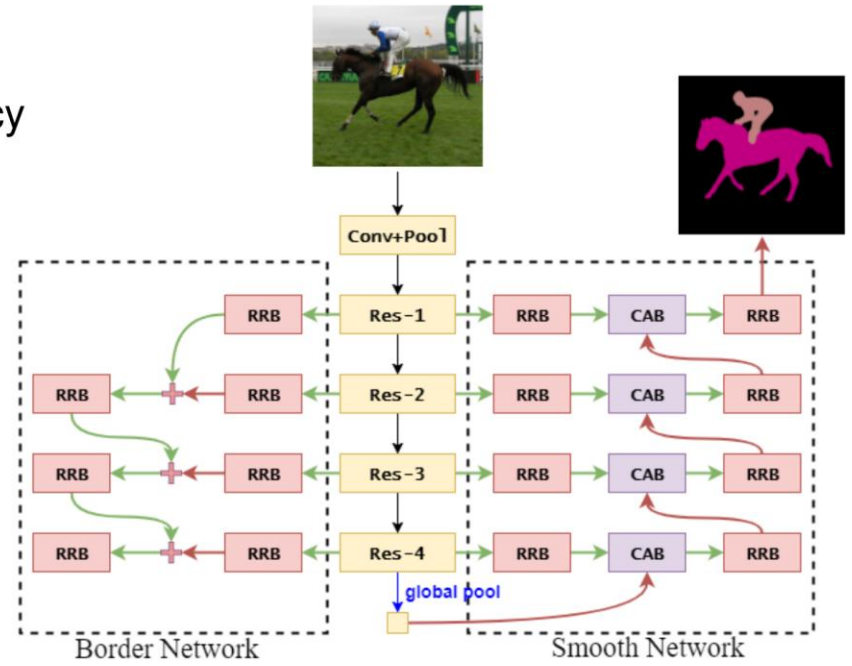
从宏观角度为同一类别的事物分配一致的语义标签，将每个类别的像素视为整体。

通过类内一致性与类间差异学习判别特征。图中依次比较输入、FCN 基础模型、平滑网络或边界网络的结果。

Discriminative Feature Network　判别特征网络

Discriminative Feature Network

- Smooth Network
  - Address: intra-class inconsistency
- Border Network
  - Address: inter-class indistinction



平滑网络用于处理类内差异，边界网络用于处理类间混淆。

两条分支共享卷积与池化特征。图中 Res-1 至 Res-4 为残差网络各阶段，RRB 为细化残差块，CAB 为通道注意力块，global pool 为全局池化。

Smooth Network 平滑网络

Discriminative Feature Network Smooth Network

- Intra-Class Inconsistency:
  - Multi-scale and global context
    - Enable the patches to know the image from local to global
  - Selection is important
    - Different scales of receptive fields produce the features with different extents of discrimination
    - Selecting the discriminative and effective features

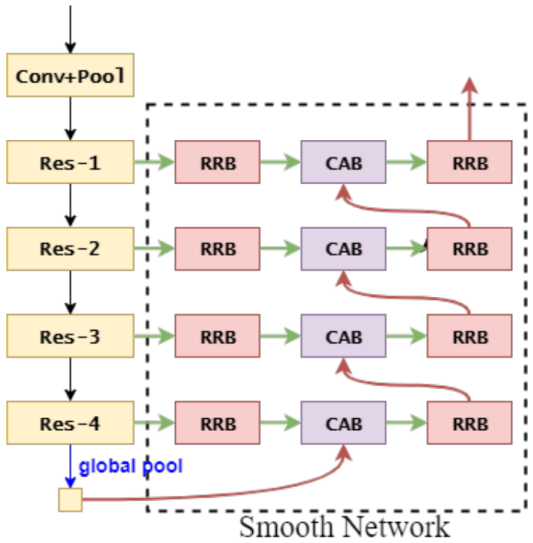
针对类内差异，引入多尺度与全局上下文，使局部图像块获得从局部到全局的信息。

特征选择具有重要作用。多种尺度的感受野所产生的特征具有各异的判别能力，需要选择判别性强且有效的特征。

Smooth Network　平滑网络结构

Discriminative Feature Network　Smooth Network

- Structure
  - U-shape + global context ⟶ V-shape
    - Introduce global context + multi-scale context
  - Channel Attention Block (CAB)
    - Change the feature weights to enhance consistency
  - Refinement Residual Block (RRB)

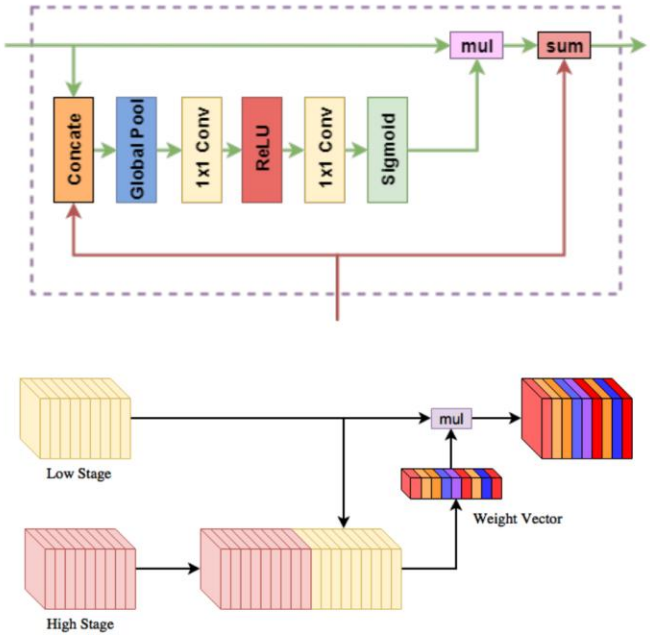


U 形结构结合全局上下文形成 V 形结构，同时引入全局上下文与多尺度上下文。

通道注意力块 CAB 调节特征权重，增强一致性。细化残差块 RRB 用于进一步处理特征。

Channel attention block　通道注意力块

Discriminative Feature Network　Smooth Network　Channel Attention Block



$$y = F(x;w) = \sum_{i=1,j=1}^{D} \omega_{i,j} x_{i,j}$$

$$y = (y_1, y_2, \cdots, y_n)$$

$$\sigma_i(y_i) = \frac{\exp(y_i)}{\sum_{j=1}^{n} \exp(y_j)}$$

$$\alpha = Sigmoid(x;w)$$

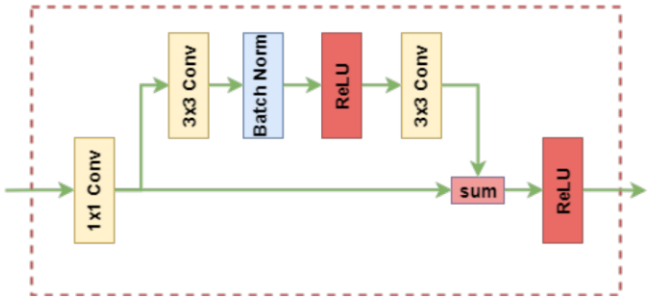
$$\bar{y} = \alpha y = \begin{bmatrix} \alpha_1 \\ \vdots \\ \alpha_n \end{bmatrix} \cdot \begin{bmatrix} y_1 \\ \vdots \\ y_n \end{bmatrix}$$

低阶段与高阶段特征拼接，经全局池化、1×1 卷积、ReLU、1×1 卷积及 Sigmoid 得到通道权重。

权重向量与低阶段特征逐通道相乘，结合高阶段信息形成输出。图中 mul 为相乘，sum 为相加。右侧公式保留特征变换、Softmax 形式以及 Sigmoid 权重 α 与加权特征 $\bar{y}=\alpha y$。

Refinement Residual Block　细化残差块

Discriminative Feature Network　Smooth Network　Refinement Residual Block



输入经 1×1 卷积调整通道后分为两条路径。

残差分支依次使用 3×3 卷积、批归一化、ReLU 与 3×3 卷积，与旁路特征相加后通过 ReLU 输出。Batch Norm 为批归一化，sum 为相加。

Border Network 边界网络

针对类间混淆，利用语义边界引导特征学习。

低阶段提供细致的边缘信息，高阶段提供语义边界信息。

Discriminative Feature Network Border Network

- Inter-class Indistinction
  - Semantic Boundary to guide feature learning
  - Low stage: detailed edge information
    High stage: semantic boundary information

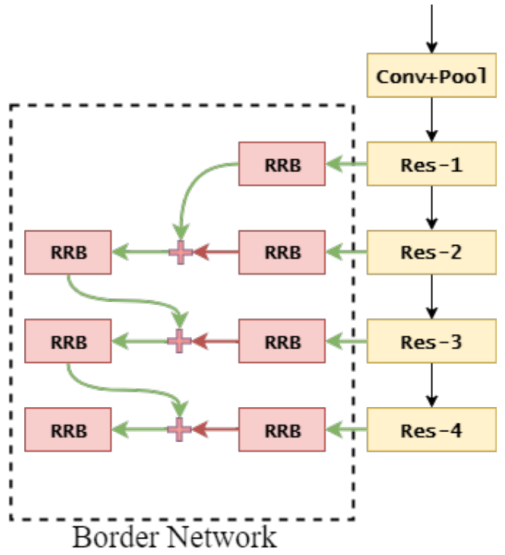
Border Network 边界网络结构

Discriminative Feature Network Border Network

使用自底向上的网络，逐阶段细化特征。

通过深度监督与焦点损失处理正负样本数量失衡，利用细化残差块 RRB 完成特征处理。

- Structure
  - Bottom-up Network
  - Stage-wise Refinement
  - Deep Supervision + Focal-Loss
    - imbalance of the positive and negative samples
  - Refinement Residual Block



Ablation Study　消融实验

Experiments



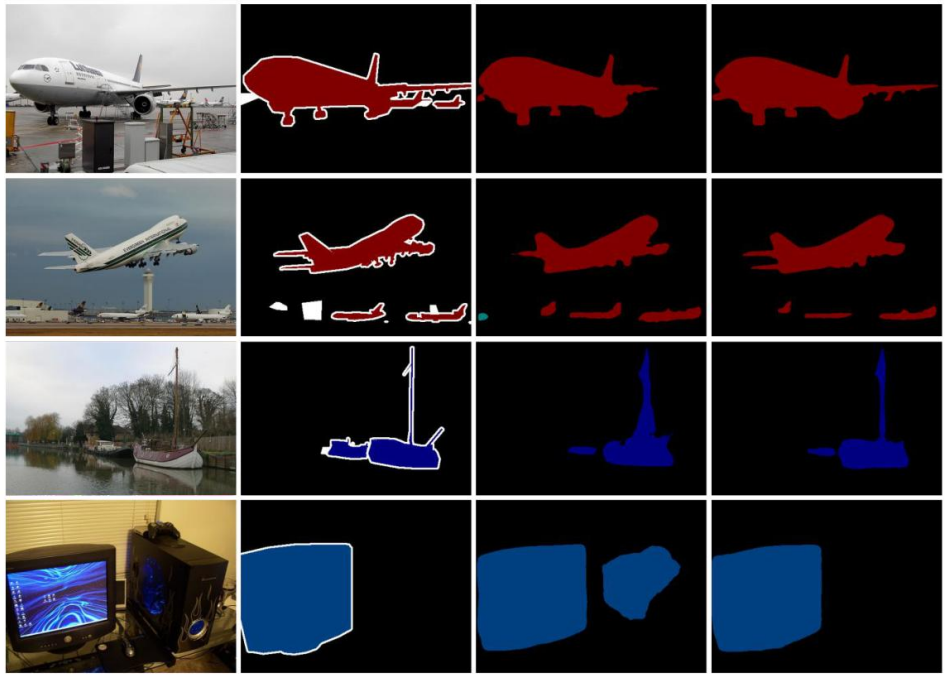
(a) Input　(b) GroundTruth　(c) Before SN　(d) After SN

实验结果。四列依次为输入图像、真实标注、加入平滑网络前、加入平滑网络后。

SN 表示平滑网络。对比显示类内区域的标签一致性变化。

Ablation Study　消融实验

Experiments



(a) Input　(b) GroundTruth　(c) Before BN　(d) After BN

实验结果。四列依次为输入图像、真实标注、加入边界网络前、加入边界网络后。

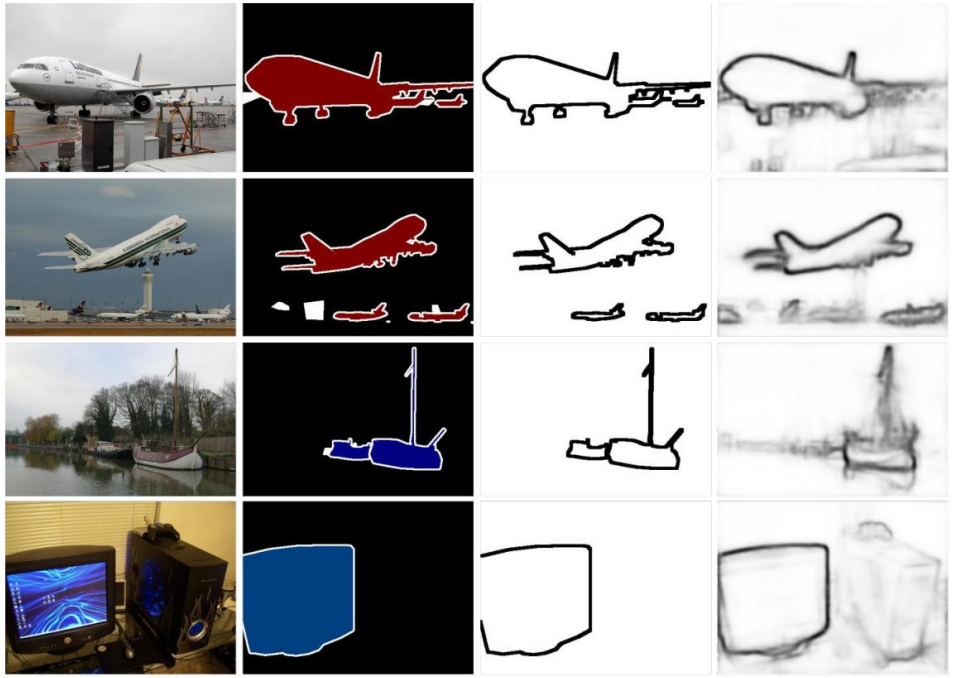
此处 BN 表示边界网络。图中比较飞机、船与显示器的分割边缘及类别混淆情况。

Boundary Output of Border Network　边界网络输出

Experiments

实验结果。四列依次为输入图像、真实标注、语义边界、预测边界。

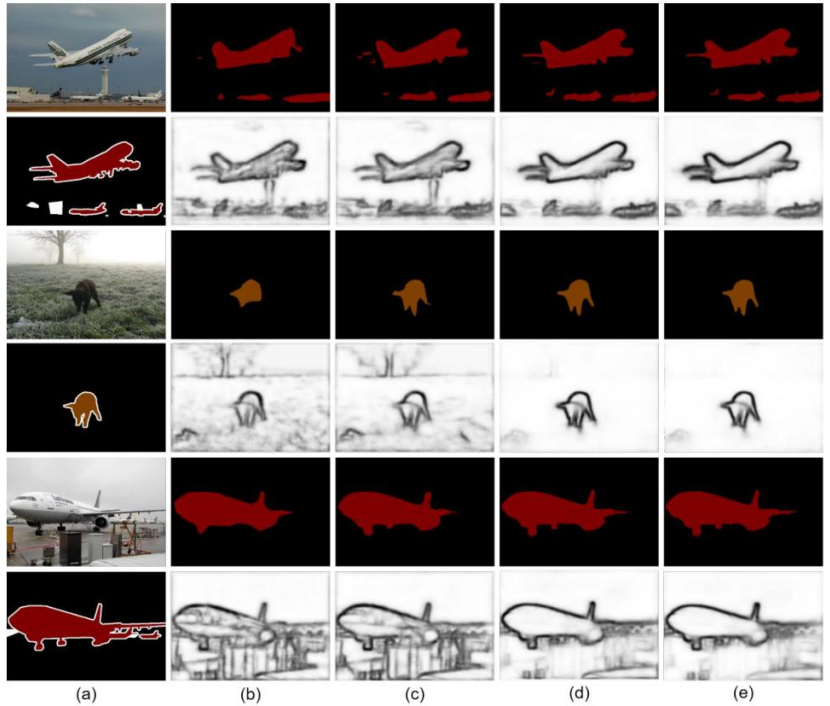
边界图用于监督网络，使预测边缘更贴合目标轮廓。



(a) Input　(b) GroundTruth　(c) Boundary　(d) Prediction

Stage-wise Refinement　逐阶段细化

Experiments



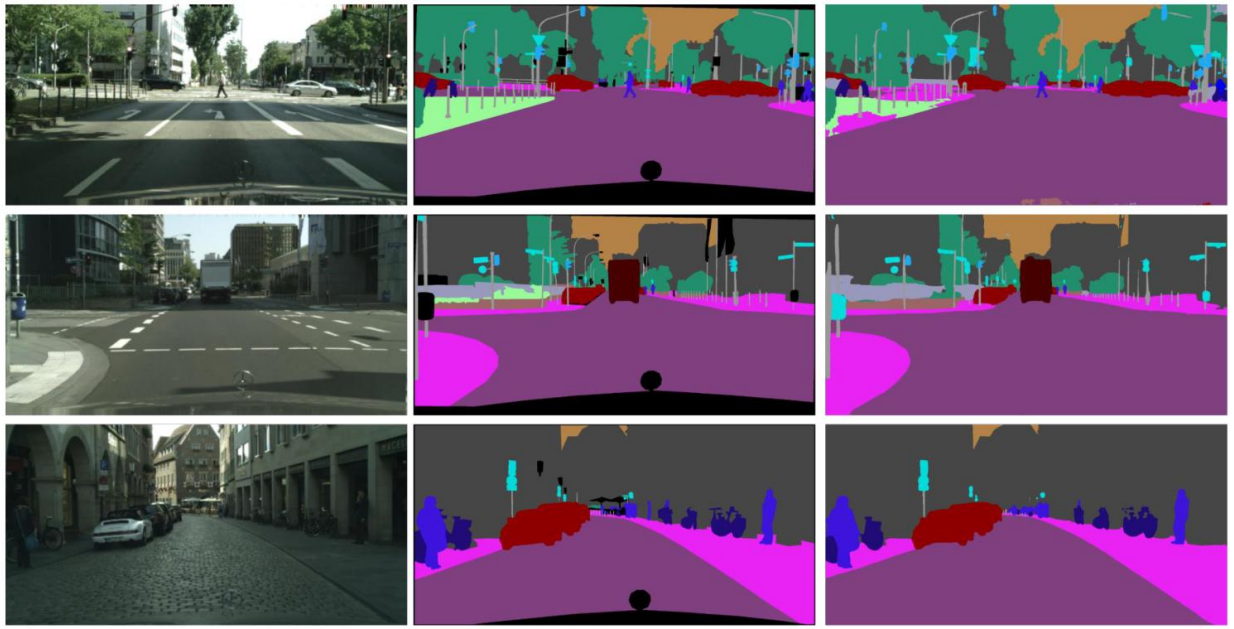
实验结果。左列为输入与真实标注，右侧各列展示逐阶段细化后的语义分割与边界预测。

颜色区域表示语义分割，灰度图表示边界响应。

Example Results on Cityscapes　Cityscapes 结果示例

Experiments

实验结果。三列依次为输入图像、真实标注与判别特征网络 DFN 的输出。



(a) Input　(b) GroundTruth　(c) DFN

Results on PASCAL VOC　PASCAL VOC 结果

Results

Method	Mean IOU(%) w/o COCO
FCN	62.2
Zoom-out	69.6
ParseNet	69.8
Deeplab v2-CRF	71.6
DPN	74.1
Piecewise	75.3
LRR-CRF	75.9
PSPNet	82.6
Ours	**82.7**

Method	Mean IOU(%) w/ COCO
Adelaide_VeryDeep_FCN	79.1
LRR_4x_ResNet-CRF	79.3
Deeplab v2-CRF	79.7
Deep Layer Cascade	82.7
DUC	83.1
GCN	83.6
RefineNet	84.2
PSPNet	85.4
Deeplab v3	85.7
Ours	**86.2**

表中 Method 为方法，Mean IoU 为平均交并比，单位为百分比，Ours 为本文方法。

左表采用省去 COCO 训练数据的设置，本文方法为 82.7，PSPNet 为 82.6。右表采用包含 COCO 数据的设置，本文方法为 86.2，DeepLab v3 为 85.7。

Results on Cityscapes　Cityscapes 结果

Results

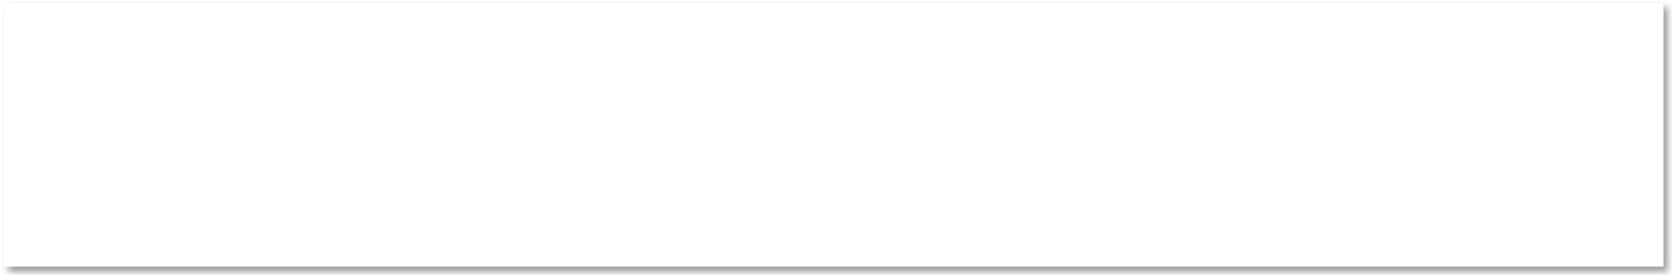
Method	Mean IOU(%) w/o coarse
FCN	65.3
DPN	66.8
LRR	69.7
Deeplab v2-CRF	70.4
Piecewise	71.6
RefineNet	73.6
GlobalLocalRefinement	77.3
DUC	77.6
SegModel	78.5
Ours	**79.6**

Method	Mean IOU(%) w/ coarse
Deeplab v2-CRF	70.4
Adelaide_context	71.6
LRR-4x	71.8
GCN	76.9
SegModel	79.2
DUC	80.1
PSPNet	80.2
Ours	**80.3**

表中 Method 为方法，Mean IoU 为平均交并比，单位为百分比，Ours 为本文方法。

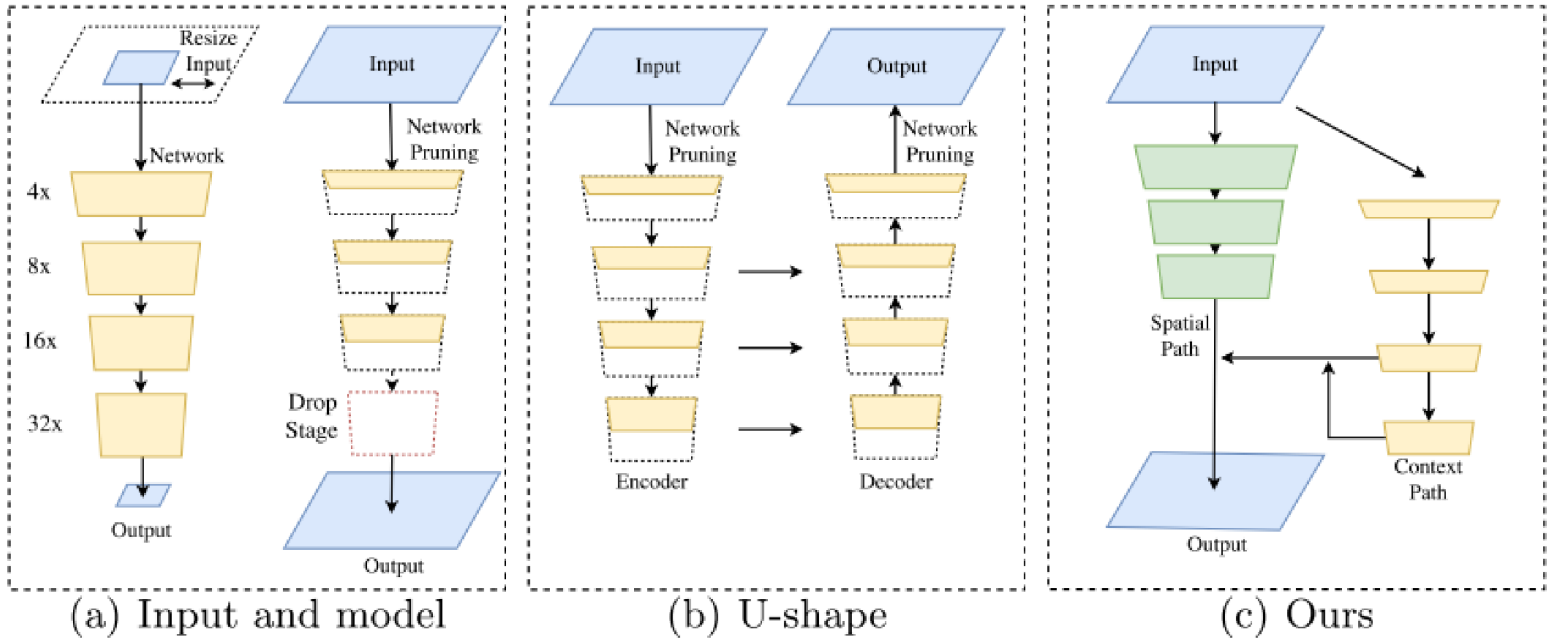
左表仅使用精细标注，本文方法为 79.6。右表加入粗标注，本文方法为 80.3，PSPNet 为 80.2。

Bilateral Segmentation Network　双分支分割网络



Previous Methods 已有方法

Motivation



研究动机。左图通过缩小输入、网络剪枝或删减网络阶段提高速度。中图使用编码器与解码器构成 U 形结构。

右图为本文双分支方案，空间路径保存空间信息，上下文路径提取语义信息，两类特征汇合得到输出。Input 为输入，Output 为输出，Resize 为缩放，Drop Stage 为删减阶段。

Previous Methods 已有方法的局限

为提高速度而牺牲精度，会损失空间细节并降低空间表征能力。

采用空间路径保存空间信息，采用上下文路径提供较大的感受野。

Motivation

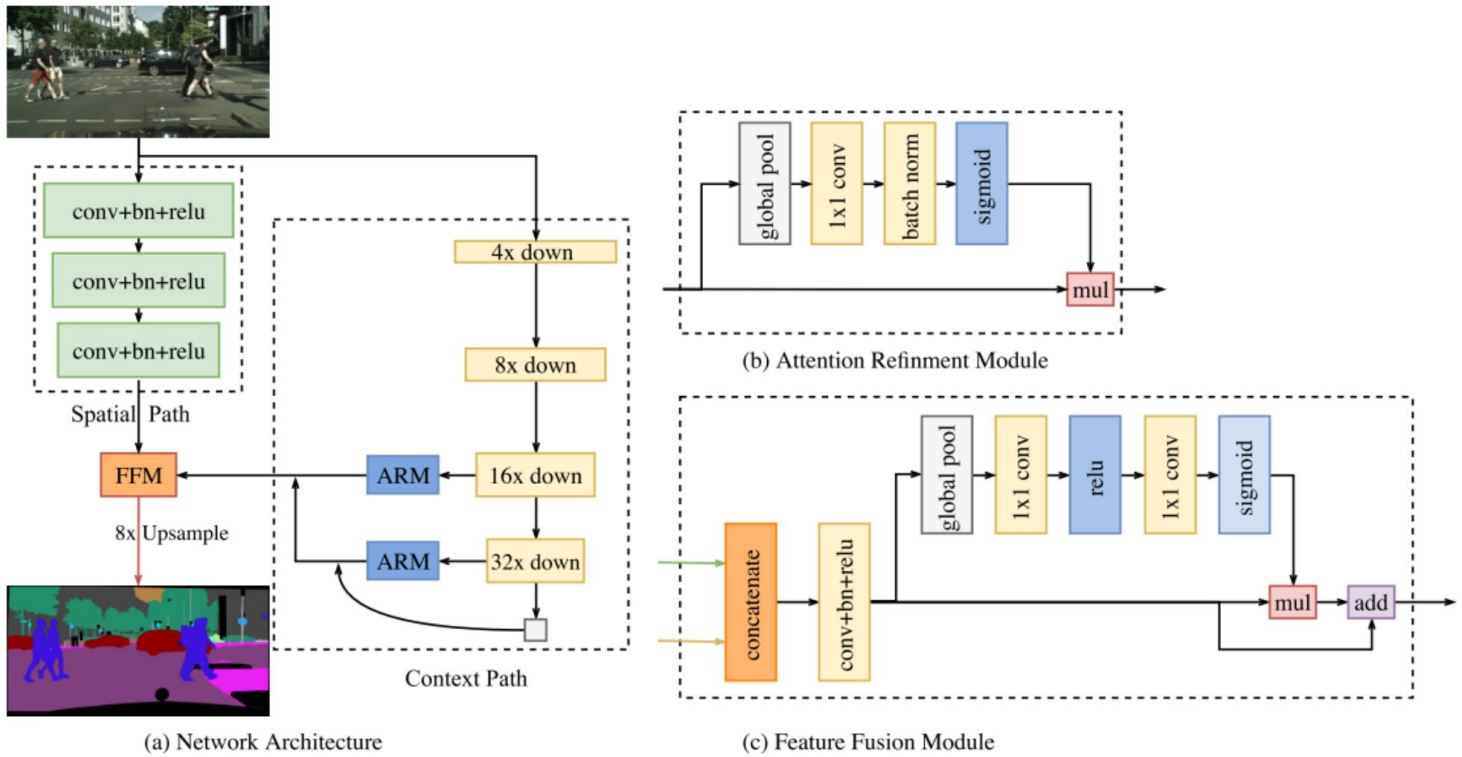
- Problem:
  - Loss of spatial details
  - Sacrifice the spatial capacity

} Compromise the accuracy to speed

- Solution:
  - Spatial Path: spatial information preservation
  - Context Path: receptive field offering

Bilateral Segmentation Network　双分支分割网络

Bilateral Segmentation Network



左图为空间路径与上下文路径组成的网络架构。空间路径使用卷积、批归一化与 ReLU，上下文路径逐步下采样。特征经过 FFM 融合，最终作 8 倍上采样。

右上为注意力细化模块 ARM，全局池化、1×1 卷积、批归一化及 Sigmoid 生成权重并与特征相乘。右下为特征融合模块 FFM，拼接两路特征并学习权重，通过相乘及残差相加输出。

Ablation Study on Cityscapes　Cityscapes 消融实验

Bilateral Segmentation Network

Method	Mean IoU(%)
CP	66.01
CP+SP(Sum)	66.82
CP+SP(FFM)	67.42
CP+SP(FFM)+GP	68.42
CP+SP(FFM)+ARM	68.72
CP+SP(FFM)+ARM+GP	71.40

CP: Context Path
SP: Spatial Path
FFM: Feature Fusion Module
ARM: Attention Refinement Module
GP: Global Average Pooling

CP 为上下文路径，SP 为空间路径，FFM 为特征融合模块，ARM 为注意力细化模块，GP 为全局平均池化。Sum 表示相加。

平均交并比依次为 CP 66.01%，CP+SP(Sum) 66.82%，CP+SP(FFM) 67.42%，加入 GP 为 68.42%，加入 ARM 为 68.72%，同时加入 ARM 与 GP 为 71.40%。

Speed Analysis on Cityscapes　Cityscapes 速度分析

Bilateral Segmentation Network

Method	BaseModel	GFLOPS	Parameters
SegNet	VGG16	286.0	29.5M
Enet	From scratch	3.8	0.4M
Ours	Xception39	2.9	5.8M
Ours	Res18	10.8	49.0M

FLOPS & Parameters

Method	NVIDIA Titan X						NVIDIA Titan XP					
	640x360		1280x720		1920x1080		640x360		1280x720		1920x1080	
	ms	*fps*	*ms*	*fps*	*ms*	*fps*	*ms*	*fps*	*ms*	*fps*	*ms*	*fps*
SegNet	69	14.6	289	3.5	637	1.6	-	-	-	-	-	-
Enet	7	135.4	21	46.8	46	21.6	-	-	-	-	-	-
Ours	**5**	**203.5**	**12**	**82.3**	**24**	**41.4**	**4**	**285.2**	**8**	**124.1**	**18**	**57.3**
Ours	8	129.4	21	47.9	43	23	5	205.7	13	78.8	29	34.4

Speed Comparison

上表比较方法、基础模型、十亿次浮点运算量 GFLOPS 与参数量。M 表示百万，From scratch 表示从头训练。

下表比较 NVIDIA Titan X 与 Titan XP 上的运行速度，输入分辨率为 640×360、1280×720、1920×1080。ms 为毫秒，fps 为每秒帧数。

Xception39 方案在 Titan X 上依次为 203.5、82.3、41.4 fps，在 Titan XP 上依次为 285.2、124.1、57.3 fps。另一本文方案使用 Res18。

Speed Analysis on Cityscapes　Cityscapes 速度分析

Bilateral Segmentation Network

Method	BaseModel	Mean IOU(%)		FPS
		val	*test*	
SegNet	VGG16	-	56.1	-
Enet	From scratch	-	58.3	-
SQ	SqueezeNet	-	59.8	-
ICNet	PSPNet50	67.7	69.5	30.3
DLC	Inception-ResNet-v2	-	71.1	-
Two-column Net	Res50	74.6	72.9	14.7
Ours	Xception39	69.0	68.4	**105.8**
Ours	Res18	**74.8**	**74.7**	65.5

Speed and Accuracy Comparison

速度与精度比较。表头为方法、基础模型、平均交并比与每秒帧数。val 为验证集，test 为测试集。

本文 Xception39 方案为验证集 69.0%、测试集 68.4%、105.8 fps。Res18 方案为验证集 74.8%、测试集 74.7%、65.5 fps。From scratch 为从头训练。

Accuracy Analysis on Cityscapes　Cityscapes 精度分析

Bilateral Segmentation Network

Method	BaseModel	Mean IOU(%)	
		val	*test*
DeepLab	VGG16	-	63.1
FCN-8s	VGG16	-	65.3
Adelaide	VGG16	-	66.4
Dilation10	VGG16	68.7	66.4
LRR	VGG16	70.0	69.7
DeepLab-v2+CRF	Res101	71.4	70.4
RefineNet	Res101	-	73.6
DUC	Res152	76.7	76.1
PSPNet	Res101	-	78.4
Ours	Xception39	72.0	71.4
Ours	Res18	78.6	77.7
Ours	Res101	**80.3**	**78.9**

Accuracy Comparison

精度比较。表头为方法、基础模型与平均交并比，val 为验证集，test 为测试集。

本文 Xception39 方案为 72.0% 与 71.4%，Res18 方案为 78.6% 与 77.7%，Res101 方案为 80.3% 与 78.9%。各项依次对应验证集和测试集。

Accuracy Analysis on COCO Stuff　COCO Stuff 精度分析

Bilateral Segmentation Network

表头为方法、基础模型、平均交并比与像素精度，单位均为百分比。

DeepLab-v2/VGG-16 为 24.0 与 58.2。本文 Xception39 为 22.8 与 59.0，Res18 为 28.1 与 63.2，Res101 为 31.3 与 65.5。

Method	BaseModel	Mean IOU(%)	Pixel Accuracy(%)
DeepLab-v2	VGG-16	24.0	58.2
Ours	Xception39	22.8	59.0
Ours	Res18	28.1	63.2
Ours	Res101	**31.3**	**65.5**

Accuracy Comparison on COCO Stuff

The end　课程结束

The end !