Computer Vision---Tracking 计算机视觉——目标跟踪

桑农、王岳环，华中科技大学。

课件参考 Trevor Darrel 教授的计算机视觉课程。

桑农 王岳环

Slides from CV course with Prof. Trevor Darrel

Tracking scenarios 目标跟踪场景

Why tracking?

Follow a point

Follow a template

Follow a changing template

Follow all the elements of a moving person, fit a model to it.

Tracking by detection vs. tracking by matching

目标跟踪用于连续观测同一对象，描述其位置、外观与运动随时间的变化。

可以跟踪一个点、一个模板、外观持续变化的模板，也可以跟踪运动人体的各个组成部分并拟合人体模型。

两类策略为基于检测的跟踪与基于匹配的跟踪。

Things to consider in tracking　跟踪中的建模因素

目标动力学描述被跟踪对象的运动规律。

观测模型描述相机测量与目标状态之间的关系。

What are the dynamics of the thing being tracked?

How is it observed?

Three main issues in tracking 跟踪的三个主要问题

- **Prediction:** we have seen $\boldsymbol{y}_0, \ldots, \boldsymbol{y}_{i-1}$ — what state does this set of measurements predict for the i'th frame? to solve this problem, we need to obtain a representation of $P(\boldsymbol{X}_i | \boldsymbol{Y}_0 = \boldsymbol{y}_0, \ldots, \boldsymbol{Y}_{i-1} = \boldsymbol{y}_{i-1})$.
- **Data association:** Some of the measurements obtained from the i-th frame may tell us about the object's state. Typically, we use $P(\boldsymbol{X}_i | \boldsymbol{Y}_0 = \boldsymbol{y}_0, \ldots, \boldsymbol{Y}_{i-1} = \boldsymbol{y}_{i-1})$ to identify these measurements.
- **Correction:** now that we have $\boldsymbol{y}_i$ — the relevant measurements — we need to compute a representation of $P(\boldsymbol{X}_i | \boldsymbol{Y}_0 = \boldsymbol{y}_0, \ldots, \boldsymbol{Y}_i = \boldsymbol{y}_i)$.

预测利用历史观测 y_0 至 y_{i-1}，估计当前状态分布 $P(X_i|y_0,\ldots,y_{i-1})$。

数据关联利用预测分布，判断当前帧中的哪些测量属于目标。

校正将关联后的当前测量 y_i 与预测结合，得到后验状态分布 $P(X_i|y_0,\ldots,y_i)$。

Simplifying Assumptions 简化假设

- **Only the immediate past matters:** formally, we require

$$P(\boldsymbol{X}_i|\boldsymbol{X}_1,\ldots,\boldsymbol{X}_{i-1}) = P(\boldsymbol{X}_i|\boldsymbol{X}_{i-1})$$

  This assumption hugely simplifies the design of algorithms, as we shall see; furthermore, it isn't terribly restrictive if we're clever about interpreting $\boldsymbol{X}_i$ as we shall show in the next section.

- **Measurements depend only on the current state:** we assume that $\boldsymbol{Y}_i$ is conditionally independent of all other measurements given $\boldsymbol{X}_i$. This means that

$$P(\boldsymbol{Y}_i,\boldsymbol{Y}_j,\ldots\boldsymbol{Y}_k|\boldsymbol{X}_i) = P(\boldsymbol{Y}_i|\boldsymbol{X}_i)P(\boldsymbol{Y}_j,\ldots,\boldsymbol{Y}_k|\boldsymbol{X}_i)$$

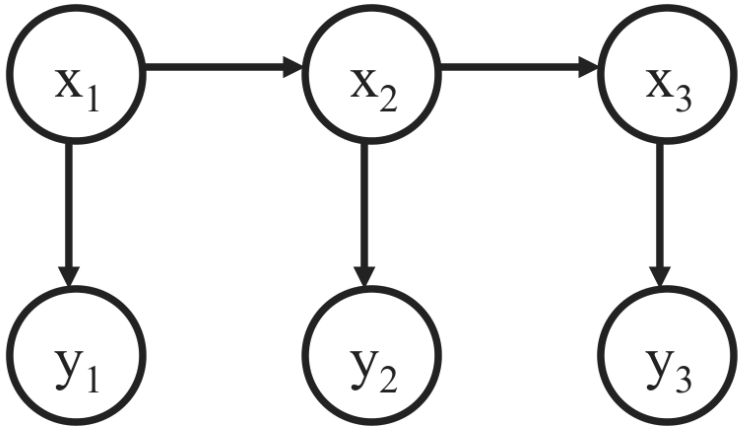
  Again, this isn't a particularly restrictive or controversial assumption, but it yields important simplifications.

状态满足一阶马尔可夫假设，即给定前一状态 X_{i-1} 后，当前状态 X_i 的分布由 $P(X_i|X_{i-1})$ 描述。

通过适当定义状态，可使该假设适应多种运动过程，并简化计算。

测量仅依赖当前状态。给定 X_i 时，Y_i 与其他时刻的测量条件独立，观测模型可按时刻分解。

Kalman filter graphical model and corresponding factorized joint probability
卡尔曼滤波图模型与联合概率分解



隐状态按 $x_1 \rightarrow x_2 \rightarrow x_3$ 构成马尔可夫链，每个状态 x_i 生成对应测量 y_i。

联合概率分解为初始状态概率、逐时刻状态转移概率与观测似然的乘积。

图中的六个因子为 $P(x_1)$、$P(y_1|x_1)$、$P(x_2|x_1)$、$P(y_2|x_2)$、$P(x_3|x_2)$ 与 $P(y_3|x_3)$。

$$P(x_1, x_2, x_3, y_1, y_2, y_3) = P(x_1)P(y_1|x_1)P(x_2|x_1)P(y_2|x_2)P(x_3|x_2)P(y_3|x_3)$$

Tracking as induction　跟踪的递推过程

Make a measurement starting in the 0th frame

Then: assume you have an estimate at the ith frame, after the measurement step.

Show that you can do prediction for the i+1th frame, and measurement for the i+1th frame.

从第 0 帧的测量开始建立状态估计。

假设已得到第 i 帧完成测量更新后的估计。

利用它预测第 i+1 帧状态，并结合第 i+1 帧测量完成更新。该过程可逐帧递推。

Base case　递推初始条件

Firstly, we assume that we have $P(\boldsymbol{X}_0)$

$$P(\boldsymbol{X}_0|\boldsymbol{Y}_0 = \boldsymbol{y}_0) = \frac{P(\boldsymbol{y}_0|\boldsymbol{X}_0)P(\boldsymbol{X}_0)}{P(\boldsymbol{y}_0)}$$

$$\propto P(\boldsymbol{y}_0|\boldsymbol{X}_0)P(\boldsymbol{X}_0)$$

初始状态具有先验分布 $P(X_0)$。获得测量 y_0 后，利用贝叶斯公式计算初始后验。

$P(X_0|y_0)=P(y_0|X_0)P(X_0)/P(y_0)$。

后验与观测似然及先验的乘积成正比，分母为归一化所需的测量概率。

Prediction step 预测步骤

Prediction

Prediction involves representing

$$P(\boldsymbol{X}_i|\boldsymbol{y}_0,\ldots,\boldsymbol{y}_{i-1})$$

given

$$P(\boldsymbol{X}_{i-1}|\boldsymbol{y}_0,\ldots,\boldsymbol{y}_{i-1}).$$

Our independence assumptions make it possible to write

$$\begin{aligned} P(\boldsymbol{X}_i|\boldsymbol{y}_0,\ldots,\boldsymbol{y}_{i-1}) &= \int P(\boldsymbol{X}_i,\boldsymbol{X}_{i-1}|\boldsymbol{y}_0,\ldots,\boldsymbol{y}_{i-1})d\boldsymbol{X}_{i-1} \\ &= \int P(\boldsymbol{X}_i|\boldsymbol{X}_{i-1},\boldsymbol{y}_0,\ldots,\boldsymbol{y}_{i-1})P(\boldsymbol{X}_{i-1}|\boldsymbol{y}_0,\ldots,\boldsymbol{y}_{i-1})d\boldsymbol{X}_{i-1} \\ &= \int P(\boldsymbol{X}_i|\boldsymbol{X}_{i-1})P(\boldsymbol{X}_{i-1}|\boldsymbol{y}_0,\ldots,\boldsymbol{y}_{i-1})d\boldsymbol{X}_{i-1} \end{aligned}$$

已知上一时刻的后验 $P(X_{i-1}|y_0,\ldots,y_{i-1})$。

将状态转移密度 $P(X_i|X_{i-1})$ 与该后验相乘，并对上一状态 X_{i-1} 积分。

所得分布 $P(X_i|y_0,\ldots,y_{i-1})$ 为当前测量到来前的状态预测。

Update step 测量更新

Correction

Correction involves obtaining a representation of

$$P(\boldsymbol{X}_i|\boldsymbol{y}_0,\ldots,\boldsymbol{y}_i)$$

given

$$P(\boldsymbol{X}_i|\boldsymbol{y}_0,\ldots,\boldsymbol{y}_{i-1})$$

$$P(y_0,\ldots,y_i) = \int P(y_i \mid \boldsymbol{X}_i, y_0 \ldots y_{i-1})\, P(\boldsymbol{X}_i, y_0 \ldots y_{i-1}) d\boldsymbol{X}_i$$
$$= \int P(y_i \mid \boldsymbol{X}_i, y_0 \ldots y_{i-1})\, P(\boldsymbol{X}_i|y_0 \ldots y_{i-1}) P(y_0 \ldots y_{i-1}) d\boldsymbol{X}_i$$
$$= P(y_0 \ldots y_{i-1}) \int P(y_i \mid \boldsymbol{X}_i)\, P(\boldsymbol{X}_i|y_0 \ldots y_{i-1}) d\boldsymbol{X}_i$$

Our independence assumptions make it possible to write

$$\begin{aligned}
P(\boldsymbol{X}_i|\boldsymbol{y}_0,\ldots,\boldsymbol{y}_i) &= \frac{P(\boldsymbol{X}_i,\boldsymbol{y}_0,\ldots,\boldsymbol{y}_i)}{P(\boldsymbol{y}_0,\ldots,\boldsymbol{y}_i)} \\
&= \frac{P(\boldsymbol{y}_i|\boldsymbol{X}_i,\boldsymbol{y}_0,\ldots,\boldsymbol{y}_{i-1})P(\boldsymbol{X}_i|\boldsymbol{y}_0,\ldots,\boldsymbol{y}_{i-1})P(\boldsymbol{y}_0,\ldots,\boldsymbol{y}_{i-1})}{P(\boldsymbol{y}_0,\ldots,\boldsymbol{y}_i)} \\
&= P(\boldsymbol{y}_i|\boldsymbol{X}_i)P(\boldsymbol{X}_i|\boldsymbol{y}_0,\ldots,\boldsymbol{y}_{i-1})\frac{P(\boldsymbol{y}_0,\ldots,\boldsymbol{y}_{i-1})}{P(\boldsymbol{y}_0,\ldots,\boldsymbol{y}_i)} \\
&= \frac{P(\boldsymbol{y}_i|\boldsymbol{X}_i)P(\boldsymbol{X}_i|\boldsymbol{y}_0,\ldots,\boldsymbol{y}_{i-1})}{\int P(\boldsymbol{y}_i|\boldsymbol{X}_i)P(\boldsymbol{X}_i|\boldsymbol{y}_0,\ldots,\boldsymbol{y}_{i-1})d\boldsymbol{X}_i}
\end{aligned}$$

已知预测分布 $P(X_i|y_0,\ldots,y_{i-1})$，利用当前观测 y_i 计算校正后的后验。

后验与 $P(y_i|X_i)P(X_i|y_0,\ldots,y_{i-1})$ 成正比。

分母对上述乘积关于当前状态 X_i 积分，得到测量证据并完成归一化。图中同时给出这一证据项的展开推导。

The Kalman Filter 卡尔曼滤波

Key ideas:

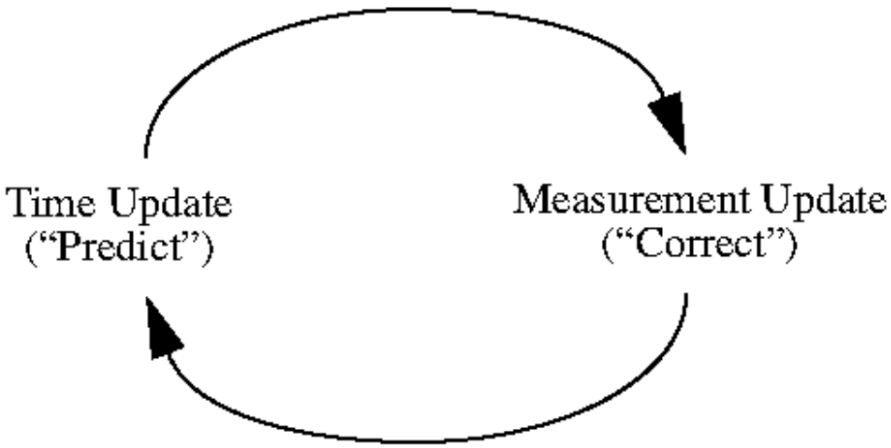
- Linear models interact uniquely well with Gaussian noise - make the prior Gaussian, everything else Gaussian and the calculations are easy
- Gaussians are really easy to represent --- once you know the mean and covariance, you're done

基本思想为线性模型与高斯噪声的组合。

初始先验为高斯分布，状态转移与观测均为线性高斯模型时，后续预测和后验仍为高斯分布，计算可用解析形式完成。

高斯分布由均值与协方差完整描述，因此可递推维护这两组参数。

The Kalman Filter　卡尔曼滤波循环



[figure from http://www.cs.unc.edu/~welch/kalman/kalmanIntro.html]

算法交替执行时间更新与测量更新。

Time Update 即时间更新，对应 Predict，利用运动模型预测状态及其误差。

Measurement Update 即测量更新，对应 Correct，结合观测校正预测。图源为 Welch 的卡尔曼滤波介绍。

The Kalman Filter in 1D　一维卡尔曼滤波

Dynamic Model

$$x_i \sim N(d_i x_{i-1}, \sigma^2_{d_i})$$

$$y_i \sim N(m_i x_i, \sigma^2_{m_i})$$

Notation

mean of $P(X_i|y_0,\ldots,y_{i-1})$ as $\overline{X}_i^-$ ← Predicted mean

mean of $P(X_i|y_0,\ldots,y_i)$ as $\overline{X}_i^+$ ← Corrected mean

the standard deviation of $P(X_i|y_0,\ldots,y_{i-1})$ as σ_i^-

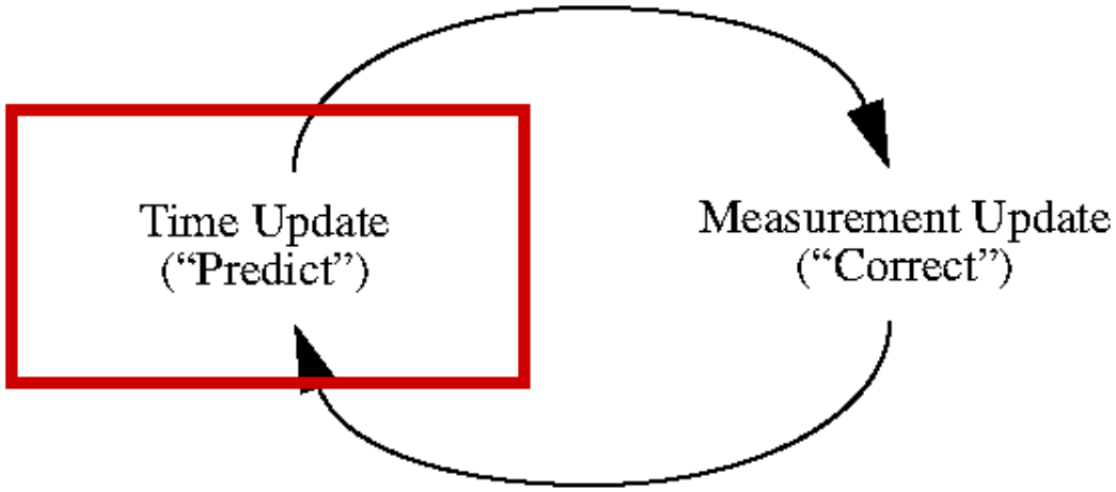
of $P(X_i|y_0,\ldots,y_i)$ as σ_i^+

动力学模型为 $x_i \sim N(d_i x_{i-1}, \sigma^2_d_i)$，观测模型为 $y_i \sim N(m_i x_i, \sigma^2_m_i)$。

d_i 为状态转移系数，m_i 为观测系数，两种 σ^2 分别描述过程噪声与测量噪声。

$\bar{x}_i^-$ 为当前测量之前的预测均值，$\bar{x}_i^+$ 为融合当前测量后的校正均值。σ_i^- 与 σ_i^+ 分别为对应标准差。

The Kalman Filter　卡尔曼滤波的时间更新



图中突出显示时间更新，即预测阶段。

由上一时刻校正后的状态与误差，计算当前时刻的预测状态和预测误差。

预测结果随后作为测量更新的输入。

Prediction for 1D Kalman filter　一维状态预测

The new state is obtained by

multiplying old state by known constant

adding zero-mean noise

$$x_i \sim N(d_i x_{i-1}, \sigma^2_{d_i})$$

Therefore, predicted mean for new state is

constant times mean for old state

Old variance is normal random variable

variance is multiplied by square of constant

and variance of noise is added.

$$\overline{X}_i^- = d_i \overline{X}_{i-1}^+$$

$$(\sigma_i^-)^2 = \sigma^2_{d_i} + (d_i \sigma_{i-1}^+)^2$$

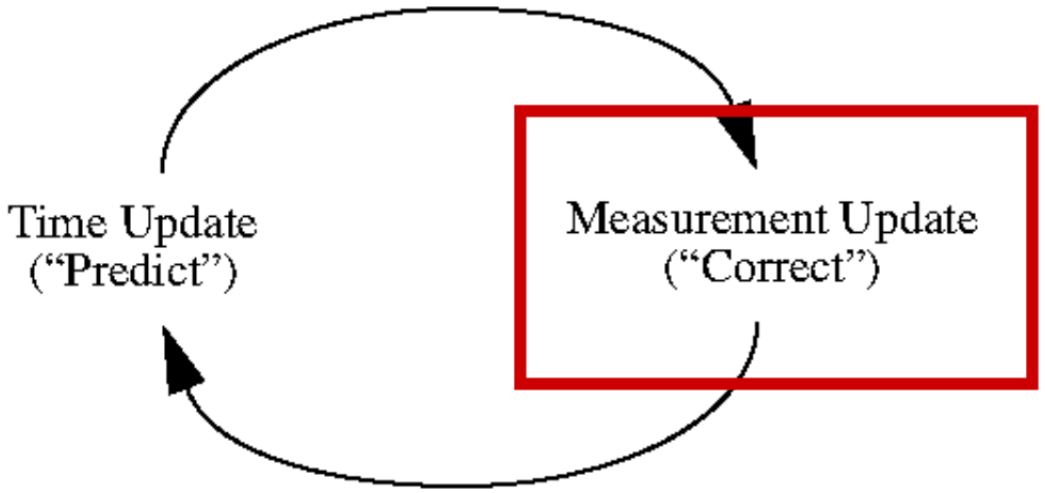
新状态由旧状态乘以已知常数 d_i，并加上零均值过程噪声得到。

预测均值为 $\bar{x}_i^- = d_i \bar{x}_{i-1}^+$。

方差传播时，旧方差乘以 d_i^2，并加上过程噪声方差。

因此预测方差为 $(\sigma_i^-)^2 = \sigma^2_d_i + (d_i \sigma_{i-1}^+)^2$。

The Kalman Filter　卡尔曼滤波的测量更新



图中突出显示测量更新，即校正阶段。

将当前观测与预测状态结合，利用卡尔曼增益计算校正后的状态及其误差。

校正结果继续参与下一时刻的时间更新。

Measurement update for 1D Kalman filter 一维测量更新

$$x_i^+ = \left(\frac{\overline{x}_i^- \sigma_{m_i}^2 + m_i y_i (\sigma_i^-)^2}{\sigma_{m_i}^2 + m_i^2 (\sigma_i^-)^2} \right)$$

$$\sigma_i^+ = \sqrt{\left(\frac{\sigma_{m_i}^2 (\sigma_i^-)^2}{(\sigma_{m_i}^2 + m_i^2 (\sigma_i^-)^2)} \right)}$$

Notice:

if measurement noise is small,

we rely mainly on the measurement,

if it's large, mainly on the prediction

σ does not depend on y

后验均值按照预测方差与测量噪声方差，对预测和当前测量进行加权融合。

测量噪声较小时，观测占较大权重。测量噪声较大时，预测占较大权重。

校正后的标准差 σ_i^+ 由噪声与预测方差决定，与具体测量值 y_i 相互独立。图中给出均值和标准差的解析公式。

一维卡尔曼滤波汇总

Dynamic Model:

$$x_i \sim N(d_i x_{i-1}, \sigma_{d_i})$$

$$y_i \sim N(m_i x_i, \sigma_{m_i})$$

Start Assumptions: $\overline{x}_0^-$ and σ_0^- are known

Update Equations: Prediction

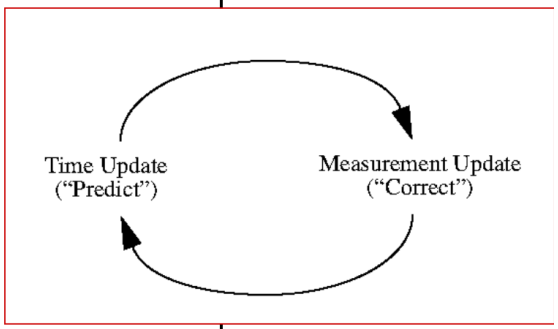
$$\overline{x}_i^- = d_i \overline{x}_{i-1}^+$$

$$\sigma_i^- = \sqrt{\sigma_{d_i}^2 + (d_i \sigma_{i-1}^+)^2}$$

Update Equations: Correction

$$x_i^+ = \left(\frac{\overline{x}_i^- \sigma_{m_i}^2 + m_i y_i (\sigma_i^-)^2}{\sigma_{m_i}^2 + m_i^2 (\sigma_i^-)^2} \right)$$

$$\sigma_i^+ = \sqrt{\left(\frac{\sigma_{m_i}^2 (\sigma_i^-)^2}{(\sigma_{m_i}^2 + m_i^2 (\sigma_i^-)^2)} \right)}$$



模型由线性状态转移与线性观测组成，两者分别叠加高斯噪声。给定初始预测均值和标准差即可开始递推。

时间更新传播均值和方差，过程噪声增加预测方差。

测量更新融合预测与观测，并根据相对噪声水平调整权重。图中汇总两阶段的完整公式。

Kalman filter for computing an on-line average
卡尔曼滤波与在线均值

What Kalman filter parameters and initial conditions should we pick so that the optimal estimate for x at each iteration is just the average of all the observations seen so far?

目标为选择卡尔曼滤波参数与初始条件，使每次迭代得到的状态估计等于目前全部观测的算术平均值。

该例展示在线统计与递推状态估计之间的联系。

在线均值的参数设置

Dynamic Model:

$$x_i \sim N(d_i x_{i-1}, \sigma_{d_i})$$

$$y_i \sim N(m_i x_i, \sigma_{m_i})$$

Start Assumptions: $\bar{x}_0^-$ and σ_0^- are known

Update Equations: Prediction

$$\bar{x}_i^- = d_i \bar{x}_{i-1}^+$$

$$\sigma_i^- = \sqrt{\sigma_{d_i}^2 + (d_i \sigma_{i-1}^+)^2}$$

Update Equations: Correction

$$x_i^+ = \left(\frac{\bar{x}_i^- \sigma_{m_i}^2 + m_i y_i (\sigma_i^-)^2}{\sigma_{m_i}^2 + m_i^2 (\sigma_i^-)^2} \right)$$

$$\sigma_i^+ = \sqrt{\left(\frac{\sigma_{m_i}^2 (\sigma_i^-)^2}{(\sigma_{m_i}^2 + m_i^2 (\sigma_i^-)^2)} \right)}$$

Kalman filter model

$$d_i = 1, m_i = 1, \sigma_{d_i} = 0, \sigma_{m_i} = 1$$

Initial conditions

$$\bar{x}_0^- = 0 \quad \sigma_0^- = \infty$$

Iteration	0	1	2
$\bar{x}_i^-$	0	y_0	$\frac{y_0 + y_1}{2}$
$\bar{x}_i^+$	y_0	$\frac{y_0 + y_1}{2}$	$\frac{y_0 + y_1 + y_2}{3}$
σ_i^-	∞	1	$\frac{1}{\sqrt{2}}$
σ_i^+	1	$\frac{1}{\sqrt{2}}$	$\frac{1}{\sqrt{3}}$

状态转移系数与观测系数均为 1，过程噪声标准差为 0，测量噪声标准差为 1。初始预测均值为 0，标准差趋于无穷。

第 0、1、2 次迭代的后验均值依次为 y_0、$(y_0+y_1)/2$、$(y_0+y_1+y_2)/3$。

对应后验标准差为 1、$1/\sqrt{2}$、$1/\sqrt{3}$。表格中的 Iteration 为迭代次数，Initial conditions 为初始条件。

What happens if the x dynamics are given a non-zero variance?
过程噪声的影响

给状态动力学加入正的过程噪声方差，使模型允许状态随时间发生变化。

此时递推估计更强调近期观测，可用于跟随随时间变化的目标。

含过程噪声的在线估计

Dynamic Model:

$$x_i \sim N(d_i x_{i-1}, \sigma_{d_i})$$

$$y_i \sim N(m_i x_i, \sigma_{m_i})$$

Start Assumptions: $\bar{x}_0^-$ and σ_0^- are known

Update Equations: Prediction

$$\bar{x}_i^- = d_i \bar{x}_{i-1}^+$$

$$\sigma_i^- = \sqrt{\sigma_{d_i}^2 + (d_i \sigma_{i-1}^+)^2}$$

Update Equations: Correction

$$x_i^+ = \left(\frac{\bar{x}_i^- \sigma_{m_i}^2 + m_i y_i (\sigma_i^-)^2}{\sigma_{m_i}^2 + m_i^2 (\sigma_i^-)^2} \right)$$

$$\sigma_i^+ = \sqrt{\left(\frac{\sigma_{m_i}^2 (\sigma_i^-)^2}{(\sigma_{m_i}^2 + m_i^2 (\sigma_i^-)^2)} \right)}$$

Kalman filter model

$$d_i = 1, m_i = 1, \sigma_{d_i} = 1, \sigma_{m_i} = 1$$

Initial conditions

$$\bar{x}_0^- = 0 \quad \sigma_0^- = \infty$$

Iteration	0	1	2
$\bar{x}_i^-$	0	y_0	$\frac{y_0 + 2y_1}{3}$
$\bar{x}_i^+$	y_0	$\frac{y_0 + 2y_1}{3}$	$\frac{y_0 + 2y_1 + 5y_2}{8}$
σ_i^-	∞	$\sqrt{2}$	$\sqrt{\frac{5}{3}}$
σ_i^+	1	$\sqrt{\frac{2}{3}}$	$\sqrt{\frac{5}{8}}$

状态转移系数与观测系数均为 1，过程噪声与测量噪声标准差均为 1。初始预测均值为 0，标准差趋于无穷。

第 0、1、2 次迭代的后验均值为 y_0、$(y_0+2y_1)/3$、$(y_0+2y_1+5y_2)/8$，较新的观测获得较大权重。

对应预测标准差为 ∞、$\sqrt{2}$、$\sqrt{(5/3)}$，后验标准差为 1、$\sqrt{(2/3)}$、$\sqrt{(5/8)}$。

Linear dynamic models　线性动态模型

A linear dynamic model has the form

$$\mathbf{x}_i = N\left(\mathbf{D}_{i-1}\mathbf{x}_{i-1}; \Sigma_{d_i}\right)$$

$$\mathbf{y}_i = N\left(\mathbf{M}_i\mathbf{x}_i; \Sigma_{m_i}\right)$$

This is much, much more general than it looks, and extremely powerful

状态模型为 $x_i \sim N(D_{i-1}x_{i-1}, \Sigma_d_i)$，观测模型为 $y_i \sim N(M_i x_i, \Sigma_m_i)$。

D_{i-1} 为状态转移矩阵，M_i 为观测矩阵。Σ_d_i 与 Σ_m_i 分别为过程噪声和测量噪声的协方差。

这种形式可描述多种运动过程，具有广泛的建模能力。

Examples of linear state space models　线性状态空间模型示例

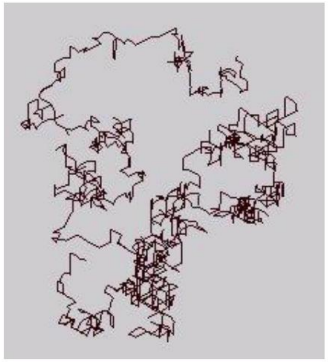
Drifting points

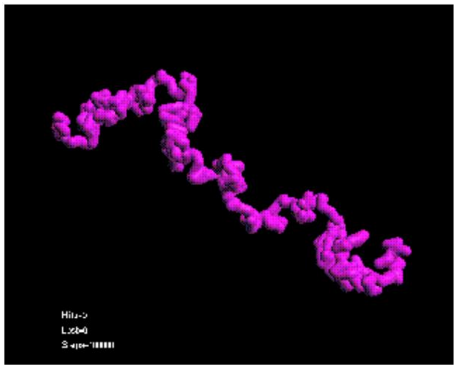
assume that the new position of the point is the old one, plus noise

D = Identity

$$\mathbf{x}_i = N\left(\mathbf{D}_{i-1}\mathbf{x}_{i-1}; \Sigma_{d_i}\right)$$

$$\mathbf{y}_i = N\left(\mathbf{M}_i\mathbf{x}_i; \Sigma_{m_i}\right)$$





cic.nist.gov/lipman/sciviz/images/random3.gif
http://www.grunch.net/synergetics/images/random3.jpg

漂移点模型假设新位置等于旧位置加上随机噪声。

此时状态转移矩阵 D 为单位矩阵，可用于描述随机游走。

图中给出漂移轨迹示例，观测仍通过线性高斯模型生成。

Constant velocity 恒速运动

We have

$$\mathbf{x}_i = N\left(\mathbf{D}_{i-1}\mathbf{x}_{i-1}; \Sigma_{d_i}\right)$$

$$\mathbf{y}_i = N\left(\mathbf{M}_i\mathbf{x}_i; \Sigma_{m_i}\right)$$

$$u_i = u_{i-1} + \Delta t v_{i-1} + \varepsilon_i$$

$$v_i = v_{i-1} + \varsigma_i$$

(the Greek letters denote noise terms)

Stack (u, v) into a single state vector

which is the form we had above

$$\begin{pmatrix} u \\ v \end{pmatrix}_i = \begin{pmatrix} 1 & \Delta t \\ 0 & 1 \end{pmatrix} \begin{pmatrix} u \\ v \end{pmatrix}_{i-1} + \text{noise}$$

$\mathbf{x_i}$ $\mathbf{D_{i-1}}$ $\mathbf{x_{i-1}}$

以位置 u 与速度 v 构成状态向量。位置由上一位置加上 Δt 倍速度及噪声得到，速度由上一速度加上噪声得到。

转移矩阵为 [[1,Δt],[0,1]]，其作用是将速度传播到下一时刻的位置。

图中的希腊字母表示噪声项，矩阵形式与一般线性动态模型一致。

Constant acceleration 恒加速度运动

$$\mathbf{x}_i = N\left(\mathbf{D}_{i-1}\mathbf{x}_{i-1}; \Sigma_{d_i}\right)$$

$$\mathbf{y}_i = N\left(\mathbf{M}_i\mathbf{x}_i; \Sigma_{m_i}\right)$$

以位置 u、速度 v 与加速度 a 构成状态向量。

离散模型为 $u_i=u_{i-1}+\Delta t v_{i-1}+\varepsilon_i$，$v_i=v_{i-1}+\Delta t a_{i-1}+\zeta_i$，$a_i=a_{i-1}+\xi_i$。

转移矩阵依次将速度传播到位置、将加速度传播到速度。希腊字母表示各分量的过程噪声。

We have

$$u_i = u_{i-1} + \Delta t v_{i-1} + \varepsilon_i$$
$$v_i = v_{i-1} + \Delta t a_{i-1} + \zeta_i$$
$$a_i = a_{i-1} + \xi_i$$

(the Greek letters denote noise terms)

Stack (u, v) into a single state vector

which is the form we had above

$$\begin{pmatrix} u \\ v \\ a \end{pmatrix}_i = \begin{pmatrix} 1 & \Delta t & 0 \\ 0 & 1 & \Delta t \\ 0 & 0 & 1 \end{pmatrix} \begin{pmatrix} u \\ v \\ a \end{pmatrix}_{i-1} + \text{noise}$$

$\mathbf{x_i}$ $\mathbf{D_{i-1}}$ $\mathbf{x_{i-1}}$

Periodic motion 周期运动

$$\mathbf{x}_i = N\left(\mathbf{D}_{i-1}\mathbf{x}_{i-1}; \Sigma_{d_i}\right)$$
$$\mathbf{y}_i = N\left(\mathbf{M}_i\mathbf{x}_i; \Sigma_{m_i}\right)$$

Assume we have a point, moving on a line with a periodic movement defined with a differential eq:

can be defined as $$\frac{d^2p}{dt^2} = -p$$

with state defined as stacked position and velocity u=(p, v)

$$\frac{d\boldsymbol{u}}{dt} = \begin{pmatrix} 0 & 1 \\ -1 & 0 \end{pmatrix} \boldsymbol{u} = \mathcal{S}\boldsymbol{u}$$

考虑沿直线运动的点，其周期运动由微分方程 $d^2p/dt^2=-p$ 描述。

将位置与速度堆叠为状态 u=(p,v)，可写成 du/dt=Su。

系统矩阵 S=[[0,1],[−1,0]] 将这一二阶微分方程转为一阶状态方程。

31

Periodic motion　周期运动的离散形式

$$\mathbf{x}_i = N\left(\mathbf{D}_{i-1}\mathbf{x}_{i-1}; \Sigma_{d_i}\right)$$

$$\mathbf{y}_i = N\left(\mathbf{M}_i\mathbf{x}_i; \Sigma_{m_i}\right)$$

$$\frac{d\boldsymbol{u}}{dt} = \begin{pmatrix} 0 & 1 \\ -1 & 0 \end{pmatrix} \boldsymbol{u} = \mathcal{S}\boldsymbol{u}$$

Take discrete approximation….(e.g., forward Euler integration with Δt stepsize.)

$$\begin{aligned} \boldsymbol{u}_i &= \boldsymbol{u}_{i-1} + \Delta t \frac{d\boldsymbol{u}}{dt} \\ &= \boldsymbol{u}_{i-1} + \Delta t \mathcal{S}\boldsymbol{u}_{i-1} \\ &= \begin{pmatrix} 1 & \Delta t \\ -\Delta t & 1 \end{pmatrix} \boldsymbol{u}_{i-1} \end{aligned}$$

$\mathbf{x_i}$　　$\mathbf{D_{i-1}}$　　$\mathbf{x_{i-1}}$

采用步长 Δt 的前向欧拉方法，对连续状态方程作离散近似。

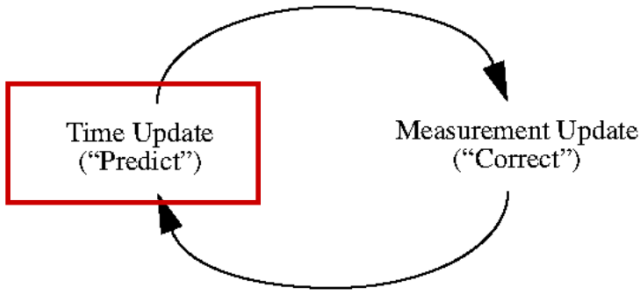
状态递推为 $u_i=(I+\Delta tS)u_{i-1}$。

因此转移矩阵 D=[[1,Δt],[−Δt,1]]，可纳入线性动态模型与卡尔曼滤波框架。

32

n-D 多维卡尔曼滤波

Generalization to n-D is straightforward but more complex.



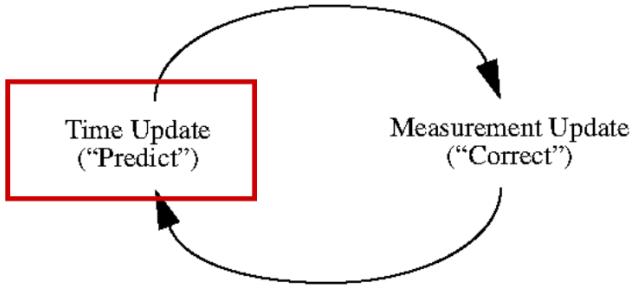
一维卡尔曼滤波可推广到 n 维状态，计算涉及向量与协方差矩阵。

算法仍由时间预测和测量校正组成，矩阵运算较一维情形复杂。

图中突出显示多维状态的预测阶段。

n-D Prediction 多维状态预测

Generalization to n-D is straightforward but more complex.



Prediction:

Multiply estimate at prior time with forward model:

$$\overline{\boldsymbol{x}}_i^- = \mathcal{D}_i \overline{\boldsymbol{x}}_{i-1}^+$$

Propagate covariance through model and add new noise:

$$\Sigma_i^- = \Sigma_{d_i} + \mathcal{D}_i \sigma_{i-1}^+ \mathcal{D}_i$$

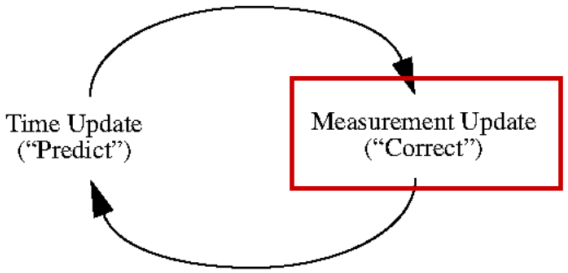
将上一时刻的估计均值乘以正向状态转移模型，得到当前预测均值。

协方差通过状态转移模型传播，并加入新的过程噪声协方差。

34

n-D Correction 多维测量校正

Generalization to n-D is straightforward but more complex.



Correction:

Update *a priori* estimate with measurement to form *a posteriori*

利用当前测量更新预测阶段得到的先验估计，形成后验估计。

状态向量与协方差矩阵共同更新。图中突出显示测量更新阶段。

35

n-D correction 多维测量校正

Find linear filter on innovations

$$\overline{\boldsymbol{x}}_i^+ = \overline{\boldsymbol{x}}_i^- + \mathcal{K}_i \left[\boldsymbol{y}_i - \mathcal{M}_i \overline{\boldsymbol{x}}_i^- \right]$$

which minimizes *a posteriori* error covariance:

$$E\left[\left(x - \overline{x^+}\right)^T \left(x - \overline{x^+}\right)\right]$$

K is the *Kalman Gain* matrix. A solution is

$$\mathcal{K}_i = \Sigma_i^- \mathcal{M}_i^T \left[\mathcal{M}_i \Sigma_i^- \mathcal{M}_i^T + \Sigma_{m_i} \right]^{-1}$$

新息为当前观测与预测观测之差 $y-M\bar{x}^-$。

状态更新为 $\bar{x}^+=\bar{x}^-+K(y-M\bar{x}^-)$，即对新息作线性加权校正。

选择卡尔曼增益矩阵 K，使后验误差协方差最小。图中给出 $K=\Sigma^-M^T(M\Sigma^-M^T+\Sigma_m)^{-1}$ 的解析解。

Kalman Gain Matrix　卡尔曼增益矩阵

$$\overline{\boldsymbol{x}}_i^+ = \overline{\boldsymbol{x}}_i^- + \mathcal{K}_i \left[\boldsymbol{y}_i - \mathcal{M}_i \overline{\boldsymbol{x}}_i^- \right]$$

$$\boxed{\mathcal{K}_i = \Sigma_i^- \mathcal{M}_i^T \left[\mathcal{M}_i \Sigma_i^- \mathcal{M}_i^T + \Sigma_{m_i} \right]^{-1}}$$

As measurement becomes more reliable, K weights residual more heavily,

$$\lim_{\Sigma_m \to 0} K_i = M^{-1}$$

As prior covariance approaches 0, measurements are ignored:

$$\lim_{\Sigma_i^- \to 0} K_i = 0$$

测量可靠性提高时，卡尔曼增益赋予残差更大的权重。

当测量噪声协方差趋于 0，且 M 可逆时，极限为 $K \to M^{-1}$。

当预测协方差趋于 0 时，$K \to 0$，测量对状态校正的影响也趋于 0。

Embellishments for tracking　跟踪模型扩展

Richer models of $P(x_n|x_{n-1})$

Richer models of $P(y_n|x_n)$

Richer model of probability distributions

可采用更丰富的状态转移模型 $P(x_n|x_{n-1})$，描述更多运动模式。

可采用更丰富的观测模型 $P(y_n|x_n)$，描述外观与测量的关系。

还可扩展概率分布的表示方式，以处理复杂状态分布。

Abrupt changes 运动突变

What if environment is sometimes unpredictable?

Do people move with constant velocity?

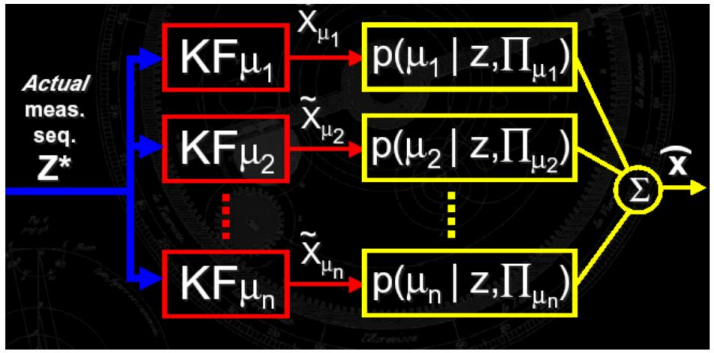
Test several models of assumed dynamics, use the best.

环境可能出现难以预测的变化，人体运动也会经历速度变化与突然停止。

同时检验多个动力学模型，依据当前观测选择表现较好的模型，可提高对运动突变的适应能力。

Multiple model filters　多模型滤波

Test several models of assumed dynamics



$$p_j(k) = \frac{f(\vec{z}|\mu_j)p_j(k-1)}{\sum_{h=1}^{r} f(\vec{z}|\mu_h)p_h(k-1)}$$

$$p_j(k) = \frac{f(\vec{z}|\mu_j)}{\sum_{h=1}^{r} f(\vec{z}|\mu_h)}$$

$$f(\vec{z}|\mu) = \frac{1}{(2\pi)^{n_\mu/2}\sqrt{|C_\mu|}} e^{-\frac{1}{2}(\vec{z}-H_\mu\vec{x}_\mu)^T C_\mu^{-1}(\vec{z}-H_\mu\vec{x}_\mu)}$$

[figure from Welsh and Bishop 2001]

41

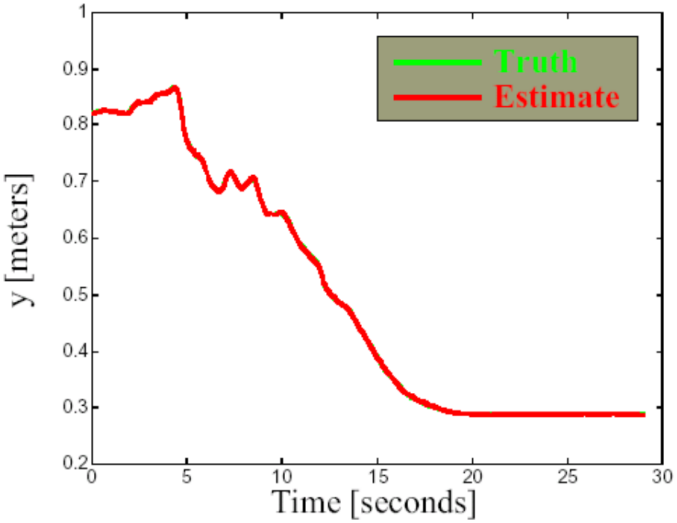
并行运行多个假设动力学模型，每个滤波器输出状态估计及当前测量的似然。

将观测似然与上一时刻模型概率相乘，并归一化，得到各模型的后验概率。

按照模型概率加权融合状态估计。图中 Actual meas. seq. 为实际测量序列，图源为 Welsh 与 Bishop，2001 年。

MM estimate　多模型状态估计

Two models: Position (P), Position+Velocity (PV)



[figure from Welsh and Bishop 2001]

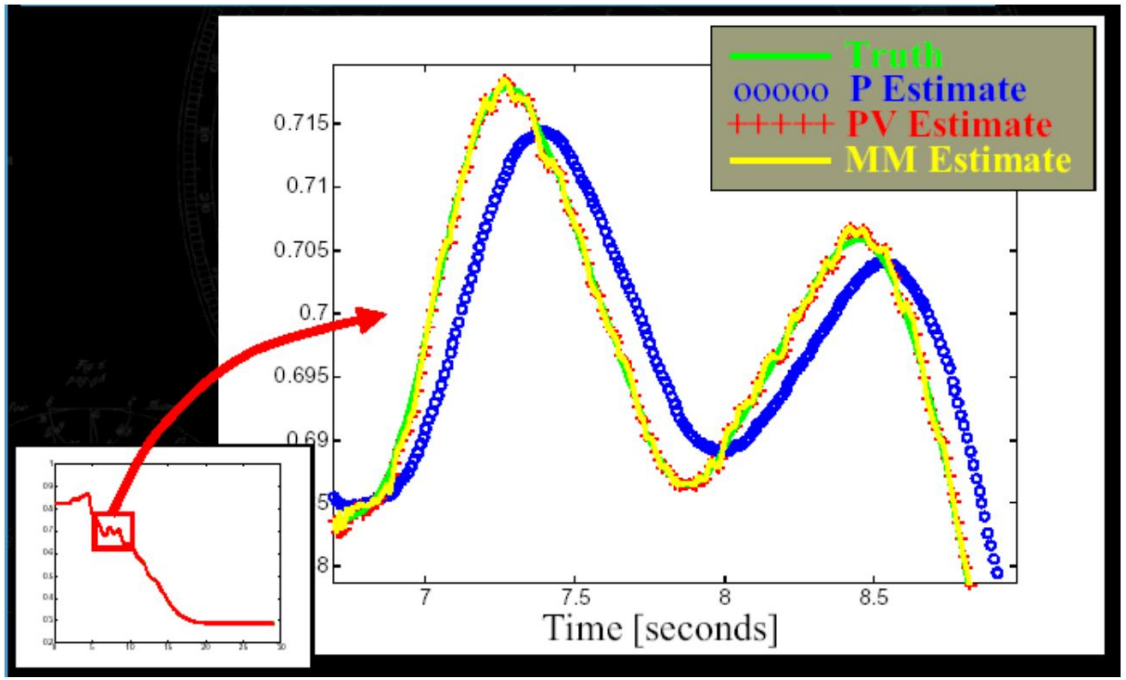
42

示例组合两个模型，即仅含位置的 P 模型，以及包含位置与速度的 PV 模型。

多模型估计在运动阶段和静止阶段动态调整各模型的贡献。

图中绿色 Truth 为真实值，红色 Estimate 为估计值。横轴为时间，单位秒，纵轴为位置，单位米。

No lag　跟踪时延比较



图中比较真实轨迹、P 模型、PV 模型与多模型 MM 的估计。

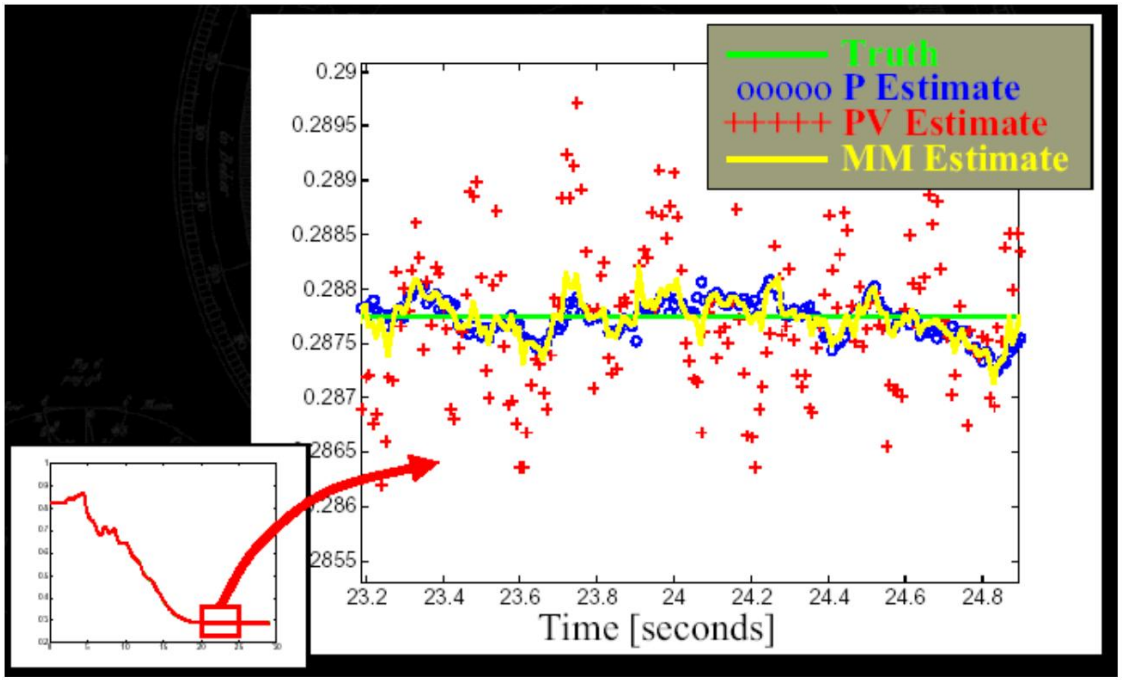
绿色曲线为真实值，蓝色圆点为 P 估计，红色叉号为 PV 估计，黄色曲线为 MM 估计。

在持续运动阶段，P 模型出现较明显的时延，PV 与 MM 对运动轨迹的跟随更及时。

[figure from Welsh and Bishop 2001]

44

Smooth when still　静止阶段的平滑性



在目标静止阶段，P 模型与多模型 MM 给出较平滑的估计，PV 模型的估计波动较大。

图例沿用真实值、P、PV 与 MM 的配色。

该比较展示多模型方法在运动跟随与静止平滑之间的适应能力。

[figure from Welsh and Bishop 2001]

45

Embellishments for tracking　观测模型扩展

Richer models of $P(y_n|x_n)$

Richer model of probability distributions

通过丰富 $P(y_n|x_n)$ 描述目标外观、背景干扰与测量噪声。

概率分布的表示方式也可扩展。此页重点转向更丰富的观测模型。

46

Jepson, Fleet, and El-Maraghi tracker
Jepson、Fleet 与 El-Maraghi 跟踪器

IEEE Conference on Computer Vision and and Pattern Recognition, Kauai, 2001, Vol. I, pp. 415–422

Robust Online Appearance Models for Visual Tracking

Allan D. Jepson* David J. Fleet† Thomas F. El-Maraghi*†

*Department of Computer Science, University of Toronto, Toronto, M5S 1A4
†Xerox Palo Alto Research Center, 3333 Coyote Hill Rd, Palo Alto, CA 94304

论文题目为《视觉跟踪的鲁棒在线外观模型》。

作者为 Allan D. Jepson、David J. Fleet 与 Thomas F. El-Maraghi。

论文发表于 CVPR 2001，第 1 卷，第 415 至 422 页，研究在线更新的目标外观模型。

47

Wandering, Stable, and Lost appearance model
漂移、稳定与丢失外观模型

Introduce 3 competing models to explain the appearance of the tracked region:

- A stable model—Gaussian with some mean and covariance.
- A 2-frame motion tracker appearance model, to rebuild the stable model when it gets lost
- An outlier model—uniform probability over all appearances.

Use an on-line EM algorithm to fit the (changing) model parameters to the recent appearance data.

使用三个相互竞争的模型解释被跟踪区域的外观。

稳定模型采用具有均值与协方差的高斯分布。两帧运动跟踪外观模型用于在稳定模型丢失时重建它。

离群模型在全部可能外观上采用均匀概率分布。

在线 EM 算法利用近期外观数据拟合持续变化的模型参数。

48

Embellishments for tracking　概率分布模型扩展

Richer model of $P(y_n|x_n)$

Richer model of probability distributions

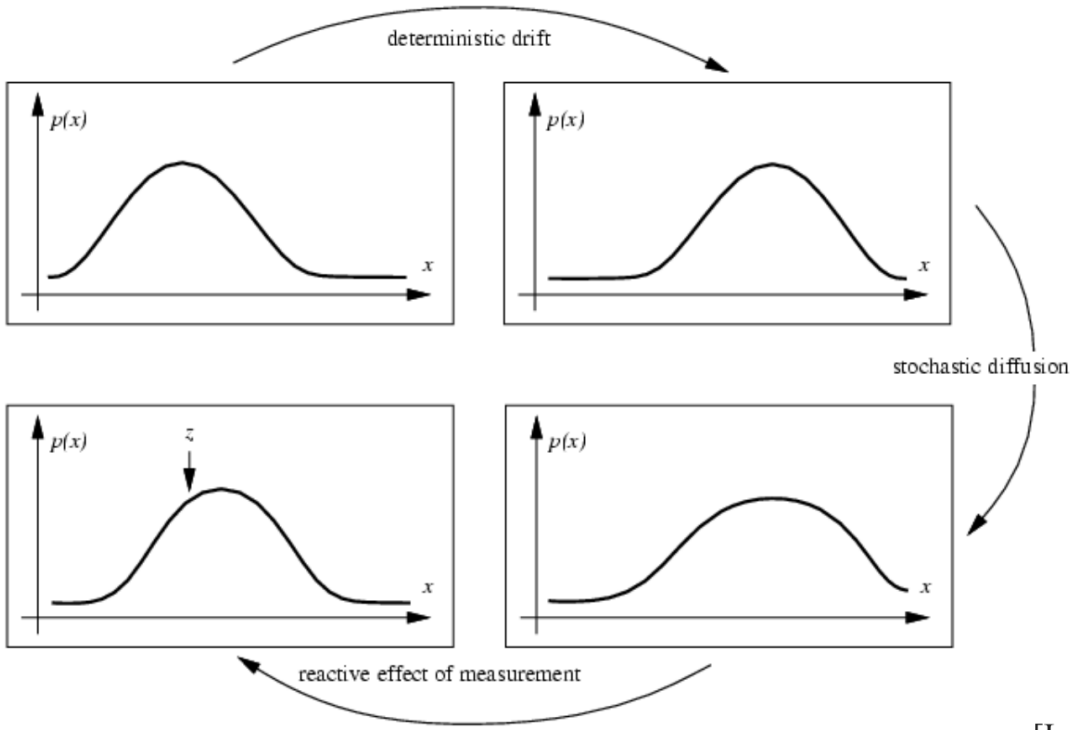
Particle filter models, applied to tracking humans

跟踪器可同时丰富观测模型 $P(y_n|x_n)$ 与状态概率分布的表示。

粒子滤波使用样本近似复杂分布，可应用于人体等对象的跟踪。

49

(KF) Distribution propagation 卡尔曼分布传播



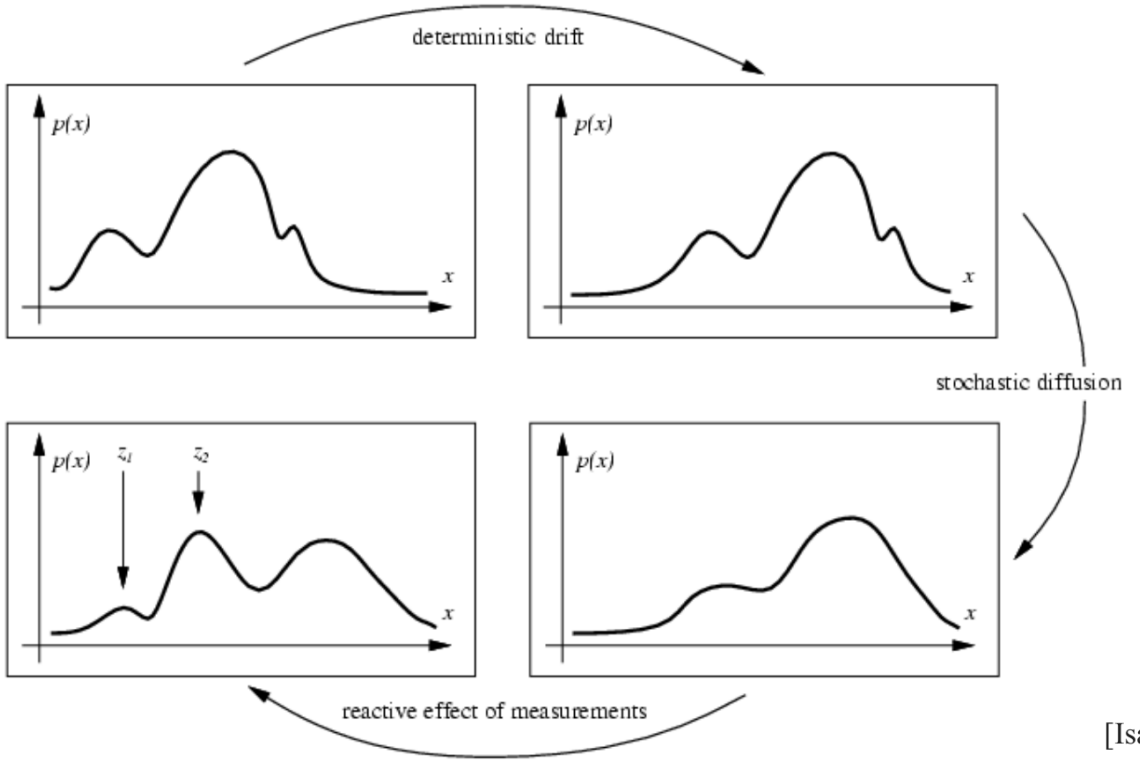
[Isard 1998]

单个高斯分布经历确定性漂移、随机扩散与测量更新。

由上一时刻状态产生预测，加入过程噪声后分布扩展，随后利用下一时刻的新测量重新约束状态。

图中 Deterministic drift 为确定性漂移，Stochastic diffusion 为随机扩散，Reactive effect of measurements 为测量更新作用。图源为 Isard，1998 年。

Distribution propagation　一般分布传播



[Isard 1998]

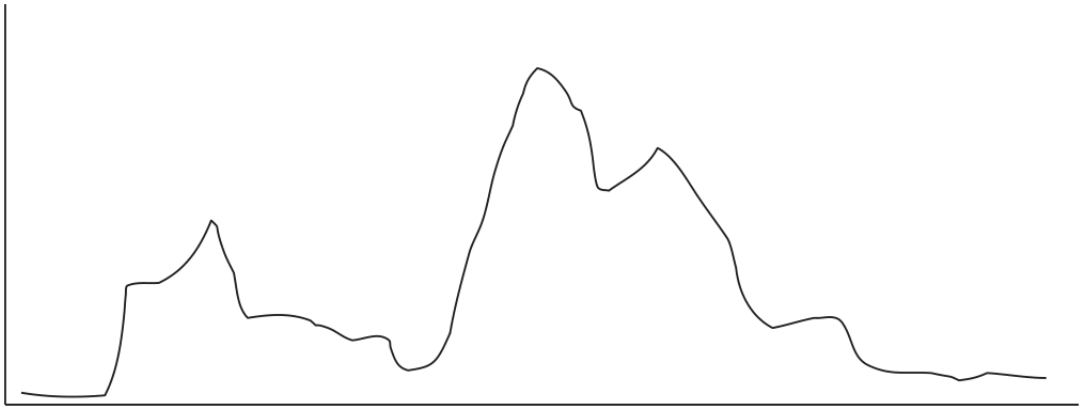
复杂状态分布同样经历确定性漂移、随机扩散与测量更新。

分布可包含多个峰值，对应多个候选状态。观测 z_1、z_2 等对各候选状态赋予相应似然，改变峰值位置与权重。

该图展示一般概率分布在跟踪递推中的演化。

Representing non-linear Distributions 一般概率分布的表示

$$p(\mathbf{x}_t|\mathcal{Z}_t) = k_t\ p(\mathbf{z}_t|\mathbf{x}_t)p(\mathbf{x}_t|\mathcal{Z}_{t-1})$$



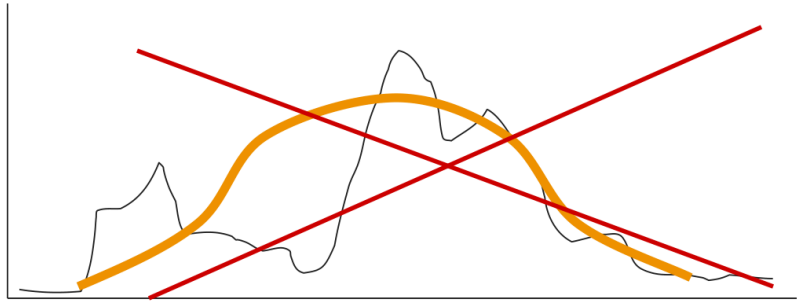
贝叶斯更新为 $p(x_t|Z_t)=k_t p(z_t|x_t)p(x_t|Z_{t-1})$ 。

其中观测似然与预测分布相乘形成后验，k_t 为归一化常数。

实际跟踪中的概率密度可能形状复杂并具有多个峰值。

Representing non-linear Distributions 单峰参数模型的局限

Unimodal parametric models fail to capture real-world densities…



真实状态密度可能具有明显的多峰结构与复杂轮廓。

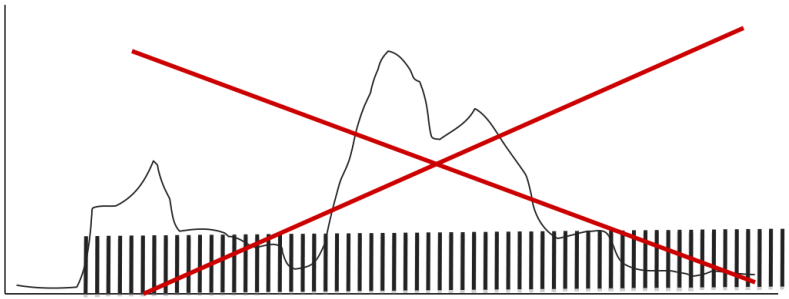
用单个高斯等单峰参数模型拟合时，会丢失多个候选状态之间的分布结构。

图中将真实多峰密度与单高斯近似进行比较。

Discretize by evenly sampling over the entire state space
全状态空间均匀采样

Tractable for 1-d problems like stereo, but not for high-dimensional problems.

$$p(\mathbf{x}|\mathbf{z}) = kp(\mathbf{z}|\mathbf{x})p(\mathbf{x})$$



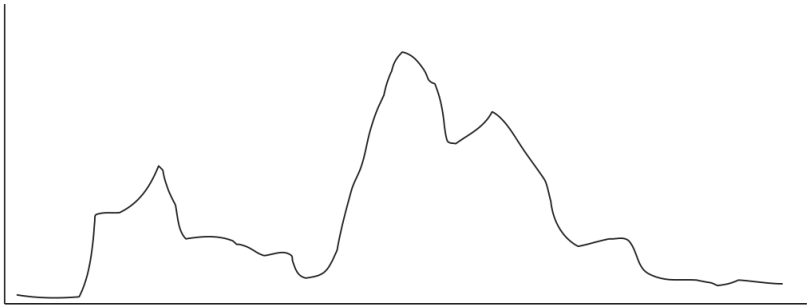
对整个状态空间均匀采样，可将连续概率密度离散化。

对于立体视觉中的一维搜索等问题，这种方法的计算规模尚可处理。

状态维数升高时，采样点数随维数快速增长，全空间均匀采样的计算代价很高。

Representing Distributions using Weighted Samples
加权样本的分布表示

Rather than a parametric form, use a set of samples to represent a density:



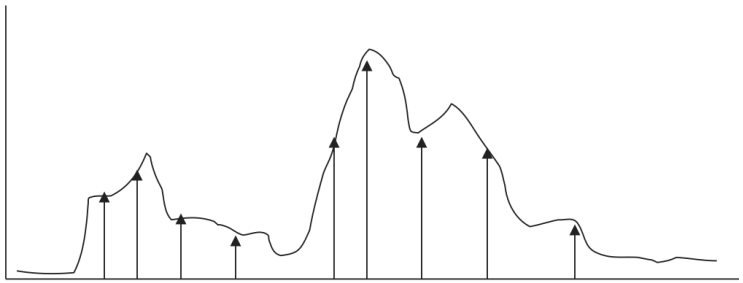
使用一组带权样本描述概率密度。

样本可以集中在高概率区域，并同时表达多个峰值。

图中以离散样本近似原有复杂密度，为粒子滤波建立表示基础。

Representing Distributions using Weighted Samples
加权样本的参数

Rather than a parametric form, use a set of samples to represent a density:



$$\{(\boldsymbol{u}^i, w^i)\}$$

Sample positions　　Probability mass at each sample

This gives us two knobs to adjust when representing a probability density by samples: the locations of the samples, and the probability weight on each sample.

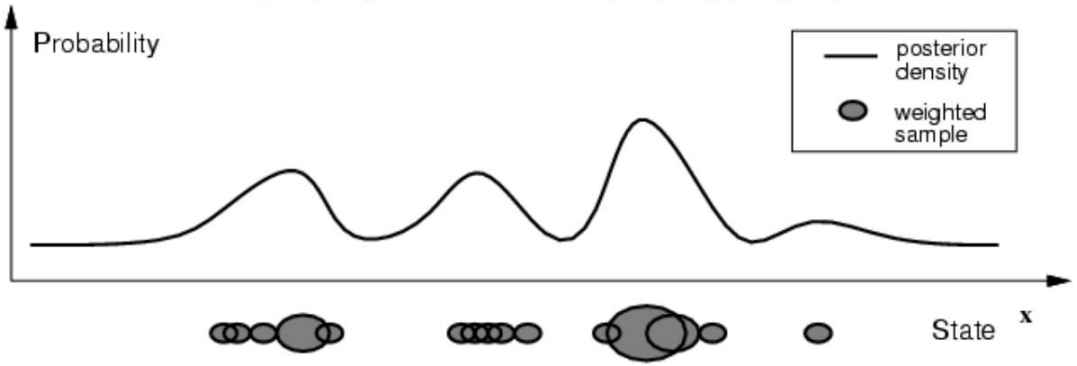
每个样本由位置 u^i 与权重 w^i 组成，权重表示该样本承载的概率质量。

用样本描述密度时，可以调整样本所在位置，也可以调整每个样本的概率权重。

Sample positions 为样本位置，Probability mass at each sample 为各样本处的概率质量。

Representing distributions using weighted samples, another picture
加权样本的图示

$$p(\mathbf{x}|\mathbf{z}) = kp(\mathbf{z}|\mathbf{x})p(\mathbf{x})$$



$$\pi_i = \frac{p_z(\mathbf{s}^{(i)})}{\sum_{j=1}^{N} p_z(\mathbf{s}^{(j)})}$$

$$p_f(x) = \sum_i w^i \delta(x - u^i)$$

$$p_z(\mathbf{x}) = p(\mathbf{z}|\mathbf{x}),$$

[Isard 1998]

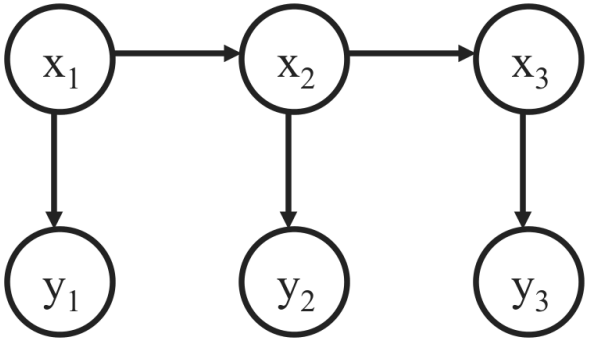
离散密度表示为 $p_f(x)=\Sigma_i w^i\delta(x-u^i)$，$\delta$ 为狄拉克函数。

图中粒子大小表示权重，较大粒子承载较多概率质量。

状态 s^i 的观测似然记为 $p_z(s^i)$，其归一化权重为 $\pi_i=p_z(s^i)/\Sigma_j p_z(s^j)$。

Probability 为概率，State 为状态，Posterior density 为后验密度，Weighted sample 为加权样本。

Tracking, in particle filter representation 粒子表示中的跟踪递推



$$p_f(x) = \sum_i w^i \delta(x - u^i)$$

$$P(x_n \mid y_1 \ldots y_n) = k\, P(y_n \mid x_n) \int dx_{n-1} P(x_n \mid x_{n-1}) P(x_{n-1} \mid y_1 \ldots y_{n-1})$$

Update step

Prediction step

状态与测量仍满足马尔可夫图模型。

预测步骤对状态转移概率与上一后验的乘积积分，形成当前预测分布。

更新步骤将预测与当前测量似然相乘并归一化，得到当前后验。

粒子滤波用加权狄拉克样本之和表示这些分布。

Particle filter 粒子滤波

Let's apply this sampled probability density machinery to generalize the Kalman filtering framework.

More general probability density representation than uni-modal Gaussian.

Allows for general state dynamics, f(x) + noise

将基于样本的概率密度表示应用于卡尔曼滤波框架的推广。

样本集合可描述多峰等复杂分布，扩展单峰高斯表示的表达能力。

状态动力学可采用一般函数 f(x) 加噪声，因而能够处理非线性运动。

Sampled Prediction　基于样本的预测

$$P(\boldsymbol{x}_i|\boldsymbol{y}_0,\ldots,\boldsymbol{y}_{i-1}) \;=\; ?$$

$$p(\boldsymbol{X}_i,\boldsymbol{X}_{i-1}|\boldsymbol{y}_0,\ldots,\boldsymbol{y}_{i-1}) = p(\boldsymbol{X}_i|\boldsymbol{X}_{i-1})p(\boldsymbol{X}_{i-1}|\boldsymbol{y}_0,\ldots,\boldsymbol{y}_{i-1})$$

$$p(\boldsymbol{X}_{i-1}|\boldsymbol{y}_0,\ldots,\boldsymbol{y}_{i-1})$$

$$\{(\boldsymbol{u}_{i-1}^k, w_{i-1}^k)\} \longrightarrow \boldsymbol{x}_i = \boldsymbol{f}(\boldsymbol{x}_{i-1}) + \xi_i \longrightarrow$$

$$\{((f(\boldsymbol{u}_{i-1}^k) + \xi_i^l, \boldsymbol{u}_{i-1}^k), w_{i-1}^k)\}$$

$$p(\boldsymbol{X}_i,\boldsymbol{X}_{i-1}|\boldsymbol{y}_0,\ldots,\boldsymbol{y}_{i-1})$$

Drop elements to marginalize to get

$$P(\boldsymbol{x}_i|\boldsymbol{y}_0,\ldots,\boldsymbol{y}_{i-1}) \;\sim=$$

$$\{(f(\boldsymbol{u}_{i-1}^k) + \xi_i^l, w_{i-1}^k)\}$$

给定上一时刻带权样本 (u^k_{i-1},w^k_{i-1})，将每个样本通过动力学函数 f 传播，并加入随机过程噪声 ξ。

预测粒子为 $f(u^k_{i-1})+\xi$，权重继承 w^k_{i-1}。

图中从当前与上一状态的联合样本表示出发，通过省去上一状态坐标完成边缘化，得到当前预测样本。

Sampled Correction (Bayes rule)　基于样本的贝叶斯校正

Prior → posterior

Reweight every sample with the likelihood of the observations, given that sample:

$$p(\boldsymbol{Y}_i = \boldsymbol{y}_i | \boldsymbol{X}_i = \boldsymbol{s}_i^{k,-}) w_i^{k,-}$$

yielding a set of samples describing the probability distribution after the correction (update) step:

$$\left\{ (\boldsymbol{s}_i^{k,-}, p(\boldsymbol{Y}_i = \boldsymbol{y}_i | \boldsymbol{X}_i = \boldsymbol{s}_i^{k,-}) w_i^{k,-}) \right\}$$

由先验样本分布计算后验样本分布。

在每个预测粒子所在状态计算当前观测的似然，并将原权重乘以该似然。

更新后的加权样本描述校正后的概率分布。将权重归一化后，其总和为 1。

Naïve PF Tracking　基本粒子滤波跟踪

Start with samples from something simple (Gaussian)

Repeat

Take each particle from the prediction step and modify the old weight by multiplying by the new likelihood

– Correct

$$\left\{(s_i^{k,-}, p(\boldsymbol{Y}_i = \boldsymbol{y}_i | \boldsymbol{X}_i = s_i^{k,-}) w_i^{k,-})\right\}$$

– Predict

$$\left\{(f(\mathbf{s}_{i-1}^k) + \xi_i^l, w_{i-1}^k)\right\}$$

Run every particle through the dynamics function and add noise.

But doesn't work that well because of sample impoverishment…

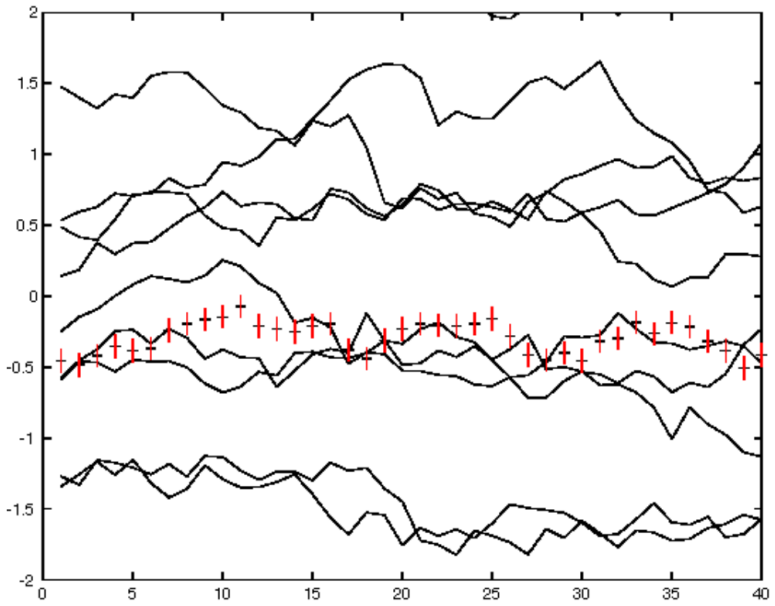
从高斯等简单分布采样，建立初始粒子集。

反复执行校正与预测。校正将预测粒子的原权重乘以新观测似然，预测将各粒子通过动力学函数传播并加入噪声。

持续运行时可能出现粒子贫化，使有效表示后验的粒子数量减少，并影响跟踪性能。

Sample impoverishment　粒子贫化

10 of the 100 particles, along with the true Kalman filter track, with variance:



图中展示 100 个粒子中的 10 条轨迹，并给出真实卡尔曼滤波轨迹及其方差范围。

随着时间推移，多条样本轨迹偏离高概率区域，仅少量样本继续有效描述后验。

这种粒子贫化现象会降低样本表示的质量。横轴 time 为时间。

Resample the prior　先验重采样

In a sampled density representation, the frequency of samples can be traded off against weight:

$$(s_k, w_k) \longrightarrow \begin{matrix}(s_k, 1)\\ (s_k, 1)\\ (s_k, 1)\\ \vdots\end{matrix} \quad N_k \text{ copies} \quad \text{s.t.} \quad \frac{N_k}{\sum_k N_k} = w_k$$

These new samples are a representation of the same density.

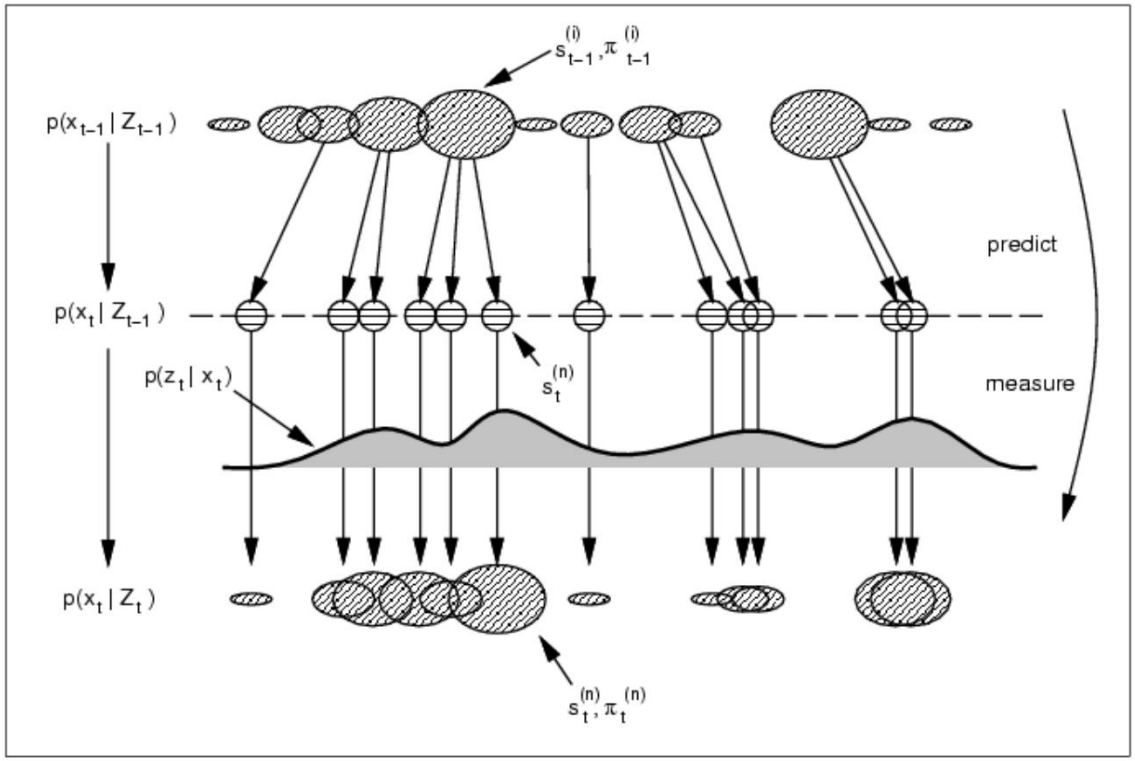
I.e., make N draws with replacement from the original set of samples, using the weights as the probability of drawing a sample.

样本出现的频率与样本权重均可表达概率质量。

按照原权重作为抽取概率，从原样本集有放回抽取 N 次，形成具有相同权重的新样本集。

高权重粒子获得较多副本，新集合近似表示相同密度。若第 k 个粒子出现 N_k 次，其频率 $N_k/\Sigma N_k$ 近似原权重 w_k。

Pictorial view　粒子滤波流程图示



[Isard 1998]

上一时刻的后验由带权粒子表示，粒子大小反映其概率权重。

按权重选择粒子，经过运动传播与随机扩散，形成当前预测粒子。

当前测量提供似然曲线，用于重新分配粒子权重，获得当前后验。

图中 Predict 为预测，Measure 为测量。图源为 Isard，1998 年。

粒子滤波跟踪实现

```
# 初始化
particles = sample_gauss(init_box, sigma0, N)   # x_0^(i)
weights   = np.ones(N) / N

for t in range(1, T):
    # 1. 预测：状态转移采样（先验）
    particles = motion_model(particles) + np.random.normal(0, sigma_dyn, particles.shape)

    # 2. 权重更新：外观似然
    for i in range(N):
        patch = crop(frame[t], particles[i])
        d = bhattacharyya(hist_model, hist(patch))     # 距离 [0,1]
        weights[i] = np.exp(-lam * d**2)               # 似然

    weights_sum = weights.sum()
    if weights_sum < 1e-12:          # 全失效 → 重新初始化
        particles = sample_gauss(prev_box, sigma0, N);
        weights = np.ones(N)/N
    else:       weights /= weights_sum

    # 3. 状态估计（加权均值）
    x_hat = (weights[:, None] * particles).sum(axis=0)
    output(x_hat)
```

```
    # 4. 自适应重采样
    n_eff = 1.0 / (weights**2).sum()
    if n_eff < N / 2:
        idx = systematic_resample(weights)
        particles = particles[idx]
        weights = np.ones(N) / N

    # 5. t += 1，回到 1
```

代码使用高斯分布初始化粒子，并赋予均匀权重。运动模型与随机噪声生成下一时刻的预测粒子。

利用目标直方图与候选区域直方图的巴氏距离 d，计算外观似然 $\exp(-\lambda d^2)$，随后归一化权重。权重总量极小时重新初始化。

状态估计采用粒子加权均值。有效样本量 $N_{eff}=1/\Sigma w^2$ 低于 N/2 时，执行系统重采样并恢复均匀权重。

原代码及已有中文注释保留。

Animation of condensation algorithm　CONDENSATION 算法演示



CONDENSATION 通过粒子近似传播条件概率密度，用于复杂运动与外观条件下的视觉跟踪。

此页为动画演示。来源 Isard，1998 年。

[Isard 1998]

Applications 粒子滤波应用

Tracking

- hands
- bodies
- Leaves

What might we expect?

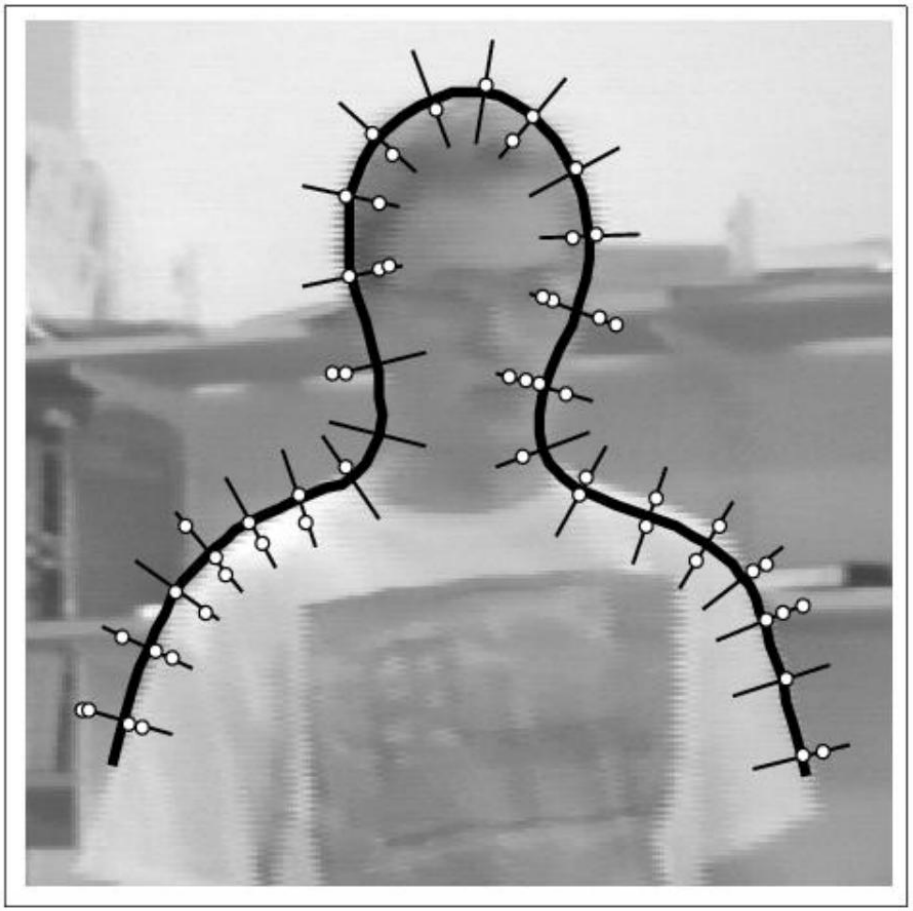
Reliable, robust, slow

应用对象包括手部、人体与叶片。

这类方法通常具有较好的可靠性与鲁棒性，计算速度较慢。

跟踪性能与粒子数、状态维数、观测模型和运动模型相关。

Contour tracking　轮廓跟踪



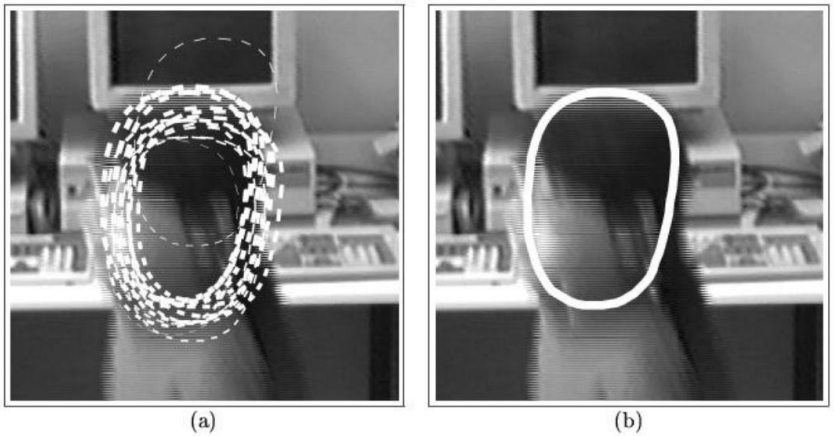
[Isard 1998]

图中以人体头部与躯干轮廓为跟踪对象，利用轮廓附近的搜索线与候选边缘点评估状态。

轮廓模型随图像边缘变化而调整，粒子描述多个候选姿态。来源 Isard，1998 年。

Head tracking　头部跟踪





The mean state

Picture of the states represented by the top weighted particles

[Isard 1998]

椭圆状态用于描述头部位置与形状，粒子集合表示多种候选椭圆。

高权重粒子对应观测支持较强的候选状态，均值状态汇总加权粒子的整体估计。

图中英文说明分别为高权重粒子表示的候选状态与均值状态。来源 Isard，1998 年。

Leaf tracking　叶片跟踪



图中在复杂植被背景中跟踪叶片，红色轮廓表示目标边界的估计。

该示例展示粒子方法对轮廓状态与复杂背景的建模应用。来源 Isard，1998 年。

[Isard 1998]

Hand tracking　手部跟踪



手部跟踪示例使用轮廓状态表示目标，并通过观测更新状态分布。

此页为视频演示。来源 Isard，1998 年。

[Isard 1998]